Bases de Datos II

Francisco Javier Mercader Martínez

Índice

Tema 1: Recuperación de datos y formatos de serialización

1.1) Necesidad de formatos de serialización

- Los formatos de **serialización** son vitales para el intercambio de datos
- Más en el ámbito *Big Data* (atacan a la "V" de la *variabilidad*)
- A lo largo de los años se han diseñado formatos de serialización
- Algunos son **más eficientes** que otros.
- Algunos se han **estandarizado**.
- En cualquier caso, son fundamentales para transmitir información, ya sea a través´s de **ficheros de disco** o bien para **comunicación por red**.
- La mayoría de los formatos son **de propósito general**, por lo que una misma información se pude codificar **de varias formas** (por ejemplo, como `INSERT` en SQL, ficheros CSV, etc.)
- Nuestro objetivo es conocer los formatos más usados para elegir el correcto en cada ocasión.

1.2) Características a analizar

- **¿Es un protocolo estándar?-** Con ello nos referimos a si está avalado por cuerpo de estándares o su especificación
- **¿Permite la codificación binaria?-** A la hora de transmitir grandes cantidades de información (ya sea en forma almacenada o bien a través de la red) es fundamental un protocolo binario para ahorrar espacio/tiempo.
- **¿Es legible por los humanos?-** A veces es interesante poder depurar un protocolo por parte de un humano. Esta idea comenzó con protocolos como XML, pero se ha ido abandonando porque no resulta muy factible salvo en ocasiones muy específicas.
- **¿Soporta referencias?-** A veces tenemos que relacionar partes de un conjunto de datos. Es interesante que los mecanismos de serialización permitan referenciar otras partes de un documento o de una comunicación.
- **¿Su estructura está definida por un Esquema o IDL?-** Al igual como sucedía con el lenguaje DDL de SQL, a veces es interesante que los datos sean conformes a algún esquema, también llamado IDL (*Interface Definition Language*).
- **¿Es extensible?-** A veces es necesario acomodar datos que no se ajustan estrictamente a un esquema, o que son directamente no-estructurados.
- **¿Poseen un API estandarizado?-** Si los formatos de serialización poseen un API estandarizado será más sencillo no sólo compartir los datos, sino también compartir el código de serialización/deserialización (también llamado **marshalling**)
- Tabla resumen

	Estándar	Bin?	Humano?	Ref?	IDL?	Ext?	API?
Apache Avro	Sí	Sí	No	N/A	Sí (acoplado)	Sí	N/A
CSV	Parcial (RFC4180)	No	Sí	No	No	Parcial	No
JSON	Sí (RFC7159)	No (BSON)	Sí	Sí (RFC6901)	Parcial	Sí	No
Thrift	No	Sí	Parcial	No	Sí (acoplado)	Sí	No
XML	Sí	Parcial	Sí	Sí	Sí	No	No

1.2.1) Pandas

- Pandas es una librería open source construida sobre `Numpy`.
- Permite una preparación, limpueza y análisis rápido de los datos.
- Una de sus principales características es la de visualización de datos.
- Puede trabajar con una gran variedad de fuentes musicales.
- Para instalar pandas es tan sencillo como ejecutar una de dichas instrucciones en el terminal

```
pip install pandas
conda install pandas
```

Dataframe

- La herramienta más conocida y usada de Pandas son los `DataFrames`.
- Permite almacenar datos tabulares en dos dimensiones similar a una hoja de cálculo o una base de datos relacional.
- Las columnas de datos

```
df = pd.DataFrame(randn(5,4),index='A B C D E'.split(),columns='W X Y Z'.split())
```

```
          W         X         Y         Z
A -1.040684 -1.692150  1.707399 -1.257771
B -0.403809 -1.024655  2.060558 -0.242150
C -0.856354  0.173779  1.124053 -0.434952
D  0.282316 -1.349518 -0.076797  1.077644
E -0.152517 -0.603708 -0.812906  0.807102
```

1.2.2) XML (eXtensible Markup Language)

- Meta-lenguaje de etiquetas derivado de SGML.
- Motivación:
  - Intercambio de datos en Internet
- Reúne los requisitos de un lenguaje de intercambio de información:
  - Simple: al estar basado en etiquetas y legible
  - Independiente de la plataforma: codificación UNICODE
  - Estándar y amplia difusión: W3C
  - Definición de estructuras complejas: DTD, Schemas
  - Validación y transformación: DTD, XSLT
  - Integración con otros sistemas
- Facilita procesamiento lado cliente.
- **No muy utilizado para BigData. Ha perdido tracción, es demasiado complejo finalmente y es muy poco eficiente en cual al porcentaje datos/metadatos**

Ejemplo

```xml
<?xml version="1.0" encoding="ISO-8859-1" ?>
<DISCO CODIGO="B000067FSG">
  <TITULO>Estrella de Mar</TITULO>
  <ARTISTA>Amaral</ARTISTA>
  <ESTILO>Pop</ESTILO>
  <REFERENCIA>
    <EDITORA>Virgin</EDITORA>
    <AÑO_EDICION>2002<AÑO_EDICION>
  </REFERENCIA>
  <MUSICOS>
    <MUSICO ROL="cantante">Amaral</MUSICO>
    <MUSICO ROL="guitarra">Juan Aguirre</MUSICO>
  </MUSICOS>
</DISCO>
```

- Instrucciones de procesamiento (línea 1)
- Raíz (línea 2)
- Etiquetas y atributos

• DTD

```
<!ELEMENT DISCO (TITULO, ARTISTA, ESTILO?, REFERENCIA, MUSICOS)>
<!ATTLIST DISCO CODIGO ID #REQUIERED>
<!ATTLIST DISCO TIPO=(CD | LP | DVD) "CD">
<!ELEMENT TITULO (#PCDATA)>
...
<!ELEMENT REFERENCIA (EDITORA, AÑO_EDICION) >
<!ELEMENT MUSICOS (MUSICO*)>
...
```

Describe los documentos XML $\Longrightarrow$ **Validación**

• DTD (ii)

Documento XML:

- **Válido:** sigue la estructura de un DTD

```
<!DOCTYPE web-app
  PUBLIC "-//Sun Microsystems, Inc.//DTD Web Application 2.2//EN"
  "http://java.sun.com/j2ee/dtds/web-app_2_2.dtd">
```

- **Bien formado:** Sigue las reglas de XML

Limitaciones:

- No es XML
- Tipado limitado de datos
- No soporta espacios de nombres

- Familias de estándares
  - Schemas
    - Mismo propósito que un DTD, pero con mayor riqueza semántica.
    - Sintaxis basada en XML.
    - Contiene tipos predefinidos
    - Espacios de nombres (*namespaces*)

```
<?xml version="1.0">
<xsd:schema xmlns:xsd="http://www.w3c.org/2000/08/XMLSchema">
<xsd:element name="Disco" type="DiscoTipo"/>
<xsd:complexType name="DiscoTipo">
  <xsd:attribute name="codigo" type="String"/>
  <xsd:sequence>
  <xsd:attribute name="Titulo" type="String"/>
  <xsd:attribute name="Artista" type="String"/>
  <xsd:attribute name="Referencia" type="ReferenciaTipo"/>
  ...
```

  - NameSpaces:
    - Espacios de nombres para cualificar elementos y atributos evitando la colisión de nombres.
    - `xmlns:xsd="http://www.w3c.org/2000/08/XMLSchema"`
  - XSLT:
    - Definición de reglas de transformación de documentos
  - XSL:
    - Definición de hojas de estilos.
  - XPath:
    - Para hacer referencia a partes de un documento
    - `/DISCO[Titulo="Estrella de Mar"], /DISCO//MUSICOS[1]`
  - XLink:
    - Enlace documentos entre sí.
  - XPointer:
    - Enlace de secciones dentro de un documento.
  - XQuery:
    - Consultas XML.
- Parsers
  - API SAX:
    - Acceso secuencial al documento

  - Modelo de programación basado en eventos (*callbacks*)
  - Simple y rápido: consume pocos recursos.
  - Sólo consulta.
- API DOM:
  - Construye una estructura arbórea a partir del documento
  - Potente, pero más costoso.
  - Permite actualizaciones.
  - Ideal para estructuras complejas.
- En Python, existen numerosas formas de poder leer documentos XML.

- API SAX

Librería **xml.sax**

```
import xml.sax

class XMLHandler(xml.sax.ContentHandler):
    def __init__(self):
        # Inicializamos variables de interés

    # Se llama cuando comienza un nuevo elemento
    def StartElement(self, tag, attributes):
        pass
    # Se llama cuando un elemento acaba
    def endElement(self, tag):
        pass

parser = xml.sax.make_parser()
parser.setFeature(xml.sax.handler.feature_namespaces, 0)
Handler = XMLHandler()
parser.setContentHandler(Handler)
parser.parse('models.xml') # nombre del documento a analizar
```

Cómo podríamos procesar con **xml.sax** este documento

```
<collection shelf="New Arrivals">
    <model number="ST001">
        <price>35000</price>
        <qty>12</qty>
        <company>Samsung</company>
    </model>
    <model number="RW345">
        <price>46500</price>
        <qty>14</qty>
        <company>Onida</company>
    </model>
```

```
</collection>
```

- Parser DOM

Librería **xml.dom**

```
# Procesar un determinado fichero
file = minidom.parse('model.xml')

# Obtener los elementos con un determinado tag
modelos = fil.getElementosByTagName('modelo')

# Obtener el atributo 'nombre' del segundo
    modelo
print('modelo #2 atributos:')
print(modelos[1].attributes['nombre'].value)

# El datos de un item específico
print('\nmodelo #2 datos:')
print(modelos[1].firstChild.data)
```

```
<data>
    <modelos>
        <modelo name='modelo1'>
            modelo1abc
        </modelo>
        <modelo name="modelo2">
            modelo2abc
        </modelo>
    </modelos>
</data>
```

- Librería BeatifulSoup

```
from bs4 import BeatifulSoup

# Leemos el fichero
with open('models.xml', 'r') as f:
    data = f.read()

# Pasamos los datos al parse
bs_data = BeatifulSoup(data, 'xml')

# Buscamos todas las instancias 'unique'
b_unique = bs_data.find_all('unique')
print(b_unique)

# Usamos .find búsquedas más concretas
b_name = bs_data.find('child', {'name':'Acer'})
print(b_name)
```

```
<modelo>
    <child name="Acer" qty="12">
        Portátil Acer
    </child>
    <unique>
        Número de modelo
    </unique>
    <child name="Acer" qty="7">
        Exclusive
    </child>
    <unique>
        1.200€
    </unique>
</modelo>
```

1.2.3) CSV (Comma-Separated Values)

- Formato basado en columnas normalmente separado por coma
- Sin embargo, el formato admite variaciones:
  - Con o sin cabecera con los nombres de las columnas
  - Separador de columans (comas, tabuladores, etc.)
  - Codificación de caracteres (UTF-8, latin-1, etc.)

- Escapado de caracteres (por ejemplo, una comilla doble como dos comillas dobles(" ") ó como \")
- Comillas opcionales (sólo si hacen falta) o en todos los campos siempre

- Carga en SQL

```
LOAD DATA [LOW_PRIORITY | CONCURRENT] [LOCAL] INFLINE 'file_name'
    [RELACE | IGNORE]
    INTO TABLE tbl_name
    [PARCTITION (parctition_name, ...)]
    [CHARACTER SET charset_name]
    [{FIELDS | COLUMS}
        [TERMINATE BY 'string']
        [[OPTIONALL] ENCLOSED BY 'char']
        [ESCAPED BY 'char']
    ]
    [LINES
        [STARTING BY 'string']
        [TERMINATE BY 'string']
    ]
    [IGNORE number {LINES | ROWS}]
    [(col_name_or_user_var, ...)]
    [SET col_name = expr, ...]
```

```
LOAD DATA LOCAL INFILE "/tmp/Posts.csv"
    INTO TABLE Posts
    COLUMNAS TERMINATED BY ',' ENCLOSED BY '"' ESCAPED BY '"'
    LINES TERMINATED BY '\r\n'
    IGNORE 1 LINES;
```

- Programación: Lectura con `Pandas DataFrame`

  - Lectura básica de un fichero CSV

```
import pandas as pd
# Read the CSV file
airbnb_data = pd.read_csv("airbnb.csv")
```

  - Si queremos establecer la columna id como índice

```
airbnb_data = pd.read_csv("airbnb.csv", index_col="id")
```

  - Si queremos leer solo un conjunto de columnas

```
usecols = ["id", "nombre", "barrio", "precio", "noches_minimias"]
airbnb_data = pd.read_csv("airbnb.csv", index_col="id", usecols=usecols)
```

  - Si queremos indicar un separador de columnas determinado

```
usecols = ["id", "nombre", "barrio", "precio", "noches_minimias"]
airbnb_data = pd.read_csv("airbnb.csv", index_col="id", usecols=usecols, sep="|")
```

- Si queremos definir el tipo de datos de determinadas columnas

```
usecols = ["id", "nombre", "barrio", "precio", "noches_minimias"]
airbnb_data = pd.read_csv("airbnb.csv", index_col="id", usecols=usecols, sep="|",
    dtype:{'precio': float, 'barrio':str, 'noches_minimas':int}, decimal=',')
```

1.2.4) JSON (JavaScript Object Notation)

Es, al mismo tiempo, un formato de archivo estándar abierto y un formato de intercambio de datos.
JSON se utiliza a menudo cuando los datos se envían desde un servidor a una página web.
En muchas ocasiones se define a JSON como *autodescriptivo* y fácil de entender.

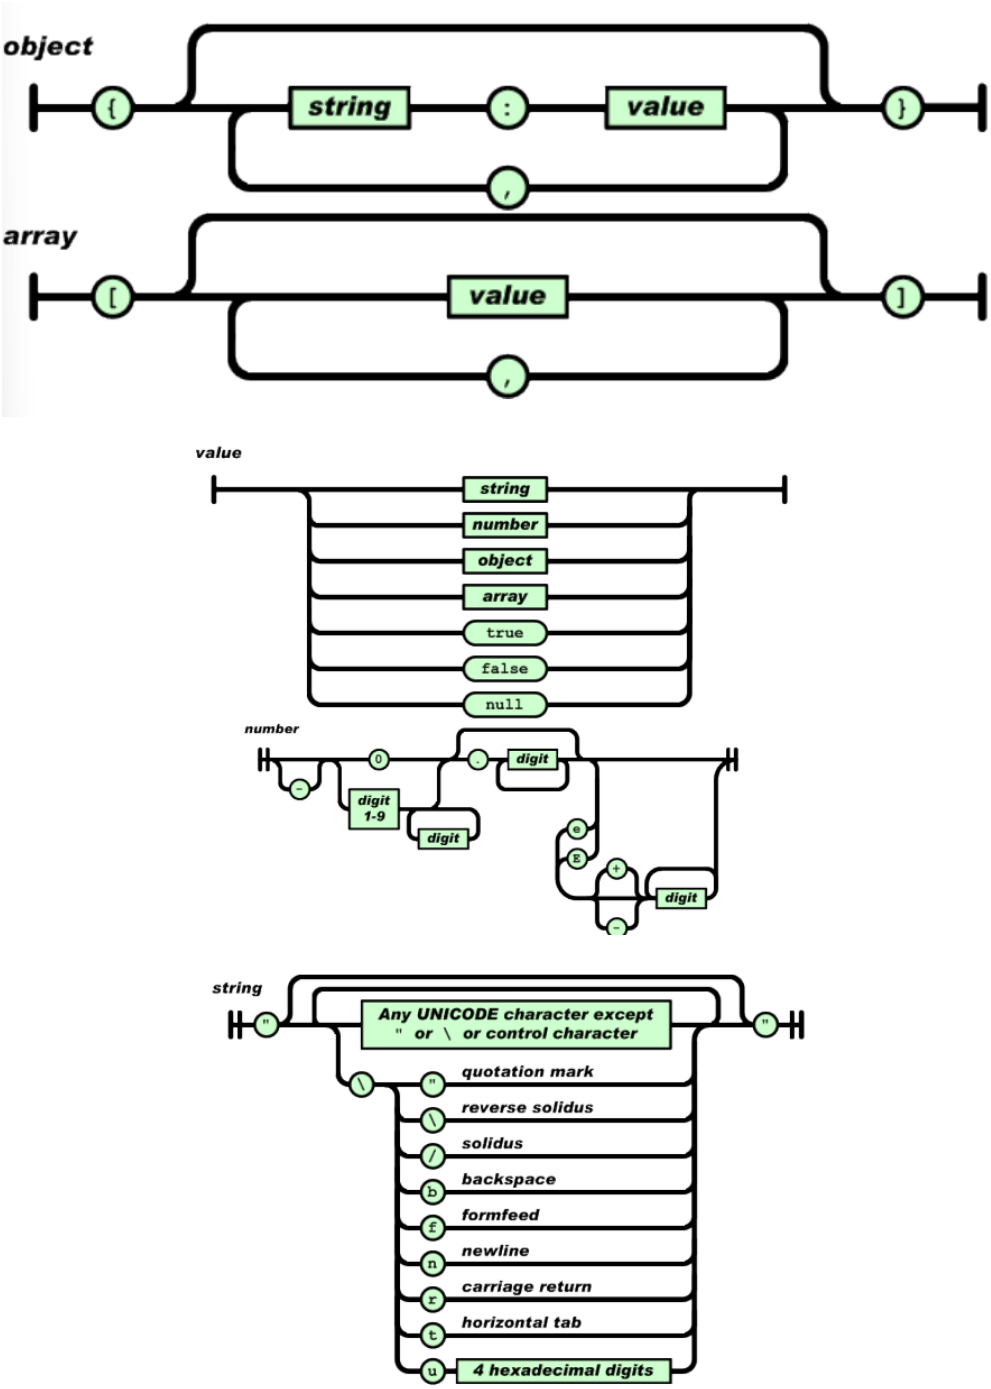

- JSON Lines (JSONL)

JSON Lines es un formato práctico para almacenar datos estructurados que pueden procesarse de uno en uno.
Ficheros con extensión `.jsonl`

Es un gran formato para archivos de registros.

Sigue las mismas convenciones que JSON salvo que el carácter `\n` se usa como delimitador de líneas.

Cada línea de un fichero `.jsonl` es un JSON válido.

```
{"nombre": "Gilbert", "victorias": [["escalera"], ["pareja"]]}
{"nombre": "Alexa", "victorias": [["dobles parejas"], ["dobles parejas"]]}
{"nombre": "Maya", "victorias": []}
{"nombre": "Marisa", "victorias": [["trio"]]}
```

- Lectura con **`Pandas DataFrame`**
  - Lectura básica de un fichero JSON

```
import pandas as pd
df = pd.read_json('data.json')
```

  - Por defecto, Pandas sigue una orientación basada en columnas en la lectura de los ficheros {`columna -> {indice -> valor`}}

```
json_str = '{"Cursos":{"r1":"Spark"},"Tasas":{"r1":"25000"},"Duracion":{"r1":"50
    días"}}'
df = pd.read_json(json_str)
print(df)
```

```
    Cursos  Tasas Duracion
r1  Spark   25000  50 días
```

  - Otras opciones son `index`, `records`, `split` y `values`.
  - Si usaramos la orientación records ...

```
json_str = '[{"Cursos":"Spark","Tasas":"25000","Duracion":"50
  días","Descuento":"2000"}]'
df = pd.read_json(json_str, orient='records')
print(df)
```

```
    Cursos  Tasas Duracion Descuento
0   Spark   25000  50 días   2000
```

  - Estableciend el parámetro `lines` a `True`

```
df = pd.read_json('cursos.json', orient='records', nrows=2, lines=True)
```

- Resumen

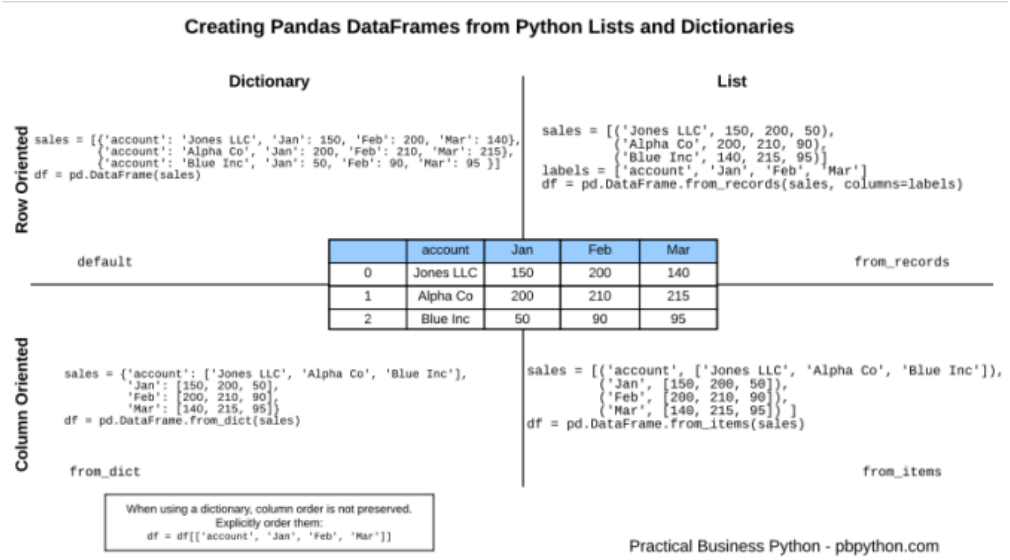

1.2.5) Apache Avro

Avro ofrece una serie de características:

- Estructuras de datos ricas
- Un formato de datos compacto, rápido y binario
- Un lenguaje de especificación de esquema (Proto + IDL)
- Un formato de fichero contenedor para almacenar datos
- Un esquema de llamada a procedimiento remoto (RPC)
- Integración con lenguajes dinámicos, donde no hace falta recompilar el IDL (opcionalmente se puede hacer para lenguajes estáticos)

- Schema
  - Una declaración de esquema se escribe en JSON. Bien un nombre de un objeto predefinido, o bien un objeto JSON de la forma:

```
{"type": "nombreTipo", ... atributos ... }
```

  - Ofrece tipos primitivos y complejos. Primitivos: `null, boolean, int, long, float, bytes, string, . . .`
  - `""type": "string""` es equivalente a "`string`".
  - Tipos complejos permitidos: registros (records), enums, mapas, arrays, uniones.
  - Tipos complejos: Récords (registros)
    - El campo `type` se establece a `"record"`.
    - El campo `name` establece su nombre.
    - El campo `fields` establece sus campos. Cada campo:
      → Atributos `name, doc, type` y `default`

```
{
  "type": "record",
  "name": "LongList",
  "fields" : [
    {"name": "value", "type": "long"}, // el campo 'value' toma valores long
    {"name": "next", "type": ["null", "LongList"]} // 'next' es opcional
  ]
}
```

- Tipos complejos: Arrays

```
{"type": "array", "items": "string"}
```

- Tipos complejos: Mapas (los índices se suponen siempre `string`)

```
{"type": "map", "values": "long"}
```

- Los protocolos permiten especificar la parte RPC del protocolo y especificar funciones y mensajes entrantes y salientes.

- Ejemplo (`mail.avpr`):

```
{"namespace": "example.proto",
  "protocol": "Mail",

  "types": [
    {"name": "Message", "type": "record",
    "fields": [
      {"name": "to", "type": "string"},
      {"name": "from", "type": "string"},
      {"name": "body", "type": "string"}
      ]
    }
  ],

  "messages": {
    "send": {
      "request": [{"name": "message", "type": "Message"}],
      "response": "string"
    }
  }
}
```

- Programación

Librería **`avro`**

Instalación con ejecutando el comando

```
pip install avro
```

Vamos a suponer el siguiente esquema:

```
{"namespace": "example.avro",
  "type": "record",
  "name": "User",
  "fields": [
    {"name": "name", "type": "string"},
    {"name": "favorite_number", "type": ["int", "null"]},
    {"name": "favorite_color", "type": ["string", "null"]}
  ]
}
```

Para serializar dos usuarios en el fichero `users.avsc`:

```
import avro.schema
from avro.datafile import DataFileReader, DataFileWriter
from avro.io import DatumReader, DatumWriter

schema = avro.schema.parse(open("user.avsc", "rb").read())

writer = DataFileWriter(open("users.avro", "wb"), DatumWriter(), schema)
writer.append({"name": "Alyssa", "favorite_number": 256})
writer.append({"name": "Ben", "favorite_number": 7, "favorite_color": "red"})
writer.close()
```

Para leer dichos usuarios de fichero

```
reader = DataFileReader(open("users.avro", "rb"), DatumReader())
for user in reader:
  print user
reader.close()
```

Librería **avro** con Protocols

Uso del protocolo definido anteriormente.

```
import avro.ipc as ipc
import avro.protocol as protocol

PROTOCOL = protocol.Parse(open("mail.avpr").read())
server_addr = ('localhost', 9090)

client = ipc.HTTPTransceiver(server_addr[0], server_addr[1])
requestor = ipc.Requestor(PROTOCOL, client)

message = dict()
message['to'] = sys.argv[1]
message['from'] = sys.argv[2]
message['body'] = sys.argv[3]

params = dict()
```

```
params['message'] = message
print("Result: " + requestor.Request('send', params))

client.Close()
```

1.2.6) Thrift

Framework de serialización + RPC desarrollado por Facebook.

Requiere de compilador siempre.

Genera *stubs* en muchos lenguajes de programación, incluyendo C++, Java, Python, . . .

Incluye un lenguaje completo de especificación de interfaces (IDL) (`.thrift`), parecido a C++.

Cada elemento de estructura o parámetro de función debe ir precedido por su etiqueta de identificación numérica.

El formato de serialización puede cambiarse, y acepta formatos binarios y de texto.

Además del modelo, genera un *processor*, que hace de procesador de mensajes del servicio.

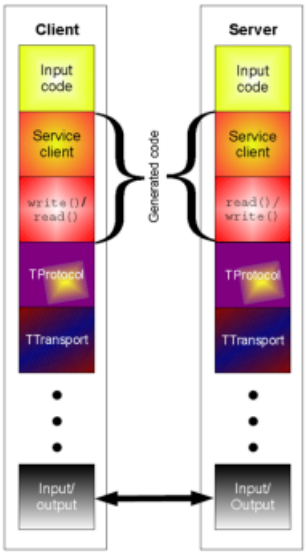

Permite el uso de varios protocolos:

- `TBinaryProtocol`, `TDenseProtocol`, `TJSONProtocol`, `TSimpleJSONProtol`

Permite el uso de varios transportes:

- `TSocket`, `TFileTransport` (a fichero), `TZlibTransport` (compresión)

Processor – Permite leer y escribir mensajes del modelo de datos

- IDL

Tipos básicos: `bool`, `byte`, `i16`, `string`, etc.

Estructuras:

```
struct Example {
  1:i32 number=10,
  2:i64 bigNumber,
  3:double decimals,
  4:string name="thrifty"
}
```

Contenedores: `list`, `set`, `map` con sintaxis C++.

Servidores RPC:

```
service StringCache {
  void set(1:i32 key, 2:string value),
  string get(1:i32 key) throws (1:KeyNotFound knf),
  void delete(1:i32 key)
}
```

- Código

Implementar un servicio `Calculator` que sume dos números

1) Definir el fichero `.thrift` con la especificación del servicio

```
service Calculator extends shared.SharedService {

  void ping(),

  i32 add (1:i32 num1, 2:i32 num2),
}
```

2) Generar el código en Python ejecutando el siguiente comando

```
thrift --gen py multiple.thrift
```

3) Definir el `handler` en el servidor

```
class CalculatorHandler:
  def __ init__(self):
    self.log = {}

  def ping(self):
    print('ping()')

  def add(self, n1, n2):
    print('add(%d, %d)') % (n1, n2)
    return n1+ n2
```

4) Arrancar el servidor

```
handler = CalculatorHandler()
processor = Calculator.Processor(handler)
transport = TSocket.TServerSocket(host='127.0.0.1', port=9090)
tfactory = TTransport.TBufferedTransportFactory()
pfactory = TBinaryProtocol.TBinaryProtocolFactory()

server = TServer.TSimpleServer(processor, transport, tfactory, pfactory)

print('Arrancando el servidor...', end='')
server.serve()
print('HECHO!')
```

5) Lanzar el cliente que hace uso del servicio

```
# Creamos un socket
transport = TSocket.TSocket('localhost', 9090)

# Los sockets pueden ser lentos. Necesitamos bufferizar
transport = TTransport.TBufferedTransport(transport)

# Definimos el protocolo Thrift a usar
protocol = TBinaryProtocol.TBinaryProtocol(transport)

# Creamos un cliente para usar el protocolo definido.
client = Calculator.Client(protocol)

#Conectamos con el servidor
transport.open()

client.ping()
print('ping()')

sum_ = client.add(1,1)
print('1+1=%d', % sum_)
```

1.2.7) Pre-procesamiento de datos con Pandas

- Datos faltantes

En muchos escenarios, nos encontraremos que los conjuntos de datos que con los que tenemos que trabajar se encuentran con valores faltantes.

La librería `Pandas` nos permite tratar dichos casos con algunos métodos de su herramienta `Dataframe`.

El método `.dropna` permite eliminar las filas (`axis=0`) o columnas (`axis=1`) de un dataframe

```
d= {'A':[1,2,np.nan], 'B':[5, np.nan, np.nan],
   'C':[1,2,3]}
df= pd.DataFrame(d)
df.dropna() #axis=0
```

El método `.dropna` permite definir cuántos valores no **NaN** deben existir en una fila o columna para no ser borrada con el parámetro `thresh`

```
d= {'A':[1,2,np.nan], 'B':[5, np.nan, np.nan],
   'C':[1,2,3]}
df= pd.DataFrame(d)
df.dropna(thresh=2) #axis=0
```

Otra alternativa cuando tenemos datos faltantes puede ser sustituir dichos datos.

	A	B	C
0	1.0	5.0	1
1	2.0	NaN	2
2	NaN	NaN	3

	A	B	C
0	1.0	5.0	1

Esto puede realizarse con el método `.fillna` especificando un valor por defecto

```
d= {'A':[1,2,np.nan], 'B':[5, np.nan, np.nan].
  'C':[1,2,3]}
df= pd.DataFrame(d)
df.fillna(valiue='FILL VALUE')
```

Sin embargo una estrategia más acertada podría ser usar la media de cada columna

```
df['A'].fillna(value=df['A'].mean())
```

La propagación de valores es también otra alternativa. Sobre todo cuando existe cierto orden pre-establecido entre filas y columnas

Con .`ffill` podemos propagar el último valor válido hacia adelante

```
df = pd.DataFrame([[np.nan, 2, np.nan, 0],
                   [3, 4, np.nan, 1],
                   [np.nan, np.nan, np.nan, np.nan],
                   [np.nan, 3, np.nan, 4]],
                  columnas=list("ABCD"))
df.ffill()
```

	A	B	C	D
0	NaN	2.0	NaN	0.0
1	3.0	4.0	NaN	1.0
2	NaN	NaN	NaN	NaN
3	NaN	3.0	NaN	4.0

	A	B	C	D
0	NaN	2.0	NaN	0.0
1	3.0	4.0	NaN	1.0
2	3.0	4.0	NaN	1.0
3	3.0	3.0	NaN	4.0

De forma similar, `.bfill` propaga hacia atrás el siguiente valor válido.

En caso de una relación temporal entre filas o columnas de un Dataframe, lo más conveniente res relllenar los valores faltantes con el método `.interpolate`.

```
s = pd.Series([0, 1, np.nan, 3])
s.interpolate()
```

0	0.0
1	1.0
2	NaN
3	3.0

0	0.0
1	1.0
2	2.0
3	3.0

Dicho método permite aplicar diferentes técnicas de regresión para imputar los valores faltantes (`quadratic, cubic, polinomial...`)

```
s.interpolate(method='polynomial', order=2)
```

Otro tipo de *impureza* frecuente que suele darse en los conjuntos de datos son las filas o columnas duplicadas. Podemos eliminarlas con el método `.drop_duplicates`

```
df.drop_duplicates()
```

También podemos forzar que determinadas columnas se conviertan al tipo de datos `Date` con `.to_datetime`

```
df['Date'] = pd.to_datetime(df['Date'])
```

1.3) Conclusiones

En el ecosistema digital actual, existe una gran variedad de alternativas para llevar a cabo la serialización de datos

XML, JSON y CSV son los formatos más extendidos

Otras soluciones, como Avro o Thrift, van más allá al definir un modelo de datos y un RPC para la implementación de sistemas distribuidos

No existe una *bala de plata* sino que dependiendo de la naturaleza de los datos y el contexto, deberemos optar por uno u otro enfoque

Independientemente del formato de serialización escogido es imprescindible un pre-procesado y limpieza de los datos para eliminar o sustituir valores incorrectos o imprecisos

Tema 2: Introducción a los sistemas NoSQL

2.1) Introducción a NoSQL

NoSQL ⟶ *hastag* llamativo que se eligió para una conferencia en 2009 (Johan Oskarsson de Last.fm)

Ahora se asocia a cientos de bases de datos diferentes, que se han clasificado en varios tipos (las veremos después), caracterizadas por **no usar SQL** como modelo de datos.

Más recientemente **NoSQL** ⟶ ***Not Only SQL*** (no sólo SQL) ⟶ Persistencia políglota (*polyglot persistence*)

2.1.1) ¿Por qué se plantearon?

1. **Mayor escalabilidad horizontal**
   - conjuntos de datos muy muy grandes
   - sistemas de alto volumen de escrituras (**streaming** de eventos, aplicaciones sociales)
2. **Demanda de productos de software libre** (crecimiento de las *start-ups*)
3. **Consultas especializadas** no eficientes en el modelo relacional (JOINs)
4. **Expresividad, flexibilidad, dinamismo.** Frustración con **restricciones** del modelo relacional

2.1.2) Características

No se basan en SQL

Modelos de datos más ricos

Orientadas a la **Escalabilidad**

Generalmente no obligan a definir un esquema

- **Schemaless**

Surgidos de la comunidad para solucionar problemas

- muchas **libres/*open source***

Diseño basado en **procesamiento distribuido**

Principios funcionales

- **MapReduce**

2.1.2.1) Categorías de NoSQL

- Bases de datos *key-value*
- Bases de datos documentales
- Bases de datos columnares (*wide column*)

- Bases de datos de grafos

- Bases de datos de arrays

2.1.3) Evolución desde el modelo relacional

El **modelo relacional ⇒ predominante en los últimos ˜30 años**
Tiene sus raíces en el denominado *business data processing*, procesamiento de transacciones y *batch*
Propuesto por Codd en los 70, **de alto nivel**
Actualmente los **sistemas SQL están muy optimizados:**

- el **grado de implantación es mayoritario**

- para el 99 % de los problemas (que caben en un ordenador) es eficiente y adecuado

2.2) Adopción de NoSQL

2.2.1) Análisis

Dominan los grandes SGBDR
El *Open Source* tiene una importancia crucial (PostgreSQL, MySQL, MongoDB, etc.)
Varias bases de datos NoSQL entre las 10 primeras. Muchas en las 20 primeras
La distancia entre los grandes SGBDR y el primer NoSQL (MongoDB) es de 5×
Paradigmas más "atrevidos" como el de grafos están entre los 20 primeros (Neo4j)

2.3) Cambio de perspectiva: Red

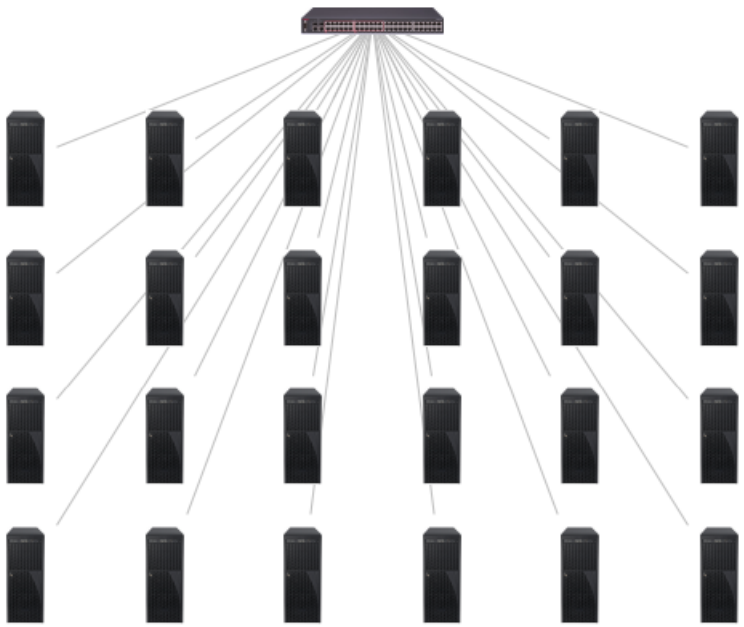

2.3.0.1) Almacenamiento distribuido

Desde los 90's: Clústers/NOC/COW: procesamiento masivamente paralelo

Almacenamiento no distribuido

Ahora los nodos ⇒ también **almacenamiento**

Minimizar el verdadero cuello de botella: **trasiego de información por la red**.

2.3.0.2) Procesamiento distribuido

Necesidad de **paralelización máxima**
Escalabilidad
Explotar de la **localidad de los datos**:

- Datos producidos se utilizan localmente en siguientes iteraciones
- Datos recibidos directamente en los *hosts* (clientes simultáneos)

Vuelta al modelo funcional inherentemente paralelo: (e.g. **Map-Reduce**)
Almacenamiento distribuido: (e.g. **HDFS**)
Coordinación distribuida: (e.g. **Zookeeper**)

2.3.0.3) Modelo de datos

El modelo relacional limita a tablas con valores primitivos y relaciones *Primary Key/Foreign Key*
En programación se utilizan **listas, arrays, tipos de datos compuestos** (*gap semántico*)
ACID es **muy compleja y costosa** en ambientes distribuidos (quizá **no necesaria** en algunas aplicaciones).

¿Y si se pudiera ver como un **GRAN ARRAY**?

- Cada nodo almacenaría una parte del array
- Búsqueda aleatoria **muy rápida** (árboles B)
- Uso de **filtros de Bloom**
- Uso de **objetos complejos** (p. ej. **documentos JSON**), para mantener la **localidad espacial de datos relacionados**
- Transacciones limitadas al **objeto complejo**

2.4) Schemaless

Las Bases de Datos NoSQL (en general) **no quieren de un esquema**

Flexibilidad: Posibilidad de almacenar entidades con una estructura diferente

- Tratar información incompleta.
- Evolucionar la base de datos/esquema.
- Añadir nuevas características a las aplicaciones

schema-on-write ⇒	***schema-on-read***
SQL	**NoSQL**
Los datos conforman al esquema cuando se **escriben**	Los datos leídos conforman a un **esquema implícito**
Tipado estricto (estático)	***Duck-Typing*** (dinámico)
Datos homogéneos	Datos **heterogéneos**
Proceso analítico a través de **consultas**	***Use as read***

Ejemplo: Añadir el campo `first_name` a partir del campo `name`

Los nuevos objetos se crean con el nuevo formato

A la hora de leerlos, se puede hacer:

```
if (user && user.name && !user.first_name) {
  // Docs anteriores a 2013 no tienen first_name
  user.first_name = user.name.split(" ")[0];
}
```

En SQL puede ser un proceso muy costoso (procesa toda la tabla, locking, puede que haya que parar las aplicaciones):

```
ALTER TABLE users ADD COLUMN first_name text;
UPDATE users SET first_name =
  substring_index(name, ' ', 1);
```

2.4.1) ¿Cuándo es apropiado *schemaless*?

Objetos heterogéneos

Estructura de los datos **impuesta externamente**

Si intuimos que los datos **cambiarán en el futuro**

Sin embargo

A veces **un esquema es conveniente**

- Facilita el desarrollo y evita inconsistencias
  - `Mongoose` para MongoDB:

```
var Comment = new Schema({
  name: {type: String, default: 'Anonymous'},
  date: {type: Date, default: Date.now},
  text: Buffer
});
// a setter with on-line modification
Comment.path('name').set(function (v) {
  return capitalize(v);
});
```

2.5) Map-Reduce

Map-Reduce: origen lenguajes funcionales:

- `map()`: Ejecuta una misma función sobre todos los elementos de un conjunto
- `reduce()`: Sumariza un conjunto de valores para producir un valor de salida

Map-Reduce combina ambas operaciones:

- Una misma operación `map()` a cada dato residente en un nodo es realizada de forma paralela en **todos** los nodos simultáneamente

- Con los resultados parciales de cada nodo, una función `reduce()` genera un resultado (o un conjunto de resultados) final
- Proceso intermedio de *shuffle* para agrupar valores **con la misma clave** antes del **reduce()**
- Resultados parciales en el mismo nodo (localidad) ⇒ procesamientos **en cadena**

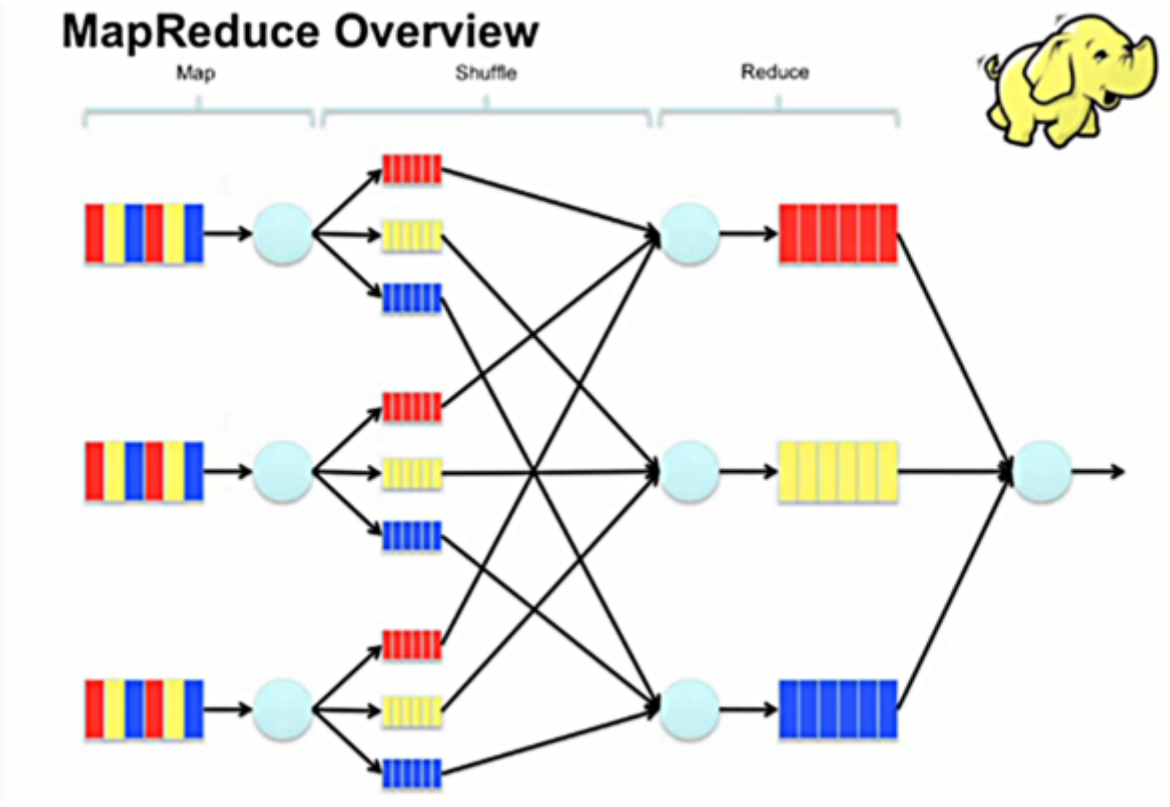

- Word-Count

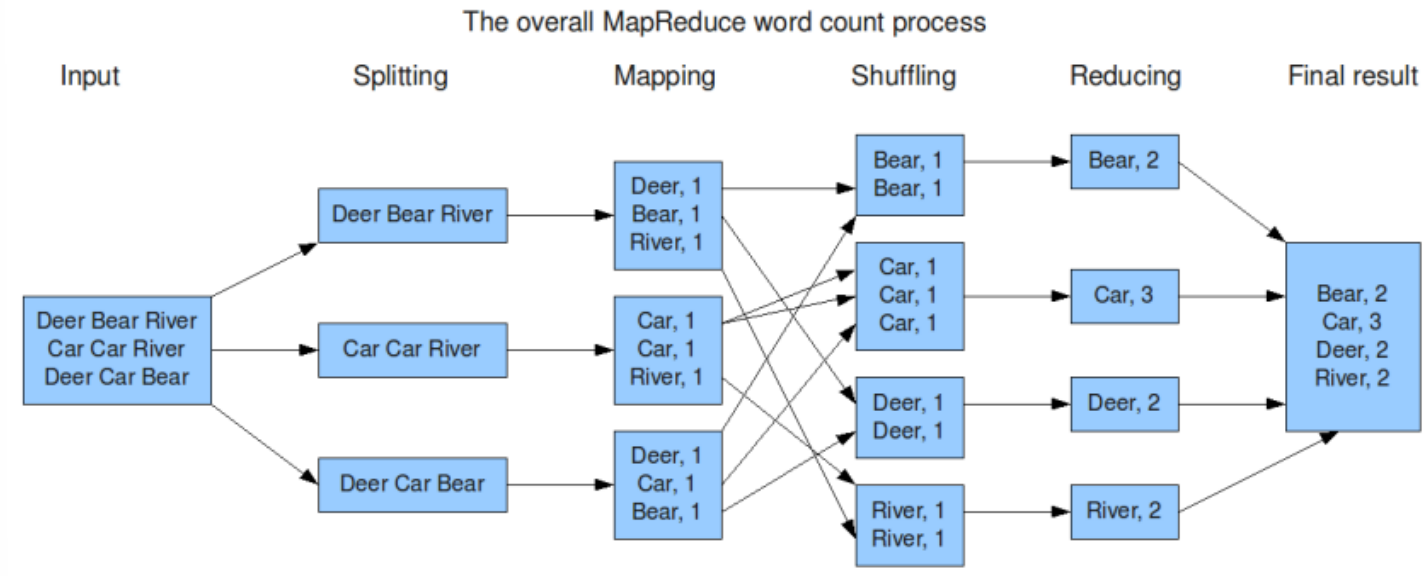

Map-Reduce en entornos Big-Data/NoSQL tiene una serie de particularidades:

- Se supone que los datos de entrada son siempre pares ¡ key, value ¿
- La función `map()` produce otro conjunto de valores $\{< key1, value1 >, < key2, value2 >, \dots\}$
- El **shuffle** agrupa los valores con la misma clave:

$$\{< key1, \{val1, val3, \dots\} >, < key2, \{val2, val4, \dots\} >, \dots\}$$

- `reduce()` procesa cada lista de valores con la misma clave, y produce otros elementos $< key', value' >$
- Hay procesamientos difíciles de expresar en Map-Reduce $\Rightarrow$ operaciones M/R **en cadena**

Se verá en profundidad en los siguientes temas de la asignatura

Map-Reduce puede usarse no sólo para computación distribuida, sino también como una **generalización de consultas**

Ejemplo: Imagínese un biólogo marino que hace anotaciones de cada animal que ve en el océano, y quiere saber cuántos tiburones ha visto por mes:

```
SELECT MONTH(observation_timestamp) AS observation_month,
       sum(num_animals) AS total_animals
FROM observations
WHERE family = 'Sharks'
GROUP BY observation_month;
```

MongoDB con el API de MapReduce:

```
db.observations.mapReduce(
  function map() {
    var year = this.observationTimestamp.getFullYear();
    var month = this.observationTimestamp.getMonth() + 1;
    emit(year + "-" + month, this.numAnimals);
  },
  function reduce(key, values) {
    return Array.sum(values);
  },
  {
    query: { family: "Sharks" },
    out: "monthlySharkReport"
  }
);
```

MongoDB ofrece además un API alternativo para funciones de agregación:

```
db.observations.aggregate([
  { $match: { family: "Sharks" } },
  { $group: {
    _id: {
      year: { $year: "$observationTimestamp" },
      month: { $month: "$observationTimestamp" }
    },
    totalAnimals: { $sum: "$sumAnimals" }
  }
  }
]);
```

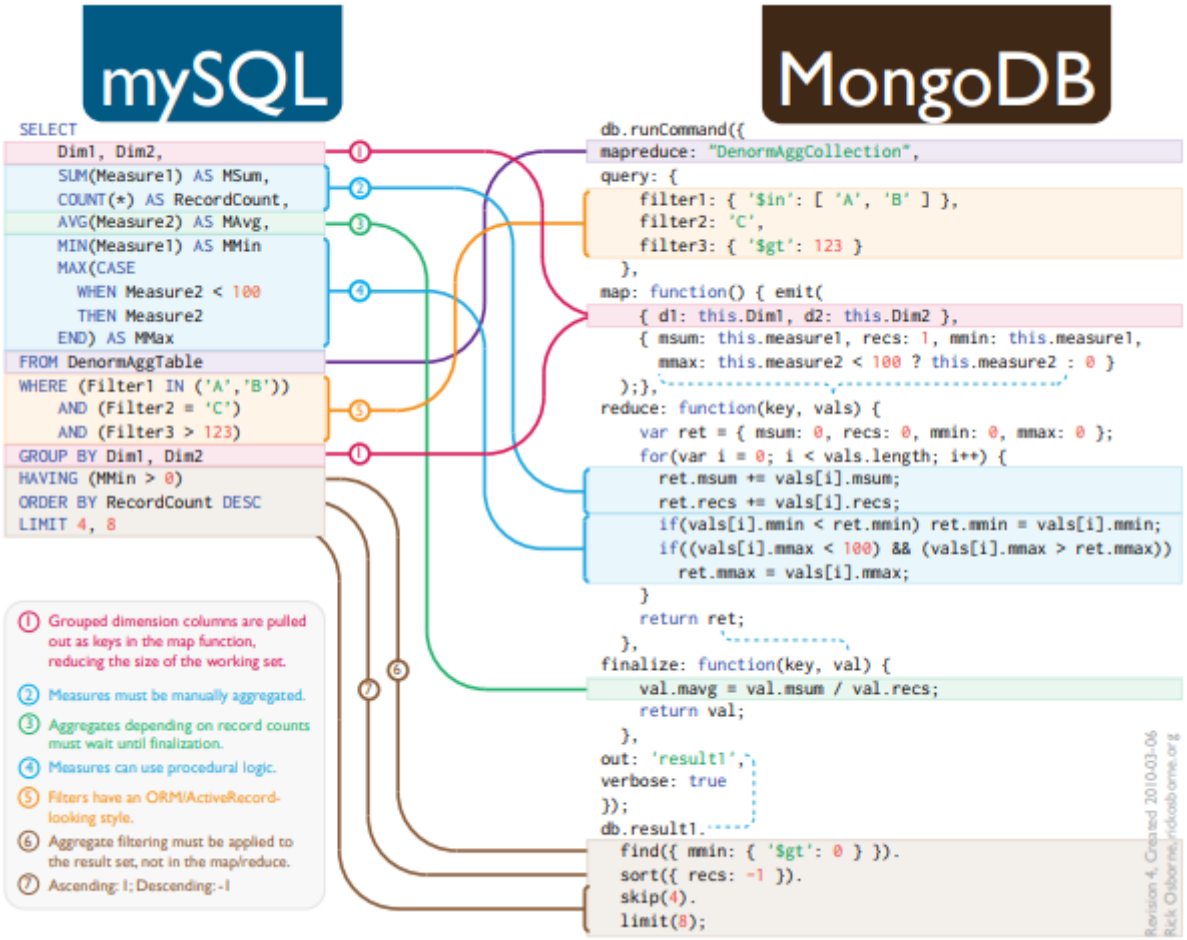

2.5.1) Eficiencia *raw*

Pero los sistemas NoSQL tienen que competir también con los SQL en términos de eficiencia neta (también llamada raw).

La prueba se realizó sobre MongoDB y sobre MySQL (se ha adaptado el original, que era para PostgreSQL)

Se parte de una tabla sencilla con cuatro valores, que muestran medidas de sensores con localización, valor de la lectura y una marca de tiempo

Se realizan seis pruebas que pueden corresponder a un conjunto de consultas normales:

1) Inicialmente se insertan un millón de elementos generados al azar, con fechas que permitan la búsqueda por rango (**Fill**)

2) Se crea un índice en la tabla para la fecha de la lectura (**Index**)

3) Se actualizan los valores de un conjunto de entradas seleccionadas por rango de fechas (**Update**)

4) Se eliminan un conjunto de filas seleccionadas por rango de fechas (**Delete**)

5) Se obtiene el número de filas restantes (**Count**)

6) Se obtiene un subconjunto de filas extraído de una consulta dada por un rango de fechas **(Interval)**

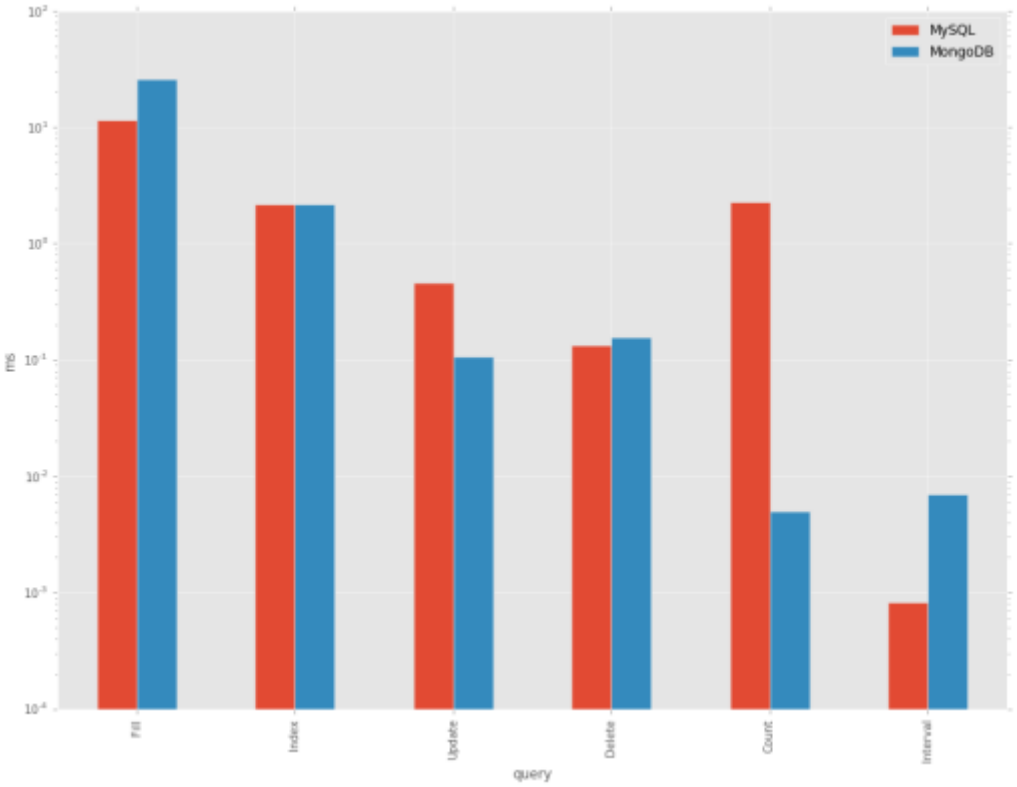

El gráfico se muestra en escala logarítmica en el eje Y (las diferencias pequeñas se acentúan)

A simple vista, ambos productos están muy igualados

- SQL (MySQL) lleva *muchos años* de optimizaciones
- Mientras que productos como MongoDB tienen menos historia a sus espaldas en cuanto a optimizaciones, ...

Hay casos en los que uno es más rápido que el otro y viceversa

No se puede decir cuál es mejor

- **Depende del patrón de accesos que vaya a tener nuestra aplicación**
- (p. ej. contado en MongoDB mucho más rápido que en MySQL; actualización algo más rápida)

2.6) Tipos de sistemas NoSQL

NoSQL incluye un conjunto de tecnologías relativamente dispares

Aún así, la mayoría comparten una serie de características:

- No se basan en SQL
- Generalmente no obligan a definir un esquema
- Surgen de la comunidad para solucionar problemas, y muchas son libres/open source
- Diseño basado en procesamiento distribuido, y aplican tecnologías funcionales como MapReduce

Divididas en subcategorías:

- Bases de datos Key-Value y Documentales
- Bases de datos columnares
- Bases de datos de grafos

- Bases de datos de arrays

2.6.1) Key-Value Stores y Documentales

Cada pieza de datos tiene asignado un identificador

La diferencia entre ambas es que:

- En Key-Value, el valor es opaco, no se conoce nada de su interior (a todos los efectos es un **blob** de datos)
- En las basadas en documentos, la base de datos puede ver el contenido del agregado, y utilizar su información como parte de las búsquedas y actualizaciones

Documentos ⇒ formatos jerárquicos tipo JSON o XML

La diferencia entre ambas queda un poco difusa

- Por ejemplo, Riak es Key-Value pero permite realizar búsquedas indexadas parecidas a las de Solr/Lucene
- Redis permite que los valores de datos sean estructurados en arrays, estructuras complejas, mapas

Key-Value: Riak, Redis, Memcache, LevelDB

Documentos: Couchbase, MongoDB, OrientDB

2.6.2) Bases de Datos Columnares

Influenciadas por el Paper de Google de 2004 sobre BigTable

En general, parecidos a las tablas SQL, salvo que cada fila puede:

- Tener un conjunto de columnas diferente
- Almacenar *series temporales* dentro de una misma fila (varias *versiones* de un mismo conjunto de columnas)

Cada fila tiene un identificador y es un agregado de familias de columnas (*column family*)

Cambian el modo de almacenamiento para favorecer ciertas aplicaciones (almacenamiento por columnas en vez de por filas)

Bases de datos: HBase, Cassandra, Vertica, H-Store

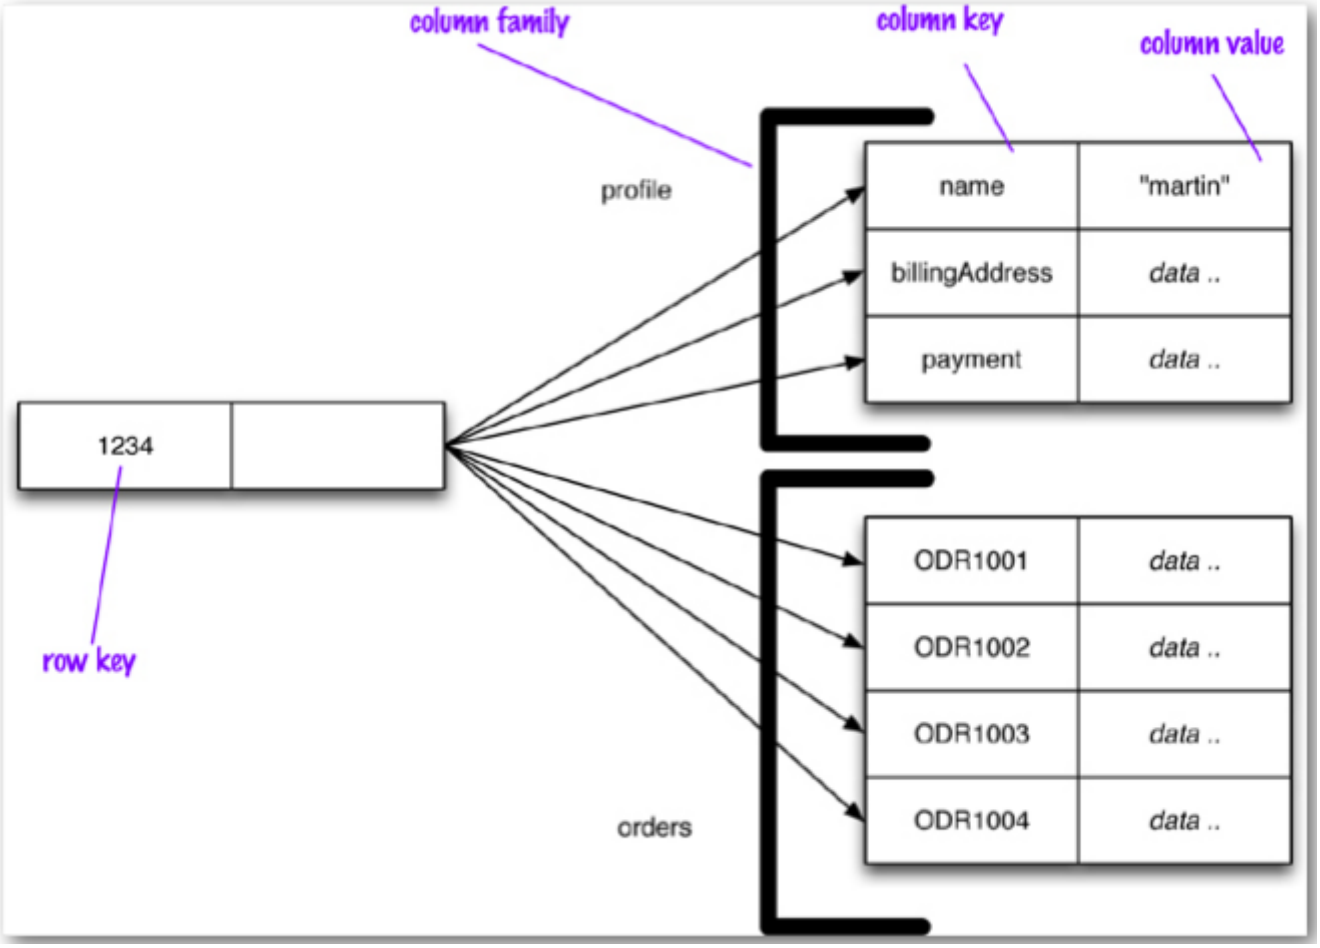

2.6.3) Bases de Datos de Grafos

Las bases de datos de grafos llevan el mecanismo **muchos a muchos** al extremo

Datos en los que existen muchas relaciones entre sí y tienen un significado primordial

Las bases de datos de grafos se basan en la construcción y consulta de grafos que constan de **Vértices**, también llamados *nodos* o *entidades*, y **Aristas (*Edges*)**, también llamados *relaciones*.

Los grafos pueden capturar relaciones complejas entre entidades y ofrecen lenguajes de búsqueda, actualización y creación que permiten trabajar con subconjuntos del grafo

Origen en las bases de datos de hechos (**Datalog**)

Ejemplos: FlockDB, Neo4J, OrientDB

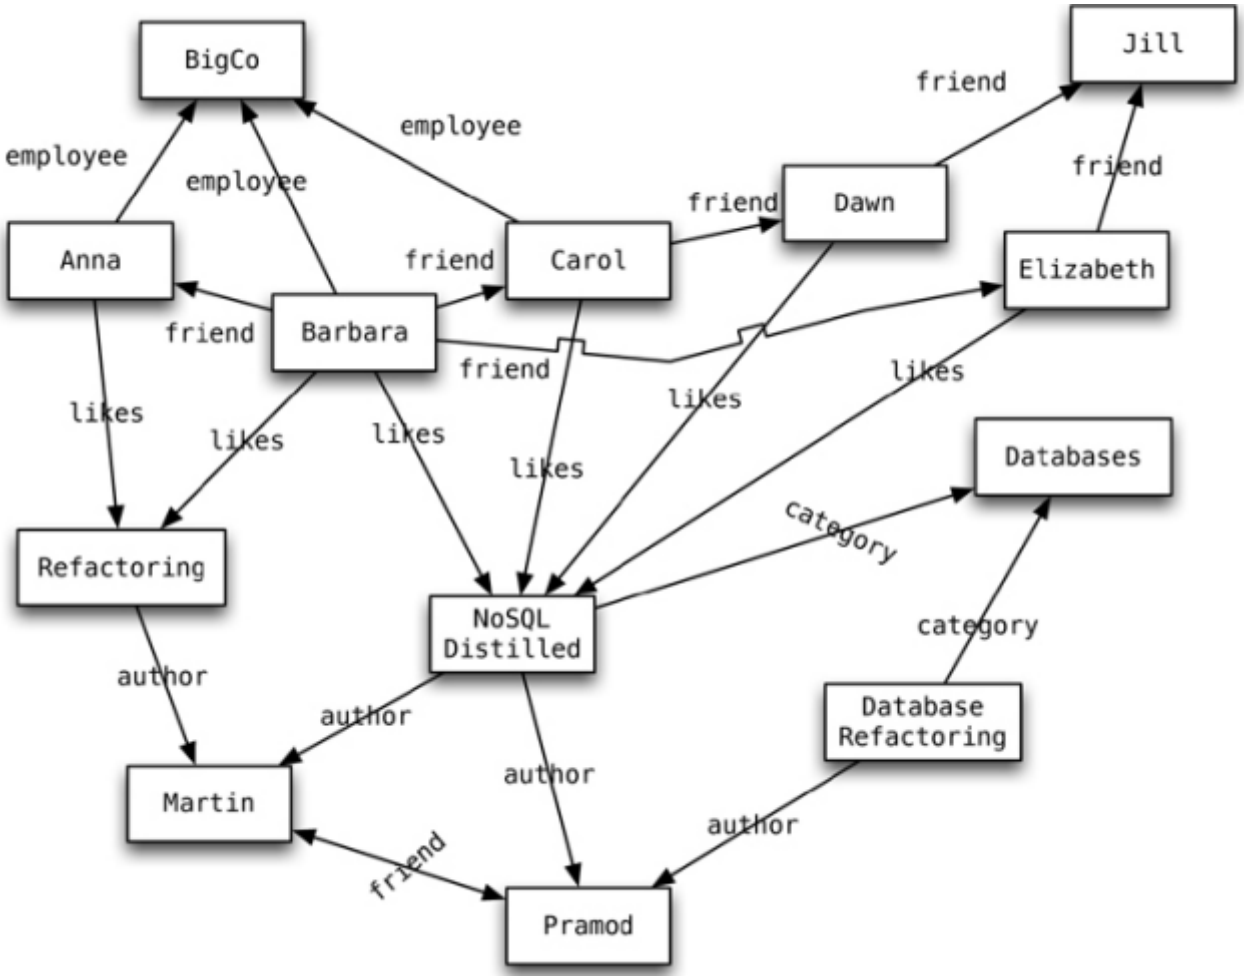

(Nota: Usa la sintaxis PostgreSQL para `json`)

```
CREATE TABLE vertices (
  vertex_id integer PRIMARY KEY,
  properties json
);

CREATE TABLE edges (
  edge_id integer PRIMARY KEY,
  tail_vertex integer REFERENCES vertices (vertex_id),
  head_vertex integer REFERENCES vertices (vertex_id),
  label text,
  properties json
);

CREATE INDEX edges_tails ON edges (tail_vertex);
CREATE INDEX edges_heads ON edges (tail_vertex);
```

2.6.3.1) Grafo y consulta en Neo4j

```
CREATE
  (NAmerica: Location {name: 'North America', type: 'continent'}),
  (USA: Location {name: 'United States', type: 'country' }),
  (Idaho:Location {name: 'Idaho', type: 'state' }),
  (Lucy:Person {name:'Lucy' }),
  (Idaho)-[:WITHIN]->(USA)-[:WITHIN]-> (NAmerica),
```

```
  (Lucy) -[:BORN_IN]-> (Idaho)
```

Consulta:

```
MATCH
(person) -[:BORN_IN] -> () -[:WITHIN*0..] -> (us.Location {name: 'United States'})
(person) -[:LIVES_IN] -> () -[:WITHIN*0..] -> (us.Location {name: 'Europe'})
RETURN person.name
```

2.6.4) Bases de Datos basadas en Arrays

Suelen presentarse como bases de datos que soportan SQL y añaden operaciones para trabajar con conjuntos de datos especiales (arrays)

Utilizadas para tratamiento de grandes cantidades de datos de forma estadística o de modelado y OLAP

Soportan también datos geográficos, ya que pueden definir rangos numéricos de una o varias dimensiones (2D para cálculos geográficos)

Ejemplos: MonetDB, SciDB, rasdaman