# Fundamentos de Inferencia Estadística

Francisco Javier Mercader Martínez

## Índice

**1 Muestreo y distribuciones muestrales** **3**
1.1 Introducción . . . 3
1.2 Ejemplos . . . 3
1.3 Surge una pregunta . . . 3
1.4 Esbozo de respuesta: tasa de participación . . . 3
1.5 Realizacción del experimento: conclusiones . . . 4
1.6 En la práctica . . . 5
1.7 Uso de la distribución muestral . . . 5
1.8 Antes de extraer una muestra: . . . 6
1.9 Otro ejemplo: valores muestrales de una distribución normal . . . 6
1.10 Un resultado importante . . . 6
1.11 Algunos términos . . . 6
1.12 Ejemplos de estadísticos . . . 7
1.13 La media muestral . . . 7
1.13.1 Esperanza y varianza de la media muestral . . . 7
1.14 Consecuencia práctica . . . 8
1.14.1 Analogía con una diana . . . 8
1.15 Varianza muestral . . . 8
1.15.1 Dos apuntes . . . 8
1.16 Esperanza de la varianza muestral . . . 8
1.17 Distribuciones muestrales de $\bar{X}$ y $S^2$ . . . 9
1.18 Distribución de $\bar{X}$ y $S^2$ para una m.a.s. de una distribución normal . . . 9
1.19 Recordatorio: distribución $\chi^2$ con $p$ grados de libertad . . . 9
1.20 Distribución t-Student . . . 10
1.20.1 ¿Cuál es la forma de la densidad de una t-Student? . . . 11
1.21 Distribución F de Snedecor para el cociente de varianzas . . . 11
1.21.1 ¿Cuál es la forma de la densidad de una F de Snedecor? . . . 11
1.22 Si la distribución de $X$ no es Normal . . . 12
1.23 Distribución muestral de la proporción muestral . . . 13
1.24 Simulación y método de Monte-Carlo . . . 14
1.24.1 Muestreo de Monte-Carlo para aproximar esperanzas . . . 14
1.24.1.1 Ejemplos . . . 14
1.24.1.2 Aplicaciones . . . 14
1.25 Movimiento Browniano . . . 15
1.26 En finanzas, el modelo de Black-Scholes . . . 15
1.27 Simulación y método de Monte-Carlo . . . 16

**2 Estimación** **32**
2.1 Introducción . . . 32
2.2 Ejemplos de estimación paramétrica . . . 32
2.3 Estimación paramétrica: estimación puntual . . . 32
2.4 Métodos de contrucción de estimadores . . . 33
2.5 Método de los momentos . . . 33
2.6 Método de máxima verosimilitud . . . 33
2.7 Estimador de máxima verosimilitud . . . 34
2.8 Métodos para evaluar un estimador . . . 36
2.9 Sesgo . . . 36
2.10 Error cuadrático medio . . . 36
2.11 Balance entre sesgo y varianza . . . 37
2.12 Comportamiento asintótico de un estimador . . . 37
2.13 Consistencia . . . 37

2.14 Normalidad asintótica . . . 37
2.15 Estimación no paramétrica . . . 38
2.16 Estimación tipo núcleo . . . 39
2.16.1 Podemos variar el núcleo . . . 39
2.16.2 Se pueden demostrar resultados asintóticos . . . 40
2.17 Ancho de banda . . . 41
2.17.1 Elección óptima del ancho de banda . . . 41
2.17.1.1 Aproximación gaussiana para el cálculo de $R(f'')$ . . . 41
2.17.1.2 Aproximación no paramétrica para el cálculo de $R(f'')$, implementación en `R` . . . 42
2.18 Introducción al Bootstrap . . . 43
2.18.1 El error estándar Bootstrap . . . 45

**3 Estimación por intervalos** **54**
3.1 Introducción . . . 54
3.2 Nivel de confianza . . . 54
3.2.1 Nivel de cobertura . . . 54
3.3 Un procedimiento general de construcción . . . 54
3.4 Intervalo de confianza para la media $\mu$ de $X \sim \mathcal{N}(\mu, \sigma^2)$, $\sigma$ conocida . . . 55
3.4.1 Interpretación . . . 56
3.5 Comentarios importantes . . . 57
3.5.1 Factores que afectan a la precisión de la estimación . . . 57
3.5.2 Determinación del tamaño muestral . . . 57
3.5.3 Otros modelos . . . 58
3.5.4 Aplicación con el ejemplo de los ingresos . . . 61

**4 Constrastes de hipótesis** **68**
4.1 Introducción . . . 68
4.2 Constrastes de hipótesis paramétricos . . . 68
4.2.1 Elementos principales . . . 68
4.2.2 Formulación general del contraste de hipótesis . . . 69
4.2.2.1 Errores . . . 69
4.3 Métodos útiles para construir tests . . . 72
4.3.1 Un primer procedimiento general . . . 72
4.4 Constraste de hipótesis para la media $\mu$ . . . 72
4.5 Procedimiento, hipótesis bilateral . . . 72
4.6 Procedimiento, hipótesis unilateral . . . 73
4.7 El $p$-valor . . . 74
4.8 Test óptimo . . . 75
4.9 Potencia de un test . . . 75
4.10 Test óptimo como el de máxima potencia . . . 76
4.11 Procedimientos basados en la verosimilitud . . . 76
4.12 Contrastes de hipótesis simples . . . 76
4.13 Hipótesis compuestas . . . 77
4.14 Cociente de verosimilitudes monótono . . . 78
4.15 Contrastes de hipótesis compuestas . . . 78
4.16 Procedimiento basado en la verosimilitud . . . 79
4.17 Test RVG para la media de una población normal con varianza conocida . . . 79
4.18 Test de razón de verosimilitudes generalizada . . . 80
4.19 Test de bondad de ajuste . . . 81

**5 Inferencia Bayesiana** **99**
5.1 Introducción . . . 99
5.2 La inferencia bayesiana . . . 99
5.3 La distribución a posteriori . . . 99
5.4 Distribución a posteriori . . . 101
5.5 En el ejemplo de las tiradas de dados . . . 102
5.6 Cambiamos la distribución a priori . . . 102
5.6.1 La distribución $\mathrm{Be}(a, b)$ es bastante flexible como a priori . . . 103
5.7 Aplicaciones de la inferencia Bayesiana . . . 103
5.7.1 Ilustración para un ejemplo simpel de sistema de recomendación: . . . 103

# 1 Muestreo y distribuciones muestrales

## 1.1 Introducción

**El contexto**

- Tenemos una pregunta acerca de un fenómeno aleatorio.
- Formulamos un modelo para la variable de interés $X$.
- Traducimos la pregunta de interés en términos de uno o varios parámetros del modelo.
- Repetimos el experimento varias veces, apuntamos los valores de $X$.
- ¿Cómo usar estos valores para extraer información sobre el parámetro?

## 1.2 Ejemplos

**¿Está la moneda trucada?**

- Experimento: tirar una moneda. $X$ = resultado obtenido:

$$P(X = +) = p,\ P(X = c) = 1 - p$$
$$¿p = \frac{1}{2}?$$

**Sondeo sobre intención de participación en unas elecciones**

- Queremos estimar la tasa de participación antes de unas elecciones generales.
- Formulamos un modelo:
  - Experimento: "escoger una persona al azar en el censo".
  - $X$: participación, variable dicotómica ("Sí" o "No"). $p = P(X = \text{"Sí"})$.
- ¿Cuánto vale $p$?
- Censo: aprox. 37 000 000. Escogemos aprox. 3000 personas.

**Determinación de la concentración de un producto**

- Quiero determinar la concentración de un producto.
- Formulo el modelo:
  - Experimento: "llevar a cabo una mediación".
  - $X$: "valor proporcionado por el aparato".
  - $X \sim \mathcal{N}(\mu, \sigma^2)$.
- ¿Qué vale $\mu$?

## 1.3 Surge una pregunta

En todas estas situaciones donde nos basamos en la repetición de un experimento simple… - ¿Cómo sabemos que nuestra situación es fiable? - ¿Qué confianza tenemos al extrapolar los resultados de una muestra de 3000 personas a una población de 37 millones de personas?

## 1.4 Esbozo de respuesta: tasa de participación

**Para convencernos, un experimento de simulación**

- Voy a simular el proceso de extracción de una muestra de 3000 personas en una población de 37 millones de personas.
- Construyo a mi antojo los distintos componentes:
  - **La población:** defino en mi ordenador de 37 000 000 de ceros y unos ($\Longleftrightarrow$ el censo electoral).
    - "1" $\Longleftrightarrow$ "la persona piensa ir a votar".
    - "0" $\Longleftrightarrow$ "la persona no piensa ir a votar".
  - **La tasa de participación "real":** Decido que en mi población el 70% piensa en ir a votar $\rightarrow$ 25 900 000 "1"s.
  - **La extración de una muestra:** construyo un pequeño programa que extrae al azar una muestra de 3000 números dentro del conjunto grande.

```
[1] 0.7056667
```

Queremos descartar que haya sido suerte. Vamos a repetir muchas veces (1000 veces por ejemplo), la extracción de una muestra de 3000 personas en la población.

```r
library(tidyverse)
lista_muestras <- replicate(
  10000,
  sample(poblacion, 3000, replace = FALSE),
  simplify = FALSE
)
p_muestras <- map_dbl(lista_muestras, mean)
head(p_muestras)
```

```
[1] 0.6970000 0.7030000 0.7036667 0.7023333 0.7013333 0.7226667
```

```r
library(tidyverse)
p_muestras <- replicate(
  10000,
  sample(poblacion, 3000, replace = FALSE),
  simplify = FALSE
) |>
  map_dbl(mean)
head(p_muestras)
```

```
[1] 0.7090000 0.7080000 0.6946667 0.7216667 0.6906667 0.6990000
```

Recogemos los valores obtenidos en un histograma.

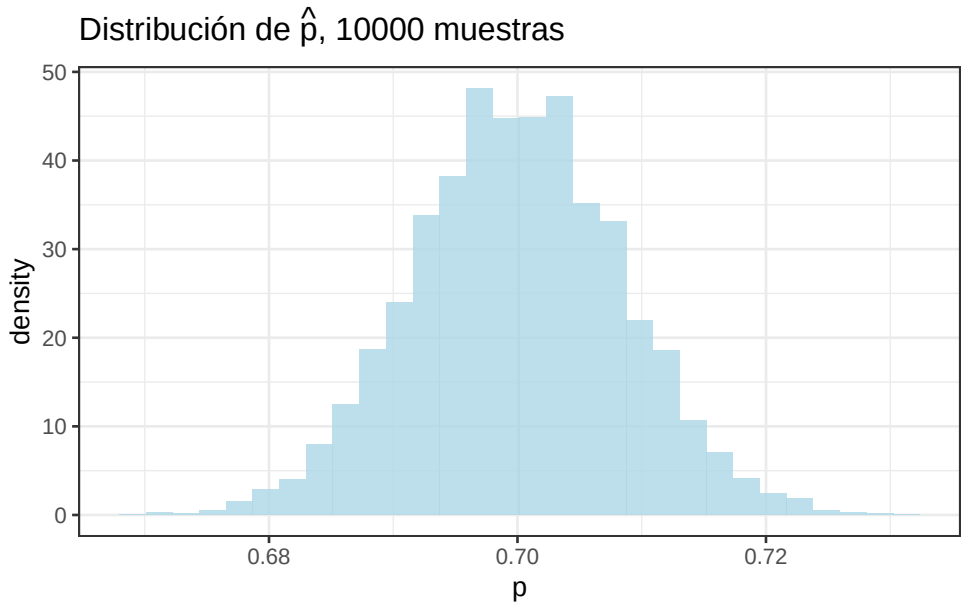


## 1.5 Realizacción del experimento: conclusiones

- La enorme mayoría de las muestras de 300 individuos proporcionan una tasa de participación muy próxima a la de la población.
  - **El riesgo** de cometer un error superior a $\pm 2$ puntos, al coger **una** muestra de 3000 individuos es muy pequeño (y asumible…)
- Si nos limitamos a muestras de 300 individuos, ¿qué esperáis?

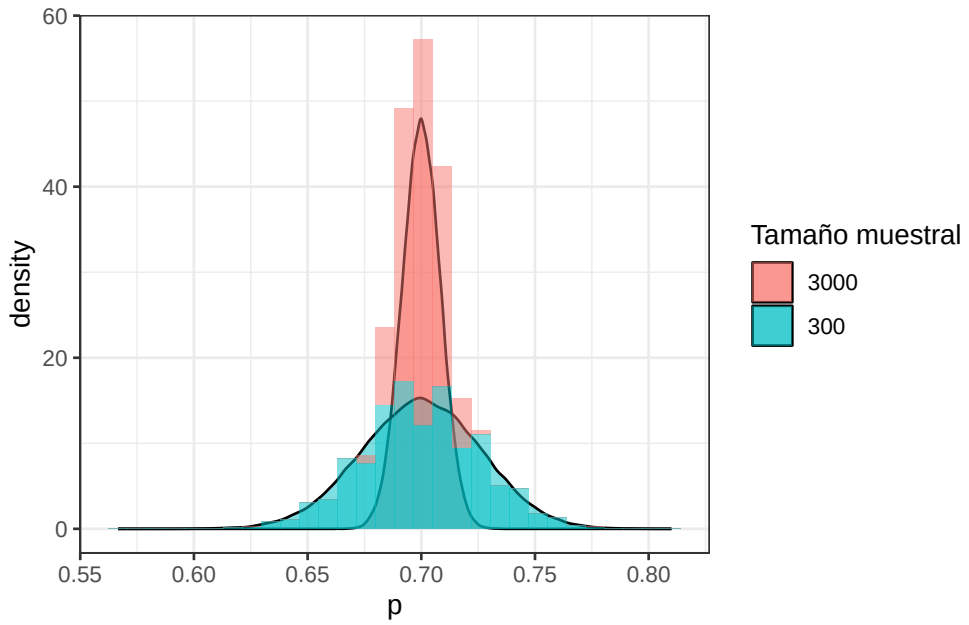


## 1.6 En la práctica

Usamos las distribuciones muestrales

- Las empresas de sondeos no se basan en simulaciones sino en cálculos teóricos.
- Experimento aleatorio: escoger al azar una muestra de 3000 personas dentro de una población de 37 000 000, con una tasa de participación $p$.
- Llamamos a $\hat{p}$ la variable aleatoria: proporción de "1"s en la muestra escogida.
- ¿Cuál es la distribución de valores de $\hat{p}$?

$$\hat{p} \sim \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$

Es lo que llamamos la distribución muestral de $\hat{p}$.

## 1.7 Uso de la distribución muestral

La distribución muestral de $\hat{p}$:

Es la distribución esperada de los valores de $\hat{p}$ respecto a todas las muestras de ese tamaño que podría extraer

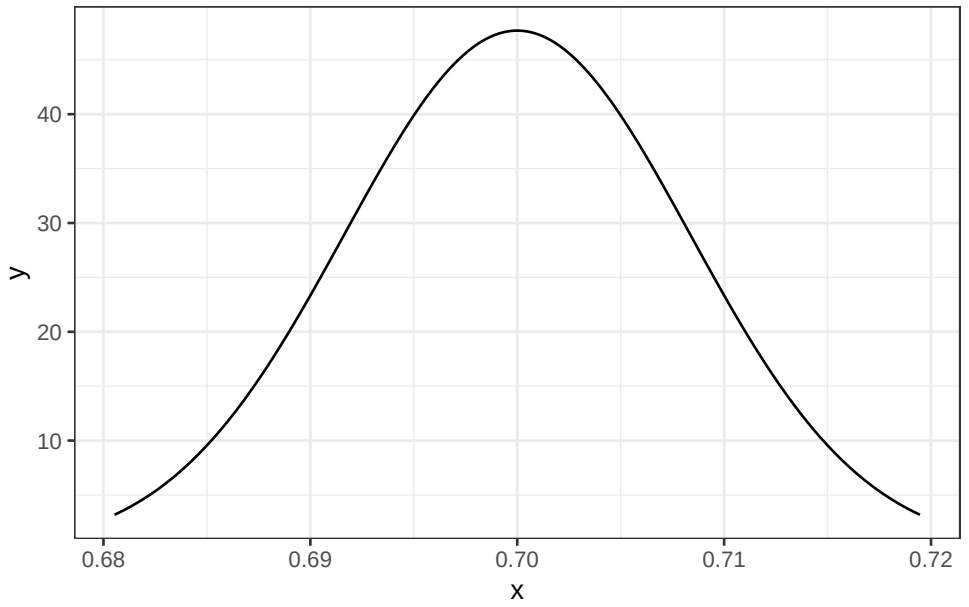

## 1.8 Antes de extraer una muestra:

- ¿Es suficiente el tamaño para el riesgo asumible y la predicción requerida?
- Una vez la muestra:
  - ¿Puedo dar un margen de error?
  - ¿Puedo decidir si $p$ poblacional es, por ejemplo, mayor que un valor dado?

## 1.9 Otro ejemplo: valores muestrales de una distribución normal

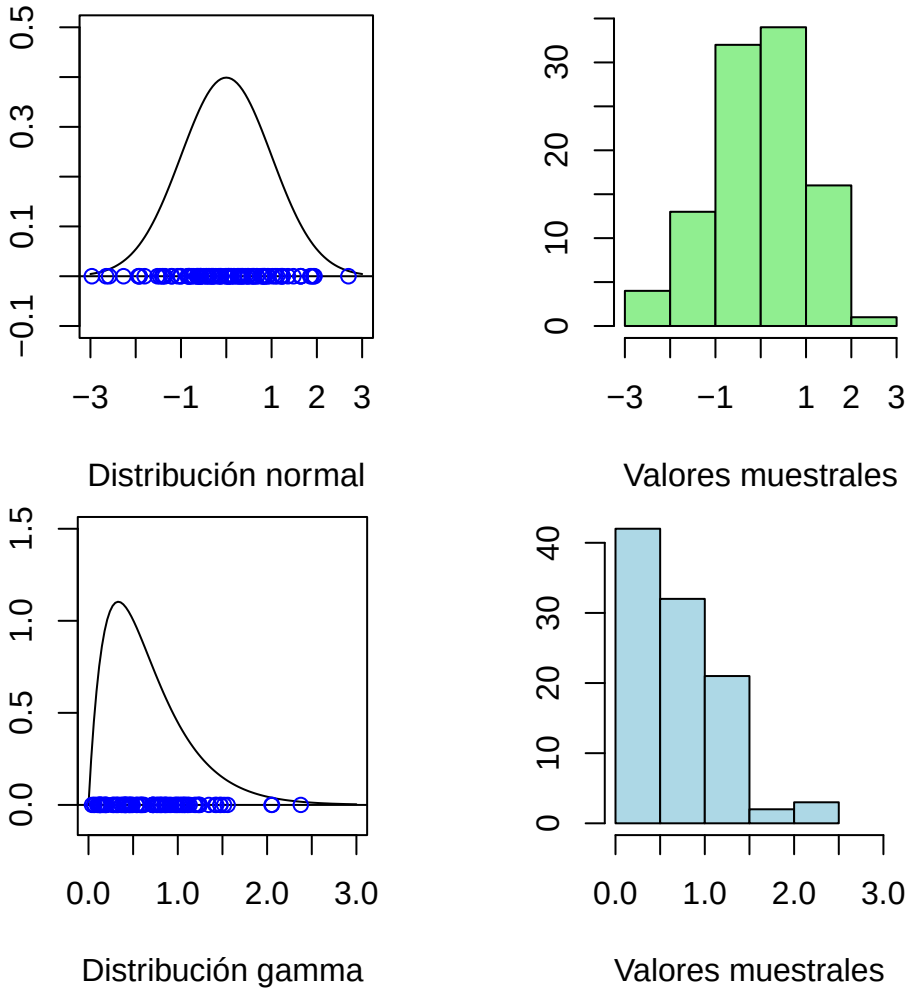


## 1.10 Un resultado importante

**Ley (débil) de los grandes números**

Sea $X$ una variable aleatoria y $q(X)$ una variable aleatoria transformada de $X$, con esperanza y momento de orden 2 finitos. Supongamos $X_1, X_2, \dots, X_n, \dots$ una sucesión de variables (vv.aa) independientes con la distribución que $X$, entonces

$$\lim_{n\to\infty} P\left[\left|\frac{\sum_{i=1}^{n} g(X_i)}{n} - E[g(x)]\right| < \varepsilon\right] = 1, \text{ para todo } \varepsilon > 0.$$

## 1.11 Algunos términos

**Definición 1.11.1**

- *Sea una variable aleatoria $X$. Consideramos $n$ variables aleatorias independientes e idénticamente distribuidas $X_1, X_2, \dots, X_n$, que se distribuyen como $X$. La variable aleatoria multidimensional $(X_1, X_2, \dots, X_n)$ es una muestra aleatoria simple (m.a.s.) de $X$.*
- *Cualquier cantidad calculada a partir de las observaciones de una muestra: estadístico.*
- *Experimento aleatorio: extraer una muestra. Consideramos un estadístico como una variable aleatoria. Nos interesa conocer la distribución del estadístico: distribución muestral.*

## 1.12 Ejemplos de estadísticos

- Proporción muestral: $\hat{p}$.
- Media muestral: $\bar{X} = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} X_i$.
- Desviación típica muestral: $S_X = \sqrt{\dfrac{1}{n+1}\displaystyle\sum_{i=1}^{n}(X_i - \bar{X})^2}$

## 1.13 La media muestral

**Contexto**

Estudiamos una variable $X$ cuantitativa. - Estamos interesados en $\mu$, el centro de la distribución de $X$. - Extraemos una muestra de tamaño $n$:

$$x_1, x_2, \dots, x_n.$$

- Calculamos su media $\bar{x}$ para aproximar $\mu$.
- ¿Cuál es la distribución muestral de $\bar{X}$?

Ejemplo:

- Quiero medir una cantidad. Hay variabilidad en las mediciones.
- Introduzco una variable aleatoria $X$ = "valor proporcionado por el aparato".
- $\mu$ representa el centro de los valores.
- Extraigo una muestra de tamaño 5 del valor de $X$

### 1.13.1 Esperanza y varianza de la media muestral

Llamamos $\mu = E[X]$ y $\sigma^2 = \mathrm{Var}(X)$.

- Tenemos

$$\boxed{E[\bar{X}] = \mu.}$$

- Es decir que el centro de la distribución muestral de $\bar{X}$ coincide con el centro de la distribución $X$.
- Tenemos $\mathrm{Var}(\bar{X}) = \dfrac{\sigma^2}{n}$, es decir, la dispersión de la distribución muestral de $\bar{X}$ es $\sqrt{n}$ veces más pequeña que la dispersión inicial de $X$.

**Ilustración: $X$ inicial, $\bar{X}$ con $n = 3$, $\bar{X}$ con $n = 10$**

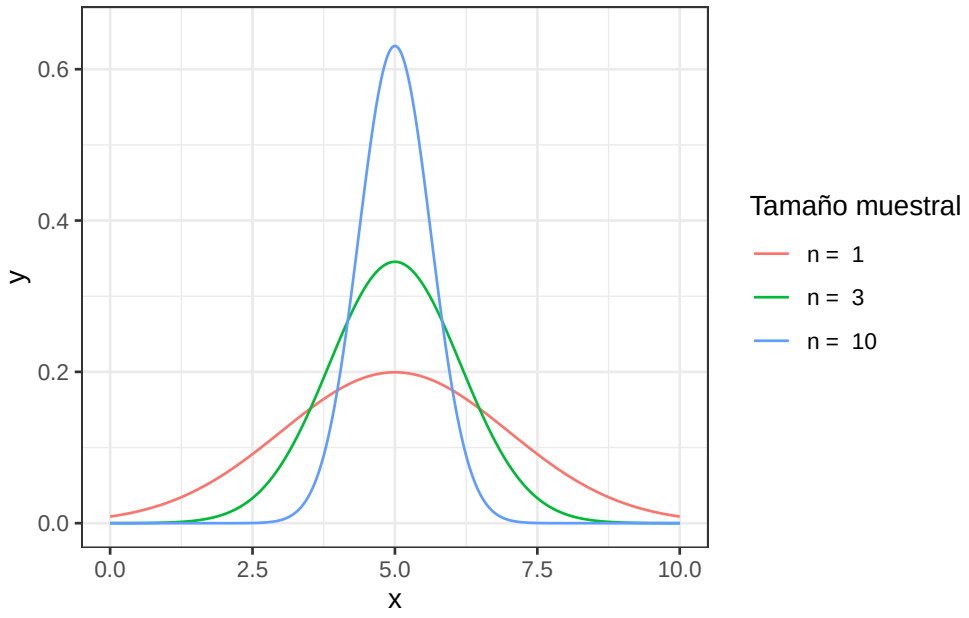

## 1.14 Consecuencia práctica

**Aparato de medición**

- Experimento: llevar a cabo una medición con un aparato.
- Variable aleatoria $X$: "valor proporcionado por el aparato".
- $E[X]$: centro de la distribución de los valores proporcionados por el aparato.
  - Lo deseable: $E[X]$ = valor exacto de la cantidad que buscamos medir.
  - En este caso, decimos: el aparato es exacto.
- $\sigma_X$: dispersión de la distribución de los valores proporcionados por el aparato.
  - Lo deseable: $\sigma_X$ pequeño.
  - En este caso, decimos: el aparato es preciso.

### 1.14.1 Analogía con una diana

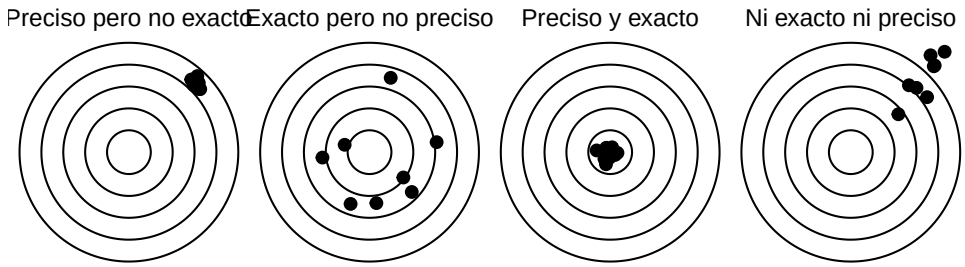


## 1.15 Varianza muestral

Si $(X_1, X_2, \dots, X_n)$ es una muestra aleatoria simple de $X$, definimos la varianza muestral $S_n^2$ como

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

**Fórmula alternativa para $S_n^2$:**

$$S_n^2 = \frac{n}{n-1}\left(\overline{X^2}_n - (\bar{X}_n)^2\right),$$

donde $\overline{X^2}_n = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} X_i^2$.

### 1.15.1 Dos apuntes

**En algunos textos en castellano**

Se suele llamar $S_n^2$ cuasi-varianza muestral, reservando el término varianza muestral para la cantidad $\dfrac{1}{n}\displaystyle\sum_{i=1}^{n}(X_i - \bar{X}_n)^2$.

**En estas fórmulas**

Omitimos, si no hay confusión posible, el subíndice $n$, escribiendo $S^2$, $\bar{X} = \displaystyle\sum_{i=1}^{n} X_i$ y $\overline{X^2} = \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} X_i^2$.

## 1.16 Esperanza de la varianza muestral

**Proposición 1.16.1** *Si $(X_1, X_2, \dots, X_n)$ es una muestra aleatoria simple de $X$ con varianza $\sigma_X^2$,*

$$E[S_n^2] = \sigma_X^2.$$

## 1.17 Distribuciones muestrales de $\bar{X}$ y $S^2$

**Tened en cuenta**

- Los resultados anteriores sobre $E[\bar{X}]$ y $\sigma_{\bar{X}}$ son válidos sea cual sea el modelo escogido para la distribución de $X$.
- Si queremos decir algo más preciso sobre la distribución de $\bar{X}$ (densidad, etc.) necesitamos especificar la distribución de $X$.
- En el caso en que la variable $X$ siga una distribución normla, el **teorema de Fisher** analiza cómo se comportan los estadísticos anteriores y nos permiten establecer una serie de consecuencias que serán utilizadas posteriormente en los temas de intervalos de confianza y de contraste de hipótesis.

## 1.18 Distribución de $\bar{X}$ y $S^2$ para una m.a.s. de una distribución normal

**Teorema de Fisher**

Consideramos una muestra aleatoria simple de una variable aleatoria $X$ con distribución normal $\mathcal{N}(\mu, \sigma^2)$, entonces se verifica: 1) $\bar{X}_n$ y $S_n^2$ son dos variables aleatorias independientes. 2) $\dfrac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$. 3) $\dfrac{(n-1)S_n^2}{\sigma^2} \sim \chi^2_{n-1}$.

## 1.19 Recordatorio: distribución $\chi^2$ con $p$ grados de libertad

**La distribución $\chi^2$.**

Para $p \in \mathbb{N}^+$, la función de densidad de la distribución $\xi^2$ es igual a

$$\frac{1}{\Gamma\left(\frac{p}{2}\right) 2^{\frac{p}{2}}} \cdot x^{\frac{p}{2}-1} e^{\frac{x}{2}}, \text{ si } x > 0,$$

donde $\Gamma$ denota la función Gamma (Nota: para cualquier real $\alpha > 0$, $\Gamma(\alpha) = \displaystyle\int_0^\infty t^{\alpha-1} e^{-t}\, \mathrm{d}t$).

**Caracterización de la $\chi^2$**

Si $Z_1, \dots, Z_p$ son $p$ variables aleatorias independientes, con $Z_i \sim \mathcal{N}(0,1)$, entonces la variable aleatoria $X$ definida como

$$X = Z_1^2 + \cdots + Z_p^2 = \sum_{i=1}^{p} Z_i^2$$

tiene un distribución $\chi^2$ con $p$ grados de libertad.

**¿Cómo es su función de desidad?**

Depende de los grados de libertad.

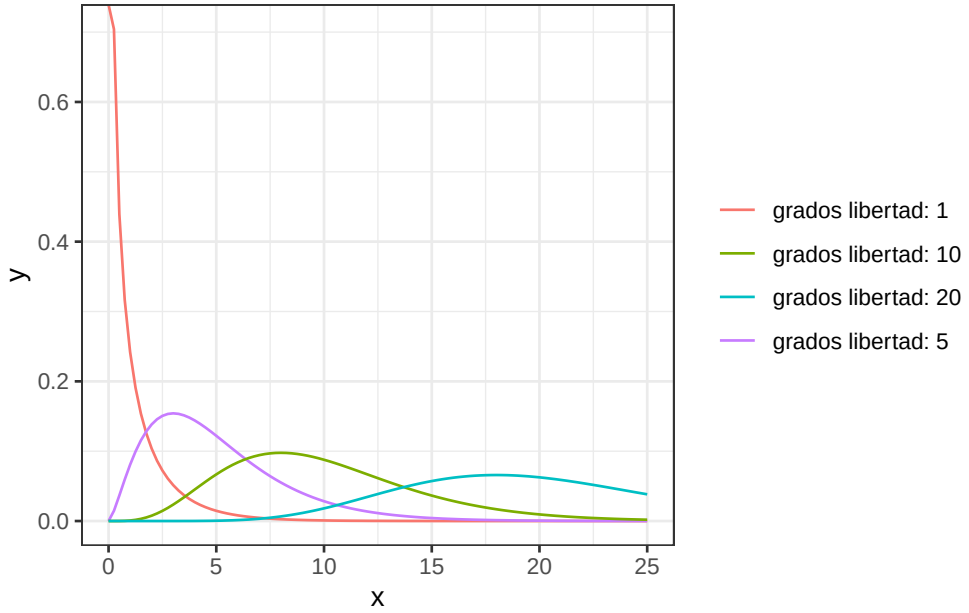


## 1.20 Distribución t-Student

Hemos visto, si $X$ es Normal:

$$\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

So queremos centrarnos en $\mu$ natural sustituir en ella $\sigma$ por $S_n$.

**Proposición 1.20.1** *Sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de una población $\mathcal{N}(\mu, \sigma^2)$,*

$$T = \frac{\bar{X}-\mu}{S/\sqrt{n}}$$

*tiene por densidad*

$$f_{n-1}(t) \propto \frac{1}{\left(\frac{1+t^2}{n-1}\right)^{n/2}}, \quad -\infty < t < \infty, \tag{1}$$

*La distribución que admit esta densidad se llama distribución t-Student con $n-1$ grados de libertad. Escribimos $T \sim t_{n-1}$.*

Su densidad

La función de densidad de una t de Student con $k$ grados de libertad:

$$f_k(t) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\Gamma\left(\frac{k}{2}\right)} \frac{1}{\sqrt{k\pi}} \frac{1}{(1+t^2/k)^{\frac{k+1}{2}}}, \quad -\infty < t < \infty,$$

donde $\Gamma$ dentoa la función Gamma.

Caracterización de la t de Student como cociente

Si $Z$ e $Y$ son dos variables aleatorias independientes, con $Z \sim \mathcal{N}(0,1)$ e $Y \sim \chi^2_p$, el cociente

$$T = \frac{Z}{\sqrt{Y/p}} \sim t_p,$$

donde $t_p$ denota la t de Student con $p$ grados de libertad.

### 1.20.1 ¿Cuál es la forma de la densidad de una t-Student?

Tiene colas más pesadas que una normal

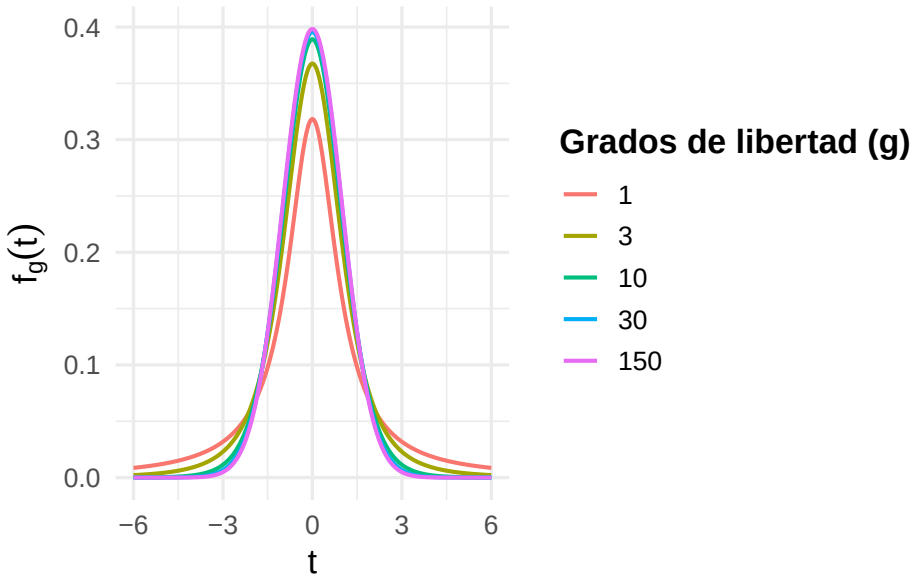


Figure 1: Densidad de la ditribución t de Student para varios valores de los grados de libertad

## 1.21 Distribución F de Snedecor para el cociente de varianzas

**Proposición 1.21.1** *Consideremos $U_1$ y $U_2$ dos variables aleatorias independientes con distribución $\chi^2$ con $p_1$ y $p_2$ grados de libertad, respectivamente.*

*El cociente $F = \dfrac{U_1/p_1}{U_2/p_2}$ admite la densidad*

$$f_F(x) = \frac{\Gamma\left(\frac{p_1+p_2}{2}\right)}{\Gamma(p_1)\Gamma(p_2)} \left(\frac{p_1}{p_2}\right)^{p_1} \frac{x^{p_1/2-1}}{\left(1+\frac{p_1}{p_2}x\right)^{\frac{p_1+p_2}{2}}}.$$

*Esta distribución se llama F de Snedecor con $p_1$ y $p_2$ grados de libertad y escribimos $F \sim F_{p_1,p_2}$.*

Consecuencia

Consideremos $X$ e $Y$ vv.aa. normales independientes con varianzas $\sigma_X^2$ y $\sigma_Y^2$, así como $X_1, \dots, X_{n_X}$ y $Y_1, \dots, Y_{n_Y}$ dos m.a.s. de $X$ y $Y$, respectivamente. Deducimos que

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n_X-1,n_Y-1}.$$

### 1.21.1 ¿Cuál es la forma de la densidad de una F de Snedecor?

Depende mucho de los grados de libertad

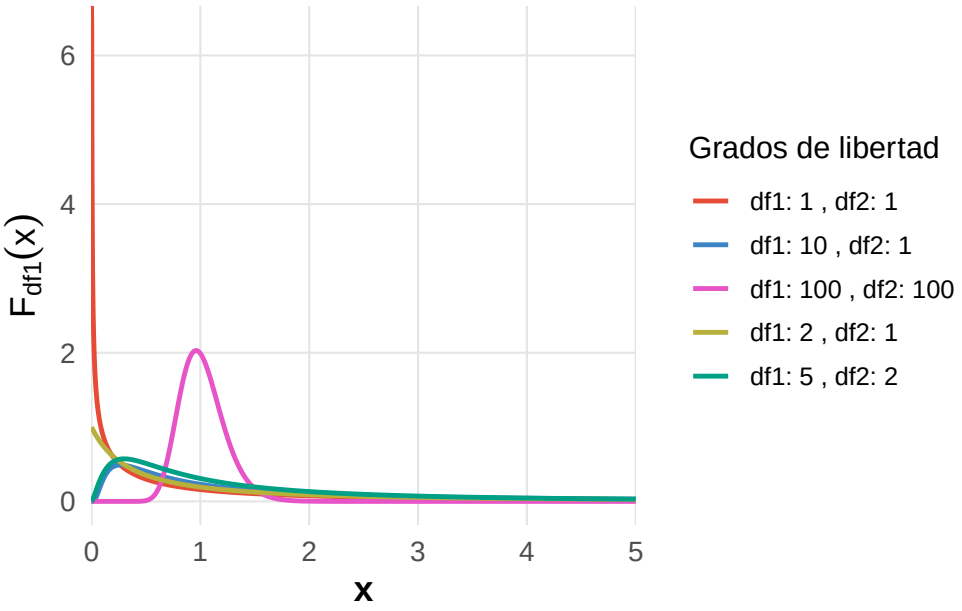


Figure 2: Densidad de la distribución F de Snedecor para varios valores de los grados de libertad

## 1.22 Si la distribución de $X$ no es Normal

No podemos decir nada en general, excepto si $n$ es grande...

**Teorema Central del Límite**

Si $n$ es *"suficientemente"* grande, se puede aproximar la distribución de $\bar{X}$ por una Normal con media $\mu$ y varianza $\frac{\sigma^2}{n}$:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \text{ aproximadamente.}$$

**Fomulación matemática**

El resultado anterior se traduce por una convergencia de la sucesión de las variables aleatorias $(\bar{X}_n)_n$ en distribución cuando $n \to \infty$.

**Teorema Centro del Límite**

¿Cuándo considerar que $n$ es grande?

- Depende de la forma de la distribución de $X$:
  - Si $X$ casi Normal: $n$ pequeño es suficiente.
  - Si $X$ muy asimétrico: $n$ mucho más grande necesario.
- En general, se suele considerar $n \geq 30$ suficiente...

**Ilustración, $X$ inicial** $\sim \text{Exp}(\lambda = 0.5)$, $\bar{X}$ **con** $n = 3, 10$ **y** $n = 30$

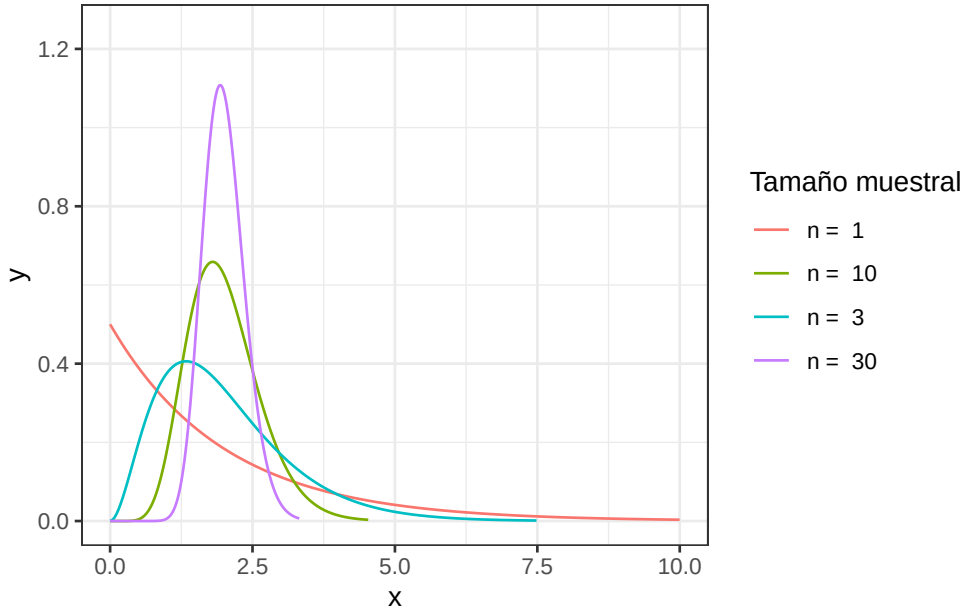


## 1.23 Distribución muestral de la proporción muestral

**Contexto**

- Hay situaciones donde $X$ toma el valor 0 o 1, con probabilidades $1-p$ y $p$, respectivamente.
- Por ejemplo, el siguiente experimento: escoger una pieza en la producción. $X=1$ si es defectuosa, $X=0$ si es correcta.
- Repetimos $n$ veces el experimento. Obtenemos

$$x_1 = 1, x_2 = 0, x_3 = 0, x_4 = 1, x_5 = 0, \dots, x_n$$

- La proporción muestral es:

$$\hat{p} = \frac{N}{n}.$$

**Distribución exacta de $\hat{p}$**

¿Cuál es la distribución de $N$?

- Experimento simple con situación dicotómica, repetimos $n$ veces…

$$N = \mathcal{B}(n, p).$$

- Podemos usar esta distribución para hacer cálculos exactos…

**Distribución aproximada de $\hat{p}$**

Tenemos que $N = X_1 + X_2 + \cdots + X_n$, por lo tanto

$$\hat{p} = \frac{N}{n} = \frac{X_1 + X_2 + \cdots + X_n}{n} = \bar{X}.$$

Por el Teorema Central del Límite:

$$\hat{p} = \mathcal{N}\left(p, \frac{p(1-p)}{n}\right) \text{ aproximadamente.}$$

Podemos usar esta distribución para hacer cálculos aproximados.

## 1.24 Simulación y método de Monte-Carlo

**Motivación**

En muchas situaciones, la capacidad de simular valores de las distribuciones de interés puede resultar útil calcular o estimar cantidades relevantes para la inferencia sobre la distribución de $X_1, X_2, \dots, X_n$.

**¿Qué es ser capaz de simular valores de una distribución $f$?**

- Se refiere a la posibilidad de producir, para cualquier tamaño $k$, conjuntos de valores $u_1, u_2, \dots, u_k$, cuyo comportamiento imita el de $k$ realizaciones aleatorias independientes de la distribución $f$.
- Quiere decir que las propiedades del conjunto generado lo hace indistinguible, si le aplicamos tests de independencia o de bondad de ajuste, de $k$ realizaciones independientes de $f$.

**Simulación y método de Monte-Carlo**

- Como hemos visto en los primeros ejemplos, gráficos como el histograma de frecuencias se comportan como la función de densidad de la variable de la que provienen las observaciones. También se pueden utilziar gráficos como la función de distribución empírica que veremos más adelante.
- Como consecuencia, dado un estadístico, si podemos obtener un número grande de observaciones del mismo podemos a través de algunos gráficos obtener información sobre su distribución.
- Podemos generar esas observaciones a través de lo que se conoce como simulaciones, observaciones generadas mediante algún algoritmo.
- Esta metodología que se puede aplicar en muchas otras situaciones se conoce como el método de Monte-Carlo.

### 1.24.1 Muestreo de Monte-Carlo para aproximar esperanzas

**Ley de los grandes números**

Consideremos una muestra aleatoria simple $X_1, X_2, \dots, X_n$ de una distribución $X$. Para cualquier función $g$ que cumple $E[g^2(X)] < +\infty$, tenemos que, con probabilidad 1,

$$\lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} g(X_i) = E[g(X)].$$

#### 1.24.1.1 Ejemplos

- $g(x) = x$ : $\lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} X_i = E[X]$, es decir $\bar{X}_n \longrightarrow E[X] = \mu_X$.
- $g(x) = (x - \mu_X)^2$ : $\lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} (X_i - \mu_X)^2 = E[(X - \mu_X)^2] = \mathrm{Var}(X)$.
- Si combinamos las dos convergencias anteriores: $\lim_{n\to\infty} \frac{1}{n}(X_i - \bar{X}_n)^2 = \mathrm{Var}(X)$, es decir, $S_n^2 \longrightarrow \mathrm{Var}(X)$.
- $g(x) = 1_{x\leq q}$ : $\lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} 1_{X_i \leq q} = P(X \leq q)$, es decir, que las frecuencias acumuladas relativas convergen hacia la probabilidad asociada.

#### 1.24.1.2 Aplicaciones

**Ejemplo: el movimiento Browniano**

- Es proceso muy usado en la predicción de precios (opciones) en matemáticas financieras.
- Una caracterízación simplificada: es la suma infinitesimal de pequeñas contribuciones normales independientes.
- Para cualquier $t$, $W_t \sim \sum_{i=1}^{\frac{t}{h}} \sqrt{h} \cdot Z_i$, donde $h$ es el paso infinitesimal y $Z_i$ son normales estándares independientes e idénticamente distribuidos.

## 1.25 Movimiento Browniano

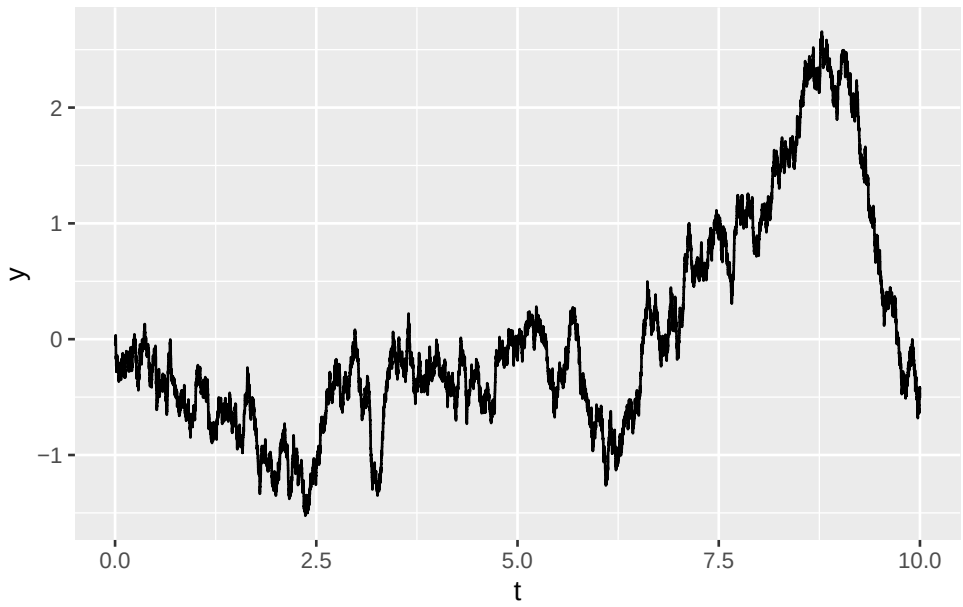


## 1.26 En finanzas, el modelo de Black-Scholes

El movimiento Browniano Geométrico:

Lo propusieron Merton, Scholes y Black como modelo teórico para precios de acciones:

$$S_t = S_0 \exp\left(\left(y - \frac{1}{2}\sigma^2\right) t + \sigma W_t\right).$$

- $S_0$: precio inicial de la acción.
- $\mu$: el drift.
- $\sigma^2$: la volatilidad.

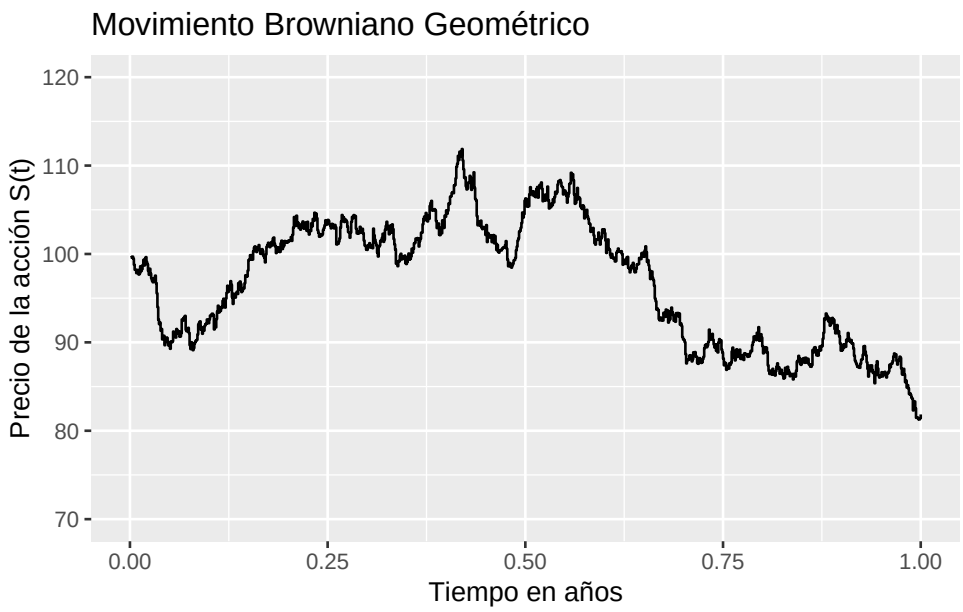


**¿Cuándo observamos $S(t) \geq 100$€?**

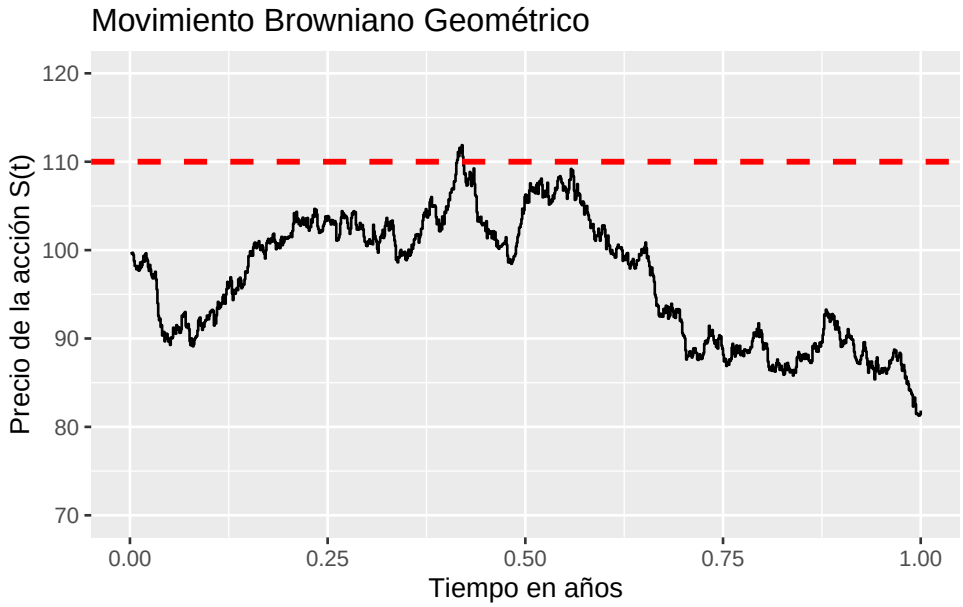


- Podemos simular muchas trayectorias del Movimiento Browniano Geométrico y observa qué pasa con el tiempo en el que supera el umbral 110.
- Esto es Monte-Carlo.
- Luego podremos obtener indicadores de la distribución de este tiempo.

**Tip**

Representamos las 8 primeras

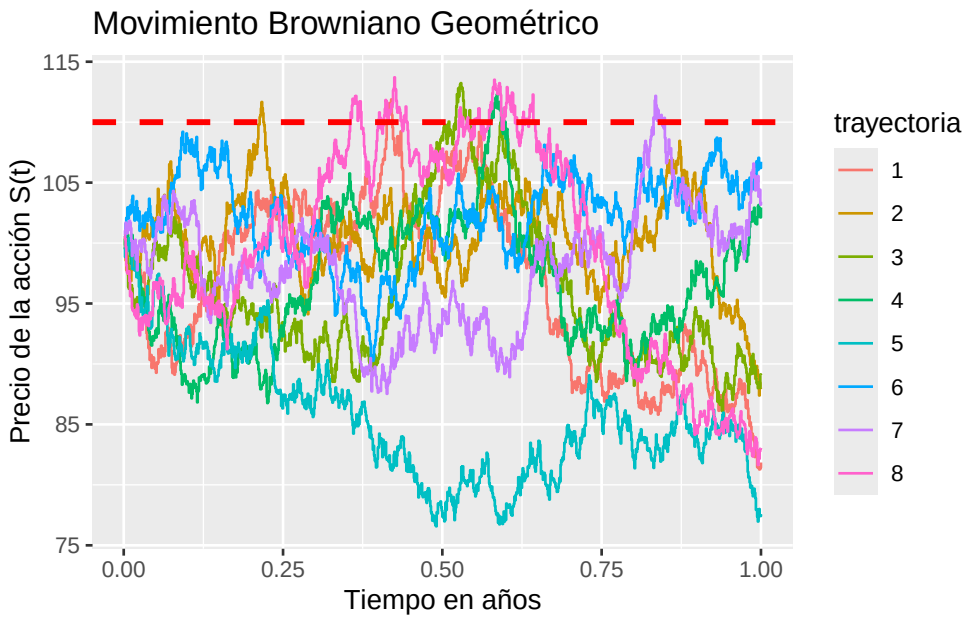


## 1.27 Simulación y método de Monte-Carlo

**Simulación de variables aleatorias**

- Lo que nos planteamos ahora es qué algoritmo podemos utilziar para generar observaciones (simulaciones) de una variable aleatoria.
- Para un gran número de variables aleatorias y modelos probabilísticos, estas simulaciones ya están incorporadas en los paquetes y lenguajes de programación con enfoque matemático y estadístico, como `R`.
- Aquí describiremos uno de los métodos más básicos, basado en la inversa de la función de distribución.
- El método de la función inversa es uno de los principales métodos de simulación de variables aleatorias.
- Está basado en la inversa de la función de distribución de una variable aleatoria.
- No todas las funciones de distribución admiten inversa, como la conoceremos usualmente. Para ello es

necesario que sea continua y estrictamente creciente.

**Inversa generalizada de la función de distribución o función cuantil**

Dada una función de distribución F, su función cuantil (inversa generalizada) se define como

$$F^{-1}(p) = \inf\{x | F(x) \geq p\}, \text{ para todo } p \in (0,1).$$

**Propiedades de la función cuantil**

1) $F(F^{-1}(p)) \geq p$, para todo $p \in (0,1)$.
2) $F^{-1}(F(x)) \leq x$, para todo $x$ donde $F(x) > 0$.
3) Si $U \sim U(0,1)$ entonces $F^{-1}(U)$ tiene como distribución $F$.
4) Dada una variable aleatoria $X$, con media finita y función de distribución $F$ se verifica que

$$E[X] = \int_0^1 F^{-1}(u)\, \mathrm{d}u.$$

**Método de la función inversa**

- Dada una variable aleatoria $X$ con función de distribución $F$, si generamos observaciones independientes $U \sim U(0,1)$, $u_1, u_2, \dots, u_n$, entonces los valores

$$x_1 = F^{-1}(u_1), x_2 = F^{-1}(u_2), \dots, x_n = F^{-1}(u_n)$$

constituyen una observación de la muestra aleatoria simple de tamaño $n$ de la variable aleatoria $X$.

**Generación de valores de una distribución uniforme**

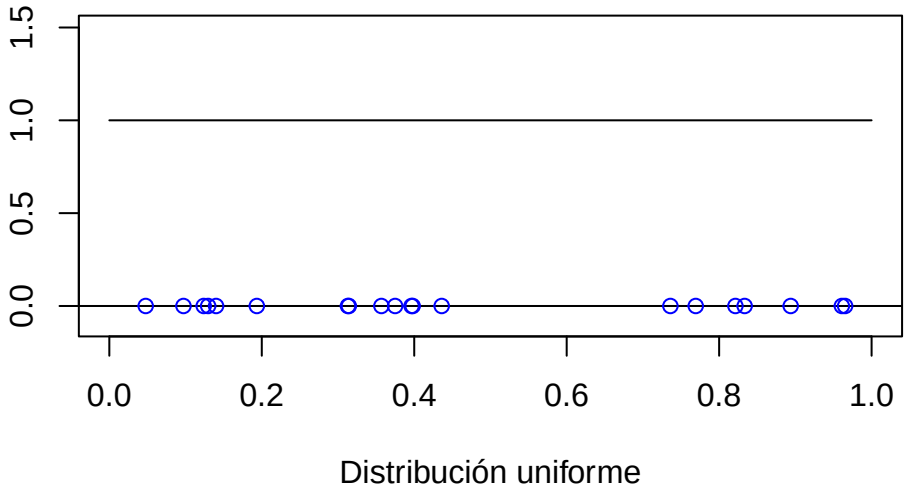


**Generación de valores de una distribución gamma**

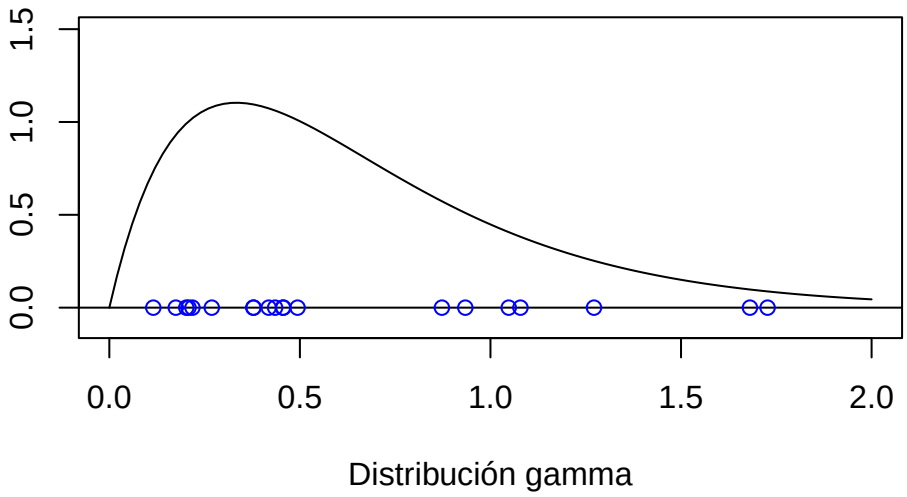


### Transformación de una variable aleatoria

**Planteamiento del problema**

En muchas ocasiones, tenemos una variable aleatoria continua $X$, de la que conocemos la función de densidad, pero nos interesa concoer cómo se comporta una transformación de $X$, $Y = \varphi(X)$.

**Teorema 1.27.1** *Sea $X$ una variable aleatoria con función de densidad $f_X$ definida en un intervalo abierto $(a, b) \subseteq \mathbb{R}$. Sea $\varphi : (a, b) \to \mathbb{R}$ tal que:*

- *Es continua.*
- *Es estrictamente creciente o decreciente.*
- *$\varphi^{-1}$ es diferenciable.*

*Entonces, la variable aleatoria $Y = \varphi(X)$ tiene función de densidad*

$$f_Y(y) = \begin{cases} f_X(\varphi^{-1}(y)) \left| \dfrac{\mathrm{d}}{\mathrm{d}x}(\varphi^{-1}(y)) \right|, & \text{si } y \in \varphi(a, b) \\ 0, & \text{en otro caso} \end{cases}$$

### Función características

**Definición 1.27.1** *Sea $X$ una variable aleatoria cualquiera. La función característica de $X$ se define como*

$$\phi(t) = E[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} \mathrm{d}F(x)$$

*en donde $i = \sqrt{-1}$.*

**Tip**

Nota: $\phi(t) = \displaystyle\int_{-\infty}^{\infty} \cos(tx)\mathrm{d}F(x) + i \int_{-\infty}^{\infty} \sin(tx)\mathrm{d}F(x)$.

**Propiedades**

- Existencia: $|\phi(t)| \leq 1$, para todo $t \in \mathbb{R}$.
- Si $X$ e $Y$ son variables aleatorias independientes, entonces

$$\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t),$$

para todo $t \in \mathbb{R}$.

### Desigualdades

**Desigualdad de Markov**

Si $Z$ es una variable aleatoria no negativa con media finita $E[Z]$ y $\varepsilon > 0$, entonces

$$\varepsilon \Pr[Z \geq \varepsilon] = \varepsilon \int_{[\varepsilon,\infty)} \mathrm{d}F_Z(x) \leq \int_{[\varepsilon,\infty)} x \mathrm{d}F_Z(x) \leq \int_{[0,\infty)} x \mathrm{d}F_Z(x) = E(Z)$$

(donde $F_Z(x) = \Pr[Z \leq x]$ es su función de distribución), es decir

$$\Pr[Z \geq \varepsilon] \leq \frac{E[Z]}{\varepsilon}.$$

**Desigualdad de Chebyshev**

Si $X$ es una variable aleatoria con media finita $\mu = E[X]$ y varianza $\sigma^2 = \mathrm{Var}(X) > 0$, entonces tomando $Z = \dfrac{(X-\mu)^2}{\sigma^2} \geq 0$ y aplicando la desigualdad de Markov, tenemos

$$\Pr\left[\frac{(X-\mu)^2}{\sigma^2} \geq \varepsilon\right] \leq \frac{1}{\varepsilon}$$

para todo $\varepsilon > 0$.
También se puede escribir como

$$\Pr[(X-\mu)^2 < \varepsilon\sigma^2] \geq 1 - \frac{1}{\varepsilon}$$

o como

$$\Pr[|X-\mu| < r] \geq 1 - \frac{\sigma^2}{r^2},$$

para todo $r > 0$.

# Hoja 1: Muestreo y distribuciones muestrales

**1)** Sea $X$ variable aleatoria con distribución Bernoulli, de parámetro $p(X \sim b(p))$ y sea $X_1, X_2, X_3$ una muestra aleatoria simple (m.a.s) de $X$. Se pide:

**a)** Estudiar la distribución del vector $(X_1, X_2, X_3)$.

El enunciado nos indica que el vector $(X_1, X_2, X_3)$ forma una muestra aleatoria simple (m.a.s.) de la variable $X$. Si consideramos $n$ variables aleatorias que conforman una m.a.s. de $X$, estas variables son **independientes e idénticamente distribuidas (i.i.d.)**, y se distribuyen igual que la variable original $X$.

Por lo tanto, la distribución del vector multidimensional $(X_1, X_2, X_3)$ está caracterizada por esta compuesta de 3 variables independientes entre sí, donde cada componente $X_i$ sigue una misma distribución Bernoulli con parámetro $p : X_i \sim b(p)$ para $i = 1, 2, 3$.

Debido a su independencia, la probabilidad conjunta del vector para unos valores concretos $(x_1, x_2, x_3)$ (donde cada $x_i$ solo puede tomar los valores 0 o 1) es el producto de las probabilidades marginales de cada componente:

$$P(X_1 = x_1, X_2 = x_2, X_3 = x_3) = P(X_1 = x_1) \cdot P(X_2 = x_2) \cdot P(X_3 = x_3)$$

**b)** Estudiar la distribución en el muestreo del estadístico $\dfrac{X_1 + X_2 + X_3}{3}$.

Cualquier cantidad calculada a partir de las observaciones de una muestra se denomina estadístico. En este caso particular, la expresión $\dfrac{X_1 + X_2 + X_3}{3}$ corresponde a la **media muestral** $\bar{X}$, que en el contexto de las variables dicotómicas (como la distribución de Bernoulli que solo toma valores 0 o 1) se conoce como la **proporción muestral**, denotada como $\hat{p}$.

Para encontrar la distribución de este estadístico, debemos observar la suma del numerador, $N = X_1 + X_2 + X_3$. Al repetir un experimento con una situación dicotómica $n$ veces, el número de "éxitos" $N$ sigue una distribución binomial $\mathcal{B}(n, p)$. Como el tamaño de muestra es $n = 3$, tenemos que:

$$N \sim \mathcal{B}(3, p).$$

Poder usar esta distribución para hacer cálculos exactos sobre $\hat{p} = \dfrac{N}{n}$. Dado que $\hat{p} = \dfrac{N}{3}$, el estadístico solo puede tomar los valores correspondientes a los posibles resultados de $N$ divididos entre 3 $(0, \frac{1}{3}, \frac{2}{3}, 1)$. Su distribución exacta en el muestreo viene dada por las probabilidades de la distribución binomial:

- $P(\hat{p} = 0) = P(N = 0) = \binom{3}{0} p^0 (1-p)^3 = (1-p)^3$
- $P(\hat{p} = \frac{1}{3}) = P(N = 1) = \binom{3}{1} p^1 (1-p)^2 = 3p(1-p)^2$
- $P(\hat{p} = \frac{2}{3}) = P(N = 2) = \binom{3}{2} p^2 (1-p)^1 = 3p^2(1-p)$
- $P(\hat{p} = 1) = P(N = 3) = \binom{3}{3} p^3 (1-p)^0 = p^3$

**2)** Sea $X$ variable aleatoria con distribución $Exp(\lambda)$. Sea $(X_1, \dots, X_n)$ una m.a.s. de $X$, estudiar la distribución en el muestreo de $S = \sum_{j=1}^{n} X_j$.

1) Distribución Exacta (Función Característica)

La función característica de la variable original $X$ se define como:

$$\phi_X(t) = E[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} \mathrm{d}F_X(x)$$

Dado que las variables de las m.a.s. son independientes, aplicamos la propiedad de la función característica para sumas de variables aleatorias independientes:

$$\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t)$$

Extendiendo esto a la suma $S$ de $n$ variables i.i.d.:

$$\phi_S(t) = \prod_{j=1}^{n} \phi_{X_j}(t) = [\phi_X(t)]^n$$

2) Distribución Aproximada (Teorema Central del Límite)

Expresamos $S$ en función de la media muestral $\bar{X}$:

$$\bar{X} = \frac{1}{n}\sum_{j=1}^{n} X_j \implies S = n\bar{X}$$

Sea $\mu = E[X]$ y $\sigma^2 = \mathrm{Var}(X)$, sabemos que:

$$E[\bar{X}] = \mu$$
$$\mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

Si el tamaño muestral es "suficientemente" grande ($n \geq 30$), aplicamos el Teorema Central de Límite:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \text{ aproximadamente}$$

Aplicando la transformación lineal $S = n\bar{X}$, la distribución asintótica de la suma es:

$$S \sim \mathcal{N}(n\mu, n\sigma^2) \text{ aproximadamente}$$

**3)** Sea $X$ variable aleatoria con distribución $N(\mu, \sigma^2)$. Sea $(X_1, \dots, X_n)$ una m.a.s. de $X$, estudiar la distribución en el muestreo de $S = \sum_{j=1}^{n} X_j$.

1) Relación con la media muestral

La media muestral se define como:

$$\bar{X}_n = \frac{1}{n}\sum_{j=1}^{n} X_j$$

Despejando, podemos expresar el estadístico $S$ en función de la media muestral:

$$S = n\bar{X}_n$$

2) Distribución de la media muestral

Al provenir la muestra de una distribución normal, aplicamos el Teorema de Fisher, el cual establece que:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Deshaciendo la estandarización, deducimos que la distribución exacta de la media muestral es una distribución normal con los parámetros de esperanza y varianza teóricos:

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

3) Esperanza y varianza del estadístico $S$

Sabiendo que $\mathbb{E}[X] = \mu$ y $\mathrm{Var}(X) = \sigma^2$, calculamos los momentos de $S$.

Por la linealidad de la esperanza:

$$\mathbb{E}[S] = \mathbb{E}\left[\sum_{j=1}^{n} X_j\right] = \sum_{j=1}^{n} \mathbb{E}[X_j] = n\mu$$

Dado que las variables de una m.a.s. son independientes entre sí, la varianza de la suma es igual a la suma de las varianzas:

$$\mathrm{Var}(S) = \mathrm{Var}\left(\sum_{j=1}^{n} X_j\right) = \sum_{j=1}^{n} \mathrm{Var}(X_j) = n\sigma^2$$

4) Distribución en el muestreo de $S$

Puesto que $S$ es una transformación lineal de $\bar{X}_n$ ($S = n\bar{X}_n$), y la media muestral sigue una distribución normal exacta según el Teorema de Fisher, la variable suma $S$ también se distribuye exactamente como una normal.

Sustituyendo los momentos calculados, concluimos que la distribución en el muestreo es:

$$S \sim \mathcal{N}(n\mu, n\sigma^2)$$

**4)** Sea $X$ una variable aleatoria con función de densidad:

$$f(x,\theta) = \frac{2x}{\theta}\exp\left(-\frac{x^2}{\theta}\right)\xi_{(0,+\infty)}(x).$$

Obtener la distribución en el muestreo del estadístico:

$$T(X_1, X_2, \dots, X_n) = \sum_{j=1}^{n} X_j^2.$$

Obtener su media y su varianza.

1) Distribución de $Y_j = X_j^2$

Para encontrar la distribución en el muestreo, primero aplicamos el **Teorema de transformación de una variable aleatoria.**

Sea $Y = \varphi(X) = X^2$. La transformación inversa y su derivada son:

$$\varphi^{-1}(y) = \sqrt{y}$$
$$\frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y)) = \frac{1}{2\sqrt{y}}$$

La función de densidad de la variable transformada $Y_j$ es:

$$f_Y(y) = f_X(\varphi^{-1}(y))\left|\frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y))\right|$$
$$f_Y(y) = \frac{2\sqrt{y}}{\theta}\exp\left(-\frac{y}{\theta}\right)\frac{1}{2\sqrt{y}} = \frac{1}{\theta}\exp\left(-\frac{y}{\theta}\right), \quad y > 0$$

2) Relación con la distribución $\chi^2$

Aplicamos una segunda transformación $W_j = \frac{2}{\theta}Y_j$:

$$\varphi^{-1}(w) = \frac{\theta}{2}w \implies \frac{\mathrm{d}}{\mathrm{d}w}(\varphi^{-1}(w)) = \frac{\theta}{2}$$
$$f_W(w) = \frac{1}{\theta}\exp\left(-\frac{\theta w/2}{\theta}\right)\frac{\theta}{2} = \frac{1}{2}\exp\left(-\frac{w}{2}\right), \quad w > 0$$

La función de densidad de una distribución $\chi^2$ con $p$ grados de libertad es:

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}}x^{p/2-1}e^{-x/2}$$

Sustituyendo $p = 2$ y sabiendo que $\Gamma(1) = 1$ (donde $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1}e^{-t}\,\mathrm{d}t$), obtenemos exactamente $\frac{1}{2}e^{-w/2}$.

Por lo tanto:

$$W_j = \frac{2X_j^2}{\theta} \sim \chi_2^2$$

3) Distribución en el muestreo del estadístico $T$

El estadístico dado es $T = \sum_{j=1}^{n} X_j^2$. Transformamos esto usando nuestra variable $W_j$:

$$\sum_{j=1}^{n} W_j = \frac{2}{\theta}\sum_{j=1}^{n} X_j^2 = \frac{2}{\theta}T$$

Como $W_j \sim \chi_2^2$ (suma de 2 normales al cuadrado) y tenemos una m.a.s. de $n$ variables independientes, la suma total se compone de $2n$ variables normales al cuadrado.

Por consiguiente:

$$\frac{2}{\theta}T \sim \chi_2^2$$
$$T \sim \frac{\theta}{2}\chi_{2n}^2$$

4) Media y Varianza de $T$

Podemos obtener los momentos de $T$ calculando primero los momentos de $X_j^2$ mediante la definición de esperanza y haciendo uso de la función Gamma $\Gamma(\alpha) = \displaystyle\int_0^\infty t^{\alpha-1}e^{-t}\,\mathrm{d}t$.

**Esperanza de $X_j^2$:**

$$\mathbb{E}[X_j^2] = \int_0^\infty x^2 \frac{2x}{\theta} \exp\left(-\frac{x^2}{\theta}\right)\,\mathrm{d}x$$

Haciendo el cambio de variable $t = \dfrac{x^2}{\theta} \implies \mathrm{d}t = \dfrac{2x}{\theta}\,\mathrm{d}x$ y $x^2 = \theta t$:

$$\mathbb{E}[X_j^2] = \int_0^\infty \theta t e^{-t}\,\mathrm{d}t = \theta\Gamma(2) = \theta$$

**Esperanza de $X_j^4$:**

$$\mathbb{E}[X_j^4] = \int_0^\infty x^4 \frac{2x}{\theta} \exp\left(-\frac{x^2}{\theta}\right)\,\mathrm{d}x = \int_0^\infty (\theta t)^2 e^{-t}\,\mathrm{d}t = \theta^2\Gamma(3) = 2\theta^2$$

**Varianza de $X_j^2$:**

$$\mathrm{Var}(X_j^2) = \mathbb{E}[X_j^4] - (\mathbb{E}[X_j^2])^2 = 2\theta^2 - \theta^2 = \theta^2$$

**Momentos del estadístico $T$:**

Dado que $T$ es una suma de variables independientes e idénticamente distribuidas, aplicamos la linealidad de la esperanza y de la varianza:

$$\mathbb{E}[T] = \mathbb{E}\left[\sum_{j=1}^n X_j^2\right] = \sum_{j=1}^n \mathbb{E}[X_j^2] = n\theta$$
$$\mathrm{Var}(T) = \mathrm{Var}\left(\sum_{j=1}^n X_j^2\right) = \sum_{j=1}^n \mathrm{Var}(X_j^2) = n\theta^2$$

**5)** Su $X$ una variable aleatoria con función de densidad:

$$f(x,\theta) = \frac{\theta}{(1+x)^{1+\theta}}\xi_{(0,+\infty)}(x).$$

Obtener la distribución en el muestreo del estadístico:

$$T(X_1, X_2, \dots, X_n) = \frac{\sum_{j=1}^n \ln(1+X_j)}{n}.$$

Obtener su media y su varianza.

1) Transformación de la variable $X_j$

Definimos una nueva variable aleatoria aplicando la transformación sobre $X_j$:

$$Y_j = \ln(1+X_j)$$

Aplicamos el **Teorema de transformación de una variable aleatoria:**

$$y = \varphi(x) = \ln(1+x)$$
$$\varphi^{-1}(y) = e^y - 1$$
$$\frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y)) = e^y$$

Calculamos la función de densidad de la nueva variable $Y_j$:

$$f_Y(y) = f_X(\varphi^{-1}(y))\left|\frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y))\right|$$
$$f_Y(y) = \frac{\theta}{(1+(e^y-1))^{1+\theta}} \cdot e^y = \frac{\theta}{e^{y(1+\theta)}} \cdot e^y = \theta e^{-y\theta}, \quad y > 0$$

2) Media y varianza de la variable transformada $Y_j$

Utilizamos la definición de la función Gamma $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1}e^{-t}\,\mathrm{d}t$ para resolver los momentos.

**Esperanza de $Y_j$:**

$$\mathbb{E}[Y_j] = \int_0^\infty y\theta e^{-\theta}\,\mathrm{d}y$$

Aplicando el cambio de variable $t = \theta y \implies \mathrm{d}t = \theta\,\mathrm{d}y$ y $y = \dfrac{t}{\theta}$:

$$\mathbb{E}[Y_j] = \int_0^\infty \frac{t}{\theta}e^{-t}\,\mathrm{d}t = \frac{1}{\theta}\Gamma(2) = \frac{1}{\theta}$$

**Esperanza de $Y_j^2$:**

$$\mathbb{E}[Y_j^2] = \int_0^\infty y^2\theta e^{-\theta y}\,\mathrm{d}y = \int_0^\infty \left(\frac{t}{\theta}\right)^2 e^{-t}\,\mathrm{d}t = \frac{1}{\theta^2}\Gamma(3) = \frac{2}{\theta^2}$$

**Varianza de $Y_j$:**

$$\mathrm{Var}(Y_j) = \mathbb{E}[Y_j^2] - (\mathbb{E}[Y_j])^2 = \frac{2}{\theta^2} - \frac{1}{\theta^2} = \frac{1}{\theta^2}$$

3) Media y varianza del estadístico $T$

El estadístico $T$ corresponde exactamente a la media muestral de las variables transformadas $Y_j$:

$$T = \frac{1}{n}\sum_{j=1}^n \ln(1+X_j) = \frac{1}{n}\sum_{j=1}^n Y_j = \bar{Y}_n$$

Aplicamos las propiedades de la esperanza y varianza de la media muestral:

$$\mathbb{E}[T] = \mathbb{E}[\bar{Y}_n] = \mathbb{E}[Y_j] = \frac{1}{\theta}$$
$$\mathrm{Var}(T) = \mathrm{Var}(\bar{Y}_n) = \frac{\mathrm{Var}(Y_j)}{n} = \frac{1}{n\theta^2}$$

4) Distribución en el muestreo del estadístico $T$

**Distribución Exacta:**

Aplicamos una segunda transformación $W_j = 2\theta Y_j$:

$$\varphi^{-1}(w) = \frac{w}{2\theta} \implies \frac{\mathrm{d}}{\mathrm{d}w}(\varphi^{-1}(w)) = \frac{1}{2\theta}$$
$$f_W(w) = \theta e^{-\theta(w/(2\theta))}\left|\frac{1}{2\theta}\right| = \frac{1}{2}e^{-w/2}, \quad w > 0$$

Esta función de densidad se corresponde con la de una distribución $\chi^2$ con $p = 2$ grados de libertad. Por lo tanto:

$$W_j \sim \chi_2^2$$

Dado que la suma de $n$ variables independientes $\chi_2^2$ resulta en una distribución $\chi_{2n}^2$:

$$\sum_{j=1}^n W_j = \sum_{j=1}^n 2\theta Y_j = 2\theta n\left(\frac{\sum_{j=1}^n Y_j}{n}\right) = 2n\theta T$$
$$2n\theta T \sim \chi_{2n}^2$$

**Distribución Aproximada (Teorema Central del Límite):**

Si el tamño de la muestra es suficientemente grande ($n \geq 30$), podemos aproximar la distribución de la media muestral $T = \bar{Y}_n$:

$$T \sim \mathcal{N}\left(\frac{1}{\theta}, \frac{1}{n\theta^2}\right) \text{ aproximadamente.}$$

**6)** Sea $X$ una variable aleatoria con función de densidad en todo $\mathbb{R}$:

$$f(x,\theta) = \exp(-(x-\theta))\exp(-\exp(-(x-\theta))).$$

Obtener la distribución en el muestreo del estadístico:

$$T(X_1, X_2, \dots, X_n) = \frac{\sum_{j=1}^{n} \exp(-X_j)}{n}.$$

Obtener su media y su varianza.

1) Transformación de la variable $X_j$

Definimos una nueva variable aleatoria aplicando la transformación sobre $X_j$ presente en el estadístico:

$$Y_j = \exp(-X_j)$$

Aplicamos el **Teorema de transformación de una variable aleatoria**:

$$\begin{gathered} y = \varphi(x) = \exp(-x) \\ \varphi^{-1}(y) = -\ln(y) \\ \frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y)) = -\frac{1}{y} \end{gathered}$$

Calculamos la función de densidad de la nueva variable $Y_j$:

$$\begin{gathered} f_Y(y) = f_X(\varphi^{-1}(y))\left|\frac{\mathrm{d}}{\mathrm{d}y}(\varphi^{-1}(y))\right| \\ f_Y(y) = \exp(-(-\ln(y)-\theta))\exp(-\exp(-(-\ln(y)-\theta)))\left|-\frac{1}{y}\right| \end{gathered}$$

Simplificando los exponentes:

$$\begin{gathered} -(-\ln(y)-\theta) = \ln(y)+\theta \\ \exp(\ln(y)+\theta) = \exp(\ln(y))\cdot\exp(\theta) = y\cdot e^{\theta} \end{gathered}$$

Sustituyendo en la densidad:

$$f_Y(y) = (ye^{\theta})\exp(-ye^{\theta})\cdot\frac{1}{y} = e^{\theta}\exp(-ye^{\theta}), \quad y>0$$

2) Media y varianza de la variable transformada $Y_j$

La densidad $f_Y(y)$ corresponde a una distribución Exponencial con parámetro $\lambda = e^{\theta}$. Calculamos sus momentos usando la función Gamma $\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1}e^{-t}\,\mathrm{d}t$.

**Esperanza de $Y_j$:**

$$\mathbb{E}[Y_j] = \int_0^{\infty} ye^{\theta}\exp(-ye^{\theta})\,\mathrm{d}y$$

Cambio de variable $t = ye^{\theta} \implies \mathrm{d}t = e^{\theta}\,\mathrm{d}y$ y $y = \frac{t}{e^{\theta}}$:

$$\mathbb{E}[Y_j] = \int_0^{\infty} \frac{t}{e^{\theta}}e^{-t}\,\mathrm{d}t = \frac{1}{e^{\theta}}\Gamma(2) = e^{-\theta}$$

**Esperanza de $Y_j^2$:**

$$\mathbb{E}[Y_j^2] = \int_0^{\infty} y^2e^{\theta}\exp(-ye^{\theta})\,\mathrm{d}y = \int_0^{\infty}\left(\frac{t}{e^{\theta}}\right)^2 e^{-t}\,\mathrm{d}t = \frac{1}{e^{2\theta}}\Gamma(3) = 2e^{-2\theta}$$

**Varianza de $Y_j$:**

$$\mathrm{Var}(Y_j) = \mathbb{E}[Y_j^2] - (\mathbb{E}[Y_j])^2 = 2e^{-2\theta} - (e^{-\theta})^2 = e^{-2\theta}$$

3) Media y varianza del estadístico $T$

El estadístico $T$ es la media muestral de las variables transformadas $Y_j$:

$$T = \frac{1}{n}\sum_{j=1}^{n}\exp(-X_j) = \frac{1}{n}\sum_{j=1}^{n} Y_j = \bar{Y}_n$$

Aplicamos las propiedades de la media muestral para la esperanza y la varianza:

$$\mathbb{E}[T] = \mathbb{E}[\bar{Y}_n] = \mathbb{E}[Y_j] = e^{-\theta}$$
$$\mathrm{Var}(T) = \mathrm{Var}(\bar{Y}_n) = \frac{\mathrm{Var}(Y_j)}{n} = \frac{e^{-2\theta}}{n}$$

4) Distribución en el muestreo del estadístico $T$

**Distribución Exacta:**

Aplicamos un nueva transformación lineal $W_j = 2e^{\theta}Y_j$:

$$\varphi^{-1}(w) = \frac{w}{2e^{\theta}} \implies \frac{\mathrm{d}}{\mathrm{d}w}(\varphi^{-1}(w)) = \frac{1}{2e^{\theta}}$$
$$f_W(w) = e^{\theta}\exp\left(-\frac{w}{2e^{\theta}e^{\theta}}\right)\left|\frac{1}{2e^{\theta}}\right| = \frac{1}{2}\exp\left(-\frac{w}{2}\right), \quad w > 0$$

Esta función coincide con la densidad de una $\chi^2$ con $p = 2$ grados de libertad. Así:

$$W_j \sim \chi^2_2$$

Por la caracterización de la $\chi^2$, la suma de $n$ variables $\chi^2_2$ independientes sigue una distribución $\chi^2_{2n}$:

$$\sum_{j=1}^{n} W_j = \sum_{j=1}^{n} 2e^{\theta}Y_j = 2ne^{\theta}\left(\frac{\sum_{j=1}^{n} Y_j}{n}\right) = 2ne^{\theta}T$$
$$2ne^{\theta}T \sim \chi^2_{2n}$$

**Distribución Aproximada (Teorema Central del Límite):**

Para muestras suficientemente grandes ($n \geq 30$), la distribución del estadístico $T = \bar{Y}_n$ se aproxima mediante una Normal:

$$T \sim \mathcal{N}\left(e^{-\theta}, \frac{e^{-2\theta}}{n}\right) \text{ aproximadamente.}$$

**7)** Sea $X_1, X_2, \dots, X_n$ una m.a.s. de una variable $X$ con distribución $N(\mu, \sigma^2)$. Sean $\bar{X}$ y $S^2$ su media y cuasi-varianzas muestrales, respectivamente. Sea $X_{n+1}$ una nueva observación de $X$ independiente de $X_1, X_2, \dots, X_n$. Obtener la distribución en el muestreo del estadístico:

$$\frac{X_{n+1} - \bar{X}}{S}\sqrt{\frac{n}{n+1}}.$$

1) Distribución del numerador

Sabemos que una observación individual $X_{n+1}$ y la media muestral $\bar{X}$ siguen distribuciones normales:

$$X_{n+1} \sim \mathcal{N}(\mu, \sigma^2)$$
$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Dado que $X_{n+1}$ es una nueva observación independiente de la muestra $(X_1, \dots, X_n)$, es independente de $\bar{X}$. La diferencia de dos variables normales independientes también es normal. Calculamos su esperanza y varianza:

$$\mathbb{E}[X_{n+1} - \bar{X}] = \mathbb{E}[X_{n+1}] - \mathbb{E}[\bar{X}] = \mu - \mu = 0$$
$$\mathrm{Var}\left(X_{n-1} - \bar{X}\right) = \mathrm{Var}(X_{n+1}) + \mathrm{Var}(\bar{X})\sigma^2 + \frac{\sigma^2}{n} = \sigma^2\left(1 + \frac{1}{n}\right) = \sigma^2\left(\frac{n+1}{n}\right)$$

Por tanto, la distribución de la diferencia es:

$$X_{n+1} - \bar{X} \sim \mathcal{N}\left(0, \sigma^2\frac{n+1}{n}\right)$$

Estandarizando esta variable, obtenemos una normal estándar $Z$:

$$Z = \frac{X_{n+1} - \bar{X}}{\sigma\sqrt{\frac{n+1}{n}}} \sim \mathcal{N}(0, 1)$$

2) Distribución del denominador

Por el **Teorema de Fisher**, sabemos que para una m.a.s. de una distribución normal, la cuasi-varianza muestral $S^2$ multiplicada por sus grados de libertad y dividida por la varianza poblacional sigue una distribución $\chi^2$:

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

Además, el Teorema de Fisher garantiza que $\bar{X}$ y $S^2$ son independientes. Como $X_{n+1}$ también es independiente de la muestra original, garantizamos que las variables $Z$ y $U$ son totalmente independientes.

3) Caracterización del estadístico

El documento define la **caracterización de la t de Student como cociente:** Si $Z \sim \mathcal{N}(0,1$ y $U \sim \chi^2_p$ son independientes, el cociente

$$T = \frac{Z}{\sqrt{U/p}} \sim t_p$$

Aplicamos esta definición sustituyendo nuestra $Z$ y nuestra $U$ (con $p = n-1$ grados de libertad):

$$T = \frac{\frac{X_{n+1}}{\sigma\sqrt{\frac{n+1}{n}}}}{\sqrt{\frac{\frac{(n-1)S^2}{\sigma^2}}{n-1}}}$$

Simplificando el denominador cancelando los grados de libertad $(n-1)$:

$$T = \frac{\frac{X_{n+1}-\bar{X}}{\sigma\sqrt{\frac{n+1}{n}}}}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{\frac{X_{n+1}-\bar{X}}{\sigma\sqrt{\frac{n+1}{n}}}}{\frac{S}{\sigma}}$$

Cancelamos la desviación típica poblacional $\sigma$:

$$T = \frac{X_{n+1}-\bar{X}}{S\sqrt{\frac{n+1}{n}}} = \frac{X_{n+1}-\bar{X}}{S}\sqrt{\frac{n}{n+1}}$$

**Conclusión**

A través de la definición matemática del cociente, hemos llegado exactamente a la expresión del estadístico planteado en el problema. Por lo tanto, la distribución en el muestreo de este estadístico es una **distribución t de Student con $n-1$ grados de libertad:**

$$\frac{X_{n+1}-\bar{X}}{S}\sqrt{\frac{n}{n++1}} \sim t_{n-1}$$

**8)** Sean $X_1, X_2, \dots, X_{n_1}$ e $Y_1, Y_2, \dots, Y_{n_2}$ muestrales aleatorias simples independientes de dos poblaciones $X \sim N(\mu_1, \sigma^2)$ e $Y \sim N(\mu_2, \sigma^2)$, respectivamente. Obtener la distribución en el muestreo del estadístico:

$$\frac{\alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\sqrt{\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}}},$$

siendo $\alpha$ y $\beta$ dos números reales fijos.

1) Distribución del Numerador

Sea la combinación lineal $W = \alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)$.

Por el **Teorema de Fisher**, sabemos que $\bar{X} \sim \mathcal{N}(\mu_1, \sigma^2/n_1)$ y $\bar{Y} \sim \mathcal{N}(\mu_2, \sigma^2/n_2)$. Al provenir de muestras aleatorias independientes, $\bar{X}$ e $\bar{Y}$ son variables normales independientes. Calculamos los momentos de $W$:

$$\mathbb{E}[W] = \alpha(\mathbb{E}[\bar{X}]-\mu_1)+\beta(\mathbb{E}[\bar{Y}]-\mu_2) = \alpha(\mu_1-\mu_1)+\beta(\mu_2-\mu_2) = 0$$
$$\mathrm{Var}(W) = \alpha^2\mathrm{Var}(\bar{X})+\beta^2\mathrm{Var}(\bar{Y}) = \alpha^2\left(\frac{\sigma^2}{n_1}\right)+\beta^2\left(\frac{\sigma^2}{n_2}\right) = \sigma^2\left(\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}\right)$$

Al ser una combinación lineal de normales, $W$ sigue una distribución normal. Si la estandarizamos, obtenemos una variable normal estándar $Z$:

$$Z = \frac{W}{\sqrt{\mathrm{Var}(W)}} = \frac{\alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)}{\sigma\sqrt{\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}}} \sim \mathcal{N}(0,1)$$

2) Distribución del Denominador

Aplicamos nuevamente el Teorema de Fisher, el cual define la distribución de las varianzas muestrales de poblaciones normales:

$$U_1 = \frac{(n_1-1)S_1^2}{\sigma^2} \sim \chi^2_{n_1-1}$$
$$U_2 = \frac{(n_2-1)S_2^2}{\sigma^2} \sim \chi^2_{n_2-1}$$

Dado que las dos muestras son independientes, las variables $U_1$ y $U_2$ también lo son. Basándonos en la caracterización de la $\chi^2$ como una suma de variables normales estándar independientes al cuadrado, la suma de dos distribuciones $\chi^2$ independientes genera una nueva distribución $\chi^2$ con la suma de sus grados de libertad:

$$U = U_1 + U_2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{\sigma^2} \sim \chi^2_{n_1+n_2-2}$$

Adicionalmente, el Teorema de Fisher establece que las medias muestrales $(\bar{X}, \bar{Y})$ y las varianzas muestrales $(S_1^2, S_2^2)$ son mutuamente independientes, asegurando que nuestra variable $Z$ y nuestra variable $U$ sean independientes.

3) Caracterización del Estadístico Final

El documento define la caracterización de la **distribución t de Student como cociente:** Si $Z \sim \mathcal{N}(0,1)$ y $U \sim \chi^2_p$ son independientes, entonces:

$$T = \frac{Z}{\sqrt{U/p}} \sim t_p$$

Sustituyendo nuestras variables calculadas $Z, U$ y tomando $p = n_1 + n_2 - 2$ grados de libertad:

$$T = \frac{\frac{\alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)}{\sigma\sqrt{\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}}}}{\sqrt{\frac{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{\sigma^2}}{n_1+n_2-2}}}$$

El término $\sigma$ en el denominador de la fracción superior se cancela matemáticamente con la constante $\sqrt{1/\sigma^2} = 1/\sigma$ que se factoriza del denominador inferior:

$$T = \frac{\alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)}{\sqrt{\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}}\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}}$$

Agrupando el denominador para que coincida con el enunciado original, demostramos formalmente que la distribución en el muestreo de este estadístico es una **t de Student con $n_1 + n_2 - 2$ grados de libertad:**

$$\frac{\alpha(\bar{X}-\mu_1)+\beta(\bar{Y}-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\sqrt{\frac{\alpha^2}{n_1}+\frac{\beta^2}{n_2}}} \sim t_{n_1+n_2-2}$$

**9)** Una empresa de agua produce botellas que deberían contener 300ml pero que presentan en la práctica una variabilidad modelada por una distribución Normal con media $\mu = 298ml$ y desviación típica $\sigma = 3ml$.

**a)** ¿Cuál es la probabilidad de que una botella elegida al azar de la producción contenga menos de 295 ml?

Buscamos calcular $P(X < 295)$. Aplicamos la transformación de estandarización para convertir la variable a una Normal Estándar $Z \sim \mathcal{N}(0,1)$:

$$Z = \frac{X-\mu}{\sigma}$$

Sustituyendo los valores:

$$Z = \frac{295-298}{3} = \frac{-3}{3} = -1$$

Por lo tanto, la probabilidad pedida es:

$$P(X < 295) = P(Z < -1) \approx 0.1587$$

**b)** ¿Cuál es la probabilidad de que el contenido medio de un paquete de seis botellassea inferior a 295 ml?

Sea una muestra aleatoria simple de tamaño $n = 6$. Buscamos calcular la probabilidad sobre la media muestra: $P(\bar{X}_6 < 295)$.

Por el **Teorema de Fisher**, dado que la población original es Normal, la distribución exacta de la media muestral viene dada por:

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$
$$\bar{X}_6 \sim \mathcal{N}\left(298, \frac{9}{6}\right) \implies \bar{X}_6 \sim \mathcal{N}(298, 1.5)$$

Aplicamos la estandarización del estadístico media muestral definida en el mismo teorema:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Sustituyendo para nuestro umbral de 295 ml:

$$Z = \frac{295 - 298}{3/\sqrt{6}} = \frac{-3}{3/\sqrt{6}} = -\sqrt{6} \approx -2.449$$

Por lo tanto, la probabilidad de la media muestral es:

$$P(\bar{X}_6 < 295) = P(Z < -2.449) \approx 0.0071$$

**10)** Se realiza una medición de peso en un laboratorio, sabiendo que la desviación típica de las mediciones es $\sigma = 10mg$. La medición se repite 3 veces, se calcula la media $\bar{x}$, y este es el resultado proporcionado como estimación del peso.

**a)** ¿Cuál es la desviación típica del resultado calculado?

El "resultado calculado" corresponde a la media muestral $\bar{X}$. La varianza muestral es $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$.

Por lo tanto, la desviación típica de la media muestral (dispersión de la distribución muestral) se expresa como:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \implies \sigma_{\bar{X}} = \frac{10}{\sqrt{3}} \approx 5.77\text{mg}$$

**b)** ¿Cuántas veces se debe repetir la medición para que la desviación típica del valor medio se reduzca a 5?

Se nos pide encontrar el tamaño de muestra $n$ que garantice una desviación típica de la media muestra $\sigma_{\bar{X}} = 5$.

Utilizando la misma ecuación matemática:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

Sustituimos la nueva condición ($\sigma_{\bar{X}} = 5$) y la desviación típica población conocida como ($\sigma = 10$):

$$5 = \frac{10}{\sqrt{n}} \implies \sqrt{n} = \frac{10}{5} = 2 \implies n = 2^2 = 4$$

Se debe repetir la medición **4 veces**.

**11)** El resultado de una encuesta fue que el 59% de la población opina que el contexto económico es bueno o muy bueno. Supongamos que, extrapolando al conjunto de la población, efectivamente la proporción de todos los españoles que piensan que la situación es buena o muy buena es del 0.59.

**a)** Sabemos que las encuestas incluyen márgenes de error que son aproximadamente $\pm 3$ puntos. ¿Cuál es la probabilidad de que una muestra aleatoria de 300 españoles presente una proporción muestral que caiga dentro del intervalo de $0.59 \pm 0.03$?

Calculamos la desviación típica del estadístico para $n = 300$:

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.59(1-0.59)}{300}} = \sqrt{\frac{0.2419}{300}} \approx 0.0284$$

Se nos pide la probabilidad de que $\hat{p}$ caiga en el intervalo $0.59 \pm 0.03$, es decir, buscamos $P(0.56 \leq \hat{p} \leq 0.62)$ o de forma equivalente $P(-0.03 \leq \hat{p} - p \leq 0.03)$.

Estandarizando:

$$P\left(\frac{-0.03}{0.0284} \leq Z \leq \frac{0.03}{0.0284}\right) \approx P(-1.056 \leq Z \leq 1.056) = P(Z \leq 1.056) - (1 - P(Z \leq 1.056)) \approx 0.8545 - (1 - 0.8545) \approx 0$$

**b)** Contesta a la pregunta anterior en el caso en que la muestra consta de 600 personas y cuando la muestra consta de 1200 personas. ¿Cuál es el efecto de aumentar el tamaño de la muestra?

Cálculo para $n = 600$:

$$\sigma_{\hat{p}} = \sqrt{\frac{0.2419}{600}} \approx 0.02008$$
$$P\left(\frac{-0.03}{0.02008} \leq Z \leq \frac{0.03}{0.02008}\right) \approx P(-1.494 \leq Z \leq 1.494)$$
$$P(-1.494 \leq Z \leq 1.494) \approx 0.9324 - (1 - 0.9324) \approx 0.865$$

Cálculo para $n = 1200$:

$$\sigma_{\hat{p}} = \sqrt{\frac{0.2419}{1200}} \approx 0.0142$$
$$P\left(\frac{-0.03}{0.0142} \leq Z \leq \frac{0.03}{0.0142}\right) \approx P(-2.113 \leq Z \leq 2.113)$$
$$P(-2.113 \leq Z \leq 2.113) \approx 0.9827 - (1 - 0.9827) \approx 0.965$$

**Efecto de aumentar el tamaño de la muestra:**

Matemáticamente, la varianza de la media/proporción muestral es inversamente proporcional al tamaño de la muestra $n$, siendo $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$. La dispersión de la distribución muestral se reduce en un factor de $\sqrt{n}$. Al hacer $n$ cada vez más grande, la campana de Gauss de la distribución se hace mucho más estrecha y concentrada alrededor del verdadero valor $p = 0.59$.

Por lo tanto, el efecto directo de aumentar el tamaño muestral es que **incrementa significativamente la probabilidad (la confianza)** de que nuestra estimación caiga dentro de un mismo margen de error de $\pm 3$ puntos (pasando del $\approx 71\%$ con 300 personas, al $\approx 96.5\%$ con 1200 personas).

**12)** Un aparato de medición es exacto (el valor proporcionado medio es el valor auténtico de la señal) y la desviación típica del valor medido es 0.1 unidades. La distribución del valor medido es aproximadamente normal. ¿Cuál es la probabilidad de que el valor de una medición se aleje de la señal auténtica en más de 0.1 unidades? ¿Y si se repite la medición 5 veces y se toma la media de los 5 valores obtenidos?

1) Probabilidad para una única medición

Se pide calcular la probabilidad de que una medición se aleje del valor auténtico en más de 0.1 unidades:

$$P(|X - \mu| > 0.1)$$

Aplicamos la estandarización para convertir $X$ en una variable Normal Estándar $Z \sim \mathcal{N}(0, 1)$:

$$Z = \frac{X - \mu}{\sigma}$$

Sustituyendo $\sigma = 0.1$:

$$P\left(\left|\frac{X - \mu}{0.1}\right| > \frac{0.1}{0.1}\right) = P(|Z| > 1)$$

Desarrollando el valor absoluto por la simetría de la distribución Normal:

$$P(|Z| > 1) = P(Z < -1) + P(Z > 1) = 2 \cdot P(Z < -1) \approx 2 \cdot 0.1587 = 0.3174$$

2) Probabilidad para la media de 5 mediciones

Ahora consideramos una muestra aleatoria simple de tamaño $n = 5$. El estadístico es la media muestral $\bar{X}$.

Dado que la población original es Normal, aplicamos el **Teorema de Fisher**, el cual establece que la media muestral se distribuye exactamente como:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

La nueva desviación típica de la media muestral será:

$$\sigma_{\bar{X}} = \frac{0.1}{\sqrt{5}} \approx 0.0447$$

Se pide calcular la probabilidad de que le media se aleje del valor auténtico es más de 0.1 unidades:

$$P(|\bar{X} - \mu| > 0.1)$$

Estandarizando el estadístico $\bar{X}$ según el Teorema de Fisher:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

Sustituyendo los valores:

$$P\left(\left|\frac{\bar{X} - \mu}{0.1/\sqrt{5}}\right| > \frac{0.1}{0.1/\sqrt{5}}\right) = P(|Z| > \sqrt{5}) = P(|Z| > 2.236) = 2 \cdot P(Z < -2.236) \approx 2 \cdot 0.0127 = 0.0254$$

**13)** En condiciones normales, una máquina produce piezas con una tasa de defectuosas del 1%. Para controlar que la máquina sigue bien ajustada, se escogen al azar cada día 100 piezas en la producción y se le somete a un test. ¿Cuál es la probabilidad de que, si la máquina está bien ajustadam haya, en una de esas muestras, más del 2% de piezas defectuosas? Si un día, 3 piezas resultan defectuosas, ¿cuáles son las conclusiones que sacaríamos sobre el funcionamiento de la máquina?

a) ¿Cuál es la probabilidad de que haya más del 2% de piezas defectuosas?

Buscamos la probabilidad $P(\hat{p} > 0.02)$.

Dado que $n = 100$, esto equivale a tener más de 2 piezas defectuosas en la muestra:

$$P(\hat{p} > 0.02) = P\left(\frac{N}{100} > 0.02\right) = P(N > 2)$$

Para un experimento simple dicotómico repetido $n$ veces, la distribución de $N$ es exactamente una distribución Binomical: $N \sim \mathcal{B}(n, p)$.

Calculamos la probabilidad exacta:

$$P(N > 2) = 1 - P(N \leq 2) = 1 - [P(N = 0) + P(N = 1) + P(N = 2)]$$

Sabiendo que $P(N = k) = \binom{n}{k} p^k (1-p)^{n-k}$, sustituimos $n = 100$ y $p = 0.01$:

- $P(N = 0) = \binom{100}{0} (0.01)^0 (0.99)^{100} \approx 0.366$
- $P(N = 1) = \binom{100}{1} (0.01)^1 (0.99)^{99} \approx 0.3697$
- $P(N = 2) = \binom{100}{2} (0.01)^2 (0.99)^{98} \approx 0.1847$

Sumamos las probabilidades acumuladas:

$$P(N \leq 2) \approx 0.3360 + 0.3697 + 0.1847 = 0.9204$$

Por lo tanto, la probabilidad de encontrar más del 2% de piezas defectuosas es:

$$P(\hat{p} > 0.02) = 1 - 0.9204 = 0.0796$$

b) Si un día 3 piezas resultan defectuosas, ¿qué concluimos?

Observar 3 piezas defectuosas en una muestra de 100 corresponde a una proporción muestral observada $\hat{p} = 0.03$.

Matemáticamente, la probabilidad de observar un resultado de 3 piezas defectuosas o más extremo ($N \geq 3$), asumiendo que la máquina sigue bien ajustada ($p = 0.01$), es el valor calculado en el apartado anterior:

$$P(N \geq 3) = P(N > 2) \approx 0.0796$$

**Conclusión analítica:**

La probabilidad de que ocurra este evento puramente por la aleatoriedad del muestreo es de aproximadamente un 7.96%. En inferencia estadística, este valor no suele ser suficientemente pequeño (usualmente no está por dejado de los niveles de riesgo habituales del 5% o 1%) como para representar una anomalía extrema.

Por tanto, aunque la tasa observada triplica la teórica, **no hay evidencia estadística concluyente** para descartar que se deba a la propia variabilidad de la muestra. Basándonos estrictamente en este cálculo probabilístico, no rechazaríamos la premisa de que la máquina sigue ajustada bajo sus parámetros normales.

# 2 Estimación

## 2.1 Introducción

- Hemos modelizado un experimento con una variable aleatoria $X$.
- La estimación hace referencia al proceso de conseguir información sobre la distribución de $X$ a partir de los valores de una muestra, aproximando valores asociados a la distribución mediante el valor de un estadístico en un muestra concreta.

**Dos situaciones**

- Nuestro modelo supone que la distribución de $X$ pertenece a una familia paramétrica de distribuciones: tienen una determinada forma con unos parámetros variables.
  - Buscamos información sobre el valor de los parámetro. Estimación paramétrica.
- No limitamos la familia de distribuciones a la que pertenece nuestro modelo.
  - Buscamos información sobre la distribución en sí (función de distribución, de densidad o función de probabilidad). Estimación no paramétrica.
- A lo largo de las prácticas veremos también la estimación de parámetros que no necesitan de una familia paramétrica, como es el caso de la mediana.

## 2.2 Ejemplos de estimación paramétrica

**Sondeo sobre intención de participación en unas elecciones**

- Queremos estimar la tasa de participación antes de unas elecciones generales.
- Formulamos un modelo: experimento: "escoger una persona al azar en el censo". $X$: variable dicotómica ("Sí" o "No"). $p = P(X = \text{Si})$.
- El modelo pertenece a la familia paramétrica de Bernoulli.

**Determinación de la concrentación de un producto**

- Quiero determinar la concentración.
- Formulo el modelo: experimento="llevar a cabo una medición". $X$: "valor proporcionado por el aparato". $X \sim \mathcal{N}(\mu, \sigma^2)$.
- El modelo pertenece a la familia paramétrica de las distribuciones normales.

## 2.3 Estimación paramétrica: estimación puntual

**Ingredientes del modelo**

- Experimento aleatorio
- Variable aleatoria $X$ con una distribución $f$ que pertenece a una familia paramétrica $\{f_\theta, \theta \in \Theta\}$.
- Disponemos de una muestra de la distribución de $X$.

**Definición 2.3.1** *Cualquier estadístico diseñado para aproximar el valor de un parámetro $\theta$ del modelo, se llama estimador puntual del parámetro $\theta$.*

**Ejemplos de estimadores paramétricos**

| $\theta$ | **Estimador** |
|---|---|
| $\mu$ | $\bar{X}$, media muestral |
| $\sigma^2$ | $S^2$, varianza muestral |
| $p$ | $\hat{p}$, proporción muestral |

**A tener en cuenta:**

- Un estimador es un variable aleatoria, su valor depende de la muestra concreta escogida.
- Para controlar bondad de nuestra estimación, nos basaremos en el estudio de la distribución del estimador.

## 2.4 Métodos de contrucción de estimadores

Para $\mu, \sigma^2$ o $p$, es fácil pensar en estimadores naturales, pero para modelos o parámetros más sofisticados, vamos a ver métodos generales.

**Veremos dos métodos en este tema:**

- El método de los momentos.
- El método de la máxima verosimilitud.

## 2.5 Método de los momentos

**Contexto**

- Experimento con una variable aleatoria $X$, suponemos $f_X \in \{x \mapsto f_\theta(x), \theta \in \Theta\}$.
- El parámetro $\theta$ tiene dimensión $p$.
- Consideramos una muestra aleatoria simple $X_1, X_2, \dots, X_n$ de $X$.

Si $\theta$ tiene dimensión $p$, igualamos los $p$ primeros momentos de $f_\theta$ con los equivalentes muestrales.

Sea $\mu_k(\theta)$ el momento de orden $k$ de la distribución $f_{\theta,\mu_k} = E[X^k]$. Resolvemos:

$$\begin{aligned} \mu_1(\theta) &= \overline{X}, \\ \mu_2(\theta) &= \overline{X^2}, \\ &\vdots \\ \mu_p(\theta) &= \overline{X^p}. \end{aligned}$$

**Ejemplos**

**Calculad los estimadores usando el método de los momentos en los dos casos:**

- Modelo normal: $X \sim \mathcal{N}(\mu, \sigma^2)$, donde $\theta = (\mu, \sigma^2)$.

$$\begin{array}{ll} X \rightsquigarrow \mathcal{N}(\mu, \sigma^2) & \mu = E[X] \\ \theta = (\mu, \sigma^2), \quad p = 2 & \sigma^2 = \mathrm{Var}[X] = E[X^2] - (E[X])^2 \to E[X^2] = \sigma^2 + \mu^2 \\ \mu_1(\theta) = E[X] = \overline{x} & \hat{\mu} = \overline{x} \\ \mu_2(\theta) = E[X^2] = \overline{x^2} & \hat{\sigma}^2 = \overline{x^2} - (\overline{x})^2 \end{array}$$

- Modelo de Bernoulli: $X \sim \mathrm{Bernoulli}(p)$, donde desconocemos $p$.

$$\begin{array}{l} X \rightsquigarrow \mathrm{Bernoulli}(p), \quad 0 < p < 1 \\ \theta = p \\ \mu(\theta) = E[X] = \bar{x} = p \\ \hat{p} = \bar{x} \text{ (proporción muestral)} \end{array}$$

## 2.6 Método de máxima verosimilitud

- El método más utilziado de construcción de un estimador puntual.
- Se basa en lo que se conoce como función de verosimilitud.

**Definición 2.6.1**

- *Sea $X$ una variable aleatoria, con distribución $x \mapsto f_X(x;\theta)$ (función de densidad o función puntual de probabilidad), donde $\theta$ es de dimensión $p : \theta \in \Theta \subset \mathbb{R}^p$.*
- *Para un valor concreto de una muestra aleatoria simple $(X_1, \dots, X_n)$, que denotamos por $(x_1, \dots, x_n)$, consideramos la función de $\theta$:*

$$L_n : \begin{cases} \Theta \subset \mathbb{R}^p \to \mathbb{R}^+ \\ \theta \mapsto L_n(\theta) = f_{X_1,\dots,X_n}(x_1, \dots, x_n; \theta) = \displaystyle\prod_{i=1}^n f_X(x_i;\theta). \end{cases}$$

- *La función $L_n$ es la función de verosimilitud. Nos dice lo creíbles (verosímiles) que son las observaciones para ese valor del parámetro.*

**Ejemplo de cálculo de la verosimilitud**

- Tiramos 10 veces una moneda (1 es cara, 0 es cruz), y obtenemos: 0,0,1,0,1,1,1,1,1,1.
- La verosimilitud asocia a cada $p$ el valor de

$$\Pr(X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1, X_7 = 1, X_8 = 1, X_9 = 1, X_{10} = 1),$$

por lo que

$$L_n(p) = (1-p)(1-p)p(1-p)p^6 = (1-p)^3 \cdot p^7.$$

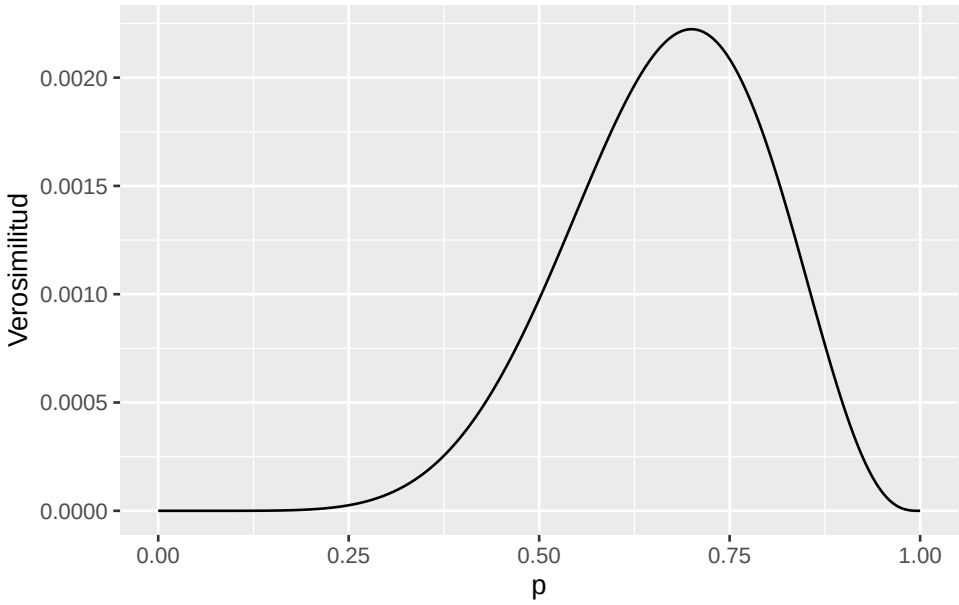


## 2.7 Estimador de máxima verosimilitud

**Definición 2.7.1** *El estimador de máxima verosimilitud $\hat{\theta}$ de $\theta$ es cualquier valor de $\theta$ que maximiza $\theta \mapsto L_n(\theta)$, es decir,*

$$\hat{\theta} \text{argmax}_{\theta \in \Theta} L_n(\theta).$$

**Nota**

- La maximización se realiza sobre todos los valores admisibles para el parámetro $\theta$.
- Podría haber de un máximo.

**Estimación de la proporción**

Retomamos el ejemplo de las 10 monedas:

$$p \mapsto L_n(p) = (1-p)(1-p)p(1-p)p^6 = (1-p)^3 \cdot p^7.$$

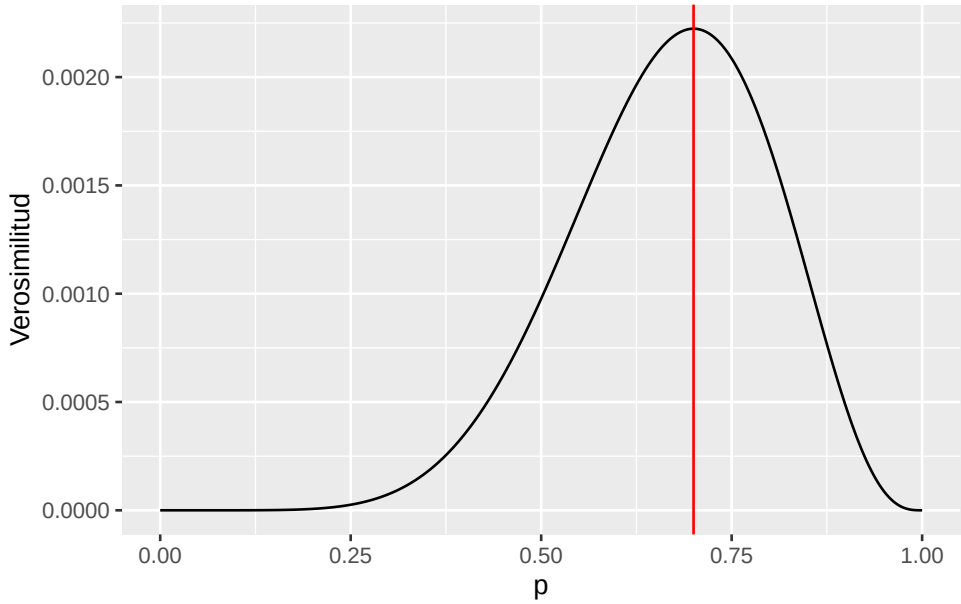


Figure 3: Verosimilitud correspondiente al ejemplo de 10 tiradas de una moneda.

**Ejemplos**

**!** Ejemplos de estimación por máxima verosimilitud

Calculad los estimadores usando el método de máxima verosimilitud en los dos casos:
- $X \sim \text{Bernoulli}(p)$, donde desconocemos $p$.
- $X \sim \mathcal{N}(\mu, \sigma^2)$, donde desconocemos $\theta = (\mu, \sigma^2)$.

- En el primer caso anterior, calcular la distribución de Bernoulli, donde desconocemos $p$.

$X \rightsquigarrow \text{Bernoulli}(p), \quad 0 < p < 1$

$(X_1, \dots, X_N)$ m.a.s. de tamaño $n$

$$L_n(\theta) = f_{X_1,\dots,X_n}(x_1, \dots, x_n; \theta) = \prod_{i=1}^{n} f_X(x_i; \theta)$$

$$L_n(p) = \prod_{i=1}^{n} f_X(x_i; p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}$$

$$\ell(p) = \log L_n(p) = \log p^{\sum_i x_i} + \log(1-p)^{n-\sum_{i=1}^n x_i} = \left(\sum_i x_i\right) \cdot \log p + \left(n - \sum_{i=1}^n x_i\right) \cdot \log(1-p)$$

$$\frac{\partial \ell(p)}{\partial p} = \left(\sum_{i=1}^n x_i\right) \cdot \frac{1}{p} + \left(n - \sum_{i=1}^n x_i\right) \cdot \left(-\frac{1}{1-p}\right) = (1-p) \cdot \sum_{i=1}^n x_i - \left(n - \sum_{i=1}^n x_i\right) \cdot p$$

$$= \sum_{i=1}^n x_i - \cancel{p \cdot \sum_{i=1}^n x_i} - np + \cancel{p \cdot \sum_{i=1}^n x_i} = 0 \implies \boxed{\hat{p} = \frac{1}{n}\sum_{i=1}^n x_i = \bar{x}}$$

- En el segundo caso anterior, calculad la esperanza del estimador de máxima verosimilitud de $\sigma^2$.

La función de denisdad de una variable aleatoria $X$ con distribución normal es:

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Si tenemos una muestra de tamaño $n$, es decir, $X_1, X_2, \dots, X_n$ que son observaciones independientes y distribuidas como $\mathcal{N}(\mu, \sigma^2)$, entonces la función de verosimilitud $L(\mu, \sigma^2)$ es el producto de las funciones de densidad de cada observación

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i|\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$$

Para simplificar los cálculos, se toma el logaritmo de la función de verosimilitud, lo que da la función de log-verosimilitud $\ell(\mu, \sigma^2)$:

$$\begin{aligned}
\ell(\mu, \sigma^2) = \log L(\mu, \sigma^2) &= \sum_{i=1}^{n} \log\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) + \sum_{i=1}^{n} \log\left(\exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)\right) \\
&= \sum_{i=1}^{n} \log\left((2\pi\sigma^2)^{-\frac{1}{2}}\right) + \sum_{i=1}^{n} -\frac{(x_i-\mu)^2}{2\sigma^2} = \sum_{i=1}^{n} -\frac{1}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 \\
&= -\frac{n}{2}\cdot\log(2\pi) - \frac{n}{2}\cdot\log(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2
\end{aligned}$$

Para encontrar los estimadores de máxima verosimilitud, derivamos $\ell(\mu, \sigma^2)$ con respecto a $\mu$ y $\sigma^2$, e igualamos a cero:

$$\begin{aligned}
\frac{\partial \ell(\mu,\sigma^2)}{\partial \mu} &= \frac{\cancel{2}}{\cancel{2}\sigma^2}\sum_{i=1}^{n}(x_i-\mu) = 0 \to \sum_{i=1}^{n}(x_i-\mu) = 0 \to \boxed{\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}} \\
\frac{\partial \ell(\mu,\sigma^2)}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(x_i-\mu)^2 = 0 \to -n\sigma^2 + \sum_{i=1}^{n}(x_i-\mu)^2 = 0 \to \boxed{\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\hat{\mu})^2}
\end{aligned}$$

## 2.8 Métodos para evaluar un estimador

**Recordar**

- Un estimador es una variable aleatoria.
- Es valioso disponer de conocimiento sobre la distribución del estimador (su distribución en el muestreo) $\implies$ permite manejar el riesgo y el error que podemos cometer al aproxima $\theta$ por $\hat{\theta}$ asociado.

**Consideramos dos aspectos de la distribución muestral de $\hat{\theta}$**

- Su localización: sesgo.
- Su variabilidad: error cuadrático medio.
- Mencionaremos su comportamiento cuando $n \to \infty$.

## 2.9 Sesgo

**Definición 2.9.1** *Consideramos para un estimador $\hat{\theta}$ de un parámetro $\theta$ : $E_\theta[\hat{\theta}] - \theta$.*

*Esta diferencia se llama el sesgo.*

**Una propiedad deseable para un estimador**

Si el sesgo de un estimador es nulo para todo valor de $\theta$, decimos que el estimador es **insesgado**.

## 2.10 Error cuadrático medio

Para medir la variabilidad en el muestreo de un estimador.

**Definición 2.10.1** *El error cuadrático medio del estimador $\hat{\theta}$ es la función de $\theta$ definida por*

$$\theta \mapsto E_\theta[(\hat{\theta} - \theta)^2]$$

**Para practicar**

Calculad el error cuadrático medio del estimador de máxima verosimilitud (e.m.v.) de $\mu$ para una muestra aleatoria simple de $X \sim \mathcal{N}(\mu, \sigma^2)$.

$X \rightsquigarrow \underbrace{\mathcal{N}(\mu, \sigma^2)}_{\text{desconocidos}}$

$\hat{\mu} = \bar{x}$ (estimador basado en los movimientos)

$E[\bar{X}] = \mu \to \hat{\mu} = \bar{X}$ es un estimador insesgado para $\mu$

$$\left.\begin{array}{l}\mathrm{Var}[\bar{X}] = \dfrac{\sigma^2}{n} \\ \mathrm{Var}[\bar{X}] = E[(\bar{X}-\mu)^2]\end{array}\right\} \to E[(\bar{X}-\mu)^2] = \frac{\sigma^2}{n} \text{ (E.C.M.)}$$

## 2.11 Balance entre sesgo y varianza

**Sesgo y varianza**

El error cuadrático medio se puede descomponer

$$E_\theta[(\hat{\theta}-\theta)^2] = \mathrm{Var}(\hat{\theta}) + [\mathrm{sesgo}(\hat{\theta})]^2$$

En ocasiones, se consigue un menor error cuadrático medio con un estimador sesgado y estamos dispuestos a sacrificar el sesgo, por conseguir una menor varianza.

**Demostración 2.11.1**

$$\begin{aligned} E_\theta[(\hat{\theta}-\theta)^2] &= E_\theta[(\hat{\theta}-E_\theta[\hat{\theta}]+E_\theta[\hat{\theta}-\theta])^2] \\ &= E_\theta[(\hat{\theta})-E_\theta[\hat{\theta}]+(E_\theta[\hat{\theta}]-\theta)^2+2(\hat{\theta}-E_\theta[\hat{\theta}])(E_\theta[\hat{\theta}]-\theta)] \\ &= \mathrm{Var}[\hat{\theta}]+[sesgo(\hat{\theta})]^2 \end{aligned}$$

## 2.12 Comportamiento asintótico de un estimador

**Cuando el tamaño muestral crece**

Muchos de los resultados en inferencia se obtienen en un contexto asintótico: nos interesa comprobar el comportamiento de nuestro estimador cuando crece el número de observaciones.

- ¿Converge $\hat{\theta}$ hacia el verdadero valor del parámetro?
- ¿Cómo se comporta el error $\hat{\theta}-\theta$?

## 2.13 Consistencia

**Definición 2.13.1** *Una sucesión de estimadores $(\hat{\theta}_n)_n$ es consistente si converge hacia $\theta$ en probabilidad, para todo $\theta$.*

*Es decir:*

$$\forall \varepsilon > 0, \quad P_\theta\left[|\hat{\theta}_n - \theta| > \varepsilon\right] \xrightarrow[n\to\infty]{} 0$$

**Note**

Si el error cuadrático medio de una sucesión de estimadores tiende a cero, esta sucesión es consistente.

## 2.14 Normalidad asintótica

- Cuando un estimador es consistente, $(\hat{\theta}_n - \theta)$ converge hacia cero en probabilidad.
- Se busca entonces la velocidad de convergencia hacia cero.

**Un resultado que se puede demostrar para muchos modelos, para el e.m.v:**

$$\sqrt{n}\left(\hat{\theta}-\theta\right) \xrightarrow[n\to\infty]{\mathcal{L}} \mathcal{N}(0,\Lambda)$$

(la distribución de $\sqrt{n}(\hat{\theta}_n - \theta)$ se aproxima a la distribución $\mathcal{N}(0,\Lambda)$).

**Ejemplo: distribución gamma**$(\alpha,\beta)$

En práctica, veremos que los estimadores de los momentos para $(\alpha,\beta)$ son

$$\hat{\alpha} = \frac{(\hat{X})^2}{\overline{X^2} - (\bar{X})^2}$$
$$\hat{\beta} = \frac{\overline{X^2} - (\bar{X})^2}{\bar{X}}$$

Simulamos 10000 muestras de tamaño 10 y 10000 muestras de tamaño 10000.

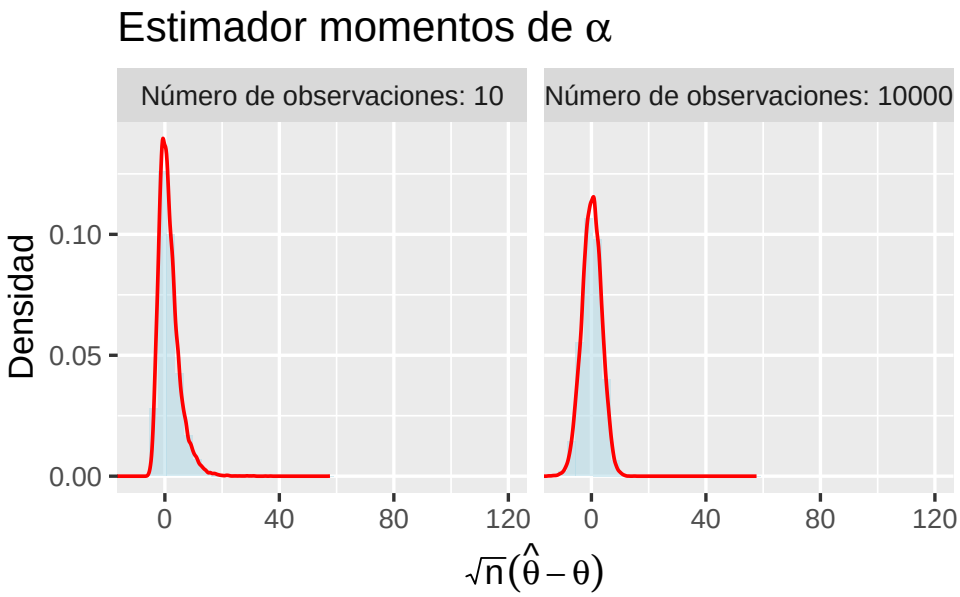


## 2.15 Estimación no paramétrica

**Estimación de funciones asociadas a una variable aleatoria**

En muchas ocasiones no interesa suponer un modelo específico para la variable aleatoria, y por lo tanto, no necesitamos conocer el valor de los parámetros que los caracterizan, sino que nos interesa aproximar el valor de alguna función asociada a la variable. Estas funciones suelen ser:

- Función de distribución: $F(x) = P(X \leq x)$ para todo $x \in \mathbb{R}$.
- Función puntual de probabilidad: $p(x) = P(X = x)$, para todo $x$ en el soporte de $X$ (en el caso discreto).
- Función de densidad: $f(x) = F'(x)$, para todo $x$ en el soporte de $X$ (en el caso continuo).
- En estas situaciones es posible considerar lo que se conoce como estimadores no paramétricas de las funciones anteriores en un valor concreto de $x$.
- En los dos primeros casos, puesto que se trata de estimar probabilidades, podremos usar la proporción muestral para hacer aproximaciones (lo veremos a continuación).
- En el caso de la función de densidad recurriremos a lo que se conoce como estimadores tipo núcleo.

**Estimación de la función de distribución**

Dado que la función de distribución en un punto $x$ es una probabilidad, $F(x) = P(X \leq x)$, tenemos como estimador la correspondiente proporción muestral que vendrá dada por

$$F_n(x) = \frac{1}{n} \sum_{i=1}^{n} I_{(\infty, x]}(X_i),$$

que se conoce como la función de distribución empírica.

**Estimación de la función puntual de probabilidad**

De la misma forma que antes el estimador $p(x) = P(X = x)$ vendrá dado por

$$\hat{p}(x) = \frac{\text{número de veces que aparece el valor } x \text{ en la muestra}}{n}$$

Primera opción: nos basamos en frecuencias relativas

- La estimación de la función de densidad no es tan sencilla.

- A partir de la expresión de la función de densidad como derivada de la función de distribución, y dada una muestra aleatoria simple $X_1, \dots, X_n$ de una variable aleatoria $X$, para cada $x$, estimaciones $F_X(x)$ por la frecuencia relativa de un vencidario de $x$:
$$\hat{f}_n(x) = \frac{1}{2nh} \sum_{i=1}^{n} I_{(x-h,x+h)}(x_i),$$
$h$ es la mitad del ancho del vecindario, "suficientemente pequeño".

Es una especie de histograma con ventana móvil, que se va deslizando.

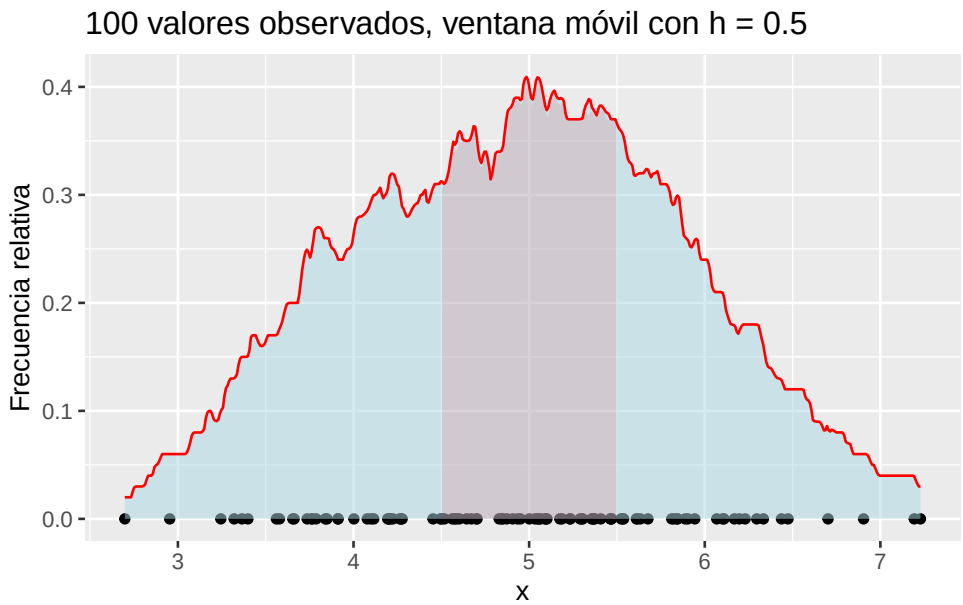


## 2.16 Estimación tipo núcleo

Podemos escribir
$$\hat{f}_n(x) = \frac{1}{2nh} \sum_{i=1}^{n} I_{(x-h,x+h)}(x_i),$$
como
$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right), \text{ con } K(z) = \frac{1}{2} I_{(-1,1)}(z).$$
$$\hat{f}_n(x) = \frac{1}{n} \sum_{i=1}^{n} K_h(x - x - i), \text{ con } K_h(z) \frac{1}{h} K\left(\frac{z}{h}\right) = \frac{1}{2h} I_{(-h,h)}(z)$$

- En la expresión anterior hay dos elementos principales, la función $K$, que en el ejemplo es la función de densidad de una distribución uniforme, y el parámetro $h$, que he dejado en 0.5 en el ejemplo, y en función de su valor tiene en cuenta valores de la muestra cercanos o alejados al valor $x$.
- En el primer caso hablamos sobre la función núcleo (kernel) y en el segundo caso del ancho de banda (bandwith).
- La principal característica de la función $K$ es que al ser la densidad de una distribución uniforme da el mismo peso a todos los puntos de la muestra que se encuentran en un entorno de valor $x$ donde estimamos la densidad.
- Podríamos pensar en otra función $K$ con la propiedad de ser simétrica y unimodal en el 0, como en el caso anterior, pero con distintos pesos para las observaciones.

### 2.16.1 Podemos variar el núcleo

**Función núcleo**

- En la literatura hay distintas propuestas de la función $K$, función núcleo.
- Cualquier estimador de la densidad en la forma anterior, con una función núcleo $K$, recibe el nombre de estimador tipo núcleo.
- Los casos más usados de función núcleo son los siguientes:
  - Núcleo normal: $K$ es la función de densidad de una distribución normal estándar. Suele ser el núcleo que más se utiliza.
  - Núcleo de Epanechnikov: $K(z) = (1 - z^2) I_{(-1,1)}$. Se considera que es el núcleo más eficiente.
- El caso considerado en la introducción se conoce como el núcleo rectangular.

Por ejemplo que tenga más peso cuando el valor muestral esté cerca del valor $x$. Este argumento parece bastante razonable, es decir, que en la estimación tengan más influencia los valores muestrales cercanos al valor $x$ en el intervalo $x \pm h$.

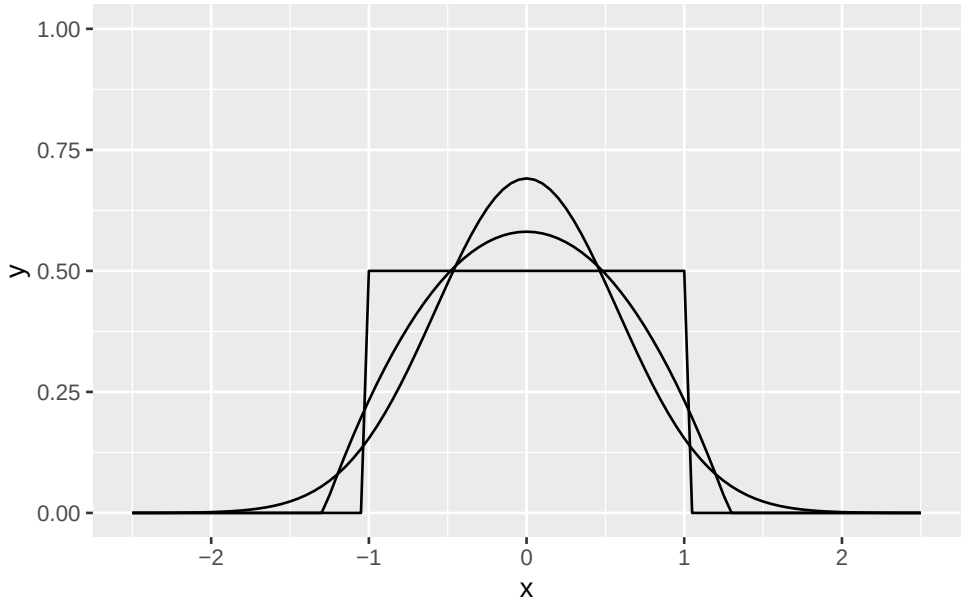


- $K$ uniforme.
- $K$ gaussiano.
- $K$ Kernel Epanechnikov:

$$K(z) = \frac{3}{4}(1 - z^2)I_{(-1,1)}(z)$$

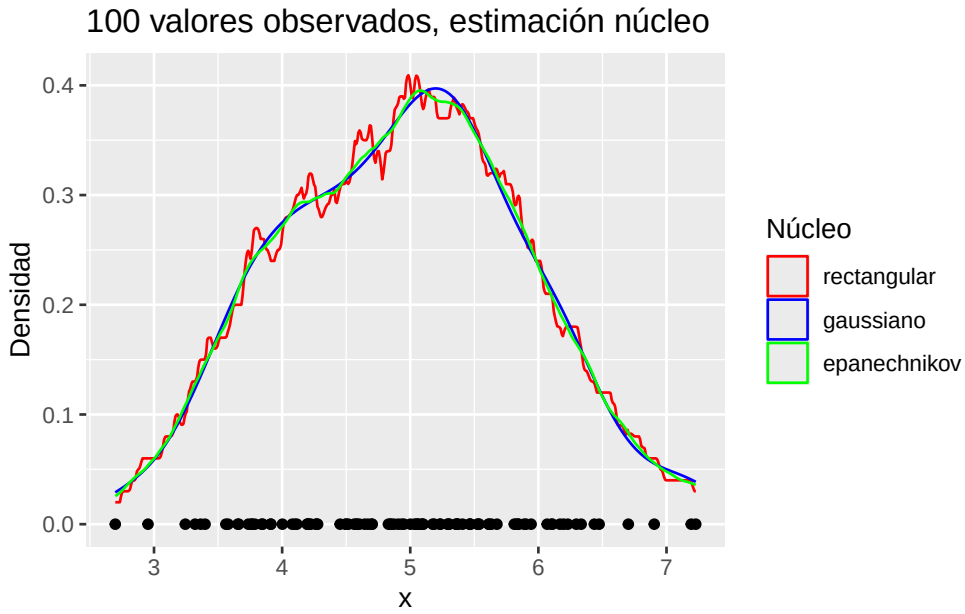


### 2.16.2 Se pueden demostrar resultados asintóticos

**Función núcleo**

Vamos a justificar, mediante el comportamiento asintótico, que los valores del estimador tipo núcleo dan buenas aproximaciones de la función de densidad.
Para el principal resultado se supondrán las siguientes condiciones sobre la función de densidad, la función núcleo y el ancho de banda:

- La densidad al cuadrado es integrable, admite derivada continua de segundo orden y esta al cuadrado es integrable. Seguiremos la notación $R(f'') = \int (f''(x))^2 \, \mathrm{d}x$.
- El núcleo es una función de densidad simétrica y acotada, con momento de orden dos finito y al cuadrado es integrable. Seguiremos en este caso la notación $R(K) = \int (K(x))^2 \, \mathrm{d}x$, y por $\mu_2(K) = \int x^2 K(x) \, \mathrm{d}x$ el valor del momento de orden 2 asociado a la densidad $K$.
- Conforme aumentamos el tamaño de muestra el ancho de banda, $h_n$, es una secuencia de valores positivos con límite 0 y $nh_n$ tiende a $+\infty$.

Si suponemos:

- $f_X$ es $L^2$, es derivable dos veces y $f_X''$ es $L^2$.
- $K$ es simétrica, acotada, $K$ es $L^2$ y admite momento de orden 2.
- Consideramos $h_n \to 0$ cuando $n \to \infty$, y además $nh_n \to \infty$.

**Resultado**

Para todo $x$,

$$E\left[\hat{f}_n(x) - f(x)\right] = \frac{1}{2}\mu_2(K)f''(x)h_n^2 + o(h_n^2) \text{ y } \operatorname{Var}\left[\hat{f}_n(x)\right] = \frac{R(K)}{nh_n}f(x) + o((nh_n)^{-1}).$$

- Este resultado junto con las suposiciones que hemos hecho anteriormente nos lleva a concluir que se producen buenas aproximaciones en términos del sesgo y la varianza, pues ambos tienden a 0 cuando aumentamos el tamaño de muestra.

## 2.17 Ancho de banda

**Si variamos el ancho de banda:**

- Cuánto mayor es la ventana o vecindario, la curva estimada es más suavizada.
- Si la ventana es pequeña, la curva estimada es *"wiggly"*.
- Puesto que el ancho de banda se puede hacer tan grande como queramos nos planteamos cómo elegir un ancho de banda que sea óptimo en algún sneitdo.
- En general el problema de la selección del ancho de banda no es sencillo.
- Se han propuesto elecciones óptimas del ancho de banda, que minimicen la distancia entre la función de densidad $f_X$ y el estimador $\hat{f}_X$.

**Elección óptima del ancho de banda**

$$h_n = \left(\frac{R(K)}{\mu_2^2(K)R(f'')n}\right)^{\frac{1}{5}}.$$

### 2.17.1 Elección óptima del ancho de banda

En la fórmula

$$h_n = \left(\frac{R(K)}{\mu_2^2(K)R(f'')n}\right)^{\frac{1}{5}}$$

aparece $R(f'')$ que es desconocida.

**Veremos dos maneras de aproximar $R(f'')$**

- Aproximación Gaussiana de $f_X$.
- Estimar $f_X$ de manera no paramétrica.

#### 2.17.1.1 Aproximación gaussiana para el cálculo de $R(f'')$

**Suponemos que $f$ es la función de densidad de una distribución normal con desviación típica $\sigma$:**

$$h_n = \left(\frac{8\pi^{\frac{1}{2}}R(K)}{3\mu_2^2(K)n}\right)^{\frac{1}{5}}\sigma$$

En la práctica, si la desviación típica $\sigma$ es desconocida la aproximamos por la cuasi-desviación típica muestra $S$:

$$\hat{h}_n = \left(\frac{8\pi^{\frac{1}{2}}R(K)}{3\mu_2^2(K)n}\right)^{\frac{1}{5}} S. \text{ Normal scales bandwidth selector}$$

Si además consideramos que el núcleo $K$ es gaussiano:

$$\hat{h}_{n,RP} = \left(\frac{4}{3n}\right)^{\frac{1}{5}} S.$$

Se llama la *"rule of thumb"* (la regla del pulgar).

La forma más complicada es dar una estimación no paramétrica de $R(f'')$. La metodología va más alla de los contenidos de esta asignatura y no veremos los detalles, solo indica que podemos seleccionar con `R` y lo veremos en prácticas.

**Implementación en `R`**

```
# más de una distribución normal de tamaño 100
set.seed(314159)
muestra <- rnorm(100, 0, 1)
# valor del ancho de banda segun la regla del pulgar
bw.nrd(x = muestra)
```

```
[1] 0.4047312
```

```
# gráfica del estimador de la función de densidad
tibble(x = muestra) |>
  ggplot(aes(x = x)) +
  geom_density(kernel = "gaussian", bw = "nrd") +
  geom_function(fun = dnorm, col = "red") +
  xlim(-5, 4) +
  ylim(0, 0.5)
```

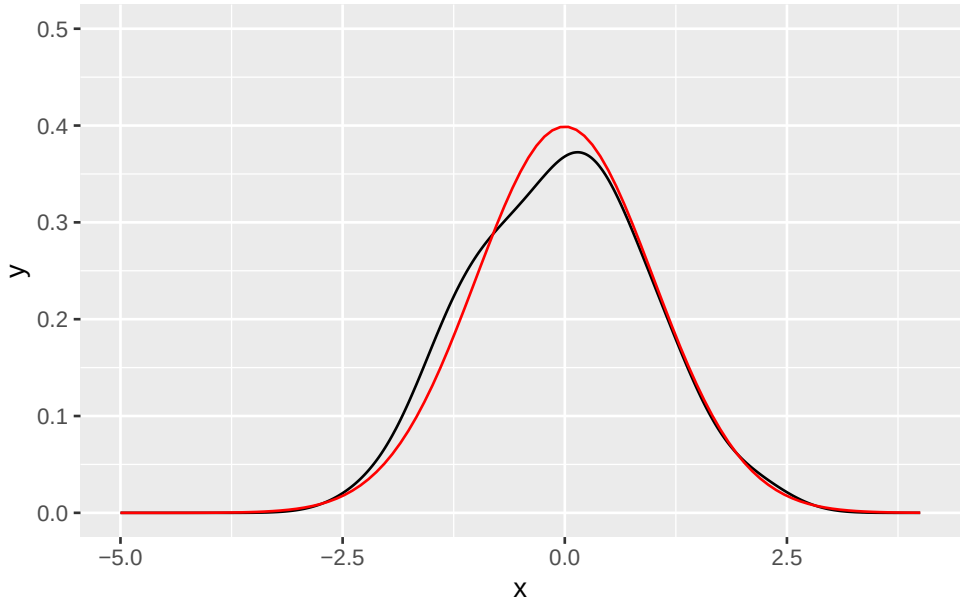


#### 2.17.1.2 Aproximación no paramétrica para el cálculo de $R(f'')$, implementación en `R`

Se usa la especificación "SJ" (Sheather & Jones, 1991) para el bandwidth.

```
# valor del ancho de banda con estimación no paramétrica
bw.SJ(x = muestra)
```

```
[1] 0.442874
```

```
# grafica del estimador de la función de densidad
tibble(x = muestra) |>
  ggplot(aes(x = x)) +
  geom_density(kernel = "gaussian", bw = "SJ") +
  geom_function(fun = dnorm, col = "red") +
  xlim(-5, 4) +
  ylim(0, 0.5)
```

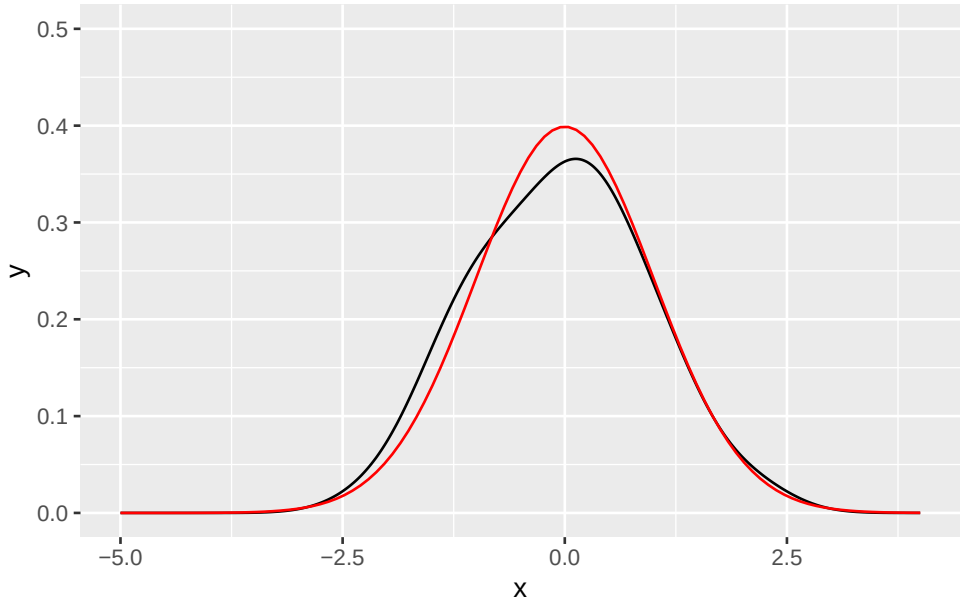


## 2.18 Introducción al Bootstrap

**Bootstrap: una manera de evaluar la incertidumbre asociada a un estimador**

Permite obtener información acerca de la distribución muestral de un estadístico relevante, usando remuestreo de la muestra disponible, es decir, submuestra de la muestra original.

- Permite estimar la distribución de un estimador (como la media, mediana, varianza, etc.) a partir de muestras obtenidas de los datos disponibles.
- Se utiliza espcialmente cuando la distribución poblacional es desconocida o cuando el tamaño de la muestra es pequeño.
- Es muy útil para hacer inferencias estadísticas sin hacer suposiciones sobre la distribución subyacente de los datos.
- Se aplica incluso cuando el modelo no permite obtener la distribución muestral.
- Nos permite aproximar el error estándar al estimador, lo que nos da una idea de su precisión.

**¿De dónde viene el nombre?**

Está asociado a la expresión: *"To pull oneself up by one's bootstrap"*, que hace referencia a situaciones en las que uno cuenta con sus propios medios para salir de una dificultad, sin contar con ayuda externa.

- Se basa en la aproximación de la función de distribución mediante la función de distribución empírica y los métodos de simulación.
- Para utilizar el método de simulación necesitamos conocer la distribución $F$. Como en muchas situaciones no conocemos $F$, lo que vamos a hacer es generar muestras a partir de $F_n$.

**Determinación del error muestral de un estadístico**

- Recordamos que el error estándar asociado a un estadístico es su desviación típica muestral.
- Para un estimador, nos indica la variabilidad de los valores que toma respecto a todas las muestras posibles. Es, por lo tanto, un indicador valioso de su precisión.
- Por ejemplo, para una población normal, $\sigma$ desconocida, el error estándar de $\bar{X}$ es $\dfrac{\sigma}{\sqrt{n}}$.
- En general, dado un parámetro $\theta$ y un estadístico $\hat{\theta}$ que aproxima (estima) el valor de $\theta$, su error muestral viene dado por
$$E[(\hat{\theta} - \theta)^2].$$
- La idea es simular muestras de $F_n$ para obtener en cada una de ellas el valor del estadístico.
- Con cada una de ellas calculamos el equivalente empírico de $E[(\hat{\theta} - \theta)^2]$, mediante el promedio de las desviaciones al cuadrado de los valores del estadístico respecto del promedio de todas las estimaciones.

**La distribución empírica asociada a una muestra**

- Consideramos una muestra concreta $\mathbf{x} = (x_1, \dots, x_n)$, asociada a una distribución $F$ en una población.
- La distribución empírica $\hat{F}$ se construye únicamente a partir de esos valores observados y es la distribución que asigna una probabilidad $\frac{1}{n}$ a cada valor $x_i, i = 1, 2, \dots, n$.
- Es por lo tanto una distribución discreta, sus valores posibles son los de $x_1, \dots, x_n$.
- Es decir $\hat{F}$ asocia a cualquier evento $A$, la probabilidad *empírica*:

$$\widehat{\text{Prob}(A)} = \frac{\#\{x_i \in A\}}{n}.$$

**Tened en cuenta**

Se pueden repetir los valores en la muestra $\mathbf{x} = (x_1, \dots, x_n)$.

**La distribución empírica asociada a una muestra**

- Es una distribución discreta, sus valores posibles son los de $x_1, \dots, x_n$.
- Es decir $\hat{F}$ asociado cualquier evento $A$, la probabilidad *empírica*: $\widehat{\text{Prob}(A)} = \frac{\#\{x_i \in A\}}{n}$.
- Podemos calcular la esperanza de cualquier función $g$:

$$\hat{E}[g] = \frac{1}{n} \sum_{i=}^{n} g(x_i).$$

- Por ejemplo:

$$\text{La esperanza de } \hat{F} = \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x},$$
$$\text{La esperanza de } \hat{F} = \frac{(n-1)}{n} s^2.$$

**El principio de plug-in**

- Es un método simple para estimar parámetros a partir de una muestra.
- Estimamos un parámetro $\theta$ que se puede calcular como una función $t(F)$ de la distribución $F$, a través de su equivalente empírico:

$$\hat{\theta} = t(\hat{F}).$$

**Nota**

- Por ejemplo, estimamos $\mu_F$ usando la esperanza de $\hat{F}$, que es $\bar{x}$.
- Es la idea que usamos en el método de los momentos también.

**Muestra Bootstrap**

Extraer una muestra Bootstrap es extraer una muestra de la distribución empírica $\hat{F}$.

- Consiste en extraer al azar, de manera equiprobable y con reemplazo, $n$ elementos del vector $\mathbf{x} = (x_1, \dots, x_n)$.
- Denotamos la muestra extraída por $\mathbf{x}^* = (x_1^*, \dots, x_n^*)$.
- Al ser con reemplazo, algunos elementos de $\mathbf{x}$ pueden aparecer repetidos y otros pueden no aparecer.

**Con R**

```r
x <- c(5.3, 4.8, 5.4, 5.0, 4.8)
set.seed(3.14159)
(x_bootstrap <- sample(x, replace = TRUE))
```

```
[1] 4.8 4.8 5.0 5.0 4.8
```

### 2.18.1 El error estándar Bootstrap

**Recordad**

- El error estándar asociado a un estadístico es su desviación típica muestral.
- Para un estimador, nos indica la variabilidad de los valores que toma respecto a todas las muestras posibles, es por lo tanto un indicador valioso de su precisión.
- Por ejemplo, para una población normal, $\sigma$ desconocida, el error estándar de $\bar{X}$ es $S/\sqrt{n}$.

**Idea del error estándar Bootstrap**

- Consideramos un estimador $\hat{\theta}$ que se expresa como $T(\mathbf{x})$.
- Vamos a aplicar el principio plug-in para aproximar el error estándar de $\hat{\theta}$, usando $\hat{F}$.
- El principio plug-in en este caso se describe como:
  - Consideramos el proceso de extraer una muestra de $\hat{F} : \mathbf{x}^*$.
  - Consideramos el estimador $T(\mathbf{x}^*)$.
  - Calculamos la desviación típica de la distribución muestral del estimador anterior, respecto a todas las muestras de $\hat{F}$ que podría extraer.
- Consideramos una variable aleatoria $X$ y una muestra $x_1, \dots, x_n$ de $X$.
- Hemos observado $\mathbf{x}$, hemos calculado el estadístico $\hat{\theta} = T(\mathbf{x})$. Procederemos de la manera siguiente:
  - Extraemos $B$ muestras Bootstrap $\mathbf{x}^{*1}, \dots, \mathbf{x}^{*n}$. Estas muestras independientes con reemplazamiento (pueden aparecer valores repetidos) de tamaño $n$ de $x_1, \dots, x_n$.
  - Para cada muestra Bootstrap, calculamos el valor del estadístico y lo denotamos por $\hat{\theta}^{*b} = T(\mathbf{x}^{*b})$, para $b = 1, \dots, B$.
- Aproximamos el error estándar de $\hat{\theta}$, que denotamos por $\hat{se}$, como la desviación típica muestral de $\hat{\theta}^{*1}, \dots, \hat{\theta}^{*B}$, esto es, como

$$\hat{se} = \sqrt{\sum_{b=1}^{B} \frac{\left(\hat{\theta}^{*b} - \sum_{i=1}^{B} \frac{\hat{\theta}^{*b}}{B}\right)}{B-1}}$$

# Hoja 2: Estimación

**1)** Sea $X$ una variable aleatoria con distribución Bernoulli, de parámetro $p(X \sim b(p))$ y sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$.

**a)** Obtener el estimador de los momentos y el estimador de máxima verosimilitud de $p$.

1) Estimador por el Método de los Momentos:

El método de los momentos consiste en igualar los primeros momentos poblacionales con los momentos muestrales correspondientes. Al tener un único parámetro $p$ (dimensión 1), solo necesitamos igualar el primer momento.

- Primer momento poblacional $\mu_1(p) = \mathbb{E}[X]$. Para una distribución Bernoulli, la esperanza es $p$.
- Primer momento muestral, que denotaremos $\bar{X}$.

Igualando ambos, obtenemos directamente el estimador:

$$\hat{p}_{MM} = \bar{X}$$

2) Estimador de Máxima Verosimilitud (EMV):

El estimador de máxima verosimilitud es el valor de $\theta$ (en este caso, $p$) que maximiza la función de verosimilitud $L_n(\theta)$. La función de verosimilitud se define como $Ln(p) = \prod_{i=1}^{n} f_X(x_i; p)$.

Para una muestra de variables Bernoulli donde $f_X(x_i; p) = p^{x_i}(1-p)^{1-x_i}$, la función de verosimilitud es:

$$L_n(p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}$$

Para encontrar el máximo, aplicamos el logaritmo (que simplifica el producto) y derivamos con respecto a $p$:

$$\ln L_n(p) = \left(\sum_{i=1}^{n} x_i\right) \ln p + \left(n - \sum_{i=1}^{n} x_i\right) \ln(1-p)$$

Derivamos e igualamos a 0:

$$\begin{aligned}
\frac{\partial}{\partial p} \ln L_n(p) = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = 0 \implies \frac{\sum x_i}{p} = \frac{n - \sum x_i}{1-p} &\implies (1-p)\sum_{i=1}^{n} x_i = p\left(n - \sum_{i=1}^{n} x_i\right) \\
&\implies \sum_{i=1}^{n} x_i - p\sum_{i=1}^{n} x_i = pn - p\sum_{i=1}^{n} x_i \\
&\implies pn = \sum_{i=1}^{n} x_i
\end{aligned}$$

Depesjando $p$, obtenemos el estimador:

$$\hat{p}_{EMV} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{X}$$

**b)** Calcular el sesgo y el error cuadrático medio de ambos estimadores.

Dado que ambos métodos resultan en el mismo estimador ($\hat{p} = \bar{X}$), los cálculos de sesgo y ECM aplican para ambos por igual.

1) Seso:

El sesgo se define matemáticamente como la diferencia $\mathbb{E}_p[\hat{p}] - p$.

Calculamos la esperanza de nuestro estimador:

$$\mathbb{E}[X] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}[X_i]$$

Sabemos que para una variable Bernoulli, $\mathbb{E}[X_i] = p$. Sustituyendo:

$$\mathbb{E}[\bar{X}] = \frac{1}{n}(np) = p$$

Aplicando la definición de sesgo:

$$\text{Sesgo} = p - p = 0$$

Dado que el sesgo es nulo, concluimos que el estimador es insesgado.

2) Error Cuadrático Medio (ECM):

El error cuadrático medio se define como la función $\mathbb{E}_p[(\hat{p}-p)^2]$. Para facilitar el cálculo, el ECM se puede descomponer como $\text{Var}(\hat{p}) + [\text{sesgo}(\hat{p})]^2$.

Como acabamos de Demostrar que el sesgo es 0:

$$ECM(\hat{p}) = \text{Var}(\hat{p}) = \text{Var}(\bar{X})$$

Desarrollamos la varianza:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\text{Var}(X_i)$$

La varianza poblacional de una distribución de Bernoulli es $p(1-p)$. Sustituyendo este valor:

$$ECM(\hat{p}) = \frac{1}{n^2}(n \cdot p(1-p)) = \frac{p(1-p)}{n}$$

**2)** Sea $X$ variable aleatoria con distribución exponencial, de parámetro $\lambda(X \sim Exp(\lambda))$ y sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$. Obtener el estimador de los momentos y el estimador de máxima verosimilitud de $\lambda$.

1) Estimador por el Método de los Momentos

Al tratarse de un parámetro de dimensión 1, el método consiste en igualar el primer momento poblacional $\mu_1(\lambda)$ con su equivalente muestral $\bar{X}$.

- Primer momento poblacional para una distribución $Exp(\lambda) : \mu_1(\lambda) = \mathbb{E}[X] = \dfrac{1}{\lambda}$
- Primer momento muestral: $\bar{X}$

Igualando ambas expresiones:

$$\frac{1}{\lambda} = \bar{X}$$

Despejando el parámetro, obtenemos el estimador de los momentos:

$$\hat{\lambda}_{EMV} = \frac{1}{\bar{X}}$$

2) Estimador de Máxima Verosimilitud (EMV)

El estimador de máxima verosimilitud es el valor que maximiza la función de verosimilitud $L_n(\lambda) = \prod_{i=1}^{n} f_X(x_i;\lambda)$.

Para una distribución exponencial, la función de densidad es $f_X(x;\lambda) = \lambda e^{-\lambda x}$.

Planteamos la función de verosimilitud para la muestra:

$$L_n(\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{n=1}^{n} x_i}$$

Para maximizar esta función de forma más sencilla, aplicamos el logaritmo neperiano (log-verosimilitud):

$$\ln L_n(\lambda) = \ln\left(\lambda^n e^{-\lambda \sum_{n=1}^{n} x_i}\right) = n\ln(\lambda) - \lambda\sum_{i=1}^{n} x_i$$

Derivamos la función respecto a $\lambda$ e igualamos a 0 para hallar el máximo:

$$\frac{\partial}{\partial\lambda}\ln L_n(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0$$

Despejamos $\lambda$:

$$\frac{n}{\lambda} = \sum_{i=1}^{n} x_i \implies \lambda = \frac{n}{\sum_{i=1}^{n} x_i}$$

Sabiendo que la media muestral es $\bar{X} = \dfrac{\sum x_i}{n}$, podemos sustituir $\sum_{i=1}^{n} x_i$ por $n\bar{X}$:

$$\hat{\lambda}_{EMV} = \frac{n}{n\bar{X}} = \frac{1}{\bar{X}}$$

**3)** Demostrar que, si $\theta \longmapsto L_n(\theta)$ es una verosimilitud, maximizar $\theta \longmapsto L_n(\theta)$ es equivalente a maximizar $\theta \longmapsto \log(L_n(\theta))$.

1) Definición y Dominio

La función de verosimilitud es una aplicación cuyo codomonio son los reales positivos:

$$L_n : \Theta \subset \mathbb{R}^p \to \mathbb{R}^+$$

Esto implica estrictamente que $L_n(\theta) > 0$ para todo $\theta$, lo que nos permite aplicar la función logaritmo sin restricciones de dominio.

2) Propiedad de la función logaritmo:

La función logaritmo, $g(x) = \log(x)$, es una función **estrictamente creciente** en el intervalo $(0, +\infty)$. Matemáticamente, esto significa que preserva el orden de las desigualdades:

$$x_1 \geq x_2 \iff \log(x_1) \geq \log(x_2)$$

3) Definición del máximo:

Es estimador de máxima verosimilitud $\hat{\theta}$ es el valor que maximiza la función $L_n(\theta)$. Es decir, se cumple la siguiente desigualdad para cualquier otro valor admisible de $\theta$:

$$L_n(\hat{\theta}) \geq L_n(\theta), \quad \forall \theta \in \Theta$$

4) Aplicación de la monotonía:

Dado que $L_n(\theta) > 0$ y que el logaritmo es estrictamente creciente, podemos aplicar el logaritmo a ambos lados de la desigualdad sin alterar su sentido:

$$\log(L_n(\hat{\theta})) \geq \log(L_n(\theta)), \quad \forall \theta \in \Theta$$

5) Conclusión:

La desigualdad anterior demuestra que el mismo valor $\hat{\theta}$ que hace máxima a la función de $L_n(\theta)$ también hace máxima a la función $\log(L_n(\theta))$. Utilizando la notación de maximización, podemos concluir la equivalencia:

$$\operatorname*{argmax}_{\theta \in \Theta} L_n(\theta) = \operatorname*{argmax}_{\theta \in \Theta} \log(L_n(\theta))$$

**4)** Sea $X$ variable aleatoria con distribución de Poisson, de parámetro $\lambda (X \sim P(\lambda))$ y sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$. Obtener el estimador de los momentos y el estimador de máxima verosimilitud de $\lambda$.

1) Estimador por el Método de los Momentos

El método de los momentos consiste en igualar los momentos teóricos de la distribución con sus equivalentes muestrales. Al tener un único parámetro, $\lambda$ (dimensión 1), solo necesitamos igualar el primer momento.

- **Primer momento muestral:** $\mu_1(\lambda) = \mathbb{E}[X$. Para una distribución de Poisson, sabemos que su esperanza es igual a su parámetro: $\mathbb{E}[X] = \lambda$.
- **Primer momento muestral:** $\bar{X} = \dfrac{1}{n} \displaystyle\sum_{i=1}^{n} X_i$.

Igualando el momento poblacional con el momento muestral, obtenemos directamente el estimador:

$$\lambda = \bar{X}$$

Por lo tanto, el estimador de los momentos es:

$$\hat{\lambda}_{MM} = \bar{X}$$

2) Estimador de Máxima Verosimilitud (EMV)

La función de verosimilitud $L_n(\theta)$ para una muestra aleatoria simple se define como el producto de las funciones puntuales de probabilidad evaluadas en los valores de la muestra. El estimador será el valor que maximice dicha función.

Para una distribución de Poisson, la función puntual de probabilidad es $f_X(x; \lambda) = \dfrac{e^{-\lambda}\lambda^x}{x!}$.

Construimos la función de verosimilitud para la muestra:

$$L_n(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda}\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}$$

Para facilitar la maximización, aplicamos el logaritmo neperiano (log-verosimilitud):

$$\ln L_n(\lambda) = \ln\left(e^{-n\lambda}\lambda^{\sum_{i=1}^{n} x_i}\right) - \ln\left(\prod_{i=1}^{n} x_i!\right)$$
$$\ln L_n(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} x_i\right)\ln(\lambda) - \ln\left(\prod_{i=1}^{n} x_i!\right)$$

Para encontrar el máximo, derivamos la función respecto a $\lambda$ e igualamos a 0:

$$\frac{\partial}{\partial\lambda}\ln L_n(\lambda) = -n + \frac{\sum_{i=1}^{n} x_i}{\lambda} = 0$$

Despejamos $\lambda$:

$$n = \frac{\sum_{i=1}^{n} x_i}{\lambda} \implies \lambda = \frac{\sum_{i=1}^{n} x_i}{n}$$

Sabiendo que $\frac{\sum_{i=1}^{n} x_i}{n}$ es la definición de la media muestral $\bar{X}$, obtenemos nuestro estimador:

$$\hat{\lambda}_{EMV} = \bar{X}$$

Al igual que en otros modelos unimodales básicos, ambos métodos nos conducen al mismo resultado mátemático para la estimación del parámetro.

**5)** Sea $X$ variable aleatoria con distribución de normal, de parámetros $\mu$ y $\sigma^2$ ($X \sim N(\mu, \sigma^2)$) y sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$. Obtener el estimador de máxima verosimilitud de $(\mu, \sigma^2)$. ¿Cuál es el sesgo y el error cuadrático medio para el estimador de máxima verosimilitud de $\mu$?

1) Obtener el estimador de máxima verosimilitud de $(\mu, \sigma^2)$

La función de densidad de una variable $\mathcal{N}(\mu, \sigma^2)$ es:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

La función de verosimilitud para una muestra $x_1, \dots, x_n$ se define como el producto de las densidades:

$$L_n(\mu, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2}$$

Para maximizar, aplicamos el logaritmo neperiano (log-verosimilitud) como se demostró en ejercicios anteriores:

$$\ln L_n(\mu, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \mu)^2$$

Para encontrar el máximo bidimensional, calculamos las derivadas parciales respecto a $\mu$ y $\sigma^2$ y las igualamos a 0.

**Derivada respecto a $\mu$:**

$$\frac{\partial}{\partial\mu}\ln L_n(\mu, \sigma^2) = -\frac{1}{2\sigma^2}\sum_{i=1}^{n} 2(x_i - \mu)(-1) = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i - \mu) = 0$$
$$\sum_{i=1}^{n} x_i - n\mu = 0 \implies \hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{X}$$

**Derivada respecto a $\sigma^2$ (tratando $\sigma^2$ como una única variable):**

$$\frac{\partial}{\partial(\sigma^2)}\ln L_n(\mu, \sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{n}(x_i - \mu)^2 = 0$$

Multiplicamos por $2(\sigma^2)^2$:

$$-n\sigma^2 + \sum_{i=1}^{n}(x_i - \mu)^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{\mu})^2$$

Sustituyendo el estimador de la media encontrado previamente, obtenemos los estimadores de máxima verosimilitud conjuntos:

$$(\hat{\mu}_{EMV}, \hat{\sigma}^2_{EMV}) = \left(\bar{X}, \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2\right)$$

2) Sesgo del estimador de máxima verosimilitud de $\mu$

El estimador que hemos obtenido es $\hat{\mu} = \bar{X}$. Se define el sesgo como $\mathbb{E}[\hat{\theta}] - \theta$.

Calculamos la esperanza de nuestro estimador:

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i]$$

Como $X_i \sim \mathcal{N}(\mu, \sigma^2)$, sabemos que $\mathbb{E}[X_i] = \mu$.

$$\mathbb{E}[\bar{X}] = \frac{1}{n}(n\mu) = \mu$$

Aplicando la fórmula del sesgo:

$$\text{Sesgo}(\hat{\mu}) = \mathbb{E}[\hat{\mu}] - \mu = \mu - \mu = 0$$

El estimador es insesgado.

3) Error cuadrático medio para el estimador de máxima verosimilitud de $\mu$

El error cuadrático medio (ECM) se descompone como $\text{Var}(\hat{\theta}) + [\text{sesgo}(\hat{\theta})]^2$.

Como hemos demostrado antes que el sesgo es nulo, el ECM coincide con la varianza del estimador:

$$ECM(\hat{\mu}) = \text{Var}(\hat{\mu}) = \text{Var}(\bar{X})$$

Calculamos la varianza de la media muestral:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\text{Var}(X_i)$$

Como la muestra es aleatoria simple (las variables son independientes) y $\text{Var}(X_i) = \sigma^2$:

$$ECM(\hat{\mu}) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}$$

**6)** Sea $X$ una variable aleatoria con función de densidad

$$f(x, \theta) = \frac{2x}{\theta}\exp\left(-\frac{x^2}{\theta}\right)\xi_{(0,+\infty)}(x).$$

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simples (m.a.s.) de $X$. Obtener el estimador de máxima verosimilitud de $\theta$.

1) Función de Verosimilitud

La función de verosimilitud $L_n(\theta)$ para una muestra aleatoria simple se define como el producto de las funciones de densidad evaluadas en cada observación $x_i$:

$$L_n(\theta) = \prod_{i=1}^{n} f(x_i, \theta) = \prod_{i=1}^{n}\left(\frac{2x_i}{\theta}\exp\left(-\frac{x_i^2}{\theta}\right)\right)$$

Agrupando los términos del producto, obtenemos:

$$L_n(\theta) = \frac{2^n \prod_{i=1}^{n} x_i}{\theta^n}\exp\left(-\frac{1}{\theta}\sum_{i=1}^{n} x_i^2\right)$$

2) Log-Verosimilitud

Para facilitar la maximización, aplicamos el logaritmo neperiano a la función de verosimilitud:

$$\ln L_n(\theta) = \ln(2^n) + \ln\left(\prod_{i=1}^{n} x_i\right) - \ln(\theta^n) - \frac{1}{\theta}\sum_{i=1}^{n} x_i^2$$

Simplificando utilizando las propiedades de los logaritmos:

$$\ln L_n(\theta) = n\ln(2) + \sum_{i=1}^{n}\ln(x_i) - n\ln(\theta) - \frac{1}{\theta}\sum_{i=1}^{n} x_i^2$$

3) Maximización

Para encontrar el máximo, calculamos la derivada de la log-verosimilitud con respecto a $\theta$ y la igualamos a cero:

$$\frac{\mathrm{d}}{\mathrm{d}\theta} \ln L_n(\theta) = 0 + 0 - \frac{n}{\theta} - \left(-\frac{1}{\theta^2}\right) \sum_{i=1}^{n} x_i^2 = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^{n} x_i^2 = 0$$

Despejamos $\theta$:

$$\frac{n}{\theta} = \frac{1}{\theta^2} \sum_{i=1}^{n} x_i^2 \implies n\theta = \sum_{i=1}^{n} x_i^2 \implies \theta = \frac{1}{n} \sum_{i=1}^{n} x_i^2$$

**Conclusión**

Por lo tanto, el estimador de máxima verosimilitud para el parámetro $\theta$ es el momento muestral de orden 2:

$$\hat{\theta}_{EMV} = \frac{1}{n} \sum_{i=1}^{n} X_i^2 = \bar{X^2}$$

**7)** Sea $X$ una variable aleatoria con función de densidad:

$$f(x, \theta) = \frac{\theta}{(1+x)^{1+\theta}} \xi_{(0,+\infty)}(x).$$

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$. Obtener el estimador de máxima verosimilitud de $\theta$.

1) Función de verosimilitud

La función de verosimilitud $L_n(\theta)$ para una muestra aleatoria simple se define como el producto de las funciones de densidad evaluadas en cada observación $x_i$:

$$L_n(\theta) = \prod_{i=1}^{n} f(x_i, \theta) = \prod_{i=1}^{n} \frac{\theta}{(1+x_i)^{1+\theta}}$$

Agrupando los términos del producto (el numerador se multiplica $n$ veces y los denominadores se multiplican entre sí), obtenemos:

$$L_n(\theta) = \frac{\theta^n}{\prod_{i=1}^{n} (1+x_i)^{1+\theta}}$$

2) Log-Verosimilitud

Para facilitar la maximización y convertir los productos y potencias en sumas y multiplicaciones, aplicamos el logaritmo neperiano a la función de verosimilitud:

$$\ln L_n(\theta) = \ln \left( \frac{\theta^n}{\prod_{i=1}^{n} (1+x_i)^{1+\theta}} \right)$$

Aplicamos las propiedades del logaritmo (el logaritmo de un cociente es la resta de logaritmos, y el logaritmo de un producto es la suma de logaritmos):

$$\ln L_n(\theta) = \ln(\theta^n) - \ln \left( \prod_{i=1}^{n} (1+x_i)^{1+\theta} \right)$$
$$\ln L_n(\theta) = n \ln(\theta) - \sum_{i=1}^{n} \ln \left( (1+x_i)^{1+\theta} \right)$$

Bajamos el exponente $(1+\theta)$ multiplicando a cada término dentro del sumatorio:

$$\ln L_n(\theta) = n \ln(\theta) - (1+\theta) \sum_{i=1}^{n} \ln(1+x_i)$$

3) Maximización

Para encontrar el máximo de esta función, calculamos la derivada de la log-verosimilitud con respecto al parámetro $\theta$ y la igualamos a cero:

$$\frac{\partial}{\partial\theta} \ln L_n(\theta) = \frac{n}{\theta} - \sum_{i=1}^{n} \ln(1+x_i) = 0$$

Despejamos $\theta$:

$$\frac{n}{\theta} = \sum_{i=1}^{n} \ln(1 + x_i)$$

Invertimos la expresión o pasamos $\theta$ multiplicando y la suma dividiendo:

$$\theta = \frac{n}{\sum_{i=1}^{n} \ln(1 + x_i)}$$

**Conclusión**

Por lo tanto, el estimador de máxima verosimilitud para el parámetro $\theta$ es:

$$\hat{\theta}_{EMV} = \frac{n}{\sum_{i=1}^{n} \ln(1 + X_i)}$$

**8)** Sea $X$ una variable aleatoria con distribución uniforme en el intervalo $(a, 5)$ con $a < 5$ ($X \sim U(a, 5)$). Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$. Obtener el estimador máxima verosimilitud de $a$. Estudiar su distribución en el muestreo.

1) Obtener el estimador de máxima verosimilitud de $a$

La función de densidad de una variable aleatoria con distribución uniforme $U(a, 5)$ se define usando la función indicatriz:

$$f(x; a) = \frac{1}{5 - a} I_{[a,5]}(x)$$

Construimos la función de verosimilitud $L_n(a)$ como el producto de las densidades:

$$L_n(a) = \prod_{i=1}^{n} \frac{1}{5 - a} I_{[a,5]}(x_i) = \frac{1}{(5 - a)^n} \prod_{i=1}^{n} I_{[a,5]}(x_i)$$

El producto de las funciones indicatrices será 1 si y sólo si los valores observados $x_i$ están dentro del intervalo $[a, 5]$. Esto equivale a decir que el valor mínimo de la muestra debe ser mayor o igual a $a$, y el valor máximo debe ser menor o igual a 5.

Denotando el mínimo muestral como $X_{(1)} = \min(x_1, \dots, x_n)$, la condición se reescribe como $a \leq X_{(1)}$. Por lo tanto:

$$L_n(a) = \begin{cases} \dfrac{1}{(5 - a)^n} & \text{si } a \leq X_{(1)} \\ 0 & \text{si } a > X_{(1)} \end{cases}$$

El estimador de máxima verosimilitud (EMV) es el valor de $a$ que maximiza $L_n(a)$. Dado que $n > 0$, la función $\dfrac{1}{(5 - a)^n}$ es estrictamente creciente con respecto a $a$.

Para maximizar esta función, debemos hacer que $a$ sea lo más grande posible, respetando la restricción impuesta por la función indicatriz ($a \leq X_{(1)}$).

Por lo tanto, el máximo se alcanza en el límite superior permitido:

$$\hat{a}_{EMV} = X_{(1)} = \min(X_1, X_2, \dots, X_n)$$

2) Estudiar su distribución en el muestreo

Para evaluar la distribución en el muestreo del estimador $\hat{a} = \min(X_1, \dots, X_n)$, calculamos su función de distribución $F_{\hat{a}}(t) = P(\hat{a} \leq t)$, basándonos en la definición $F(x) = P(X \leq x)$.

Aplicamos la propiedad del mínimo:

$$F_{\hat{a}} = P(\min(X_1, \dots, X_n) \leq t) = 1 - P(\min(X_1, \dots, X_n) > t)$$

Para que el mínimo de una muestra sea mayor que $t$, todos los elementos de la muestra deben ser simultáneamente mayores que $t$. Al ser una m.a.s. (variables independientes e idénticamente distribuidas):

$$1 - P(X_1 > t, X_2 > t, \dots, X_n > t) = 1 - \prod_{i=1}^{n} P(X_i > t) = 1 - [P(X > t)]^n$$

Calculamos la probabilidad $P(X > t)$ para la distribución original $U(a, 5)$ en el rango $a \leq t \leq 5$:

$$P(X > t) = \int_t^5 \frac{1}{5 - a} \, \mathrm{d}x = \frac{5 - t}{5 - a}$$

Sustituimos en la función de distribución:

$$F_{\hat{a}}(t) = 1 - \left(\frac{5-t}{5-a}\right)^n, \text{ para } a \leq t \leq 5$$

Para encontrar la función de densidad muestral $f_{\hat{a}}(t)$, derivamos la función de distribución $F_{\hat{a}}(t)$ con respecto a $t$:

$$f_{\hat{a}}(t) = \frac{\partial}{\partial t}\left[1 - \left(\frac{5-t}{5-a}\right)^n\right] = -n\left(\frac{5-t}{5-a}\right)^{n-1} \cdot \left(-\frac{1}{5-a}\right)$$

Simplificando, obtenemos la distribución muestral del estimador:

$$f_{\hat{a}}(t) = \frac{n(5-t)^{n-1}}{(5-a)^n}, \text{ para } a \leq t \leq 5$$

**9)** Sea $X$ variable aleatoria con distribución $gamma(\alpha, \beta)$, de parámetros $\alpha$ y $\beta(X \sim gamma(\alpha, \beta))$ y sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria simple (m.a.s.) de $X$.

**a)** Obtener los estimadores de $\alpha$ y $\beta$ usando el método de los momentos.

$$\hat{\alpha} = \frac{(\bar{X})^2}{\bar{X^2} - (\bar{X})^2}$$
$$\hat{\beta} = \frac{\bar{X^2} - (\bar{X})^2}{\bar{X}}$$

**b)** Obtener la log-verosimilitud como función de $(\alpha, \beta)$.

La función de verosimilitud se construye como el producto de las funciones de densidad evaluadas en la muestra. Para resolver el cálculo utilizamos la definición estándar de Gamma en función de sus parámetros de forma $(\alpha)$ y escala $(\beta)$:

$$f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$$

Planteamos la función de verosimilitud para la muestra:

$$L_n(\alpha, \beta) = \prod_{i=1}^n \frac{1}{\Gamma(\alpha)\beta^\alpha} x_i^{\alpha-1} e^{-x_i/\beta} = \frac{1}{(\Gamma(\alpha))^n \beta^{n\alpha}} \left(\prod_{i=1}^n x_i\right)^{\alpha-1} e^{-\frac{1}{\beta}\sum_{i=1}^n x_i}$$

Para obtener la log-verosimilitud, aplicamos el logaritmo neperiano:

$$\ln L_n(\alpha, \beta) = \ln\left((\Gamma(\alpha))^{-n}\right) + \ln(\beta^{-n\alpha}) + \ln\left(\left(\prod_{i=1}^n x_i\right)^{\alpha-1}\right) + \ln\left(e^{-\frac{1}{\beta}\sum_{i=1}^n x_i}\right)$$

Simplificando mediante las propiedades de los logaritmos, obtenemos la función final:

$$\ln L_n(\alpha, \beta) = -n\ln(\Gamma(\alpha)) - n\alpha\ln(\beta) + (\alpha - 1)\sum_{i=1}^n \ln(x_i) - \frac{1}{\beta}\sum_{i=1}^n x_i$$

**c)** Demostrar que, para un valor de $\alpha$ fijado, el valor de $\beta$ que maximiza la log-verosimilitud es:

$$\hat{\beta} = \bar{x}/\alpha.$$

Observación: Deducimos de este resultado un procedimiento numérico en dos pasos para obtener el estimador de máxima verosimilitud de $(\alpha, \beta)$.

Para encontrar el máximo respecto a $\beta$ (con $\alpha$ constante), calculamos la derivada parcial de la log-verosimilitud obtenida con el apartado anterior y la igualamos a cero:

$$\frac{\partial}{\partial\beta}\ln L_n(\alpha, \beta) = 0 - n\alpha\left(\frac{1}{\beta}\right) + 0 - \left(-\frac{1}{\beta^2}\right)\sum_{i=1}^n x_i = -\frac{n\alpha}{\beta} + \frac{1}{\beta^2}\sum_{i=1}^n x_i = 0$$

Procedemos a despejar $\beta$:

$$\frac{n\alpha}{\beta} = \frac{\sum_{i=1}^n x_i}{\beta^2} \implies n\alpha\beta = \sum_{i=1}^n x_i \implies \beta = \frac{\sum_{i=1}^n x_i}{n\alpha} = \frac{n\bar{x}}{n\alpha} = \frac{\bar{x}}{\alpha}$$

# 3 Estimación por intervalos

## 3.1 Introducción

**Estimación paramétrica**

En el contexto de la estimación paramétrica, queremos aprovechar nuestro conocimiento sobre la distribución muestral del estimador, para proporcionar margen de error y riesgo.

**Boostrap**

También construiremos intervalos de confianza en percentiles Bootstrap

**Idea básica**

Supongamos:
- $X \sim \mathcal{N}(\mu, 4)$.
- Consideramos una muestra aleatoria simple $X_1, \dots, X_4$, estimaciones $\mu$ con $\bar{X}$.

Deducimos:
- Sabemos que $\bar{X} \sim \mathcal{N}(\mu, 1)$.
- Implica: el 95% de los valores de $\bar{X}$ está aproximadamente entre $\mu \pm 2$.
- Si sé donde está $\mu$, sé que, con probabilidad 0.95, $\bar{X}$ se encuentre a menos de 2 unidades.
- Ahora al revés: si he observado un valor de $\bar{X}$, ¿dónde está $\mu$? la probabilidad de que $\mu$ se encuentre a menos de 2 unidades de $\bar{X}$ es 0.95.

La probabilidad de que, habiendo observado un valor de $\bar{X}, \mu$ se encuentre a menos de 2 unidades es 0.95.

$$\mu \in \bar{X} \pm 2, \quad \text{con probabilidad } 0.95$$

- $\bar{X} \pm 2$ es un intervalo aleatorio. - Para una muestra concreta que extraigamos, será $\bar{x} \pm 2$. - $\pm 2$ expresa el margen de error. - "con probabilidad 0.95" expresa la confianza que tenemos en que nuestra información sea cierta. - Corremos un riesgo de error de 0.05 al afirmar, $\mu \in \bar{X} \pm 2$.

**Definición 3.1.1**

- *$(X_1, \dots, X_n)$ una muestra asociada a $f_\theta$.*
- *Un intervalo de estimación está ascoiado por dos estadísticos $I(X_1, \dots, X_n)$ (extremo inferior) y $D(X_1, \dots, X_n)$ (extremo superior) y persigue capturar el valor del parámetro $\theta$.*

**Un intervalo de estimación es aleatorio**

- Sus extremos dependen de la muestra concreta escogida.
- $\theta \in [I(X_1, \dots, X_n), D(X_1, \dots, X_n)]$ define un suceso aleatorio.
- La probabilidad de este suceso $\mathbb{P}_\theta[\theta \in [I(X_1, \dots, X_n), D(X_1, \dots, X_n)]]$ se llama **nivel de cobertura** del intervalo para este valor de $\theta$.
- El nivel de cobertura depende de $\theta$.

## 3.2 Nivel de confianza

### 3.2.1 Nivel de cobertura

$$\theta \mapsto \mathbb{P}_\theta[\theta \in [I(X_1, \dots, X_n), D(X_1, \dots, X_n)]]$$

El nivel de confianza es el valor mínimo del nivel de cobertura calculado cuando varía $\theta$.

**Confianza vs Precisión**

Deberemos buscar una alta confianza pero sin sacrificar en exceso la precisión.

## 3.3 Un procedimiento general de construcción

Se aplica en muchas situaciones de modelización.

**Procedimiento**

- Nos fijamos en el "nivel de riesgo", $0 < \alpha < 1$, por ejemplo, $0.1, 0.5$, o $0.01$.
- Buscamos $T(X_1, \dots, X_n)$ que se pivota, es decir, que su distribución no depende de $\theta$.
- Escogemos dos cotas $a$ y $b$:

$$\mathbb{P}_\theta[a \leq T(X_1, \dots, X_n) \leq b] = 1 - \alpha, \quad \forall \theta \in \Theta.$$

- Procuramos despejar $\theta$:

$$\mathbb{P}_\theta[I(X_1, \dots, X_n) \leq \theta \leq D(X_1, \dots, X_n)] = 1 - \alpha.$$

**Nota**

- $T$ es pivotal $\implies$ el nivel de cobertura $1 - \alpha$ de $[I(X_1, ..., X_n)]$ no depende de $\theta$.
- $1 - \alpha$ es el nivel de confianza.

## 3.4 Intervalo de confianza para la media $\mu$ de $X \sim \mathcal{N}(\mu, \sigma^2)$, $\sigma$ conocida

Consideramos una muestra aleatoria simple de una distribución $X \sim \mathcal{N}(\mu, \sigma^2)$. El valor de $\sigma^2$ es conocido

- Usaremos $\bar{X}$ para estimar $\mu$.

  Estadístico pivotal:

$$T(X_1, \dots, X_n; \theta) = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

- Dibujamos en la densidad del estadístico pivotal $\dfrac{\bar{X} - \mu}{\sigma/\sqrt{n}}$, una región central que represente el $100(1 - \alpha)\%$ del área total.

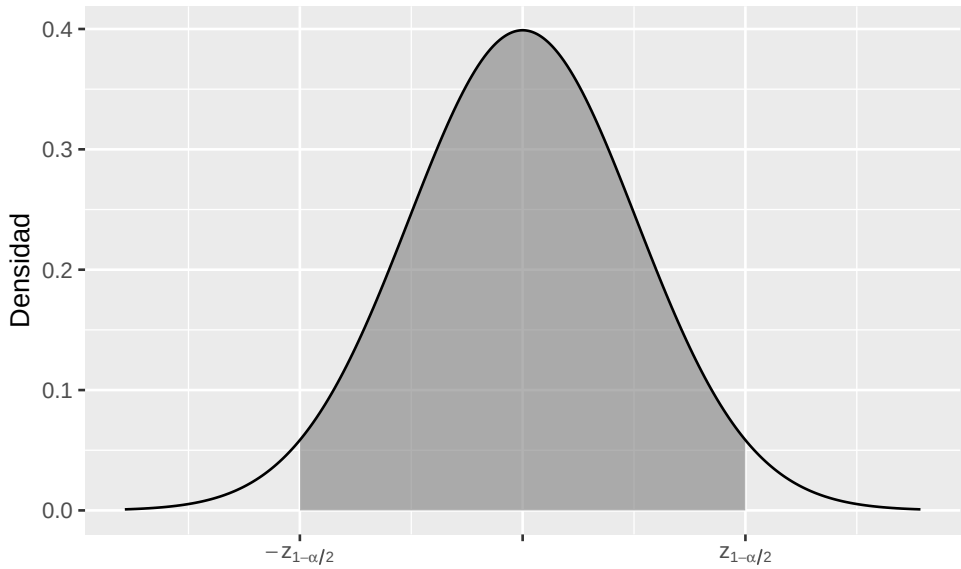


**Cuantil**

Para $0 \leq u \leq 1$, $z_u$ es el **cuantil** $u$ de una $\mathcal{N}(0, 1)$, es decir, el valor que cumple $\mathbb{P}(Z \leq z_u) = u$.

$$\mathbb{P}\left[-z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right] = 1 - \alpha.$$

Despejamos $\mu$:

- $\mathbb{P}\left[\bar{X} - z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}\right] = 1 - \alpha$
- El intervalo de confianza al $100(1 - \alpha)\%$ para $\mu$ es:

$$\mu \in \left(\bar{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}; \bar{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right).$$

- De forma equivalente: $\mu \in \bar{X} \pm z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}$.

Margen de error

$z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}$ se llama **término de error.**

### 3.4.1 Interpretación

Importante

- El intervalo de confianza $\left[\bar{X} - z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}; \bar{X} + z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}\right]$ es un intervalo **aleatorio.**
- Al extraer una muestra, tengo una probabilidad $\alpha$ de que, al afirmar que $\mu$ se encuentra en $\left[\bar{X} - z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}; \bar{X} - z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}\right]$, me equivique.

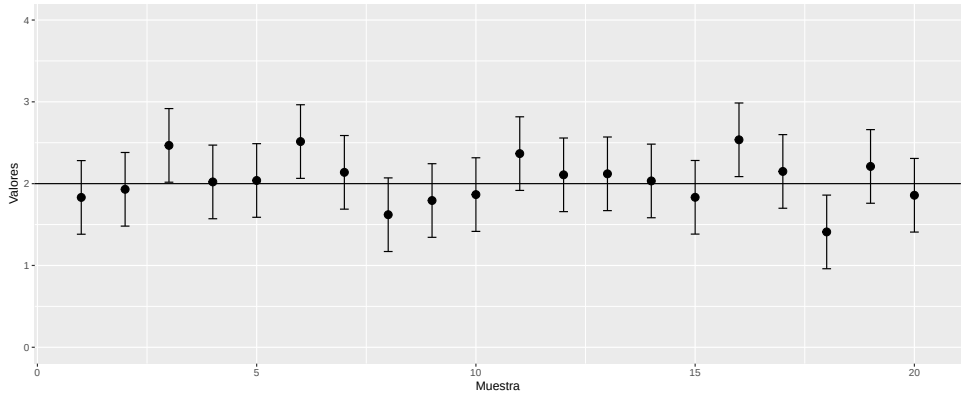


Ejemplo:

- Queremos estimar la longitud media de un artículo producido por una máquina.
- Por experiencia, sabemos que es razonable modelizar la distribución de los valores de la longitud de los artículos producidos por una distribución Normal con media $\mu$ y desviación típica a 0.05.
- Para estimar $\mu$ extraemos una muestra de 5 artículos:

$$20.1,\ 20.05,\ 19.95,\ 19.99$$

- Construir un intervalo de confianza al 90%.

$$\begin{aligned}
&\bar{x} = 20.02\\
&1-\alpha = 0.90\\
&\alpha = 0.1\\
&\frac{\alpha}{2} = 0.05\\
&\left(20.2 \mp 1.645\frac{0.05}{\sqrt{5}}\right) = (20.02 \mp 0.0367) = (19.9833, 20.0588)
\end{aligned}$$

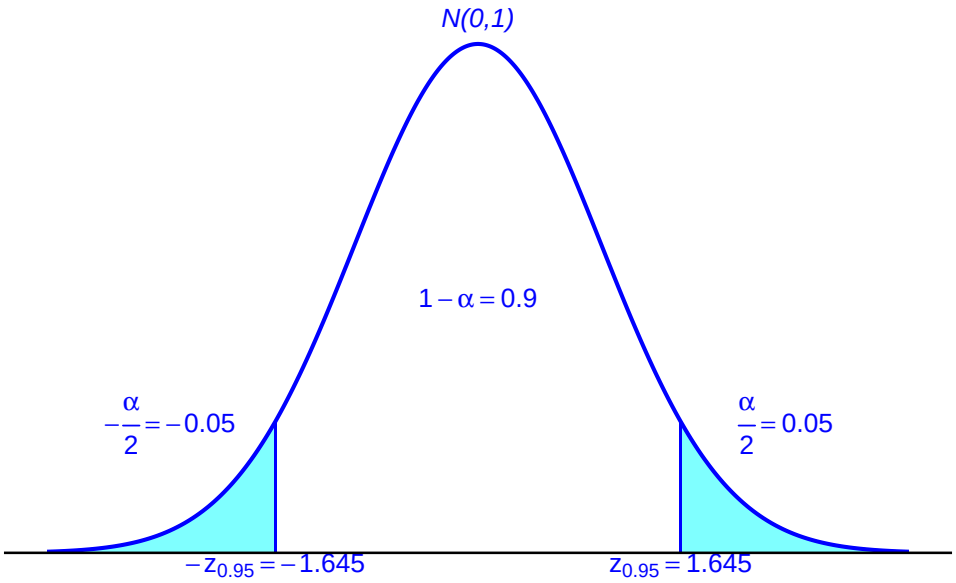


## 3.5 Comentarios importantes

Si $X$ no es Normal

- Hemos trabajado con la hipótesis de que $X$ es Normal para encontrar el estadístico pivotal $\dfrac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$.
- Si $X$ no es Normal, no podemos garantizar la confianza especificada.
- Sin embargo, si $n$ es grande, tenemos por el Teorema Central del Límite

$$\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1), \text{ aproximadamente,}$$

entonces la confianza especificada no será exacta pero casi...

### 3.5.1 Factores que afectan a la precisión de la estimación

El margen de error es $z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}}$

- $n \uparrow \rightarrow$ precisión $\uparrow$
- $\sigma \uparrow \rightarrow$ precisión $\downarrow$
- Confianza $\uparrow \rightarrow$ precisión $\downarrow$

### 3.5.2 Determinación del tamaño muestral

Contexto

Antes de extraer la muestra:
- Tenemos decidido el valor de $\sigma$.
- Tenemos decidido la confianza con la que trabajamos.
- Tenemos decidido el margen de error máximo $max$ que estamos dispuestos a cometer.

¿Qué tamaño de la muestra debemos escoger?

Margen de error: $z_{1-\alpha/2}\dfrac{\sigma}{\sqrt{n}} \leq max \rightarrow$ Despejamos $n$

### 3.5.3 Otros modelos

> $X \sim \mathcal{N}(\mu, \sigma^2)$, estimamos $\mu, \sigma$ desconocida
>
> Estadístico pivotal:
>
> $$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Debemos encontrar valores $a$ y $b$ tales que:

$$P\left[a \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq b\right]$$
$$P\left[-t_{n-1,1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1,1-\frac{\alpha}{2}}\right]$$
$$P\left[X - t_{n-1,1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq X + t_{n-1,1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}}\right] = 1 - \alpha$$

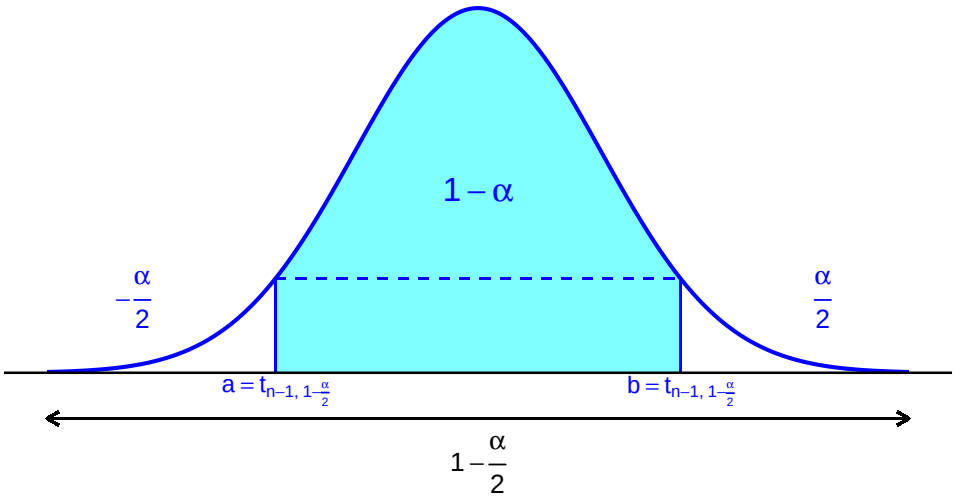


Obteniendo como I.C aleatoria a nivel $100(1-\alpha)\%$

$$X - t_{n-1,1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}}$$

> $X \sim \mathcal{N}(\mu, \sigma^2)$, estimamos $\sigma^2$
>
> Estadístico pivotal:
>
> $$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

I.C para $\sigma^2$ al nivel de confianza $(1-\alpha)100\%$

$$T = \frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2_{n-1}$$

Debemos encontrar valores $a$ y $b$ tales que: $P\left[a \leq \frac{(n-1)S^2}{\sigma^2} \leq b\right] = 1 - \alpha$

$$P\left[-\chi^2_{n-1,1-\frac{\alpha}{2}} \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{n-1,1-\frac{\alpha}{2}}\right] = 1 - \alpha$$
$$P\left[-\frac{1}{\chi^2_{n-1,1-\frac{\alpha}{2}}} \leq \frac{\sigma^2}{(n-1)S^2} \leq \frac{1}{\chi^2_{n-1,1-\frac{\alpha}{2}}}\right] = 1 - \alpha$$
$$P\left[-\frac{(n-1)S^2}{\chi^2_{n-1,1-\frac{\alpha}{2}}} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi^2_{n-1,1-\frac{\alpha}{2}}}\right] = 1 - \alpha$$

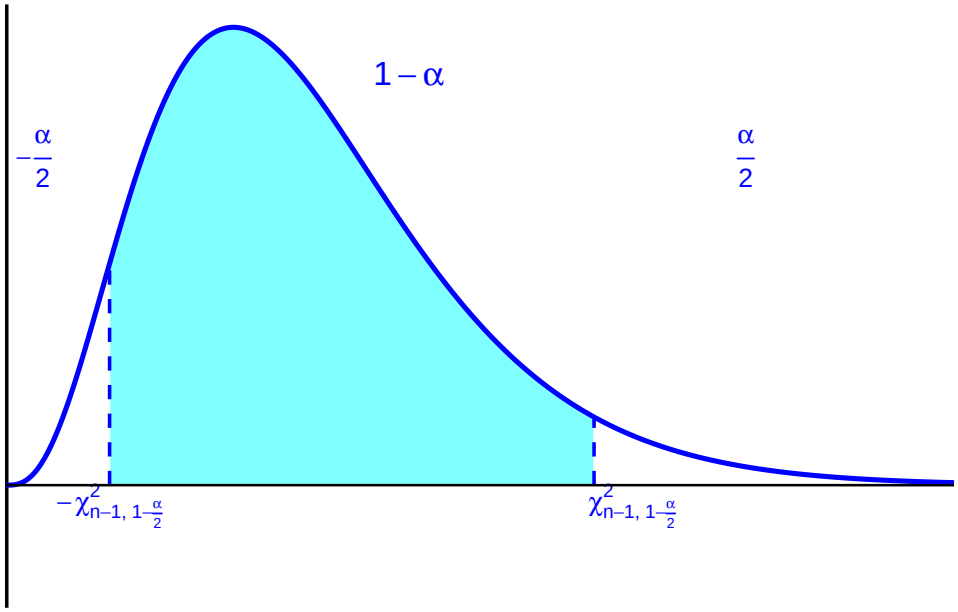


**$X \sim$ Bernoulli, estimamos $p$**

Estadístico pivotal aproximado:

$$\frac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})/n}} \sim \mathcal{N}(0,1) \quad \text{aprox.}$$

**Diferencias de dos variables aleatorias normales**

Contexto:

- $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ y $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$, independientes.
- Dos muestras aleatorias simples $X_1, \dots, X_{n_X}$ e $Y_1, \dots, Y_{n_Y}$, de $Y$.
- Suponemos que conocemos $\sigma_X^2$ y $\sigma_Y^2$.

Estadístico pivotal:

$$\frac{\bar{X}-\bar{Y}-(\mu_X-\mu_Y)}{\sqrt{\dfrac{\sigma_X^2}{n_X}+\dfrac{\sigma_Y^2}{n_Y}}} \sim \mathcal{N}(0,1).$$

**Diferencias de dos variables aleatorias normales**

Contexto:

- $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ y $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$, independientes.
- Dos muestras aleatorias simples $X_1, \dots, X_{n_X}$ e $Y_1, \dots, Y_{n_Y}$, de $Y$.
- Desconocemos $\sigma_X^2$ y $\sigma_Y^2$, pero las suponemos iguales, $\sigma_X^2 = \sigma_Y^2$.

Estadístico pivotal:

$$\frac{\bar{X}-\bar{Y}-(\mu_X-\mu_Y)}{\sqrt{\dfrac{(n_X-1)S_X^2+(n_Y-1)S_Y^2}{n_X+n_Y-2}}\sqrt{\dfrac{1}{n_X}+\dfrac{1}{n_Y}}} \sim t_{n_X+n_Y-2}.$$

**Diferencias de dos variables aleatorias normales**

Contexto:

- $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ y $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$, independientes.
- Dos muestras aleatorias simples $X_1, \dots, X_{n_X}$ e $Y_1, \dots, Y_{n_Y}$, de $Y$.

Estadístico pivotal:

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n_X-1, n_Y-1}.$$

$$P\left[a \leq \frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \leq b\right] = 1-\alpha$$
$$P\left[F_{n_X-1,n_Y-1,\frac{\alpha}{2}} \leq \frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \leq F_{n_X-1,n_Y-1,1-\frac{\alpha}{2}}\right]$$

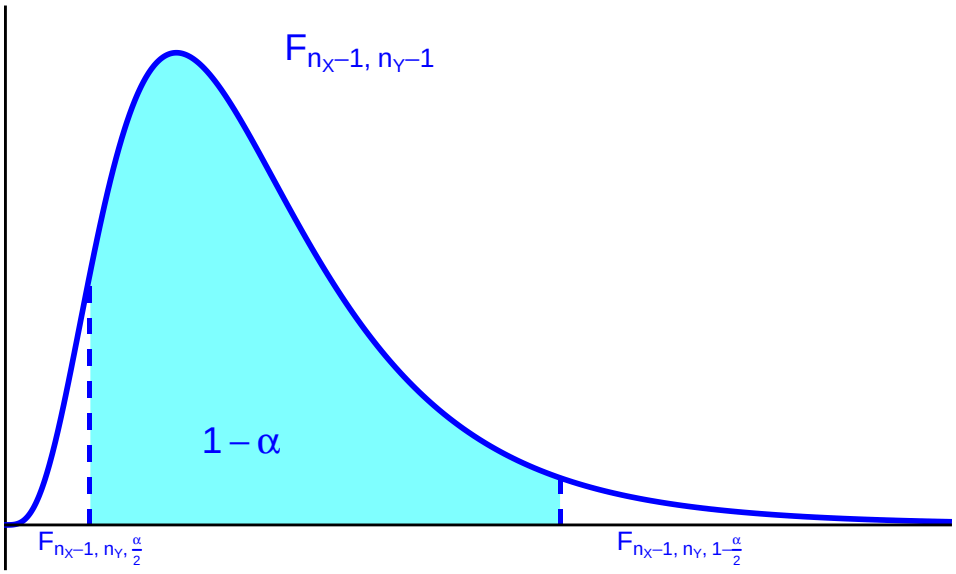


$$\boxed{P\left[\frac{S_Y^2}{S_X^2}F_{n_X-1,n_Y-1,\frac{\alpha}{2}} \leq \frac{\sigma_Y^2}{\sigma_X^2}F_{n_X-1,n_Y-1,1-\frac{\alpha}{2}}\right] = 1-\alpha}$$

```r
ingresos <- c(22010, 43950, 31416, 134200, 19298, 21521, 60025, 24320, 18221, 29528)
```

```r
library(tidyverse)
B <- 200
lista_boot_muestras <- replicate(
    B,
    sample(ingresos, size = length(ingresos), replace = TRUE),
    simplify = FALSE
)
valores_medianas <- map_dbl(lista_boot_muestras, median)
error_estandar_estimacion <- sd(valores_medianas)
```

En el ejemplo de los ingresos, obtenemos para la mediana: $26924 \pm 12311$.

**La construcción anterior es una aproximación**

- Es posible, en particular si $n$ no es grande o si la distribución es asimétrica, que el nivel de confianza no sea correcto.
- Siempre produce intervalos simétricos, lo que puede ser una limitación.
- Para mejorar la veracidad del intervalo construido, vamos a ver el intervalo de confianza basado en percentiles Bootstrap.

**Procedimiento**

- Habiendo observado una muestra $\mathbf{x}$, queremos estimar $\theta$, usando un estimador $\hat{\theta} = T(\mathbf{x})$.
- Simulamos un gran número $B$ de muestras Boostrap a partir de $\mathbf{x}$, obteniendo $\mathbf{x}^{*1}, \ldots, \mathbf{x}^{*n}$.
- Calculamos para cada muestra Boostrap, $\hat{\theta}^{*b} = T(\mathbf{x}^{*b})$.
- Si $1-\alpha$ es el nivel de confianza, consideramos el conjunto $\hat{\theta}^{*1}, \ldots, \hat{\theta}^{*B}$ y calculamos:
  - $\hat{\theta}^{(\alpha/2)}$ el percentile $100 \cdot \dfrac{\alpha}{2}$.
  - $\hat{\theta}^{(1-\alpha/2)}$ el percentile $100 \cdot \left(1 - \dfrac{\alpha}{2}\right)$.
- Nuestro intervalo al $100(1-\alpha)$ es $[\hat{\theta}^{(\alpha/2)}, \hat{\theta}^{(1-\alpha/2)}]$.

¿Cómo se calcula el percentile $100 \cdot p$?

Si tenemos un conjunto $\hat{\theta}^{*1}, \dots, \hat{\theta}^{*B}$, $B$ grande, para calcular el percentil $100 \cdot p$ para $0 \leq p \leq 1$, podemos seguir estos pasos:

- Ordenamos los datos de menos a mayor.
- Calculamos un índice como $u = p \times (B + 1)$, donde $B$ es el número de observaciones.
- Si $i$ es un número entero, podemos interpolar entre los puntos de datos adyacentes.
  - Existen distintas posibilidades para la interpolación.
  - En **R**: Usamos la función **`quantile`**, que admite hasta 9 tipos de interpolación con el argumento **`type`**.

### 3.5.4 Aplicación con el ejemplo de los ingresos

Simulamos $B = 10000$ muestras Boostrap, calculamos las 10000 medianas $\hat{\theta}^{*1}, \dots, \hat{\theta}^{*10000}$ y hacemos un histograma.

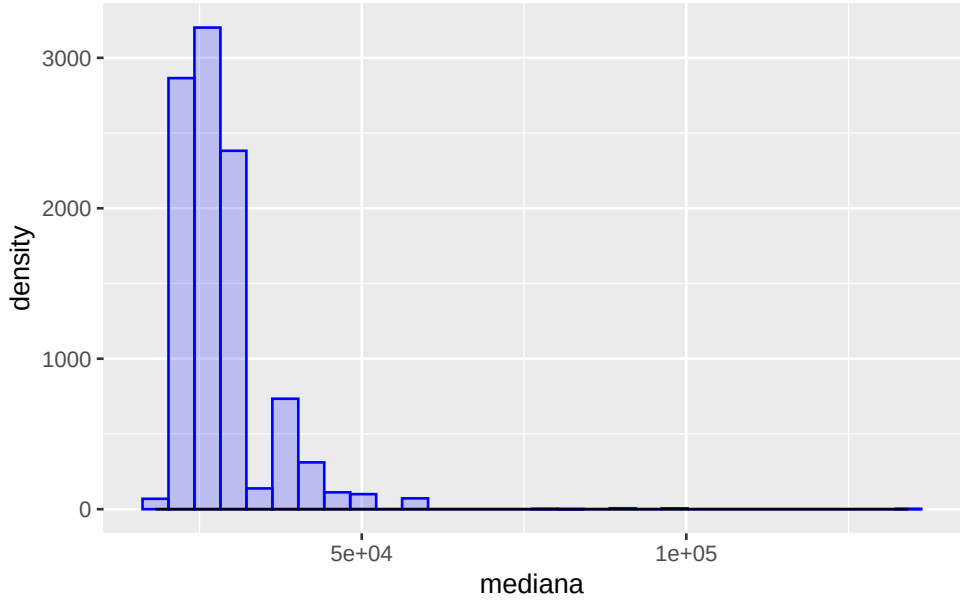


Calculamos los percentiles 2.5% y 97.5%

```
str_glue("El intervalo basado en percentiles Bootstrap para la mediana es:
         [{formatC(quantile(valores_medianas, 0.025), format = 'd')},
          {formatC(quantile(valores_medianas, 0.975), format = 'd')}]")
```

```
El intervalo basado en percentiles Bootstrap para la mediana es:
[20654,
 45720]
```

Recordad que, con la aproximación $\hat{\theta}_n + 1 - 96 \cdot \hat{se}$,

habíamos obtenido $[14612, 39235]$.

```
[1]  22010  43950  31416 134200  19298  21521  60025  24320  18221  29528
```

# Hoja 3: Intervalos de confianza

**1)** Sea $X \sim N(\mu, \sigma^2)$ y se considera una m.a.s. de tamaño de $X$.

**a)** Suponiendo $\sigma^2$ conocida obtener un intervalo de confianza para $\mu$ con nivel de confianza $1-\alpha$. Determinar el tamaño de muestra necesario para estimar $\mu$ con una precisión $\pm\delta$.

1) Construcción del Intervalo de Confianza

Partimos de una muestra aleatoria simple de $X \sim \mathcal{N}(\mu, \sigma^2)$ con $\sigma$ conocida.

El estadístico pivotal a utilizar es:

$$T = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

Fijamos el nivel de confianza $1-\alpha$ y escogemos las cotas centrales en la distribución normal estándar:

$$\mathbb{P}\left[-z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right] = 1-\alpha$$

Dejamos el parámetro $\mu$:

$$\mathbb{P}\left[-z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \bar{X} - \mu \leq z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = 1-\alpha$$

Multiplicando por $-1$ e invirtiendo las desigualdades:

$$\mathbb{P}\left[\bar{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = 1-\alpha$$

El intervalo de confianza al $100(1-\alpha)\%$ es:

$$IC_{1-\alpha}(\mu) = \left(\bar{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right)$$

2) Determinación del tamaño de muestra ($n$) para precisión $\delta$

El margen de error (o precisión) del intervalo es el término $z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}$.

Establecemos la inecuación donde el margen de error debe ser menor o igual a la precisión máxima $\delta$:

$$z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \delta$$

Despejamos $n$:

$$\sqrt{n} \geq \frac{z_{1-\alpha/2}\sigma}{\delta}$$
$$n \geq \left(\frac{z_{1-\alpha/2}\sigma}{\delta}\right)^2$$

**b)** Suponiendo $\sigma^2$ desconocida, obtener un intervalo de confianza óptimo para $\mu$ con nivel de confianza $1-\alpha$. Determinar el tamaño de muestra necesario para estimar $\mu$ con una precisión $\pm\delta$.

1) Construcción del Intervalo de Confianza

Para $X \sim \mathcal{N}(\mu, \sigma^2)$ estimamos $\mu$ con $\sigma^2$ desconocida.

El estadístico pivotal cambia, utilizando la desviación típica muestral $S$:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Aplicando el procedimiento general, fijamos las cotas usando los cuantiles de la distribución t de Student con $n-1$ grados de libertad:

$$\mathbb{P}\left[-t_{n-1,1-\alpha/2} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1,1-\alpha/2}\right] = 1-\alpha$$

Despejando $\mu$ de forma análoga al caso anterior:

$$\mathbb{P}\left[-t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}} \leq \bar{X} - \mu \leq t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}\right] = 1-\alpha$$
$$\mathbb{P}\left[\bar{X} - t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}\right] = 1-\alpha$$

El intervalo de confianza óptimo es:

$$IC_{1-\alpha}(\mu) = \left(\bar{X} - t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}, \bar{X} + t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}\right)$$

2) Determinación del tamaño de muestra ($n$) para precisión $\delta$

El margen de error ahora depende de $S$ y de la distribución t de Student. Igualamos a la precisión deseada $\delta$:

$$t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}} \leq \delta$$

Despejamos $n$:

$$\sqrt{n} \geq \frac{t_{n-1,1-\alpha/2}S}{\delta}$$
$$n \geq \left(\frac{t_{n-1,1-\alpha/2}S}{\delta}\right)^2$$

**2)** Sea $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ independientes. Se considera una m.a.s. de tamaño $n_1$ de $X$ y una m.a.s. de tamaño $n_2$ de $Y$.

**a)** Suponiendo $\sigma_1^2$ y $\sigma_2^2$ conocidas obtener un intervalo de confianza para $\mu_1 - \mu_2$ con nivel de confianza $1-\alpha$.

1) Estadístico pivotal:

Para diferencias de dos variables aleatorias normales independientes con varianzas conocidas, el estadístico pivotal es:

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1)$$

2) Procedimiento general de construcción:

Fijamos el nivel de riesgo $\alpha$ y establecemos las cotas usando los cuantiles de la distribución normal estándar:

$$\mathbb{P}\left[-z_{1-\alpha/2} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq z_{1-\alpha/2}\right] = 1-\alpha$$

3) Despeje del parámetro $(\mu_1 - \mu_2)$:

Multiplicamos por el denominador:

$$\mathbb{P}\left[-z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq (\bar{X} - \bar{Y}) - (\mu_1 - \mu_2) \leq z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{n_2}}\right] = 1-\alpha$$

Multiplicamos por $-1$ e invertimos las desigualdades, sumando $(\bar{X} - \bar{Y})$ a todos los términos:

$$\mathbb{P}\left[(\bar{X} - \bar{Y}) - z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq (\bar{X} - \bar{Y}) + z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right] = 1-\alpha$$

4) Intervalo de confianza final:

$$IC_{1-\alpha}(\mu_1 - \mu_2) = \left((\bar{X} - \bar{Y}) - z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$$

**b)** Suponiendo $\sigma_1^2$ y $\sigma_2^2$ desconocidas pero iguales, obtener un intervalo de confianza para $\mu_1 - \mu_2$ con nivel de confianza $1-\alpha$.

1) Estadístico pivotal:

Bajo la asunción de varianzas iguales per desconocidas, se utiliza un estimador combinado para la varianza y el estadístico se distribuye como una t de Student con $n_1 + n_2 - 2$ grados de libertad:

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

Sea $S_p = \sqrt{\dfrac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}$. Podemos reescribir:

$$T = \frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

2) Procedimiento general de construcción:

Fijamos las cotas usando los cuantiles correspondientes a la distribución t:

$$\mathbb{P}\left[-t_{n_1+n_2-2,1-\alpha/2} \leq \frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \leq t_{n_1+n_2-2,1-\alpha/2}\right] = 1-\alpha$$

3) Despeje del parámetro $(\mu_1-\mu_2)$:

$$\mathbb{P}\left[-t_{n_1+n_2-2,1-\alpha/2}S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}} \leq (\bar{X}-\bar{Y})-(\mu_1-\mu_2) \leq t_{n_1+n_2-2,1-\alpha/2}S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right]$$
$$\mathbb{P}\left[(\bar{X}-\bar{Y})-t_{n_1+n_2-2,1-\alpha/2}S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}} \leq \mu_1-\mu_2 \leq (\bar{X}-\bar{Y})+t_{n_1+n_2-2,1-\alpha/2}S_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right]$$

4) Intervalo de confianza final:

Sustituyendo $S_p$ por su valor completo:

$$IC_{1-\alpha}(\mu_1-\mu_2) = \left((\bar{X}-\bar{Y}) \pm t_{n_1+n_2-2,1-\alpha/2}\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right)$$

**3)** Sea $X \sim \mathcal{N}(\mu,\sigma^2)$. Se considera una muestra aleatoria simple de tamaño $n$ de $X$. Suponiendo $\mu$ desconocida obtener un intervalo de confianza para $\sigma^2$ con nivel de confianza $1-\alpha$.

1) Estadístico pivotal:

Para una muestra de $X \sim \mathcal{N}(\mu,\sigma^2)$ donde estimamos $\sigma^2$, el estadístico pivotal se distribuye según una Chi-cuadrado con $n-1$ grados de libertad:

$$T = \frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2_{n-1}$$

2) Procedimiento general de construcción:

Fijamos el nivel de confianza $1-\alpha$ y establecemos las cotas de probabilidad usando los cuantiles de la distribución $\chi^2_{n-1}$:

$$\mathbb{P}\left[\chi^2_{n-1,\alpha/2} \leq \frac{(n-1)S_n^2}{\sigma^2} \leq \chi^2_{n-1,1-\alpha/2}\right] = 1-\alpha$$

3) Despeje del parámetro $\sigma^2$:

Para despejar $\sigma^2$, primero invertimos las fracciones, lo cual invierte el sentido de las desigualdades matemáticas:

$$\mathbb{P}\left[\frac{1}{\chi^2_{n-1,1-\alpha/2}} \leq \frac{\sigma^2}{(n-1)S_n^2} \leq \frac{1}{\chi^2_{n-1,\alpha/2}}\right] = 1-\alpha$$

A continuación, multiplicamos todos los términos de la inecuación por el numerador $(n-1)S_n^2$ para aislar el parámetro:

$$\mathbb{P}\left[\frac{(n-1)S_n^2}{\chi^2_{n-1,1-\alpha/2}} \leq \sigma^2 \leq \frac{(n-1)S_n^2}{\chi^2_{n-1,\alpha/2}}\right] = 1-\alpha$$

4) Intervalo de confianza:

Expresado en forma de intervalo:

$$IC_{1-\alpha}(\sigma^2) = \left(\frac{(n-1)S_n^2}{\chi^2_{n-1,1-\alpha/2}}, \frac{(n-1)S_n^2}{\chi^2_{n-1,\alpha/2}}\right)$$

**4)** Sea $X$ una población con función de densidad

$$f(x,\theta) = \frac{2x}{\theta^2} \text{ para } x \in (0,\theta),$$

siendo $\theta$ un parámetro positivo desconocido. Se considera una muestra aleatoria simple de tamaño $n$ de $X$. Obtener el intervalo de confianza óptima para $\theta$ con nivel de confianza $1-\alpha$.

1) Distribución del estadístico suficiente

Dado que el dominio de la variable depende del parámetro $\theta$, el estimador natural es el máximo muestral $X_{(n)} = \max(X_1, \dots, X_n)$.

Primero calculamos la función de distribución de $X$:

$$F_X(x) = \int_0^x \frac{2t}{\theta^2}\,\mathrm{d}t = \frac{x^2}{\theta^2}$$

La función de distribución del máximo $X_{(n)}$ es:

$$F_{X_{(n)}} = [F_X(t)]^n = \left(\frac{t^2}{\theta^2}\right)^n = \frac{t^{2n}}{\theta^{2n}}, \qquad \text{para } 0 < t < \theta$$

2) Estadístico pivotal

Definimos el estadístico $T = \dfrac{X_{(n)}}{\theta}$. Buscamos su función de distribución:

$$F_T(t) = \mathbb{P}\left[\frac{X_{(n)}}{\theta} \le t\right] = \mathbb{P}[X_{(n)} \le t\theta] = \frac{(t\theta)^{2n}}{\theta^{2n}} = t^{2n}, \qquad \text{para } 0 < t < 1$$

Derivando, obtenemos su función de densidad:

$$f_T(t) = 2nt^{2n-1}, \qquad \text{para } 0 < t < 1$$

Como esta distribución no depende de $\theta$, $T$ es un estadístico pivotal válido.

3) Procedimiento de construcción óptima

Notamos que la densidad $f_T(t) = 2nt^{2n-1}$ es una función estrictamente creciente en $(0,1)$. Para obtener un intervalo óptimo (de longitud mínima para $\theta$), debemos concentrar la probabilidad en la región de mayor densidad, que es el extremo derecho. Por tanto, fijamos la cota superior en $b = 1$ y buscamos la cota inferior $a$:

$$\mathbb{P}\left[a \le \frac{X_{(n)}}{\theta} \le 1\right] = 1-\alpha$$

Resolvemos la integral para encontrar $a$:

$$\begin{gathered}
\int_a^1 2nt^{2n-1}\,\mathrm{d}t = 1-\alpha \\
\left[t^{2n}\right]_a^1 = 1-\alpha \\
1-a^{2n} = 1-\alpha \\
a^{2n} = \alpha \implies a = \alpha^{\frac{1}{2n}}
\end{gathered}$$

4) Despeje del parámetro $\theta$

Sustituimos la cota $a$ en la expresión de probabilidad:

$$\mathbb{P}\left[\alpha^{\frac{1}{2n}} \le \frac{X_{(n)}}{\theta} \le 1\right] = 1-\alpha$$

Invertimos las fracciones (lo que invierte el sentido de las desigualdades):

$$\mathbb{P}\left[1 \le \frac{\theta}{X_{(n)}} \le \frac{1}{\alpha^{\frac{1}{2n}}}\right] = 1-\alpha$$

Multiplicamos todo por $X_{(n)}$:

$$\mathbb{P}\left[X_{(n)} \le \theta \le X_{(n)}\alpha^{-\frac{1}{2n}}\right] = 1-\alpha$$

5) Intervalo de confianza final

$$IC_{1-\alpha}(\theta) = \left[X_n, \frac{X_{(n)}}{\alpha^{\frac{1}{2n}}}\right]$$

**5)** Sea $X$ una población con función de densidad

$$f(x,\theta) = \exp(-(x-\theta)), \text{ para } x \in (\theta, +\infty),$$

siendo $\theta$ un parámetro positivo desconocido. Se considera una muestra aleatoria simple de tamaño $n$ de $X$. Obtener el intervalo de confianza óptima para $\theta$ con nivel de confianza $1-\alpha$.

1) Distribución del estadístico suficiente

Dado que el dominio de la variable depende del parámetro $\theta\,(x > \theta)$, el estimador natural es el mínimo muestral $X_{(1)} = \min(X_1, \dots, X_n)$.

Primero calculamos la función de distribución de $X$:

$$F_X(x) = \int_\theta^x e^{-(t-\theta)}\,\mathrm{d}t = [-e^{-(t-\theta)}]_\theta^x = 1 - e^{-(x-\theta)}$$

La función de distribución del mínimo $X_{(1)}$ se obtiene como:

$$F_{X_{(1)}}(t) = 1 - [1 - F_X(t)]^n = 1 - [e^{-(t-\theta)}]^n = 1 - e^{-n(t-\theta)} = 1 - e^{-nt}, \quad \text{para } t > \theta$$

2) Estadístico pivotal

Definimos el estadístico $T = X_{(1)} - \theta$. Buscamos su función de distribución:

$$F_T(t) = \mathbb{P}[X_{(1)} - \theta \le t] = \mathbb{P}[X_{(1)} \le t + \theta] = 1 - e^{-n(t+\theta-\theta)} = 1 - e^{-nt}, \quad \text{para } t > 0$$

Derivando, obtenemos su función de densidad:

$$f_T(t) = ne^{-nt}, \quad \text{para } t > 0$$

Dado que esta distribución (Exponencial de parámetro $n$) no depende de $\theta$, $T$ es un estadístico pivotal válido.

3) Procedimiento de construcción óptima

La longitud del intervalo de confianza para $\theta$ dependerá de la diferencia entre las cotas $b$ y $a$. Para que el intervalo sea óptimo (de longitud mínima), debemos concentrar la probabilidad en la región donde la densidad del estadístico es mayor.

Como la función $f_T(t) = ne^{-nt}$ es estrictamente decreciente en su dominio, la mayor densidad se encuentra pegada al origen. Por lo tanto, fijamos la cota inferior en $a = 0$ y calculamos la cota superior $b$:

$$\mathbb{P}[0 \le X_{(1)} - \theta \le b] = 1 - \alpha$$

Resolvemos la integral para encontrar $b$:

$$\int_0^b ne^{-nt}\,\mathrm{d}t = 1 - \alpha$$
$$[-e^{-nt}]_0^b = 1 - \alpha$$
$$1 - e^{-nb} = 1 - \alpha$$
$$e^{-nb} = \alpha \implies -nb = \ln(\alpha) \implies b = \frac{-\ln(\alpha)}{n}$$

4) Despeje del parámetro $\theta$

Sustituimos los valores de $a$ y $b$ en la expresión inicial:

$$\mathbb{P}\left[0 \le X_{(1)} - \theta \le \frac{-\ln(\alpha)}{n}\right] = 1 - \alpha$$

Restamos $X_{(1)}$ a todos los términos de la inecuación:

$$\mathbb{P}\left[-X_{(1)} \le -\theta \le -X_{(1)} - \frac{\ln(\alpha)}{n}\right] = 1 - \alpha$$

Multiplicamos por $-1$, lo que invierte el sentido de las desigualdades:

$$\mathbb{P}\left[X_{(1)} + \frac{\ln(\alpha)}{n} \le \theta \le X_{(1)}\right] = 1 - \alpha$$

5) Intervalo de confianza final

$$IC_{1-\alpha}(\theta) = \left[X_{(1)} + \frac{\ln(\alpha)}{n}, X_{(1)}\right]$$

**6)** En un laboratorio, se estudia la velocidad de combustión de dos tipos de combustibles sólidos A y B. Se pretende determinar qué combustibles presentan una velocidad de combustión en promedio mayor de 50 cm/s. Los resultados obtenidos fueron:

| Combustible | Tamaño muestral | Media muestral | Varianza muestral |
|---|---|---|---|
| A | 25 | 51.3 | 3.9 |
| B | 30 | 51.5 | 3.6 |

Suponiendo que la distribución de las variables es normal, se pide:

**a)** Obtener un intervalo de confianza al 95% para la velocidad esperada para el combustible A y otro para el combustible B.

Dado que las varianzas poblacionales ($\sigma^2$) son desconocidas, utilizamos el siguiente estadístico pivotal:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Despejando $\mu$, la estructura general del intervalo es:

$$IC_{1-\alpha}(\mu) = \left(\bar{x} - t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}, \bar{x} - t_{n-1,1-\alpha/2}\frac{S}{\sqrt{n}}\right)$$

**Para el combustible A:**

Sustituimos los datos y el cuantil de la distribución t de Student con $n_A - 1 = 24$ grados de libertad:

$$IC_{0.95}(\mu_A) = \left(51.3 - t_{24,0.975}\sqrt{\frac{3.9}{25}}, 51.3 + t_{24,0.975}\sqrt{\frac{3.9}{25}}\right)$$

**Para el combustible B:**

Sustituimos los datos y el cuantil de la distribución t de Student con $n_B - 1 = 29$ grados de libertad:

$$IC_{0.95}(\mu_B) = \left(51.5 - t_{29,0.975}\sqrt{\frac{3.6}{30}}, 51.5 + t_{29,0.975}\sqrt{\frac{3.6}{30}}\right)$$

**b)** Obtener un intervalo de confianza al 95% para la varianza de la velocidad de combustión del combustible A y la velocidad esperada para el combustible B.

**Para la varianza del combustible A ($\sigma_A^2$):**

El estadístico pivotal para la varianza de una población normal con media desconocida es:

$$T = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

Despejando $\sigma^2$, obtenemos el intervalo:

$$IC_{1-\alpha}(\sigma^2) = \left(\frac{(n-1)S^2}{\chi^2_{n-1,1-\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{n-1,\alpha/2}}\right)$$

Sustituyendo los datos para el combustible A (con 24 grados de libertad):

$$IC_{0.95}(\sigma_A^2) = \left(\frac{(25-1)\cdot 3.9}{\chi^2_{24,0.975}}, \frac{(25-1)\cdot 3.9}{\chi^2_{24,0.025}}\right) = \left(\frac{93.6}{\chi^2_{24,0.975}}, \frac{93.6}{\chi^2_{24,0.025}}\right)$$

Para la velocidad esperada del combustible B ($\mu_B$):

Dado que el enunciado vuelve a solicitar la velocidad esperada para el combustible B, el intervalo es exactamente el mismo que el calculado en el apartado anterior:

$$IC_{0.95}(\mu_B) = \left(51.5 - t_{29,0.975}\sqrt{\frac{3.6}{30}}, 51.5 + t_{29,0.975}\sqrt{\frac{3.6}{30}}\right)$$

# 4 Constrastes de hipótesis

## 4.1 Introducción

Basándonos en una muestra, queremos decidir entre dos opciones o hipótesis acerca de la distribución de interés en la población.

Las hipótesis pueden verter sobre:

- La forma de la distribución: ¿Es una Poisson? ¿Es una Normal? Constrastes no paramétricos.
- Los paramétricos de la distribución, si suponemos dada la familia paramétrica. Constrastes paramétricos.
- Si consideramos dos variables, ¿existe una relación de dependencia? Constrastes no paramétricos.

## 4.2 Constrastes de hipótesis paramétricos

### 4.2.1 Elementos principales

**!** Idea básica

Un **test de hipótesis** es una regla que nos lleva a decidir si lo observado en la muestra es compatible con una hipótesis planteada sobre los parámetros del modelo.

**i** Ejemplo

Un nuevo medicamento pretende mejorar un medicamento en el mercado, que tiene probabilidad $\theta_0 = 0.7$ de curar un paciente.

- Planteamos $X \sim \text{Bernoulli}(\theta), X = 1 \leftrightarrow$ el paciente se cura con el medicamento nuevo.
- Lanzamos el nuevo medicamento si $\theta > \theta_0 + 0.15$, es decir, que debemos decidir entre

$$\begin{aligned} H_0 &: \theta \leq \theta_0 + 0.15 \\ H_1 &: \theta > \theta_0 + 0.15 \end{aligned}$$

- Consideramos una muestra aleatoria simple de tamaño 100, el estadístico $T(X_1, \dots, X_{100}) = \sum_{i=1}^{100} X_i$, resumen de la información muestral.
- Posible test:
  - Aceptamos $H_0$ si $\sum_{i=1}^{100} X_i \leq 85$.
  - Rechazamos $H_0$ si $\sum_{i=1}^{100} X_i > 85$.

Si queremos ser más conservadores: aceptamos $H_0$ si $\sum_{i=1}^{100} X_i \leq 90$, y rechazamos $H_0$ si $\sum_{i=1}^{100} X_i > 90$.

**i** Podemos cometer dos tipos de errores:

- Rechazar una hipótesis verdadera.
- Aceptar una hipótesis falsa.

### 4.2.2 Formulación general del contraste de hipótesis

**Contexto**

- $X \sim F(x, \theta)$, con $\theta \in \Theta \subseteq \mathbb{R}^p$.
- $\mathbf{X} = (X_1, X_2, \dots, X_n)$ una muestra aleatoria simple de $X$.
- $\Theta_0$ y $\Theta_1$ dos subcojuntos del espacio paramétrico $\Theta$ tales que: $\Theta = \Theta_0 \cup \Theta_1$ y $\Theta_0 \cap \Theta_1 = \emptyset$.

**Definición**

Un test o contraste es una regla basada en $\mathbf{X}$ para decidir entre las dos hipótesis:

$$H_0 : \theta \in \Theta_0 \text{ vs } H_1 : \theta \in \Theta_1.$$

**Llamamos**

- $H_0$: hipótesis nula.
- $H_1$: hipótesis alternativa.

**Definición**

Se llama test (no aleatorio) a una función: $\delta : sop(\mathbf{X}) \to \{0, 1\}$ tal que:
- si $\delta(\mathbf{x}) = 0$ se acepta la hipótesis nula $H_0$,
- si $\delta(\mathbf{x}) = 1$ se rechaza la hipótesis $H_0$.

**Notación**

- $sop(\mathbf{X})$ es el soporte de $\mathbf{X}$, que es el conjunto donde $f(x)$, la función puntual de probabilidad (caso discreto) o la función densidad (caso continuo) de $\mathbf{X}$ es $> 0$.
- Denotaremos por $T$ el conjunto de tests definidos sobre el $sop(\mathbf{X})$.

Dado un test $\delta \in T$ se definen los siguientes conjuntos:

**Definición**

- Región de aceptación:
$$S_0 = \{\mathbf{x} \in sop(\mathbf{X}) : \delta(\mathbf{x}) = 0\}.$$
- Región de rechazo:
$$S_1 = \{\mathbf{x} \in sop(\mathbf{X}) : \delta(\mathbf{x}) = 1\}.$$

#### 4.2.2.1 Errores

**Definimos los errores asociados:**

- Error de tipo I: rechazar $H_0$ cuando es cierta.
- Error de tipo II: aceptar $H_0$ cuando es falsa.

**Resumen**

| | $\mathbf{X} \in S_1$ | $\mathbf{X} \in S_0$ |
|---|---|---|
| $\theta \in \Theta_0$ | Error tipo I | Correcto |
| $\theta \in \Theta_1$ | Correcto | Error tipo II |

Recordad, $S_0$ región de aceptación, $S_1$ región de rechazo.

**Definimos las probabilidades asociadas, para un test $\delta$ dado,**

- La probabilidad de cometer un error de tipo I, si el valor del parámetro es $\theta$, se denota por:
$$\text{Si } \theta \in \Theta_0 : \quad P_{I,\delta}(\theta) = P_\theta(\mathbf{X} \in S_1).$$

- La probabilidad de cometer un error de tipo II, si el valor del parámetro es $\theta$, se denota por:

$$\text{Si } \theta \in \Theta_1: \quad P_{II,\delta}(\theta) = P_\theta(\mathbf{X} \in S_0).$$

**¿Qué buscamos?**

Queremos encontrar un test $\delta$ con $P_{I,\delta}(\theta)$ y $P_{II,\delta}(\theta)$ lo más pequeñas posibles simultáneamente.

**Ejemplo de test: control de calidad**

**Contexto**

- En la producción de un artículo electrónico, se cuida que la tensión que circula por un componente es 10mV. Hay variabilidad en la tensión conseguida en los artículos producidos, que pensamos modelizar por una Normal con desviación típica 0.05.
- Para controlar la calidad de los artículos producidos, se escogen al azar cada día 20 artículos y se mida su tensión.
- ¿Qué regla podríamos fijar que describa cuándo debe saltar una alarma si parece que la tensión se aleja de 10mV?

**Traducimos el contexto**

- $X$: tensión medida en un artículo escogido al azar en la producción. $X \sim \mathcal{N}(\mu, 0.025)$.
- $\mathbf{X} = (X_1, X_2, \dots, x_{20})$ una muestra aleatoria simple de $X$ de tamaño 20.
- Queremos controlar si $\mu = 10$.

- Planteamos las hipótesis:

$$H_0 : \mu = 10 H_1 : \mu \neq 10$$

- Nuestra regla, es decir nuestro test $\delta$, se basará en $\bar{\mathbf{X}}$:
  - si $\bar{\mathbf{X}}$ está "alejado" de 10, rechazaremos $H_0$.
  - si $\bar{\mathbf{X}}$ está "cerca" de 10, aceptaremos $H_0$.

**Nuestra regla**

Nos fijamos un umbral $u$,
- si $\bar{X} < 10 - u$ ó $\bar{X} > 10 + u$, rechazaremos $H_0$.
- si $10 - u \leq \bar{X} \leq 10 + u$, aceptaremos $H_0$.
- $\delta(\mathbf{x}) = 1$, si $|\bar{X} - 10| > u$.
- $\delta(\mathbf{x}) = 0$, si $|\bar{X} - 10| \leq u$.

**Calculamos las probabilidades de error**

Si $\mu = 10$,

$$P_\mu(\text{rechazar } H_0) = P_\mu(|\bar{X} - 10| > u) = 1P\left(Z > \frac{u}{0.05/\sqrt{20}}\right)$$

Si $\mu \neq 10$,

$$P_\mu(\text{aceptar } H_0) = P_\mu(|\bar{X} - 10| \leq u) = P\left(\frac{10 - u - \mu}{0.05/\sqrt{20}} \leq Z \leq \frac{10 + u - \mu}{0.05/\sqrt{20}}\right)$$

Por ejemplo, si fijamos $u = 0.025$, $P_\mu(\text{rechazar } H_0) = 0.03$

Podemos variar $u$:

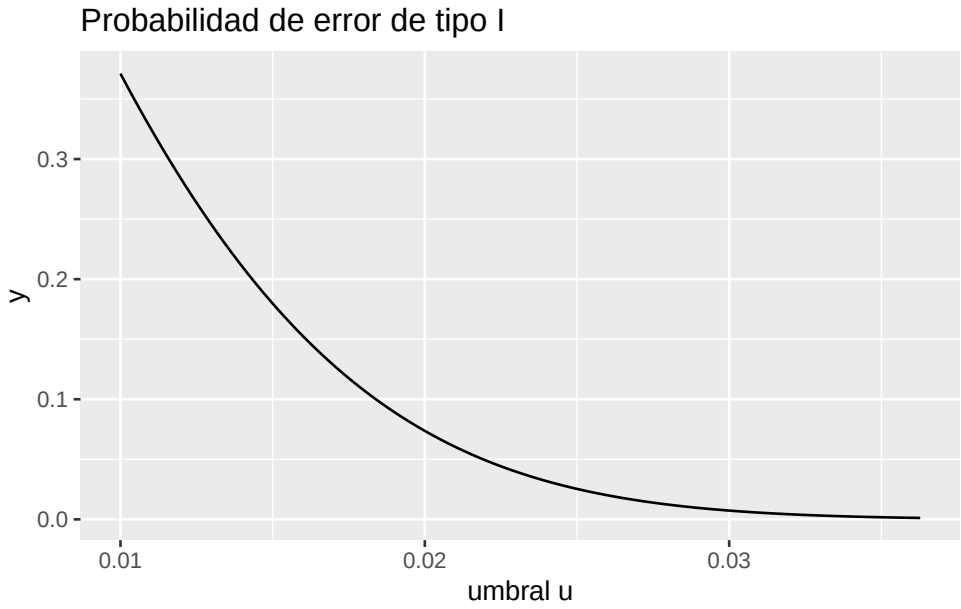


Si fijamos $u = 0.02$, tenemos una probabilidad de error de tipo I de 0.05.

¿Qué pasa con la probabilidad de error de tipo II?

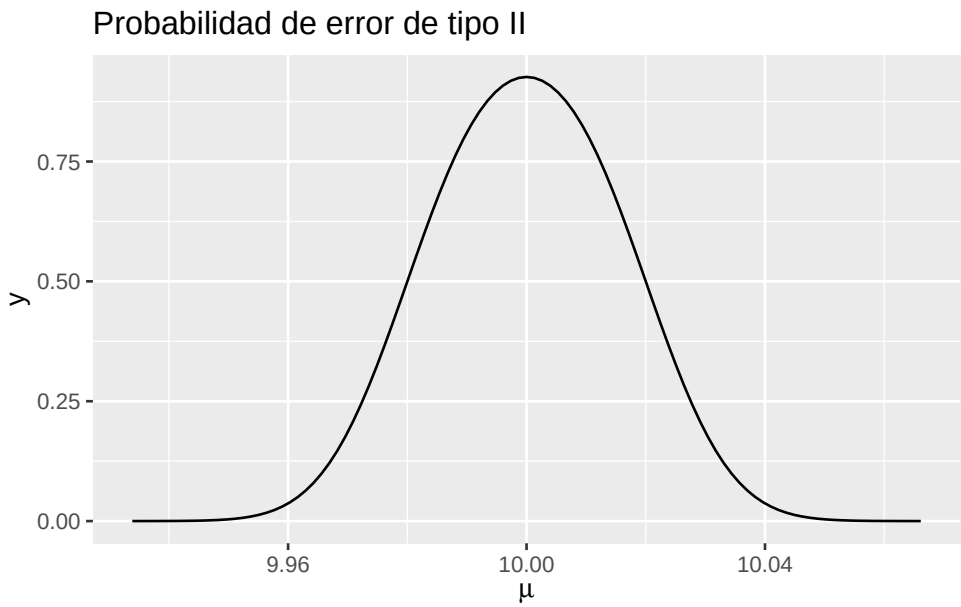


Queremos detectar $\mu = 10.05$ con un probabilidad suficiente pero a la vez, no queremos rechazar $H_0$ erróneamente con demasiada facilidad.

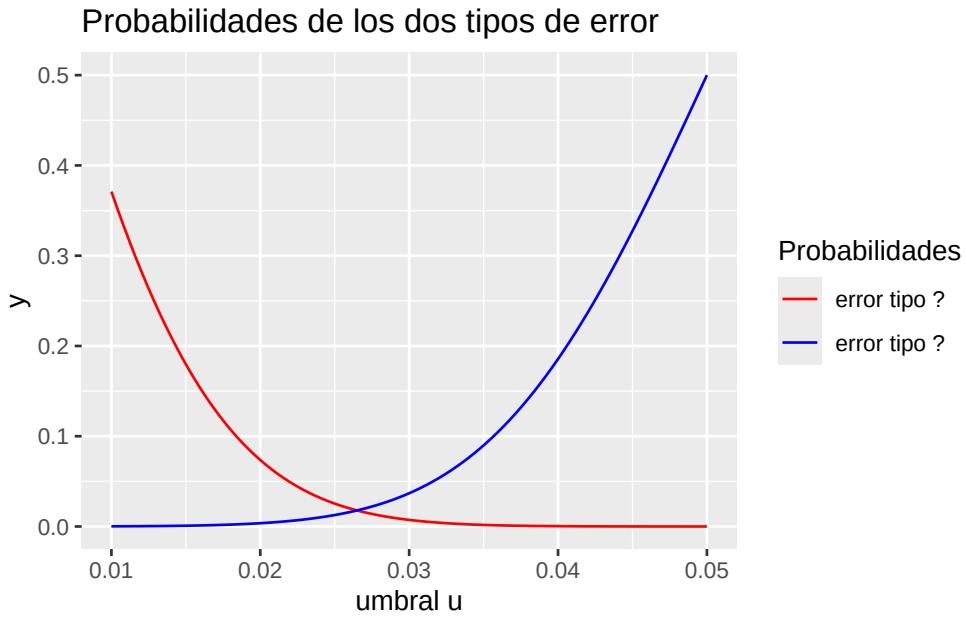

## 4.3 Métodos útiles para construir tests

### 4.3.1 Un primer procedimiento general

Para llevar a cabo un contraste de hipótesis, podemos

- Formular las hipótesis $H_0$ y $H_1$.
- Fijarnos la probabilidad de error de tipo I, $\alpha$.
- Para construir nuestra regla $\delta$, escogemos el estadístico de prueba $T(X_1, \dots, X_n)$ basado generalmente en un estimador del parámetro. Consideramos su distribución muestral suponiendo $H_0$ cierta.
- Determinamos la región de rechazo $S_1$, teniendo en cuenta la probabilidad de error I, es decir,

$$P_{H_0}(T(X_1, \dots, X_n) \in S_1) = \alpha.$$

- Para nuestra muestra, calculamos $T(x_1, \dots, x_n)$ y decidimos si aceptamos o rechazamos $H_0$, según si su valor está en $S_0$ o en $S_1$.

## 4.4 Constraste de hipótesis para la media $\mu$

Primer paso

Empezamos por considerar la construcción de un contraste para la media $\mu$ de una población Normal con varianza conocida.

Contexto

- Consideramos una variable aleatoria $X$.
- Hemos decidido modelar: $X \sim \mathcal{N}(\mu, \sigma^2)$.
  Tenemos fijado el valor de $\sigma$ (valor poblacional, por ejemplo gracias a datos históricos).
- Queremos llevar a cabo un contraste sobre $\mu$.
- Para ello, extraeremos una muestra de tamaño $n$ de la distribución de $X$.

## 4.5 Procedimiento, hipótesis bilateral

- Formulamos las hipótesis:

$$\begin{cases} H_0 : \mu = \mu_0, \\ H_1 : \mu \neq \mu_0, \end{cases}$$

  donde $\mu_0$ representa el valor concre→con el que queremos comparar $\mu$.
- Dijamos el valor de $\alpha$.
- El estadístico de prueba es la versión tipificada de $\bar{X}$:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

- Si $H_0$ es cierto, $\mu = \mu_0$

$$Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

- Establecemos la región de rechazo:

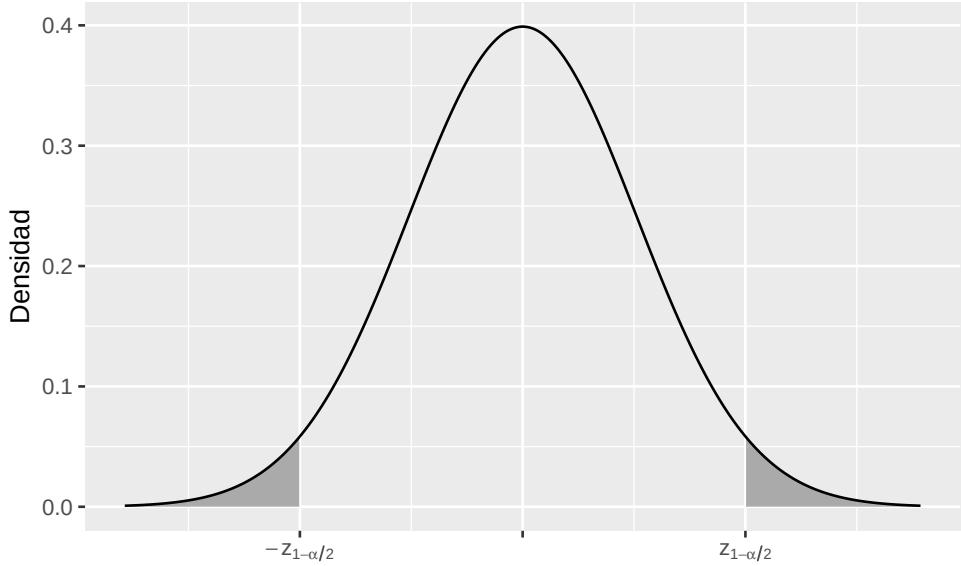


La región $S_1$ está formada por los valores menores que $-z_{1-\frac{\alpha}{2}}$ o mayores que $z_{1-\frac{\alpha}{2}}$.

- Nos queda calcular, para nuestra muestra, el valor concreto del estadístico de prueba $z_0$:
  - Si pertenece a $S_1$, rechazaremos $H_0$ y afirmaremos $H_1$.
  - Si no pertence a $S_1$, admitiremos $H_0$.

**Ejemplo**

> **i** En un proceso de producción
>
> - La longitud de los artículos producidos se modeliza a través de una distribución Normal con media $\mu$.
> - Por experiencia acerca del proceso, se cuantifica su desviación típica en $\sigma = 1mm$.
> - En condiciones de funcionamiento correcto, se espera que la longitud media de los artículos sea de 50 mm.
> - Para comprobar la calidad se decide tomar una muestra de 10 artículos que resultan tener la longitud media $\bar{x}$ igual a 51 mm.
> - Basándonos en esta muestra, ¿qué podemos decir acerca del funcionamiento del proceso?

## 4.6 Procedimiento, hipótesis unilateral

Todo igual, excepto $S_1$:

- Si la hipótesis es $H_1 : \mu > \mu_0$, la región de rechazo será

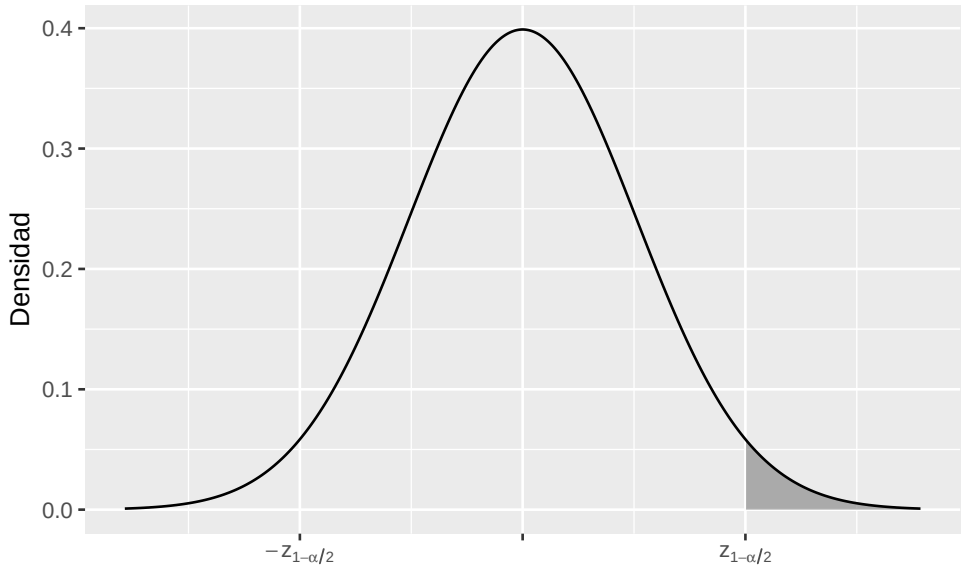


- Si la hipótesis es $H_1 : \mu > \mu_0$, la región de rechazo será

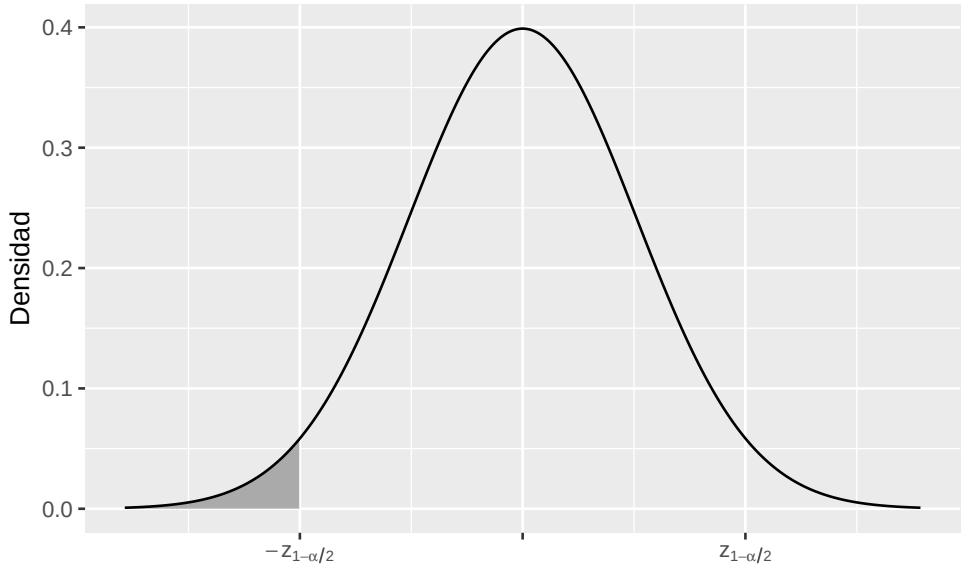


## 4.7 El $p$-valor

**Definición 4.7.1** *Consideramos un contraste, un test, y hemos observado una muestra concreta* $\mathbf{x}$.

- *El p-valor es el nivel de significación más pequeño que nos lleve, para esa muestra* $\mathbf{x}$, *a rechazar la hipótesis nula.*
- *El p-valor está asociado a la región* $S_1$ *más pequeñas que nos lleve, para esa muestra, a rechazar* $H_0$.

**Ejemplo**

Volvamos al ejemplo de la longitud de los artículos producidos. Para el contraste

$$H_0 : \mu = 50,$$
$$H_1 : \mu \neq 50.$$

Supongamos que hemos encontrado un estadístico de prueba $z_0 = 1.75$ y rechazamos $H_0$ al 95% confianza. ¿Cuál habría sido nuestra decisión al 90%? ¿Y al 99% de confianza?

**Importante**

Si rechazamos $H_0$ a un nivel de confianza dado, también la rechazamos a cualquier nivel de confianza menor.

**Para calcularlo:**

- Dibujamos la densidad de la distribución muestral del estadístico de prueba.
- Colocamos el valor de $z_0$ calculado para mi muestra concreta.
- Dibujamos una región de rechazo de manera que $z_0$ coincida con una de las fronteras.
- El $p$-valor $\alpha_0$ es el valor de $\alpha$ correspondiente a esta regiónde rechazo.

Para el ejemplo de las longitudes, sabemos $z_0 = 1.75$, lo colocamos:

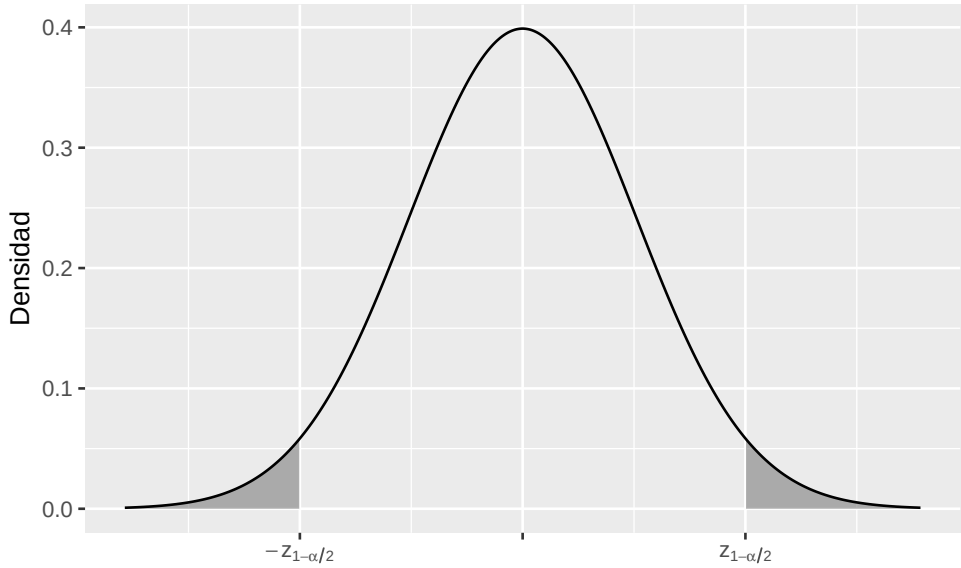


Por lo que $\frac{\alpha_0}{2} = \mathbb{P}(Z \geq 1.75)$, es decir que $\alpha_0 = 2(1 - \phi(1.75))$, lo que lleva a $\alpha_0 \simeq 0.08$.

**Para nuestro ejemplo**

- Ejemplo un $p$-valor igual a 0.08, por lo que deducimos que la confianza máxima con la que podríamos haber rechazado $H_0$ es del 92%.
- Deducimos que habríamos en particular rechazado $H_0$ al 90% de confianza, pero, por ejemplo, no al 95% de confianza.

**Cuidado con la interpretación del $p$-valor**

El $p$-valor se puede interpretar como una medida de compatibilidad de los datos con la hipótesis nula.

- No debemos usarlo como el única criterio para basar nuestra decisión.
- Es bueno hacer gráficas, considerar el contexto, ver si el efecto es relevante y no solamente significativo.
- Se debe evitar considerar $p - valor < 0.05$ como un valor mágico que es sinómino de efecto significativo.

## 4.8 Test óptimo

Empezamos por considerar los tests con probabilidad de error tipo I menor o igual que $\alpha$:

- Dado $\alpha$, sea
$$T_\alpha = \{\delta \in T | P_{i,\delta}(\theta) \leq \alpha \text{ para todo } \theta \in \Theta_0\},$$
llamaremos $\alpha$ el nivel de significación del test.
- Para un test $\delta$, se llama tamaño o extensión de $\lambda$ a: $\sup_{\theta \in \Theta_0} P_{I,\delta}(\theta)$.

**Definición 4.8.1** *Dado $\delta^* \in T_\alpha$ decimos que es óptimo si*

$$P_{II,\delta^*}(\theta) \text{ para todo } \delta \in T_\alpha \text{ y para todo } \theta \in \Theta_1.$$

## 4.9 Potencia de un test

**Definición 4.9.1** *La función potencia de un test $\delta$ asocia a cada $\theta$ la probabilidad de rechazar la hipótesis nula:*

$$\theta \mapsto \pi_\delta(\theta) = P_\theta(X \in S_1), \quad \text{con } \theta \in \Theta.$$

**Relación de la potencia con los errores**

- Si $\theta \in \Theta_0$ entonces $\pi_\delta(\theta) = P_{I,\delta}(\theta)$.
- Si $\theta \in \Theta_1$ entonces
$$\pi_\delta(\theta) = P_\theta(X \in S_1) = 1 - P_\theta(X \in S_0) = 1 - P_{II,\delta}(\theta).$$

## 4.10 Test óptimo como el de máxima potencia

Sea $\delta^* \in T_\alpha$ diremos que es el test uniforme de máxima potencia para el contraste

$$H_0 : \theta \in \Theta$$

frente a

$$H_1 : \theta \in \Theta_1$$

si se verifica

$$\pi_{\delta^*}(\theta) \geq \pi_\delta(\theta) \text{ para todo } \delta \in T_\alpha \text{ y para todo } \theta \in \Theta_1.$$

**Nuestro deseo**

Encontrar el test uniforme de máxima potencia.

## 4.11 Procedimientos basados en la verosimilitud

**Un procedimiento natural**

Puesto que la verosimilitud expresa la compatibilidad de los datos con el modelo considerado, es natural construir un test basado en la comparación de la verosimilitud para los valores de $\Theta_0$ y para los valores de $\Theta_1$.

**Constrastes de hipótesis simples**

En este tipo de contraste los subconjuntos del espacio paramétrico solo tienen un elemento, es decir $\Theta_0 = \{\theta_0\}$ y $\Theta_1 = \{\theta_1\}$ y por lo tanto los errores de ambos tipos son cantidades fijas. Implícitamente, estamos asumiendo que el parámetro es unidimensional.

## 4.12 Contrastes de hipótesis simples

**Lema de Neyman-Pearson**

Sea $X \sim F(x, \theta), \Theta = \{\theta_0, \theta_1\}, \mathbf{X} = (X_1, X_2, \dots, X_n)$, una muestra aleatoria simple de la población $X, \alpha$ fijo con $0 < \alpha < 1$. Para contrastar la hipótesis nula $H_0 : \theta = \theta_0$ frente a la hipótesis alternativa $H_1 : \theta = \theta_1$, el test de región de rechazo:

$$S_1 = \left\{ \mathbf{x} \in \text{Sop}(\mathbf{X}) \middle| \frac{L(\mathbf{x}, \theta_1)}{L(\mathbf{x}, \theta_0)} \geq k \right\}$$

con $k > 0$, que además tenga tamaño $\alpha$, es decir $\alpha = P(\mathbf{X} \in S_1 \mid \theta = \theta_0)$, que cumple que es el test de máxima potencia en la clase de los tests $T_\alpha$.

**Observaciones**

- Si la ditribución es de tipo continuo siempre se cumple que el test alcanza el tamaño obteniéndose el test de extensión de $\alpha$.
- Si la distribución es de tipo discreto, en general, el test de máxima potencia será de extensión menor que $\alpha$.

**Demostración**

Sea $\delta^*$ el test definido anteriormente.

- La condición

  $$\alpha = P(\mathbf{X} \in S_1 \mid \theta = \theta_0)$$

  nos asegura que $\delta^* \in T_\alpha$. Sea ahora $\delta \in T_\alpha$ cualquiera. Tenemos que probar que:

  $$\pi_{\delta^*}(\theta_1) \geq \pi_\delta(\theta_1)$$

  supondremos $X$ variable aleatoria continua (en el caso discreto se razonará de forma análoga).
- Sea $\mathbf{X} \in \text{sop}(X)$ se verifica que:

  $$(\delta^*(\mathbf{X}) - \delta(\mathbf{X}))(L(\mathbf{x}, \theta_1) - kL(\mathbf{x}, \theta_0)) \geq 0.$$

- Sea $\delta(\mathbf{X})^* = 1$ entonces:
$$\frac{L(\mathbf{x},\theta_1)}{L(\mathbf{x},\theta_0)} \geq k \leftrightarrow L(\mathbf{x},\theta_1) - kL(\mathbf{x},\theta_0) \geq 0$$
y $\delta^*(\mathbf{X}) - \delta(\mathbf{X}) \geq 0$ ($\delta(\mathbf{X})$ sólo puede ser 0 o 1) y el producto es no negativo.
- Si $\delta(\mathbf{X})^* = 0$ entonces:
$$\frac{L(\mathbf{x},\theta_1)}{L(\mathbf{x},\theta_0)} < k \leftrightarrow L(\mathbf{x},\theta_1) - kL(\mathbf{x},\theta_0) < 0$$
y $\delta^*(\mathbf{X}) - \delta(\mathbf{X}) \leq 0$ ($\delta(\mathbf{X})$ sólo puede ser 0 o 1) y el producto es no negativo.
- La integral de la expresió anterior sobre el $\text{sop}(\mathbf{X})$ será no negativa:
$$\int_{\text{sop}(\mathbf{X})} (\delta^*(\mathbf{X}) - \delta(\mathbf{X}))(L(\mathbf{x},\theta_1) - kL(\mathbf{x},\theta_0))\,\mathrm{d}x \geq 0$$
$$\int_{\text{sop}(\mathbf{X})} \delta^*(\mathbf{X})L(\mathbf{x},\theta_1)\,\mathrm{d}\mathbf{x} - \int_{\text{sop}(\mathbf{X})} \delta(\mathbf{X})L(\mathbf{x},\theta_1)\,\mathrm{d}\mathbf{x} - k\int_{\text{sop}(\mathbf{X})} \delta^*(\mathbf{X})L(\mathbf{x},\theta_0)\,\mathrm{d}\mathbf{x} - \int_{\text{sop}(\mathbf{X})} \delta(\mathbf{X})L(\mathbf{x},\theta_0)\,\mathrm{d}\mathbf{x}$$
notar que ambos contrastes solo toman el valor 1 en sus respectivas regiones de rechazo (y cero en las regiones de aceptación) con lo que al desarrollar los términos de la integral tenemos:
$$\pi_{\delta^*} - \pi_\delta(\theta_1) - k(\pi_{\delta^*}(\theta_0) - \pi_\delta(\theta_0)) \geq 0.$$
- Como $\delta \in T_\alpha$ tenemos que $\pi_\delta(\theta_0) \leq \alpha$ con lo que:
$$0 \leq \alpha - \pi_\delta(\delta_0) = \pi_{\delta^*}(\theta_0) - \pi_\delta(\theta_0)$$
y por lo tanto:
$$k(\pi_{\delta^*}(\theta_0) - \pi_\delta(\theta_0)) \geq 0$$
con lo que:
$$0 \leq \pi_{\delta^*}(\theta_1) - \pi_\delta(\theta_1) - k(\pi_{\delta^*}(\theta_0) - \pi_\delta(\theta_0)) \leq \pi_{\delta^*}(\theta_1) - \pi_\delta(\theta_1)$$
de donde se deduce:
$$\pi_{\delta^*}(\theta_1) \geq \pi_\delta(\theta_1)$$
que era lo que queríamos probar.

## 4.13 Hipótesis compuestas

Planteamiento

En las aplicaciones a problemas reales no suelen plantearse, en general, contrastes de hipótesis simple y alternativa simple, pues las hipótesis alternativas no suelen ser tan precisas para que estén definidas por un único valor del parámetro. Consideremos ahora contrastes de hipótesis donde al menos una de ellas es compuesta.

Casos

a) $H_0 : \theta = \theta_0$, $H_1 : \theta > \theta_0$

b) $H_0 : \theta = \theta_0$, $H_1 : \theta < \theta_0$

c) $H_0 : \theta \leq \theta_0$, $H_1 : \theta > \theta_0$

d) $H_0 : \theta \geq \theta_0$, $H_1 : \theta < \theta_0$

e) $H_0 : \theta = \theta_0$, $H_1 : \theta \neq \theta_0$

f) $H_0 : \theta \in [\theta_1, \theta_2]$, $H_1 : \theta \notin [\theta_1, \theta_2]$

En los casos a)-d) anteriores es posible obtener tests uniformes de máxima potencia para casos en los que la variable pertenece a la familia exponencial uniparamétrica.

## 4.14 Cociente de verosimilitudes monótono

**Resultado**

Sea $X \sim F(x,\theta), \theta \in \Theta \subset \mathbb{R}$ y $X_1, \dots, X_n$ una muestra aleatoria simple de $X$. Decimos que $X$ o $F$ tienen la propiedad de cociente de verosimilitud monótono en el estadístico $R = R(X_1, \dots, X_n)$, si para todo $\theta_0, \theta_1 \in \Theta$ con $\theta_0 < \theta_1$ se verifica que el cociente de verosimilitudes $\dfrac{L(\mathbf{x},\theta_1)}{L(\mathbf{x},\theta)}$, es una función monótona creciente de $R(\mathbf{x})$.

**Nota**

A los efectos de la definición si $L(\mathbf{x},\theta_0) = 0$ y $L(\mathbf{x},\theta_1) > 0$, el cociente anterior se considerará igual a infinito.

**Familia exponencial uniparamétrica**

Se dice que la variable $X \sim F(x,\theta)$ pertenece a la familia exponencial uniparamétrica si su función de verosimilitud se puede escribir en la forma:

$$L(\mathbf{x},\theta) = \exp\{A(\theta)T(\mathbf{x}) + B(\theta) + h(\mathbf{x})\}$$

para toda muestra $\mathbf{x}$.
Si $A(\theta)$ es monótona creciente (decreciente) en $\theta$, entonces $X$ tiene cociente de verosimilitud monótono en el estadístico $T(X_1, \dots, X_n)(-T(X_1, \dots, X_n))$.

**Cociente de verosimilitudes monótono**

Sea $X \sim F(x,\theta), \theta \in \Theta \subseteq \mathbb{R}$ y $X_1, \dots, X_n$ una m.a.s. de $X$. Supongamos que $X$ tiene cociente de verosimilitud monótono en el estadístico $R = R(X_1, \dots, X_n)$ para contrastar $H_0 : \theta = \theta_0$ frente a $H_1 : \theta > \theta_0$, se sigue que el test

$$\delta_1(\mathbf{x}) \begin{cases} 0 & \text{si } R(\mathbf{x}) < c \\ 1 & \text{si } R(\mathbf{x}) \geq c \end{cases}$$

que cumpla $P_{I,\delta_1}(\theta_0) = \alpha$, es el test uniforme de máxima potencia en la clase de tests $T_\alpha = \{\delta \in T | P_{I,\delta}(\theta_0) \leq \alpha\}$, con $0 < \alpha < 1$.

**Tip**

El teorema anterior se extiende al contraste $H_0 : \theta \leq \theta_0$ frente a $H_1 : \theta > \theta_0$.

**Cociente de verosimilitudes monótono**

Sea $X \sim F(x,\theta), \theta \in \Theta \subseteq \mathbb{R}$ y $X_1, \dots, X_n$ una m.a.s. de $X$. Supongamos que $X$ tiene cociente de verosimilitud monótono en el estadístico $R = R(X_1, \dots, X_n)$ para contrastar $H_0 : \theta = \theta_0$ frente a $H_1 : \theta < \theta_0$, se sigue que el test

$$\delta_1(\mathbf{x}) \begin{cases} 0 & \text{si } R(\mathbf{x}) > c \\ 1 & \text{si } R(\mathbf{x}) \leq c \end{cases}$$

que cumpla $P_{I,\delta_1}(\theta_0) = \alpha$, es el test uniforme de máxima potencia en la clase de tests $T_\alpha = \{\delta \in T | P_{I,\delta}(\theta_0) \leq \alpha\}$, con $0 < \alpha < 1$.

**Tip**

El teorema anterior se extiende al contraste $H_0 : \theta \geq \theta_0$ frente a $H_1 : \theta < \theta_0$.

## 4.15 Contrastes de hipótesis compuestas

La metodología anterior no se puede aplicar en los casos e) y f) y en los casos de parámetros que no sean unidimensionales. Por tanto, es importante para muchos problemas prácticos, disponer de métodos de contrucción de contrastes, basados en principios razonables y que permitan diseñar el test según el problema planteado. El método más importante lo constituye el **test de la razón de verosimilitudes generalizado**.

**Razón de verosimilitudes Generalizada (RVG)**

Se llama razón de verosimilitudes generalizada para contrastar la hipótesis $H_0 : \theta \in \Theta_0$ frente $H_1 : \theta \in \Theta_1$ al cociente

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\mathbf{x}; \theta)}{\sup_{\theta \in \Theta} L(\mathbf{x}; \theta)}.$$

## 4.16 Procedimiento basado en la verosimilitud

**Test de razón de verosimilitud generalizada**

Un test de razón de verosimilitud generalizada (RVG) para las hipótesis anteriores es aquel que tiene región crítica de la forma

$$S_1 = \left\{ \mathbf{x} \in \mathrm{Sop}(X_1, \dots, X_n) | \lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\mathbf{x}; \theta)}{\sup_{\theta \in \Theta} L(\mathbf{x}; \theta)} < k \right\}$$

Determinamos la constante $k$, imponiendo que el test tenga extensión $\alpha$, es decir:

$$\sup_{\theta \in \Theta_0} P((X_1, \dots, X_n) \in S_1 | \theta) = \alpha.$$

## 4.17 Test RVG para la media de una población normal con varianza conocida

**Ejercicio**

- $X \sim \mathcal{N}(\mu, \sigma^2)$, suponemos $\sigma$ conocida.
- M.a.s $X_1, \dots, X_n$ de $X$.
- Formulamos las hipótesis

$$H_0 : \mu = \mu_0$$
$$H_1 : \mu \neq \mu_0$$

1) Demostrar que el test que rechaza $H_0$ si $\left| \frac{\bar{\mathbf{X}} - \mu_0}{\sigma / \sqrt{n}} \right| > z_{1-\frac{\alpha}{2}}$ es de extensión $\alpha$.
2) Demostrar que el test anterior es el test de RVG.

**¿Es de extensión $\alpha$?**

- Hemos de comprobar que: $\sup_{\theta \in \Theta_0} P_{i,\delta}(\theta) = \alpha$.
- En este caso $H_0$ es simple, si $\mu = \mu_0$ se cumple que $\frac{\bar{\mathbf{X}} - \mu_0}{\sigma / \sqrt{n}} \sim \mathcal{N}(0, 1)$.

$$P\left( \left| \frac{\bar{\mathbf{X}} - \mu_0}{\sigma / \sqrt{n}} \right| > z_{1-\frac{\alpha}{2}} | \mu_0 \right) = \alpha.$$

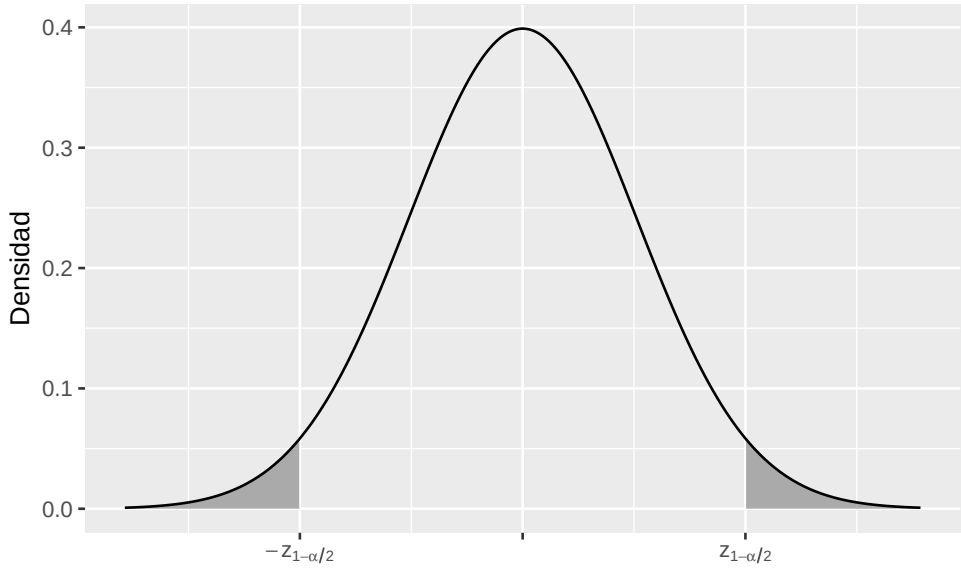


**¿Es el test de RVG?**

$$\lambda(\mathbf{x}) = \frac{\sup_{\mu=\mu_0} L(\mathbf{x};\mu)}{\sup_{\mu\in R} L(\mathbf{x};\mu)}.$$

- Numerador:

$$L(\mathbf{X};\mu_0) = \frac{1}{\sigma^{\frac{n}{2}}(2\pi)^{\frac{\alpha}{2}}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu_0)^2\right)$$

- El supremo en el denominador se alcanza en el EMV $\hat{\mu} = \bar{x}_n$.

$$\lambda(\mathbf{x}) = \exp\left(-\frac{n}{2\sigma^2}\sum_{i=1}^{n}(\bar{x}_n-\mu_0)^2\right)$$

**¿Es el test de RVG?**

- Determinamos la constante $k$, imponiendo que el test tenga extensión $\alpha$, es decir,

$$\begin{aligned}
P(\lambda(\mathbf{x}) < k|\mu_0) = \alpha \\
\alpha = P\left(0 < \exp\left(-\frac{n}{2\sigma^2}\sum_{i=1}^{n}(\bar{x}_n-\mu_0)^2\right) < k|\mu_0\right) \\
= P(-\infty < -\frac{n}{2\sigma^2}\sum_{i=1}^{n}(\bar{x}_n-\mu_0)^2 < \log(k)|\mu \\
= P\left(\left(\frac{\bar{x}_n-\mu_0}{\sigma/\sqrt{n}}\right)^2 > -2\log(k)|\mu_0\right) \\
= P\left(\left|\frac{\bar{x}_n-\mu_0}{\sigma/\sqrt{n}}\right| > \sqrt{-2\log(k)}|\mu_0\right) = P\left(\left|\frac{\bar{x}_n-\mu_0}{\sigma/\sqrt{n}}\right| > c|\mu_0\right)
\end{aligned}$$

tomamos $c = z_{1-\frac{\alpha}{2}}$.

## 4.18 Test de razón de verosimilitudes generalizada

**Lo más dificil**

Aunque el test RVG sea un test que suele tener buenas propiedades en cuanto a errores, para muchos modelos, no es sencillo deducir su distribución muestral.

**Aproximación asintótica de la distribución muestral para el test RVG**

Para el contraste

$$H_0 : \theta \in \Theta_0$$

frente a la alternativa

$$H_1 : \theta \in \Theta_1$$

si $\dim(\Theta) = q$ y $\dim(\Theta_0) = q'$ se verifica, bajo ciertas condiciones, que el estadístico $-2\log\lambda(\mathbf{X})$ converge en distribución a una ji-cuadrado con $q - q'$ grados de libertad.

## 4.19 Test de bondad de ajuste

Es un constraste no paramétrico

- Su objetivo es comprobar hasta qué punto los datos observados parecen haber sido generados por una distribución de probabilidad dada.
- Se conoce como "contraste chi-cuadrado", porque es la distribución que usamos para construir nuestra regla de decisión.

Primer ejemplo, el caso más sencillo:

- Tenemos $k$ clases posibles asociadas a un experimento aleatorio: $A_1, \dots, A_k$.
- Tenemos unos valores esperados para sus probabilidades

$$p_1 = P(A_1), \dots, p_k = P(A_k).$$

- Observamos $n$ realizaciones del experimento y queremos decidir si lo observado es compatible con los valores esperados.

### Caso sencillo bondad de ajuste

El caso más sencillo:

- Planteamos

$$\begin{aligned} H_0 &: P(A_1) = p_i,\ i = 1, \dots, k \\ H_1 &: \text{Existe } i \text{ tal que } P(A_i) \neq p_i. \end{aligned}$$

- Tenemos $k$ clases posibles asociadas a un experimento aleatorio: $A_1, \dots, A_k$.
- Tenemos unos valores esperados para sus probabilidades

$$p_1 = P(A_1), \dots, p_k = P(A_k).$$

- Observamos $n$ realizaciones del experimento y queremos decidir si lo observado es compatible con los valores esperados.

### Caso sencillo bondad de ajuste: grupo sanguíneo

Cuatro grupos sanguíneos

Experimento: escoger una persona

- $A_1 =$"Su grupo es O", $A_2 =$"Su grupo es A", $A_3 =$"Su grupo es B", $A_4 =$"Su grupo es AB".
- Los valores esperados para sus probabilidades son

$$p_1 = 43\%, p_2 = 40\%, p_3 = 12\%, p_4 = 5\%.$$

- En un grupo de 250 personas, observamos $f_1 = 100$"O", $f_2 = 100$"A", $f_3 = 30$"B", $f_4 = 10$"AB".
- En el grupo de 250, esperamos $\hat{f}_1 = 250 \times 43\% \simeq 107.5$"O", $\hat{f}_2 = 2500 \times 40\% \simeq 100$"A", $\hat{f}_3 = 250 \times 12\% \simeq 30$"B", $\hat{f}_4 = 250 \times 5\% \simeq 12.5$"AB".
- Escribimos los datos en una tabla

| **Clases** | $A_1$ | $A_2$ | $A_3$ | $A_4$ |
|---|---|---|---|---|
| Frecuencia observada | $f_1 = 110$ | $f_2 = 100$ | $f_3 = 30$ | $f_4 = 10$ |
| Frecuencia esperada | $\hat{f}_1 = 107.5$ | $\hat{f}_2 = 100$ | $\hat{f}_3 = 30$ | $\hat{f}_4 = 12.5$ |

**Construimos el estadístico para el contraste**

El estadístico chi-cuadrado de Pearson

Para constrastar

$$H_0 : P(A_i) = p_i,\ i = 1, \dots, kH_1 : \text{Existe } i \text{ tal que } P(A_i) \neq p_i.$$

Karl Pearson propuso el estadístico

$$\chi^2 = \sum_{i=1}^{k} \frac{\left(f_i - \hat{f}_i\right)^2}{\hat{f}_i}.$$

Si $n$ es suficientemente grande,

$$\chi^2 = \sum_{i=1}^{k} \frac{\left(f_i - \hat{f}_i\right)^2}{\hat{f}_i} \text{ es aprox. } \chi^2_{k-1}.$$

$$\chi^2 = \sum_{i=1}^{k} \frac{\left(f_i - \hat{f}_i\right)^2}{\hat{f}_i} = \frac{(100 - 107.5)^2}{107.5} + \frac{0^2}{100} + \frac{0^2}{30} + \frac{(10 - 12.5)^2}{12.5} = 1.02$$

Para calcular el $p$-valor, lo comparamos con los cuantiles de una $\chi^2_3$, valores extremos positivos nos llevan a rechazar $H_0$.

$p$-valor:

Encontramos $p$-valor$= 0.79$, lo que nos lleva a afirmar que los datos apoyan la hipótesis nula, y son compatibles con los valores esperado $p_1 = 43\%$"O", $p_2 = 40\%$"A", $p_3 = 12\%$"B", $p_4 = 5\%$"AB".

Validez de la aproximación de la distribución de estadístico de Pearson por un $\chi^2_{k-1}$.

$n$ debe ser "suficientemente" grande.

- Se suele considerar que todas las frecuencias esperadas deben ser al menos 5, excepto una, y que sea mayor que 0.5.
- Si dos de ellas son pequeñas, entonces esas no deben ser menor que 1, y el resto debe ser al menos 5.
- Si no cumple, se agrupan clases.

**Segundo caso: debemos estimar parámetros para calcular las frecuencias esperadas.**

Segundo ejemplo, un caso común:

- Tenemos $k$ clases posibles asociadas a un experimento aleatorio $A_1, \dots, A_k$.
- Los valores esperados para las probabilidades $p_1 = P(A_1), \dots, p_k = P(A_k)$ dependen de unos parámetros desconocidos.
- Observamos $n$ realizaciones del experimento y queremos decidir si lo observado es compatible con los valores esperados.
- Planteamos $H_0 : P(A_i) = p_i,\ i = 1, \dots, k$ frente a $H_1$ :Existe $i$ tal que $P(A_i) \neq p_i$.

Procederemos igual que antes, pero:

- Estimaremos los parámetros desconocidos a partir de las observaciones.
- El estadístico de Pearson tendrá como distribución aproximada $\chi^2_{k-d-1}$, donde $d$ es el número de parámetros

que debemos estimar para aproximar las frecuencias esperadas.

**Ejemplo: daltonismo**

La incidencia del daltonismo depende del sexo:

- Los genes responsables del daltonismo se encuentran en el cromosoma $X$.
- Los hombres tienen un solo cromosoma $X \implies$ una copia del gen defectuoso en su cromosoma $X$ es suficiente para ser daltónico.
- Las mujeres tienen dos cromosomas $X \implies$ dos copias del gen defectuoso son necesarias para ser daltónicas.

Si llamamos $q$ a la probabilidad de que el cromosoma $X$ tenga el gen defectuoso y $p = 1 - q$

Tenemos:

| | **Masculino** | **Femenino** |
|---|---|---|
| Normales | $\frac{p}{2}$ | $\frac{p^2}{2} + pq$ |
| Daltónicos | $\frac{q}{2}$ | $\frac{q^2}{2}$ |

## Datos observados

Para una muestra de 1000 personas:

| | **Masculino** | **Femenino** |
|---|---|---|
| Normales | 442 | 514 |
| Daltónicos | 38 | 6 |

# Hoja 4: Contrastes de hipótesis

**1)** Sea $X \sim N(\mu, \sigma^2)$ y se considera una m.a.s. de tamaño $n$ de $X$, donde $\sigma^2$ es conocida.

**a)** Consideremos las hipótesis $H_0 : \mu = \mu_0$ y $H_1 : \mu > \mu_0$. Demostrar que el test con región de rechazo $S_1 = \{m\mathbf{x} \in m\mathbf{X} | (m\bar{\mathbf{x}} - \mu_0)/(\sigma/\sqrt{n}) > z_{1-\alpha}\}$ es de extensión $\alpha$ para las hipótesis anteriores.

Para demostrar que un test es de **extensión** $\alpha$, debemos veriifcar que el supremo de la probabilidad de cometer un error de tipo I sea igual a $\alpha$.

1) Definición de Extensión:

$$\text{extensión} = \sup_{\theta \in \Theta_0} P_{I,\delta}(\theta) = \sup_{\theta \in \Theta_0} P(\mathbf{x} \in S_1 | \theta)$$

2) Cálculo para la hipótesis nula simple ($H_0 : \mu = \mu_0$):

Como $\Theta_0$ solo contiene el valor $\mu_0$, el supremo es simplemente la probabilidad evaluada en ese punto:

$$P(\mathbf{x} \in S_1 | \mu = \mu_0) = P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha} | \mu = \mu_0\right)$$

3) Distribución

Sabemos que si $H_0$ es cierta ($\mu = \mu_0$), el estadístico tipificado sigue una distribución normal estándar:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

4) Resultado final:

Por definición del cuantil $z_{1-\alpha}$ en una distribución normal:

$$P(Z > z_{1-\alpha}) = \alpha$$

Por lo tanto, el test es de **extensión** $\alpha$**.**

**b)** Consideremos las hipótesis $H_0 : \mu \leq \mu_0$ y $H_1 : \mu > \mu_0$. Demostrar que el test con región de rechazo $S_1 = \{m\mathbf{x} \in m\mathbf{X} | (m\bar{\mathbf{x}} - \mu_0)/(\sigma/\sqrt{n}) > z_{1-\alpha}\}$ es de extensión $\alpha$ para las hipótesis anteriores.

En este caso, la hipótesis nula es compuesta ($\Theta_0 = \{\mu : \mu \leq \mu_0\}$). Debemos encontrar el máximo de la función de potencia en dicha región.

1) Función de Probabilidad de Error Tipo I:

Para cualquier $\mu \leq \mu_0$, definimos la probabilidad de rechazar $H_0$ como:

$$P_\mu(\mathbf{x} \in S_1) = P_\mu\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}\right)$$

2) Tipificación general:

Para una $\mu$ cualquiera, el estadístico que sigue una $\mathcal{N}(0, 1)$ es $\dfrac{\bar{X} - \mu}{\sigma/\sqrt{n}}$. Operamos en la desigualdad:

$$P_\mu\left(\frac{\bar{X} - \mu + \mu - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha}\right) = P\left(Z > z_{1-\alpha} + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}}\right)$$

3) Análisis de la función:

La probabilidad $P(Z > \text{valor})$ es una función decreciente respecto al "valor":

- Si $\mu < \mu_0$, entonces $\dfrac{\mu_0 - \mu}{\sigma/\sqrt{n}} > 0$, lo que implica que el valor de la probabilidad es menor que $\alpha$.
- El valor máximo de esta probabilidad en la región $\Theta_0$ se alcanza cuando $\mu$ es lo más grande posible, es decir, en el límite $\mu = \mu_0$.

4) Conclusión por definición de extensión:

$$\sup_{\mu \leq \mu_0} P_\mu(\mathbf{X} \in S_1) = P_{\mu_0}(\mathbf{x} \in S_1) = \alpha$$

Al ser el supremo exactamente $\alpha$, el test es de **extensión** $\alpha$**.**

**2)** Sea $X \sim N(\mu, \sigma^2)$ con $\sigma^2$ conocida. Se considera una muestra aleatoria simple de tamaño $n$ de $X$.

**a)** Obtener el test de máxima potencia y extensión $\alpha$ para el test (contraste): $H_0 : \mu = \mu_0$ frente a $H_1 : \mu = \mu_1$, con $\mu_1 > \mu_0$.

Al ser un contraste de hipótesis simple frente simple, aplicamos el **Lema de Neyman-Pearson** para obtener el test uniforme de máxima potencia.

1) Definición de la región de rechazo ($S_1$):

El lema establece que la región crítica es:

$$S_1 = \left\{ \mathbf{x} \in \mathrm{Sop}(X) \middle| \frac{L(\mathbf{x}, \mu_1)}{L(\mathbf{x}, \mu_0)} \geq k \right\}$$

2) Función de verosimilitud:

Para una m.a.s. de la distribución Normal, la verosimilitud:

$$L(\mathbf{x}; \mu) = \frac{1}{\sigma^{n/2}(2\pi)^{n/2}} \exp\left( \frac{-1}{2\sigma^2} \sum_{i=1}^{n} (x_i - \mu)^2 \right)$$

3) Cociente de verosimilitudes:

$$\frac{L(\mathbf{x}, \mu_1)}{L(\mathbf{x}, \mu_0)} = \frac{\exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu_1)^2\right)}{-\frac{1}{\sigma^2} \sum (x_i - \mu_0)^2} = \exp\left( \frac{1}{2\sigma^2} \left[ \sum (x_i - \mu_0)^2 - \sum (x_i - \mu_1)^2 \right] \right)$$

Desarrollando los términos en la suma del exponente:

$$\sum (x_i - \mu_0)^2 - \sum (x_i - \mu_1)^2 = 2(\mu_1 - \mu_0) \sum x_i + n(\mu_0^2 - \mu_1^2)$$

Sustituyendo $\sum x_i = n\bar{X}$ e insertando en la inecuación de Neyman-Pearson:

$$\exp\left( \frac{1}{2\sigma^2} [2n(\mu_1 - \mu_0)\bar{X} + n(\mu_0^2 - \mu_1^2)] \right) \geq k$$

Tomando logaritmo neperiano a ambos lados y despejando $\bar{X}$:

$$\bar{X} \geq \frac{2\sigma^2 \ln(k) - n(\mu_0^2 - \mu_1^2)}{2n(\mu_1 - \mu_0)} = c$$

4) Imponer la extensión $\alpha$:

$$P(\mathbf{x} \in S_1 | \mu = \mu_0) = \alpha$$
$$P(\bar{X} \geq c | \mu_0) = \alpha$$

Tipificamos el estadístico bajo $H_0$ sabiendo que $Z = \dfrac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$:

$$P\left( \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq \frac{c - \mu_0}{\sigma/\sqrt{n}} \right) = \alpha \implies \frac{c - \mu_0}{\sigma/\sqrt{n}} = z_{1-\alpha}$$

Por lo tanto, la región de rechazo de máxima potencia queda matemáticamente definida como:

$$S_1 = \left\{ \mathbf{x} \middle| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq z_{1-\alpha} \right\}$$

**b)** Si $X \sim N(\mu, \sigma^2 = 4)$ representa la duración en días de una determinada enfermedad y se considera la duración de una muestra de 9 enfermos resultando en días: 5,3,4,2,6,4,5,3,4, aplicar los resultados del ejemplo anterior, para decidir entre: $H_0 : \mu = 3$ frente a $H_1 : \mu = 4$, con un nivel de significación $\alpha = 0.05$.

Recopilamos los datos del enunciado:

- $\mu_0 = 3, \mu_1 = 4$
- Varianza $\sigma^2 = 4 \implies \sigma = 2$
- Tamaño de muestra $n = 9$
- Nivel de significación $\alpha = 0.05 \implies z_{1-\alpha} = z_{0.95} = 1.645$

- Muestra: $x = (5, 3, 4, 2, 6, 4, 5, 3, 4)$

1) Cálculo del estadístico de prueba:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{5+3+4+2+6+4+5+3+4}{9} = \frac{36}{9} = 4$$

2) Cálculo del estadístico de prueba:

Sustituyendo en la fórmula del estadístico tipificado obtenida en el apartado anterior:

$$Z_{obs} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{4-3}{2/\sqrt{9}} = \frac{1}{2/3} = \frac{3}{2} = 1.5$$

3) Decisión:

La regla de rechazo obtenida para $\mu_1 > \mu_0$ es rechazar si el estadístico es $> z_{1-\alpha}$. Comparamos:

$$1.5 < 1.645$$

Dado que 1.5 no pertenece a la región de rechazo $S_1$, **aceptamos la hipótesis nula $H_0$.** Los datos no proporcionan evidencia estadísticamente significativa para rechazar que $\mu = 3$ en favor de $\mu = 4$ con un $\alpha = 0.05$.

**3)** Sean $X \sim N(\mu_X, \sigma_X^2)$ e $Y \sim N(\mu_Y, \sigma_Y^2)$ independientes. Se considera una m.a.s. de tamaño $n_X$ de $X$ y una m.a.s. de tamaño $n_Y$ de $Y$.

**a)** Suponiendo $\sigma_X^2$ y $\sigma_Y^2$ conocidas, obtener un procedimiento para contrastar $H_0 : \mu_X = \mu_Y$ frente a $H_1 : \mu_X \neq \mu_Y$.

1) Formulación de hipótesis:

Podemos reescribir el contraste planteado en función de la diferencia de medias, equivalente a comparar con un $\mu_0 = 0$:

$$H_0 : \mu_X - \mu_Y = 0$$
$$H_1 : \mu_X - \mu_Y \neq 0$$

2) Estadístico de prueba:

Para construir nuestra regla $\delta$, escogemos un estadístico basado en los estimadores de los parámetros. Definimos la variable de diferencia $D = \bar{X} - \bar{Y}$. Por ser variables normales e independientes:

$$D \sim \mathcal{N}\left(\mu_X - \mu_Y, \frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}\right)$$

3) Distribución bajo la hipótesis nula ($H_0$):

Consideramos su distribución muestral suponiendo $H_0$ cierta ($\mu_X - \mu_Y = 0$). Siguiendo el mismo procedimiento de tipificación que en el caso de una sola media, el estadístico de prueba es:

$$Z = \frac{(\bar{X} - \bar{Y}) - 0}{\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}} \sim \mathcal{N}(0, 1)$$

4) Región de rechazo ($S_1$):

Al tratarse de una hipótesis alternativa bilateral ($H_1 : \neq$), fijamos el valor del error tipo I, $\alpha$. La región de rechazo estará formada por los valores extremos (las dos colas) de la distribución Normal estándar:

$$S_1 = \{(\mathbf{x}, \mathbf{y}) \mid |Z| > z_{1-\alpha/2}\} \text{ o equivalente } S_1 = \{(\mathbf{x}, \mathbf{y}) \mid Z < -z_{1-\alpha/2} \text{ ó } Z > z_{1-\alpha/2}\}$$

**b)** Suponiendo $\sigma_X^2$ y $\sigma_Y^2$ desconocidas pero iguales, obtener un procedimiento para contrastar $H_0 : \mu_X \leq \mu_Y$ frente a $H_1 : \mu_X > \mu_Y$.

1) Formulación de hipótesis:

Reescribimos el contraste compuesto:

$$H_0 : \mu_X - \mu_Y \leq 0$$
$$H_1 : \mu_X - \mu_Y > 0$$

2) Planteamiento del procedimiento:

Como la varianza común $\sigma^2$ es desconocida, no podemos usar directamente la variable tipificada $Z$ con varianza teórica como en el caso anterior.

Según el principio del **Test de la Razón de Verosimilitudes Generalizada (RVG),** cuando hay parámetros desconocidos en las hipótesis compuestas, estos deben estimarse a partir de la muestra (como se hace con el Estimador Máximo Verosímil).

Por lo tanto, la varianza común $\sigma^2$ debe ser reemplazada por su correspondiente estimador muestral (varianza combinada, que denotaremos genéricamente como $\hat{\sigma}^2$ o $S_p^2$).

3) Estadístico de prueba conceptual:

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n_X} + \frac{1}{n_Y}\right)}}$$

4) Región de rechazo ($S_1$):

Determinamos la región de rechazo $S_1$, teniendo en cuenta la probabilidad de error I, es decir: $P_{H_0}(T \in S_1) = \alpha$. Al ser una hipótesis alternativa unilateral (tipo $>$), la región de rechazo se sitúa en la cola superior de la distribución de $T$. El test general queda definido como:

$$S_1 = \{(\mathbf{x}, \mathbf{y} \mid T > c_{1-\alpha})\}$$

Donde $c_{1-\alpha}$ representa el cuantil correspondiente al nivel $\alpha$ de la distribución muestral del estadístico $T$ bajo $H_0$ evaluado en el supremo $\mu_X = \mu_Y$.

**4)** Consideremos una m.a.s. $X_1, \dots, X_n$ de una población tiene una densidad $f(x;\theta) = e^{-(x-\theta)}\xi_{(\theta,+\infty)}$. Obtener el test RVG para $H_0 : \theta \leq \theta_0$ frente a $H_1 : \theta > \theta_0$.

1) Definición del cociente RVG:

El estadístico de la razón de verosimilitud generalizada se define como:

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\mathbf{x};\theta)}{\sup_{\theta \in \Theta} L(\mathbf{x};\theta)}$$

2) Función de Verosimilitud:

Dada la muestra aleatoria simple de tamaño $n$ de $f(x;\theta) = e^{-(x-\theta)} I_{(\theta,+\infty)}(x)$, la función de verosimilitud conjunta es:

$$L(\mathbf{x};\theta) = \prod_{i=1}^{n} e^{-(x_i-\theta)} I_{(\theta,+\infty)}(x_i) = e^{-\sum x_i + n\theta} I_{(\theta,+\infty)}(x_{(1)})$$

donde $x_{(1)} = \min(x_1, \dots, x_n)$ es el mínimo muestral.

Esto significa que $L(\mathbf{x};\theta) > 0$ si y sólo si $\theta \leq x_{(1)}$.

3) Denominador (Supremo global en $\Theta$):

Debemos maximizar $e^{-\sum x_i + n\theta}$ sujeto a la restricción $\theta \leq x_{(1)}$.

Como $e^{n\theta}$ es una función estrictamente creciente de $\theta$, el máximo se alcanza en el valor más grande posible de $\theta$, que es el Estimador de Máxima Verosimilitud (EMV): $\hat{\theta} = x_{(1)}$.

$$\sup_{\theta \in \Theta} L(\mathbf{x};\theta) = e^{-\sum x_i n x_{(1)}}$$

4) Numerador (Supremo bajo $H_0$):

Debemos maximizar $L(\mathbf{x};\theta)$ sujeto a $\theta \leq x_{(1)}$ y, además, a la restricción de la hipótesis nula $\theta \leq \theta_0$.

Por tanto, debemos maximizar en $\theta \leq \min(x_{(1)}, \theta_0)$. De nuevo, por ser creciente en $\theta$, se maximiza en el límite superior. Tenemos dos casos:

- **Caso A:** Si $x_{(1)} \leq \theta_0 \implies$ el máximo es $\theta = x_{(1)}$.

$$\sup_{\theta \in \Theta_0} L(\mathbf{x};\theta) = e^{-\sum x_i + n x_{(1)}}$$

- **Caso B:** Si $x_{(1)} > \theta_0 \implies$ el máximo es $\theta = \theta_0$.

$$\sup_{\theta \in \Theta_0} L(\mathbf{x}; \theta) = e^{-\sum x_i - n\theta_0}$$

5) Cálculo de $\lambda(\mathbf{x})$:

Sustituyendo el numerador y el denominador en la definición del RVG:

$$\lambda(\mathbf{x}) = \begin{cases} \dfrac{e^{-\sum x_i + nx_{(1)}}}{e^{-\sum x_i + nx_{(1)}}} = 1 & \text{si } x_{(1)} \leq \theta_0 \\ \dfrac{e^{-\sum x_i + n\theta_0}}{e^{-\sum x_i + nx_{(1)}}} = e^{n(\theta_0 - x_{(1)})} & \text{si } x_{(1)} > \theta_0 \end{cases}$$

6) Región de rechazo ($S_1$):

El test RVG tiene como región crítica los valores donde $\lambda(\mathbf{x}) < k$.

Dado que rechazamos para valores pequeños de $\lambda$, esto ocurre cuando $e^{n(\theta_0 - x_{(1)})} < k$. Operando con logaritmos:

$$n(\theta_0 - x_{(1)}) < \ln k \implies x_{(1)} > \theta_0 - \frac{\ln k}{n} = c$$

Por tanto, la forma de la región de rechazo es:

$$S_1 = \{\mathbf{x} \in Sop(X_1, \dots, X_n) \mid x_{(1)} > c\}$$

7) Determinación de la constante $c$ (Extesión $\alpha$):

Para que el test tenga extensión $\alpha$, imponiendo que el supremo de la probabilidad de error tipo I sea $\alpha$:

$$\sup_{\theta \leq \theta_0} P_\theta(X_{(1)} > c) = \alpha$$

Como $P_\theta(X_{(1)} > c)$ es máxima en la frontera, evaluamos en $\theta = \theta_0$:

$$P_{\theta_0}(X_{(1)} > c) = \alpha$$

Sabiendo que $P(X_{(1)} > c) = [P(X_1 > c)]^n$ y que $P(X_1 > c) = \displaystyle\int_c^\infty e^{-(x-\theta)}\, \mathrm{d}x = e^{-(x-\theta_0)}$:

$$\left[e^{-(c-\theta_0)}\right]^n = e^{-n(c-\theta_0)} = \alpha$$

Aplicamo logaritmo neperiano:

$$-n(c - \theta_0) = \ln \alpha \implies c = \theta_0 - \frac{\ln \alpha}{n}$$

**Conclusión final:**

El test de RVG para este contraste es: **Rechazar** $H_0$ **si** $x_{(1)} > \theta_0 - \dfrac{\ln \alpha}{n}$

**5)** Sea $X \sim N(\mu, \sigma^2)$ y se considera una m.a.s. de tamaño $n$ de $X$. Consideramos las hipótesis $H_0 : \mu = \mu_0$ frente a $H_1 : \mu > \mu_0$. Demostrar que el test que rechaza $H_0$ si $\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}} > t_{n-1,1-\alpha}$ es de extensión $\alpha$.

1) Definición de Extensión (Tamaño del test):

La extensión de un test $\delta$ se define como el supremo de la probabilidad de error tipo I en la región nula:

$$\text{extensión} = \sup_{\theta \in \Theta_0} P_{I,\delta}(\theta) = \sup_{\mu = \mu_0} P(\mathbf{x} \in S_1 | \mu)$$

2) Evaluación bajo la Hipótesis Nula ($H_0$):

Dado que la hipótesis nula es simple ($H_0 : \mu = \mu_0$), el conjuunto $\Theta_0$ solo contiene un elemento. Por lo tanto, el supremo es simplemente la probabilidad evaluada en $\mu = \mu_0$:

$$P(\mathbf{x} \in S_1 | \mu_0) = P\left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > t_{n-1,1-\alpha} \middle| \mu = \mu_0\right)$$

3) Distribución del estadístico de prueba:

Si $H_0$ es cierta, sabemos por la teoría estadística subyacente a poblaciones normales con varianza poblacional desconocida que el estadístico, al usar la desviación típica muestral $S$, sigue una distribución t de Student con $n-1$ grados de libertad:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

4) Resultado final:

Sustituyendo el estadístico $T$ en la probabilidad calculada en el paso 2:

$$P(T > t_{n-1,1-\alpha})$$

Por la definición del cuantil $t_{n-1,1-\alpha}$, que deja a su derecha un área igual a $\alpha$, tenemos que:

$$P(T > t_{n-1,1-\alpha}) = 1 - (1-\alpha) = \alpha$$

Por lo tanto, la extensión del test es, efectivamente, $\alpha$.

**6)** A continuación indicamos para distintas situaciones las hipótesis sobre la media poblacional de una variable normal para $\sigma$ conocida que se plantearon, así como el valor del estadístico de prueba $z_0 = \dfrac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$, que se obtuvo. Determinar los $p$-valores correspondientes e indicar cuál es la decisión acerca de $H_0$.

**a)** $H_0 : \mu = 120; H_1 : \mu \neq 120$, estadístico de prueba: $z_0 = 2.32$.

1) **Planteamiento:** Al ser la hipótesis alternativa de distinto ($\neq$), la región de rechazo se divide en dos colas.

2) **Cálculo del $p$-valor:** El $p$-valor se calcula sumando la probabilidad de las dos colas a partir del valor absoluto del estadístico.

$$p = P(Z \geq |z_0|) + P(Z \leq -|z_0|) = 2 \cdot P(Z \geq 2.32) = 2 \cdot (1 - 0.9898) = 0.0204$$

3) **Decisión:** Un $p$-valor de 0.0204 indica que **rechazaríamos** $H_0$ a un nivel de significación del 5% ($\alpha = 0.05$), pero la aceptaríamos si exigiéramos un nivel más estricto del 1% ($\alpha = 0.01$).

**b)** $H_0 : \mu = 120; H_1 : \mu \neq 120$, estadístico de prueba: $z_0 = -1.88$.

1) **Planteamiento:** Igual que en el caso anterior, tenemos un contraste de dos colas.

2) **Cálculo del $p$-valor:**

$$p = 2 \cdot P(Z \geq |-1.88|) = 2 \cdot P(Z \geq 1.88) = 2 \cdot (1 - 0.9699) = 2 \cdot 0.0301 = 0.0602$$

3) **Decisión:** Un $p$-valor de 0.0602 es mayor que 0.05. Por lo tanto, bajo el nivel de significación estándar del 5%, **no rechazaríamos** $H_0$ (aceptamos que $\mu = 120$).

**c)** $H_0 : \mu = 1000; H_1 : \mu > 1000$, estadístico de prueba: $z_0 = 1.6$.

1) **Planteamiento:** Al ser la hipótesis alternativa de mayor ($>$), la región de rechazo se concentra únicamente en la cola superior.

2) **Cálculo del $p$-valor:**

$$p = P(Z \geq z_0) = P(Z \geq 1.6) = 1 - 0.9452 = 0.0548$$

3) **Decisión:** El $p$-valor es 0.0548. Puesto que es ligeramente superior a 0.05, estadísticamente **no hay evidencia suficiente para rechazar** $H_0$ al nivel de confianza del 95%.

**d)** $H_0 : \mu = 1000; H_1 : \mu < 1000$, estadístico de prueba: $z_0 = -1.24$

1) **Planteamiento:** Al ser la hipótesis alternativa de menor ($<$), la región de rechazo se concentra únicamente en la cola inferior.

2) **Cálculo del $p$-valor:**

$$p = P(Z \leq z_0) = P(Z \leq -1.24)$$

Por simetría de la distribución Normal estándar, $P(Z < -1.24) = P(Z \geq 1.24)$:

$$p = (1 - P(Z \geq 1.24)) = 1 - 0.8925 = 0.1075$$

3) **Decisión:** Un $p$-valor de 0.1075 es notablemente alto, indicando gran compatibilidad de los datos con la hipótesis nula. Por tanto, **se acepta** $H_0$ a cualquier nivel de significación habitual $(1\%, 5\%, 10\%)$.

**7)** En un laboratorio, se estudia la velocidad de combustión de dos tipos de combustibles sólidos A y B. Se pretende determinar qué combustibles presentan una velocidad de combustión en promedio mayor de 50 cm/s. Los resultados obtenidos fueron:

| Combustible | tamaño muestral | Media muestral | Varianza muestral |
|---|---|---|---|
| A | 25 | 51.3 | 3.9 |
| B | 30 | 51.5 | 3.6 |

Suponiendo que la distribución de las variables es normal, plantear un test para contrastar si la varianza en la población de la velocidad de combustión para A es superior a la de B.

1) Extracción de datos muestrales:

- **Combustible A:** $n_A = 25, \bar{x}_A = 51.4, S_A^2 = 3.9$
- **Combustible B:** $n_B = 30, \bar{x}_B = 51.5, S_B^2 = 3.6$

2) Formulación de la hipótesis:

Queremos contrastar si la varianza de A es superior a la de B:

$$\begin{array}{c} H_0 : \sigma_A^2 \leq \sigma_B^2 \\ H_1 : \sigma_A^2 > \sigma_B^2 \end{array}$$

3) Estadístico de prueba y distribución muestral:

Bajo la suposición de que $H_0$ es cierta en su frontera $(\sigma_A^2 = \sigma_B^2)$, el estadístico natural basado en los estimadores de las varianzas es el cociente de las varianzas muestrales, el cual sigue una distribución $F$ de Snedecor con $n_A - 1$ y $n_B - 1$ grados de libertad:

$$F = \frac{S_A^2}{S_B^2} \sim F_{n_A-1, n_B-1}$$

4) Cálculo del valor observado del estadístico:

Sustituyendo los datos de la tabla:

$$F_{obs} = \frac{3.9}{3.6} = 1.0833$$

5) Determinación de la región de rechazo $(S_1)$:

Dado que la hipótesis alternativa postula un valor "mayor que" $(H_1 :>)$, se trata de un contraste unilateral derecho. La región de rechazo estará formada por los valores en al cola superior de la distribución:

$$S_1 = \{(\mathbf{x}_A, \mathbf{x}_B) \mid F > \mathcal{F}_{n_A-1, n_B-1, 1-\alpha}\}$$

Sustituyendo los grados de libertad:

$$S_1 = \{(\mathbf{x}_A, \mathbf{x}_B) \mid F > \mathcal{F}_{24, 29, 1-\alpha}\}$$

6) Regla de Decisión:

Fijado un nivel de significación $\alpha$, la regla deductiva exacta será:

- **Rechazar** $H_0$ si $1.0833 > \mathcal{F}_{24,29,1-\alpha}$
- **Aceptar** $H_0$ si $1.0833 < \mathcal{F}_{24,29,1-\alpha}$

**8)** Sea $X$ una población con función de densidad gamma:

$$f(x; \theta) = \theta^2 x \exp(-\theta x),$$

con $x > 0, \theta > 0$. Se considera una muestra de tamaño $n$ de $X$.

**a)** Estudiar el modelo anterior tiene cociente de verosimilitudes monótono en algún estadístico.

1) Verosimilitud de la muestra:

Dada la m.a.s. de tamaño $n$ para la densidad $f(x; \theta) = \theta^2 x \exp(-\theta x)$, la función de verosimilitud conjunta es:

$$L(\mathbf{x}; \theta) = \prod_{i=1}^{n} \theta^2 x_i \exp(-\theta x_i) = \theta^{2n} \left( \prod_{i=1}^{n} x_i \right) \exp\left( -\theta \sum_{i=1}^{n} x_i \right)$$

2) Verificación del CVM:

Para dos valores del parámetro tales que $\theta_0 < \theta_1$, calculamos el cociente de verosimilitudes:

$$\frac{L(\mathbf{x};\theta_1)}{L(\mathbf{x};\theta_0)} = \frac{\theta_1^{2n}(\prod x_i)\exp(-\theta_1 \sum x_i)}{\theta_0^{2n}(\prod x_i)\exp(-\theta_0 \sum x_i)} = \left(\frac{\theta_1}{\theta_0}\right)^{2n} \exp\left(-(\theta_1-\theta_0)\sum_{i=1}^n x_i\right)$$

Dado que $\theta_1 > \theta_0$, el término $(\theta_1 - \theta_0)$ es positivo. Por lo tanto, el exponente $-(\theta_1-\theta_0)\sum x_i$ es una función estrictamente **decreciente** respecto al estadístico $T(\mathbf{x}) = \sum_{i=1}^n x_i$. Esto es matemáticamente equivalente a decir que el cociente es una función **creciente** (monótona) respecto al estadístico opuesto:

$$R(\mathbf{x}) = -\sum_{i=1}^n x_i$$

*Alternativamente, usando la familia exponencial uniparamétrica:*

$$L(\mathbf{x};\theta) = \exp\left\{-\theta\sum x_i + 2n\ln\theta + \ln\left(\prod x_i\right)\right\}$$

Aquí $A(\theta) = -\theta$. Como $A(\theta)$ es decreciente en $\theta$, el modelo tiene CVM en el estadístico $-T(\mathbf{x}) = -\sum x_i$.

**b)** En caso afirmativo, obtener el test uniforme de máxima potencia y extensión $\alpha$ para el contraste $H_0 : \theta = \theta_0$ frente a $H_1 : \theta > \theta_0$.

1) Región de rechazo:

Sabiendo que el modelo tiene CVM en $R(\mathbf{x}) = -\sum x_i$, el teorema establece que el test UMP tiene una región de rechazo de la forma:

$$S_1 = \{\mathbf{x} \mid R(\mathbf{x}) \geq c'\} \implies -\sum_{i=1}^n x_i \geq c' \implies \sum_{i=1}^n \leq c$$

*Rechazamos para valores pequeños de la suma muestral, o equivalentemente de la media muestral* $\bar{X} \leq c^*$.

2) Extesión $\alpha$: La constante $c$ se determina imponiendo la condición de tamaño:

$$P_{I,\delta}(\theta_0) = P_{\theta_0}\left(\sum_{i=1}^n X_i \leq c\right) = \alpha$$

**c)** Si $n = 20, \alpha = 0.05, \theta_0 = 1$ y $\bar{X} = 1.2$, ¿qué criterio de decisión se tomaría? Obtener el $p$-valor para dicha muestra.

1) Momentos bajo $H_0$:

Si $\theta_0 = 1$, la distribución es una $Gamma(2,1)$. Sus momentos teóricos son:

$$\mu = \frac{2}{\theta} = 2 \text{ y } \sigma^2 = \frac{2}{\theta^2} = 2$$

2) Tipificación del estadístico:

Usando el Teorema Central del Límite (para $n = 20$), la distribución muestral de $\bar{X}$ se aproxima a $\mathcal{N}(\mu, \sigma^2/n) = \mathcal{N}(2, 2/20) = \mathcal{N}(2, 0.1)$.

El valor tipificado observado es:

$$z_{obs} = \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} = \frac{1.2-2}{\sqrt{0.1}} = \frac{-0.8}{0.3162} \approx -2.53$$

3) Cálculo del $p$-valor:

Como la región de rechazo demostrada en (b) se encuentra en la cola inferior ($\bar{X} \leq c^*$), el $p$-valor se calcula como:

$$p\text{-valor} = P(Z \leq -2.53) = 1 - P(Z \geq 2.53) \approx 1 - 0.9943 = 0.0057$$

**d)** Obtener el test de razón de verosimilitudes generalizado y extensión $\alpha$, para el contraste $H_0 : \theta = 2$ frente a la hipótesis $H_1 : \theta \neq 2$.

1) Estimador de Máxima Verosimilitud (EMV):

Para el denominador de RVG, necesitamos el supremo global. Derivando el log-verosimilitud:

$$\ln L(\mathbf{x};\theta) = 2n\ln\theta - \theta\sum x_i + \ln\left(\prod x_i\right)$$
$$\frac{\partial \ln L}{\partial\theta} = \frac{2n}{\theta} - \sum x_i = 0 \implies \hat{\theta} = \frac{2n}{\sum x_i} = \frac{2}{\bar{x}}$$

El supremo global es: $L(\mathbf{x},\hat{\theta}) = \left(\frac{2}{\bar{x}}\right)^2 \left(\prod x_i\right)\exp(-2n)$.

2) RVG ($\lambda(\mathbf{x})$):

El numerador bajo $H_0$ es evaluando $\theta = 2:\ L(\mathbf{x},2) = 2^{2n}\left(\prod x_i\right)\exp\left(-2\sum x_i\right)$.

$$\lambda(\mathbf{x}) = \frac{L(\mathbf{x};2)}{L(\mathbf{x};\hat{\theta})} = \frac{2^{2n}\exp(-2n\bar{x})}{\left(\frac{2}{\bar{x}}\right)^{2n}\exp(-2n)} = \bar{x}^{2n}\exp(-2n(\bar{x}-1))$$

3) Región de rechazo y extensión

El test rechaza si $\lambda(\mathbf{x}) < k$. La constante $k$ se determina por:

$$P_{\theta=2}(\lambda(\mathbf{x}) < k) = \alpha$$

**9)** Sea $X$ una población con función de densidad

$$f(x;\theta) = \frac{2\theta}{1-\theta}x^{\frac{3\theta-1}{1-\theta}}\ 0 < x < 1$$

donde $\theta \in (0,1)$ es un parámetro desconocido. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple de $X$, se pide:

**a)** Obtener el test uniforme de máxima potencia y extensión $\alpha$ para el contraste $H_0 : \theta = \theta_0$ frente a $H_1 : \theta = \theta_1$, con $\theta_0 > \theta_1$.

Por el Lema de Neyman-Pearson, la región de rechazo de máxima potencia es:

$$S_1 = \left\{\mathbf{x}\middle|\frac{L(\mathbf{x},\theta_1)}{L(\mathbf{x},\theta_0)} \geq k\right\}$$

Sustituyendo verosimilitudes:

$$\exp\left([A(\theta_1) - A(\theta_0)]\sum_{i=1}^{n}\log(x_i)\right) \geq k'$$

Como $\theta_1 < \theta_0$ y $A(\theta)$ es creciente, $A(\theta_1) - A(\theta_0) < 0$. Al aplicar logaritmos y despejar, la desigualdad se invierte:

$$S_1 = \left\{\mathbf{x}\middle|\sum_{i=1}^{n}\log(x_i) \leq c\right\}$$

Donde $c$ se determina imponiendo la extensión $\alpha:\ P_{\theta_0}\left(\sum\log(X_i) \leq c\right) = \alpha$.

**b)** Si $n = 20, \alpha = 0.05, \theta_0 = \frac{1}{2}$ y $\sum_{i=1}^{20}\log(x_i) = -6.21$, obtener el $p$-valor para dicha muestra. ¿Qué criterio de decisión se tomaría?

Para $\theta_0 = \frac{1}{2}$, la densidad es $f(x;1/2) = 2x$.

Haciendo la transformación $Y = -\log(X)$, se obtiene que $Y \sim Exp(\lambda = 2)$.

El estadístico $W = -\sum_{i=1}^{20}\log(X_i) = \sum_{i=1}^{20}Y_i$ sigue una distribución $Gamma(20,2)$, por lo que $2W \sim \chi^2_{40}$.

1) **Valor observado:** $\sum\log(x_i) = -6.21 \implies W_{obs} = 6.21 \implies 2W_{obs} = 12.42$.

2) **$p$-valor:** Como la región de rechazo es $\sum\log(x_i) \leq c$ (equivalentemente $2W \geq c'$), el $p$-valor es la probabilidad de observar un valor máx extremo hacia la región de rechazo:

$$p\text{-valor} = P_{H_0}\left(\sum\log(X_i) \leq -6.21\right) = P(\chi^2_{40} \geq 12.42)$$

3) **Decisión:** En una $\chi^2_{40}$, la media es 40. Un valor de 12.42 deja casi toda el área a su derecha ($p \approx 0.999$). Al ser $p$-valor $> \alpha$, **se acepta** $H_0$.

**c)** Si para el contraste anterior, $\theta_0 = \frac{1}{2}, \theta_1 = \frac{1}{4}$ y las probabilidades de error de primer y segundo tipo son iguales a 0.05, obtener el tamaño muestral y la región crítica de dicho test.

Bajo $H_0(\theta_0 = 1/2)$, demostramos que $2W \sim \chi^2_{2n}$.

Bajo $H_1(\theta_1 = 1/4)$, la densidad de $f(x; 1/4) = \frac{2}{3}x^{-\frac{1}{3}}$. Haciendo $Y = -\log(X), Y \sim Exp(\lambda = 2/3)$. Por tanto, $\frac{4}{3}W \sim \chi^2_{2n}$.

Con las probabilidades de error $\alpha$ y $\beta$ definimos el sistema de ecuaciones para el límite $c^*$ del estadístico $W$:

1) $P_{H_0}(W \geq c^*) = 0.05 \implies P(\chi^2_{2n} \geq 2c^*) = 0.05 \implies 2c^* = \chi^2_{2n,0.05}$

2) $P_{H_1}(W < c^*) = 0.05 \implies P_{H_1}(W \geq c^*) = 0.95 \implies P\left(\chi^2_{2n} \geq \frac{4}{3}c^*\right) = 0.95 \implies \frac{4}{3}c^* = \chi^2_{2n,0.95}$

El tamaño muestral $n$ obtiene resolviendo la relación entre los cuantiles:

$$\frac{\chi^2_{2n,0.05}}{\chi^2_{2n,0.95}} = \frac{2c^*}{\frac{4}{3}c^*} = 1.5$$

Una vez hallado $n$, la región crítica exacta queda como $S_1 = \left\{\mathbf{x} \middle| -\sum \log(x_i) \geq \frac{1}{2}\chi^2_{2n,0.05}\right\}$

**d)** Obtener el test uniforme de máxima potencia y extensión $\alpha$ para el contraste $H_0 : \theta = \theta_0$ frente a $H_1 : \theta < \theta_0$.

Puesto que el modelo posee Cociente de Verosimilitud Monótono en $T(\mathbf{x}) = \sum \log(x_i)$, el test uniforme de máxima potencia para alternativas unilaterales mantiene exactamente la misma estructura que en el apartado (a):

$$S_1 = \left\{\mathbf{x} \middle| \sum_{i=1}^{n} \log(x_i) \leq c\right\}$$

Con extensión $\alpha = P_{\theta_0}\left(\sum \log(X_i) \leq c\right)$.

**e)** ¿Se puede extender el contraste anterior $H_0 : \theta \geq \theta_0$ frente a $H_1 : \theta < \theta_0$?

**Sí, se puede extender.** La construcción fundamentada en el CVM "se extiende al contraste $H_0 : \theta \geq \theta_0$ frente a $H_1 : \theta < \theta_0$". El estadístico, la región de rechazo y la obtención de la constante de extensión $\alpha$ calculada en el límite ($\theta = \theta_0$) permanecen idénticos.

**10)** Sea $X$ una población con función de densidad

$$f(x; \theta) = \frac{1}{\theta(1-x)^2} \exp\left(-\frac{x}{\theta(1-x)}\right) \chi_{(0,1)}(x),$$

donde $\theta$ es un parámetro desconocido estrictamente positivo. Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de $X$.

**a)** Estudiar si $X$ tiene un cociente de verosimilitud monótono en algún estadístico.

1) Verosimilitud de la muestra:

Dada una muestra aleatoria simple de tamaño $n$, la función de verosimilitud conjunta es:

$$L(\mathbf{x}, \theta) = \prod_{i=1}^{n} \frac{1}{\theta(1-x_i)^2} \exp\left(-\frac{x_i}{\theta(1-x_i)}\right)$$
$$L(\mathbf{x}; \theta) = \theta^{-n} \left(\prod_{i=1}^{n} \frac{1}{(1-x_i)^2}\right) \exp\left(-\frac{1}{\theta}\sum_{i=1}^{n} \frac{x_i}{1-x_i}\right)$$

2) Pertenencia a la familia exponencial:

Reescribimos la función para identificar si pertenece a la familia exponencial uniparamétrica:

$$L(\mathbf{x}; \theta) = \exp\left\{-\frac{1}{\theta}\sum_{i=1}^{n} \frac{x_i}{1-x_i} - n\ln(\theta) - 2\sum_{i=1}^{n} \ln(1-x_i)\right\}$$

Esta expresión tiene la forma $L(\mathbf{x}; \theta) = \exp\{A(\theta)T(\mathbf{x}) + B(\theta) + h(\mathbf{x})\}$, donde:

- $A(\theta) = -\dfrac{1}{\theta}$
- $T(\mathbf{x}) = \displaystyle\sum_{i=1}^{n} \frac{x_i}{1-x_i}$

3) Condición de Monotonía:

Calculamos la derivada de $A(\theta)$:

$$A'(\theta) = \frac{1}{\theta^2} > 0 \text{ para todo } \theta > 0$$

Dado que $A(\theta)$ es una función estrictamente creciente, la variable $X$ tiene un **Cociente de Verosimilitud Monótono** en el estadístico $T(\mathbf{x}) = \displaystyle\sum_{i=1}^{n} \frac{x_i}{1-x_i}$.

**b)** Si $X$ tiene un cociente de verosimilitud monótono, obtener el test uniforme de máxima potencia y extensión $\alpha$, para el contraste $H_0 : \theta > \theta_0$ frente a la hipótesis $H_1 : \theta < \theta_0$.

Para constrastar $H_0 : \theta \geq \theta_0$ frente a $H_1 : \theta < \theta_0$:

Al cumplirse que el modelo tiene CVM en el estadístico $T(\mathbf{x}) = \sum \dfrac{x_i}{1-x_i}$, el teorema establece que para la alternativa menor ($<$), el test UMP tiene una región de rechazo de la forma:

$$S_1 = \left\{ \mathbf{x} \in \text{Sop}(X) \middle| T(\mathbf{x}) = \sum_{i=1}^{n} \frac{x_i}{1-x_i} \leq c \right\}$$

La constante $c$ queda unívocamente determinada al imponer la condición de que la expresión sea $\alpha$ evaluada en el límite $\theta = \theta_0$:

$$P_{I,\delta}(\theta_0) = P_{\theta_0}\left( \sum_{i=1}^{n} \frac{X_i}{1-X_i} \leq c \right) = \alpha$$

**c)** Si consideramos una muestra de tamaño $n = 25$ y $\theta_0 = 0.2, \alpha = 0.05$ y $\displaystyle\sum_{i=1}^{25} \frac{x_i}{1-x_i} = 6.23$, obtener el $p$-valor de dicha muestra. Explicar de dos formas diferentesqué criterio de decisión se tomaría en este caso.

para obtener la distribución del estadístico $T(\mathbf{X})$, analizamos la variable transformada $Y_i = \dfrac{X_i}{1-X_i}$. Aplicando el teorema de cambio de variable, se demuestra que $Y_i \sim Exp(\theta)$. Consecuentemente, la suma de exponenciales independientes da lugar a una distribución Gamma, y tras el oportuno escalado:

$$\frac{2}{\theta} \sum_{i=1}^{n} \frac{X_i}{1-X_i} \sim \chi^2_{2n}$$

1) Evaluación bajo $H_0$:

Sustituimos $n = 25$ y $\theta_0 = 0.2$:

$$\frac{2}{0.2} T = 10 \cdot T \sim \chi^2_{50}$$

2) Valor observado y $p$-valor:

Dado $T_{obs} = 6.23$, el valor estadístico tipificado es $10 \cdot 6.23 = 62.3$.

Como la región de rechazo demostrada en el apartado (b) está en la cola inferior ($T \leq c$), el $p$-valor se calcula como el área a la izquierda del valor observado:

$$p\text{-valor} = P(\chi^2_{50} \leq 62.3) > 0.5$$

3) Dos criterios de decisión:

- **Criterio 1 (Vía $p$-valor):** Dado que el $p$-valor $> 0.5$ es estrictamente mayor que el nivel de significación $\alpha = 0.05$, la decisión es **aceptar la hipótesis nula** $H_0$.
- **Criterio 2 (Vía Región Crítica):** La frontera de la región crítica se obtiene buscando el cuantil $\chi^2_{50,0.05}$ (que deja un 5% a su izquierda). Rechazaríamos $H_0$ si $10 \cdot T_{obs} \leq \chi^2_{50,0.05}$. Como 62.3 no es menor que el valor crítico de la cola inferior, el estadístico no cae en $S_1$, decidiendo **aceptar** $H_0$**.**

**d)** Utilizando el test de la razón de verosimilitudes generalizado, obtener la región crítica del contraste $H_0 : \theta = \frac{1}{2}$ frente a la hipótesis $H_1 : \theta \neq \frac{1}{2}$.

Para constrastar $H_0 : \theta = \frac{1}{2}$ frente a $H_1 : \theta \neq \frac{1}{2}$.

1) Estimador de Máxima Verosimilitud (EMV):

Para el denominador de $\lambda(\mathbf{x})$, hallamos el supremo maximizando $\ln L(\mathbf{x};\theta)$:

$$\frac{\partial \ln L}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} T(\mathbf{x}) = 0 \implies \hat{\theta}_{EMV} = \frac{T(\mathbf{x})}{n}$$

2) Construcción del estadístico $\lambda(\mathbf{x})$:

Sustituyendo $\theta = \frac{1}{2}$ (numerador) y $\theta = \frac{T}{n}$ (denominador) en la función de verosimilitud:

$$\lambda(\mathbf{x}) = \frac{L(\mathbf{x};1/2)}{L(\mathbf{x};T/n)} = \frac{2^n \exp(-2T)}{(n/T)^n \exp(-n)} = \left(\frac{2T}{n}\right)^n \exp(n-2T)$$

3) Región Crítica ($S_1$):

El test RVG rechza $H_0$ cuando $\lambda(\mathbf{x}) < k$:

$$S_1 = \left\{ \mathbf{x} \in \mathrm{Sop}(\mathbf{X}) \middle| \left(\frac{2T(\mathbf{x})}{n}\right)^n \exp(n - 2T(\mathbf{x})) < k \right\}$$

Al estudiar la función $g(T) = \left(\frac{2T}{n}\right)^n \exp(n-2T)$, observamos que alcanza su máximo en $T = \frac{n}{2}$ y decrece al alejarse de este valor central. Por tanto, la desigualdad $g(T) < k$ se traduce en dos colas para el estadístico suficiente. La región crítica resultante es de la forma:

$$S_1 = \left\{ \mathbf{x} \middle| \sum_{i=1}^n \frac{x_i}{1-x_i} < c_1 \cup \sum_{i=1}^n \frac{x_i}{1-x_i} > c_2 \right\}$$

*(Donde $c_1$ y $c_2$ garantizan la extensión $\alpha$ exigida al test).*

**11)** Sea $X$ una población con función de densidad:

$$f(x;\theta) = \frac{\theta}{(1+x)^{\theta+1}} \chi_{(0,\infty)}(x),$$

con $\theta > 0$. Se considera una muestra aleatoria simple de $X$ de tamaño $n$.

**a)** Obtener el test de máxima potencia y extensión $\alpha$ para el contraste $H_0 : \theta = \theta_0$ frente a la hipótesis $H_1 : \theta = \theta_1$ con $\theta_0 < \theta_1$.

Por el Lema de Neyman-Pearson, el test de región de rechazo de máxima potencia es:

$$S_1 = \left\{ \mathbf{x} \middle| \frac{L(\mathbf{x},\theta_1)}{L(\mathbf{x},\theta_0)} \geq k \right\}$$

Sustituimos la verosimilitud en el cociente:

$$\frac{\theta_1^n \exp(-(\theta_1+1)T(\mathbf{x}))}{\theta_0^n \exp(-(\theta_0+1)T(\mathbf{x}))} = \left(\frac{\theta_1}{\theta_0}\right)^n \exp(-(\theta_1-\theta_0)T(\mathbf{x})) \geq k$$

Tomando logaritmos y operando:

$$n \ln\left(\frac{\theta_1}{\theta_0}\right) - (\theta_1 - \theta_0)T(\mathbf{x}) \geq \ln(k)$$

Dado que la condición del enunciado establece $\theta_0 < \theta_1$, el término $(\theta_1 - \theta_0)$ es positivo. Al despejar $T(\mathbf{x})$, el signo de la inecuación se invierte:

$$T(\mathbf{x}) \leq \frac{n \ln(\theta_1/\theta_0) - \ln(k)}{\theta_1 - \theta_0} = c$$

Por tanto, la región crítica queda expresada matemáticamente como:

$$S_1 = \left\{ \mathbf{x} \middle| \sum_{i=1}^{n} \ln(1+x_i) \leq c \right\}$$

Con extensión $\alpha$ : $P_{\theta_0}\left(\sum_{i=1}^{n} \ln(1+X_i) \leq c\right) = \alpha$.

**b)** Si $\alpha = 0.05$ y la probabilidad del error de tipo $II$ es 0.2, obtener el diseño del test.

Para calcular las probabilidades, necesitamos la distribución de $T$. Efectuando el cambio de variable $Y_i = \ln(1+X_i)$, se demuestra analíticamente que $Y_i \sim Exp(\theta)$. Por propiedad de adición de exponenciales, la suma $T = \sum Y_i \sim \text{Gamma}(n, \theta)$, lo que implica que la variable escaladasigue una chi-cuadrado:

$$2\theta T \sim \chi^2_{2n}$$

Se plantean dos ecuaciones para determinar el diseño (tamaño muestral $n$ y frontera $c$):

1) **Error tipo I ($\alpha = 0.05$):** $P_{\theta_0}(T \leq c) = 0.05 \implies P(2\theta_0 T \leq 2\theta_0 c) = 0.05$.

$$2\theta_0 c = \chi^2_{2n,0.95} \text{ (cuantil inferior 5\%)}$$

2) **Error tipo II ($\beta = 0.2$):** $P_{\theta_1}(T > c) = 0.2 \implies P_{\theta_1}(T \leq c) = 0.8 \implies P(2\theta_1 T \leq 2\theta_1 c) = 0.8$.

$$2\theta_1 c = \chi^2_{2n,0.20} \text{ (cuantil inferior 80\%)}$$

El diseño se obtiene resolviendo el sistema. Dividiendo ambas ecuaciones, se despeja $n$ independiente de $c$:

$$\frac{\chi^2_{2n,0.20}}{\chi^2_{2n,0.95}} = \frac{\theta_1}{\theta_0}$$

**c)** Obtener el test uniforme de máxima potencia y extensión $\alpha$, para el contraste $H_0 : \theta \geq \theta_0$ frente a $H_1 : \theta < \theta_0$.

Reescribiendo la verosimilitud como $L(\theta) \propto \exp\{A(\theta)T(\mathbf{x})\}$, tenemos que $A(\theta) = -(\theta+1)$.

La derivada $A'(\theta) = -1 < 0$ indica que $A(\theta)$ es estrictamente decreciente. Por tanto, la familia posee Cociente de Verosimilitud Monótono (CVM) inverso respecto al estadístico $T(\mathbf{x})$, o directo respecto a $-T(\mathbf{x})$.

Para la alternativa $H_1 : \theta < \theta_0$, el teorema de CVM estipula que la región de rechazo se opone al comportamiento de la función $A(\theta)$. Puesto que al derivada es negativa, el test rechaza para valores **grandes** del estadístico:

$$S_1 = \left\{ \mathbf{x} \middle| \sum_{i=1}^{n} \ln(1+x_i) \geq c \right\}$$

Con extensión impuesta en la frontera: $P_{\theta_0}\left(\sum_{i=1}^{n} \ln(1+X_i) \geq c\right) = \alpha$.

**d)** Si consideramos una muestra de tamaño $n = 20$ y $\theta_0 = 2, \alpha = 0.05$ y $\sum_{i=1}^{20} \ln(1+x_i) = 37.3$, obtener el $p$-valor de dicha muestra. Explicar de dos formas diferentes qué criterio de decisión se tomaría en este caso.

Aplicamos el test del apartado (c) ($H_0 : \theta \geq 2$ frente a $H_1 : \theta < 2$). Rechazamos si $T \geq c$.

Bajo la frontera nula $\theta_0 = 2$, sabemos que:

$$2\theta_0 T \sim \chi^2_{2n} \implies 4T \sim \chi^2_{40}$$

1) Valor observado tipificado:

$$4 \cdot T_{obs} = 4 \cdot 37.3 = 149.2$$

2) Cálculo del $p$-valor:

Dado que la región de rechazo está en la cola superior:

$$p\text{-valor} = P_{\theta=2}(T \geq 37.3) = P(\chi^2_{40} \geq 149.2)$$

*(Sabiendo que la media de una $\chi^2_{40}$ es 40, el valor 149.2 está extremandamente alejado en la cola derecha, por lo que $p$-valor $\approx 0$).*

3) Dos criterio de decisión:

- **Via $p$-valor:** Como $p$-valor $\approx 0 < \alpha = 0.05$, existe evidencia abrumadora para **rechazar la hipótesis nula** $H_0$ en favor de la alternativa.
- **Via Región Crítica:** Calculamos la región de rechazo buscando el cuantil superior $\chi^2_{40,0.05}$ (aproximadamente 55.76). Puesto que el estadístico $149.2 \geq 55.76$, cae plenamente dentro de la región de rechazo $S_1$, decidiendo **rechazar** $H_0$.

**12)** Sea $X \sim N(\mu, \sigma^2)$ con $\mu$ conocida y $\sigma^2 \in \Theta = \mathbb{R}^+$. Dada una m.a.s. de tamaño $n$, obtener el test de máxima potencia y extensión $\alpha$ para el test (contraste) $H_0 : \sigma^2 = \sigma_0^2$ frente a $H_1 : \sigma^2 : \sigma_1^2$, con $(\delta_1^2 > \sigma_0^2)$.

1) Función de verosimilitud:

Dado que $X \sim \mathcal{N}(\mu, \sigma^2)$ con $\mu$ conocida, la función de verosimilitud para una muestra aleatoria simple de tamaño $n$ es:

$$L(\mathbf{x}; \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \mu)^2\right)$$

2) Cociente de Neyman-Pearson:

El lema establece que la región de rechazo $S_1$ del test de máxima potencia cumple la condición:

$$\frac{L(\mathbf{x}; \sigma_1^2)}{L(\mathbf{x}; \sigma_0^2)} \geq k$$

Sustituyendo las verosimilitudes:

$$\frac{(2\pi\sigma_1^2)^{-n/2} \exp\left(-\frac{1}{2\sigma_1^2}\sum_{i=1}^{n}(x_i - \mu)^2\right)}{(2\pi\sigma_0^2)^{-n/2} \exp\left(-\frac{1}{2\sigma_0^2}\sum_{i=1}^{n}(x_i - \mu)^2\right)} \geq k$$

Simplificando los términos constantes:

$$\left(\frac{\sigma_0^2}{\sigma_1^2}\right)^{n/2} \exp\left(-\frac{1}{2}\left(\frac{1}{\sigma_1^2} - \frac{1}{\sigma_0^2}\right)\sum_{i=1}^{n}(x_i - \mu)^2\right) \geq k$$

3) Aislamiento del estadístico:

Tomamos logaritmos neperianos a ambos lados de la desigualdad para despejar el estadístico de los datos:

$$\frac{n}{2}\ln\left(\frac{\sigma_0^2}{\sigma_1^2}\right) - \frac{1}{2}\left(\frac{1}{\sigma_1^2} - \frac{1}{\sigma_0^2}\right)\sum_{i=1}^{n}(x_i - \mu)^2 \geq \ln(k)$$

Operamos la fracción dentro del paréntesis:

$$-\frac{1}{2}\left(\frac{\sigma_0^2 - \sigma_1^2}{\sigma_1^2\sigma_0^2}\right)\sum_{i=1}^{n}(x_i - \mu)^2 \geq \ln(k) - \frac{n}{2}\ln\left(\frac{\sigma_0^2}{\sigma_1^2}\right)$$
$$\left(\frac{\sigma_1^2 - \sigma_0^2}{2\sigma_1^2\sigma_0^2}\right)\sum_{i=1}^{n}(x_i - \mu)^2 \geq k'$$

Dado que en la hipótesis alternativa $\sigma_1^2 > \sigma_0^2$, el factor multiplicativo $\left(\frac{\sigma_1^2 - \sigma_0^2}{2\sigma_1^2\sigma_0^2}\right)$ es estrictamente positivo. Al dividir por él, la inecuación mantiene su sentido original, definiendo la región de rechazo de la forma:

$$S_1 = \left\{\mathbf{x} \middle| \sum_{i=1}^{n}(x_i - \mu)^2 \geq c\right\}$$

4) Determinación de la constante $c$ (Extensión $\alpha$):

Para que el test tenga extensión $\alpha$, debe cumplirse que la probabilidad de error de tipo I sea igual a $\alpha$:

$$P_{\sigma_0^2}\left(\sum_{i=1}^{n}(X_i - \mu)^2 \geq c\right) = \alpha$$

Sabiendo que, bajo la hipótesis nula $H_0$, la variable tipificada sigue una distribución ji-cuadrado con $n$ grados de libertad:

$$\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma_0^2} \sim \chi_n^2$$

Dividimos ambos lados de la desigualdad de la probabilidad por $\sigma_0^2$:

$$P\left(\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma_0^2} \geq \frac{c}{\sigma_0^2}\right) = \alpha \implies P\left(\chi_n^2 \geq \frac{c}{\sigma_0^2}\right) = \alpha$$

Por lo tanto, el valor $\frac{c}{\sigma_0^2}$ se corresponde con el cuantil superior de la distribución $\chi_n^2$ que deja una probabilidad $\alpha$ a su derecha (denotado como $\chi_{n,\alpha}^2$):

$$\frac{c}{\sigma_0^2} = \chi_{n,\alpha}^2 \implies c = \sigma_0^2 \cdot \chi_{n,\alpha}^2$$

**Conclusión final:**

El test de máxima potencia y extensión $\alpha$ queda definido por la región de rechazo:

$$\textbf{Rechazar } H_0 \textbf{ si } \sum_{i=1}^{n}(x_i-\mu^2) \geq \sigma_0^2 \cdot \chi_{n,\alpha}^2.$$

# 5 Inferencia Bayesiana

## 5.1 Introducción

Lo que hemos visto hasta el momento:

- Se llama al enfoque frecuentista, o clásico de la inferencia.
- Hay otro enfoque, llamado la **inferencia bayesiana.**

La inferencia bayesiana

- Asume que modelizamos la información que podemos tener sobre el parámetro a través de una distribución de probabilidad.
- Formulamos como parte del modelo una **distribución a priori** sobre $\theta$. Su f.p.p. o función de densidad se denota como $\pi(\theta)$.
- La inferencia bayesiana actualiza la información a priori, usando para ello la muestra $\mathbf{x}$ observada, para poder obtener la **distribución a posteriori** $\pi(\theta|\mathbf{x})$.

## 5.2 La inferencia bayesiana

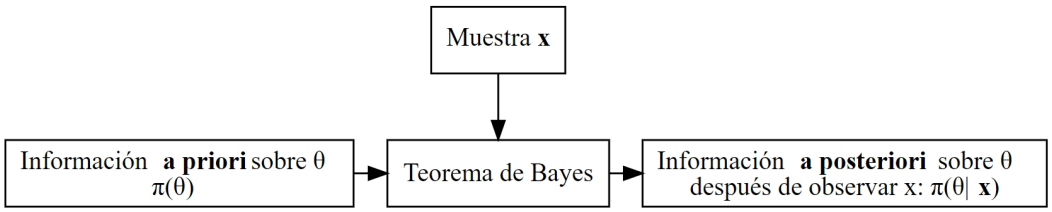


Fórmula de Bayes

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

Para distribuciones condicionadas:

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}|\theta)\pi(\theta)}{m(\mathbf{x})}$$

- $m(\mathbf{x})$ es la margina de $\mathbf{x}$.
- Si $\pi$ es uan distribución continua: $m(\mathbf{x}) = \int f(\mathbf{x}|u)\pi(i)\,\mathrm{d}u$, la densidad margina de $\mathbf{x}$ calculada a partir de la conjunta.
- Esta integral se realiza sobre el conjunto de valores posibles de $\theta$.

## 5.3 La distribución a posteriori

En la expresión

$$\pi(\theta|\mathbf{x}) = \frac{f(\mathbf{x}|\theta)\pi(\theta)}{m(\mathbf{x})},$$

$\mathbf{x}$ es el input, una constante. Nos interesa la variable $\theta$, y el denominador solo depende de $\mathbf{x}$. Escribimos

$$\pi(\theta|\mathbf{x}) \propto f(\mathbf{x}|\theta)\pi(\theta),$$

donde $\propto$ quiere decir "es proporcional a".

Consejo

A veces, será suficiente reconocer el modelo de distribución que sigue $\pi(\theta|\mathbf{x})$ sin tener que calcular el denominador.

## Ejemplo

Ingredientes

Lanzamos un dado $n$ veces y apuntamos en cada tirada si ha salido par o impar.

- $X \sim \text{Bernoulli}(p), X = 1$ si el resultado es par.
- muestra: $(x_1, \dots, x_n)$, tenemos que

$$f(x_1, \dots, x_n|p) = p^{n\bar{x}}(1-p)^{n(1-\bar{x})}.$$

- Información a priori sobre $p$: puede tomar cualquier valor en $(0,1)$ con igual probabilidad:

$$\pi(p) = \begin{cases} 1 & \text{si } p \in (0,1) \\ 0 & \text{en otro caso} \end{cases}$$

$$\pi(p|\mathbf{x}) \propto p^{n\bar{x}}(1-p)^{n(1-\bar{x})}.$$

Reconocemos una distribución beta

Sean dos parámetros positivos $a$ y $b$, $X \sim \text{Be}(a,b)$, si

$$f(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1}(1-x)^{b-1}, \text{ para todo } x \in (0,1),$$

siendo $\Gamma$ la función gamma.

- Su esperanza: $E[X] = \dfrac{a}{a+b}$
- Su varianza: $\text{Var}[X] = \dfrac{ab}{(a+b)^2(a+b+1)}$.
- Incluye la distribución uniforme en $(0,1)$, si $a = 1$ y $b = 1$.
- En `R`, `dbeta`, `pbeta`, `qbeta`.

Tiramos 10 veces el dado, obtenemos 6 veces un número par

$$\pi(p|\mathbf{x}) \propto p^{n\bar{x}}(1-p)^{n(1-\bar{x})}.$$
$$\pi(p|\mathbf{x}) \sim \text{Be}(1+n\bar{x}, 1+n(1-\bar{x}))$$

¿Qué vale $n\bar{x}$?

$$\pi(p|\mathbf{x}) \sim \text{Be}(7,5)$$

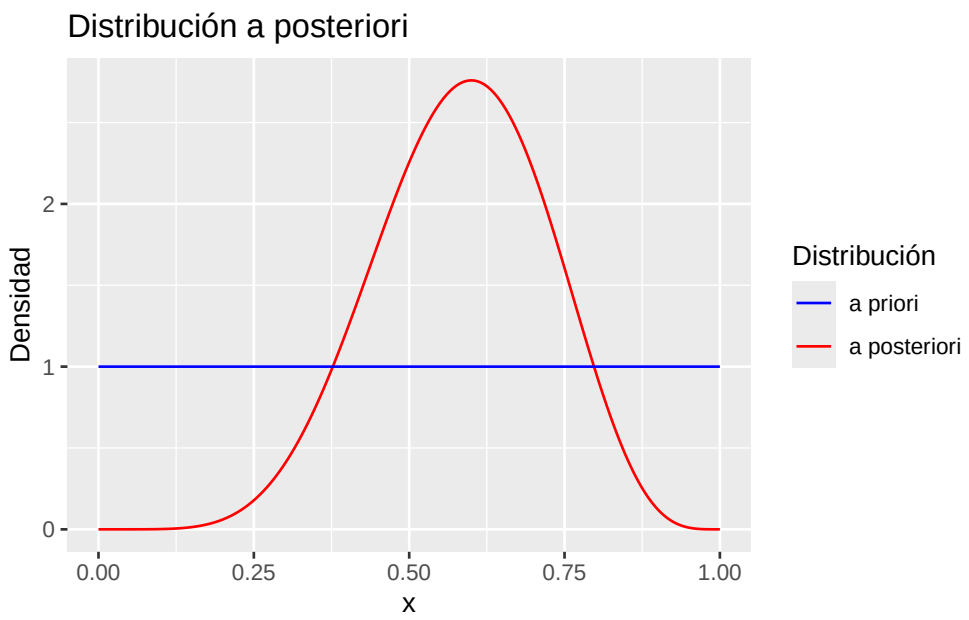


Seguimos tirando el dado, hasta 50 veces, obtenemos otras 18 veces un número par, en total 24 veces: $\pi(p) = 1, \pi(p|\mathbf{x}) \sim \text{Be}(25, 27)$

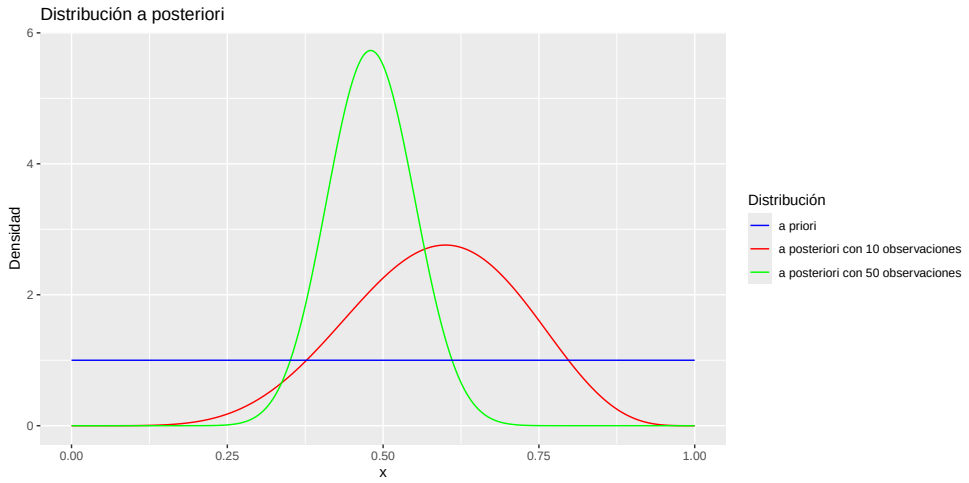


## 5.4 Distribución a posteriori

Con el enfoque bayesiano, el resultado de la inferencia, una vez observada una muestra, es una distribución entera, la distribución a posteriori.

- Podemos representarla, contiene toda la información que hemos inferido sobre $\theta$, a partir de la muestra y nuestra especificación de la distribución a priori.
- Podemos resumirla, por ejemplo con la media, la mediana.
- Podemos incluso dar un intervalo que contiene el 95% de los valores de $\theta$. (*"intervalo de credibilidad al 95%"*).

**Estimador Bayes**

Si consideramos una función de pérdida $L(\theta, a)$ asociada a estimar $\theta$ por $a$, la pérdida esperada a partir de la distribución a posteriori sería:

$$E[L(\theta, a)][\mathbf{x}] = \int_{\Omega} L(\theta, a)\pi(\theta|\mathbf{x})\, \mathrm{d}\theta$$

para cada valor posible $\mathbf{x}$ del vector aleatorio $\mathbf{X}$, sea $\delta^*(\mathbf{x})$ un valor de a cuya pérdida esperada, dada por la expresión anterior sea mínima. La función $\delta^*(\mathbf{X})$ define un estimado llamado estimador Bayes:

$$\delta^*(\mathbf{X}) = \min_{a \in \Theta} E[L(\theta, a)|\mathbf{x}]$$

- Si $L(\theta, a) = (\theta - a)^2 \to \delta^*(\mathbf{X}) = E(\theta|\mathbf{X})$.
- Si $L(\theta, a) = |\theta - a| \to \delta^*(\mathbf{X}) = \text{mediana}$.

## 5.5 En el ejemplo de las tiradas de dados

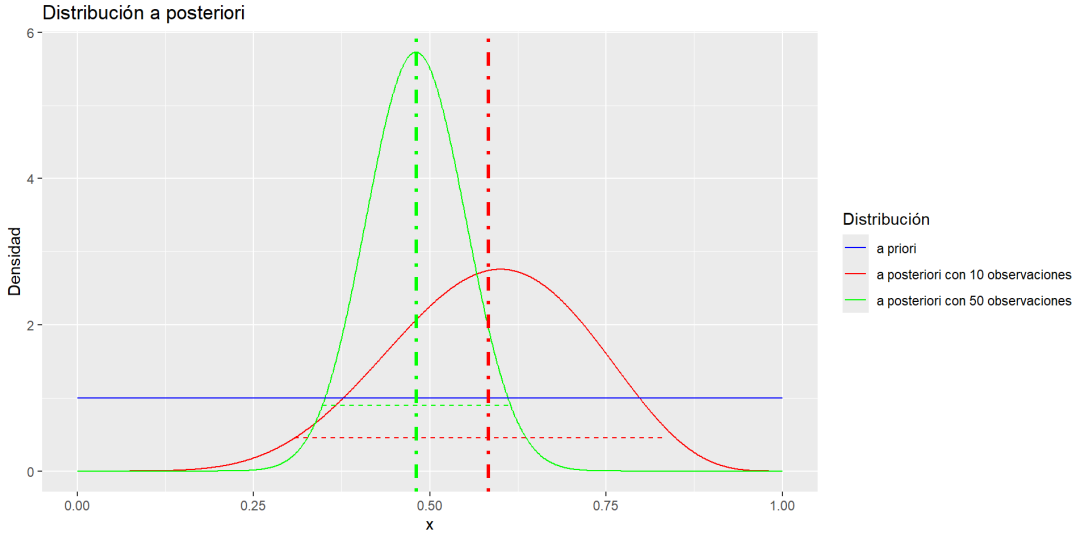


**Cuando usamos las 10 primeras observaciones**

- $E[p|\mathbf{x}] = \dfrac{7}{12} = 0.58$
- Intervalo credibilidad al 95%:
  `(qbeta(0.025,7,5),qbeta(0.975,7,5))=(0.31,0.83)`

**Cuando usamos las 50 primeras observaciones**

- $E[p|\mathbf{x}] = \dfrac{25}{52} = 0.48$
- Intervalo credibilidad al 95%:
  `(qbeta(0.025,25,27),qbeta(0.975,25,27))=(0.35,0.62)`

## 5.6 Cambiamos la distribución a priori

Si $\pi(p) \sim \text{Be}(a_0, b_0)$, y $X|p \sim \text{Bernoulli}(p)$ entonces

$$\pi(p|\mathbf{x}) \sim \text{Be}(a' + n\bar{x}, b_0 + n(1 - \bar{x})).$$

**Clases conjugadas**

Decimos que las clases Bernoulli (para $X$) y Beta (para la priori) son **conjugables:** la posteriori se queda en la misma clase de distribuciones que la a priori.

### 5.6.1 La distribución $\mathrm{Be}(a, b)$ es bastante flexible como a priori

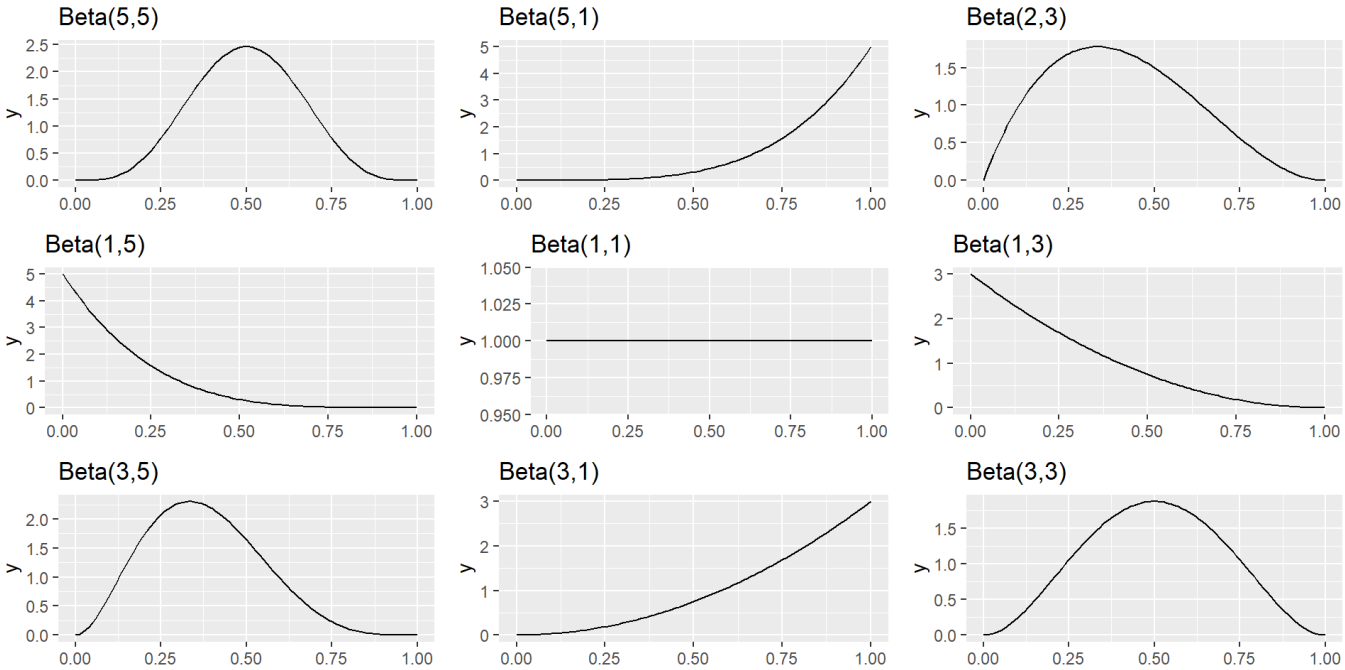


## 5.7 Aplicaciones de la inferencia Bayesiana

La inferencia bayesiana se utiliza en varias áreas del aprendizaje máquina

- **Redes Bayesianas** (Belief Networks): Modelos gráficos que permiten representar las dependencias condicionales entre variables aleatorias de forma compacta.
- **Optimización Bayesiana:** Se utiliza para optimizar funciones objetivas que son costosas de evaluar, útil en el ajuste de hiperparámetros para modelos de aprendizaje máquina.
- **Procesamiento de Lenguaje Natural** (PLN): Por ejemplo para la clasificación de texto y el análisis de sentimientos.
- **Sistemas de Recomendación:** Los modelos bayesianos se pueden utilizar para predecir la preferencias de los usuarios y hacer recomendaciones.

### 5.7.1 Ilustración para un ejemplo simpel de sistema de recomendación:

Contexto:

- Queremos predecir la probabilidad de que un usuario aprecie una nueva pelicula, para incluirla en las recomendaciones. Sabemos que, entre las 10 películas de este mismo tipo que ha visto, siete le han gustado.
- $X \sim \mathrm{Bernoulli}(p) : X = 1 \leftrightarrow$ "el usuario aprecia una película de este tipo".
- Observamos $x_1, x_2, \dots, x_{10}$.
- Usamos una a priori no informativa para $p : \pi(p) = \begin{cases} 1 & \text{si } p \in (0,1) \\ 0 & \text{en caso contrario} \end{cases}$

$$\pi(p|\mathbf{x}) \sim \mathrm{Be}(1 + n\bar{x}, 1 + n(1 - \bar{x})) \sim \mathrm{Be}(8, 4).$$

Inferencia bayesiana predictiva:

- Tenemos la posteriori $\pi(p|\mathbf{x})$.
- Nos interesa $P(X = 1|\mathbf{x})$, que es la llamada probabilidad predictiva.

Para calcularla la obtenemos como margina usando la posteriori:

$$P(X = 1|\mathbf{x}) = \int P(X = 1|p)\pi(p|\mathbf{x})\mathrm{d}p = \int p\pi(p|\mathbf{x})\mathrm{d}p.$$

En este caso: $P(X_1|\mathbf{x}) = E[p|\mathbf{x}] = \dfrac{8}{12} = \dfrac{2}{3}$.

# Hoja 5: Inferencia Bayesiana

**1)** Consideramos el caso en que $X \sim P(\lambda)$ y $\pi(\lambda)$ sigue una distribución gamma con densidad $\pi(\lambda) \propto \lambda^{\alpha-1}\exp(-\lambda/\beta)$Observamos una m.a.s. de $X$, estudiar la distribución a posteriori de $\lambda$.

Para obtener la distribución a posteriori de $\lambda$, aplicaremos el Teorema de Bayes omitiendo la constante de normalización (el denominador), tal como indica la regla de proporcionalidad:

$$\pi(\lambda|x) \propto f(x|\lambda) \cdot \pi(\lambda)$$

1) Función de Verosimilitud

Dado que tenemos una muestra aleatoria simple (m.a.s.) de tamaño $n$, donde cada variable sigue una distribución de Poisson $X_i \sim P(\lambda)$, la verosimilitud conjunta (descartando las constantes de los factoriales que no dependen de $\lambda$) es:

$$f(x_1, \dots, x_n|\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} \propto e^{-n\lambda}\lambda^{\sum_{i=1}^{n} x_i}$$

Si definimos la suma de la muestra como $n\bar{x}$, tenemos:

$$f(x|\lambda) \propto e^{-n\lambda}\lambda^{n\bar{x}}$$

2) Distribución a Priori

El enunciado define la distribución a priori como una Gamma con la siguiente densidad proporcional:

$$\pi(\lambda) \propto \lambda^{\alpha-1}e^{-\lambda/\beta}$$

3) Distribución a Posteriori

Multiplicamos la verosimilitud por la priori:

$$\pi(\lambda|x) \propto \left(e^{-n\lambda}\lambda^{n\bar{x}}\right) \cdot \left(\lambda^{\alpha-1}e^{-\lambda/\beta}\right)$$

Agrupamos los términos con la misma base para $\lambda$, y factorizamos los exponentes de $e$:

$$\pi(\lambda|x) \propto \lambda^{(n\bar{x}-\alpha)-1}e^{-\lambda\left(n+\frac{1}{\beta}\right)}$$

**Conclusión**

Reconocemos en la expresión resultante el núcleo de la nueva **distribución Gamma**. Al comparar con la forma general $\lambda^{k-1}e^{-\lambda/\theta}$ (donde $k$ es la forma y $\theta$ es la escala), identificamos los nuevos parámetros:

- **Parámetro de forma actualizado:** $\alpha' = \alpha + n\bar{x} = \alpha + \sum_{i=1}^{n} x_i$
- **Parámetro de escala actualizado:** $\beta' = \dfrac{1}{n + 1/\beta} = \dfrac{\beta}{n\beta + 1}$

Por lo tanto, la distribución a posteriori es:

$$\lambda|x \sim \text{Gamma}\left(\alpha + \sum_{i=1}^{n} x_i, \frac{\beta}{n\beta + 1}\right)$$

**2)** Consideramos una m.a.s. de $X \sim N(\mu, \sigma^2)$, con $\sigma^2$ conocida y escogemos como distribución a priori $\pi(\mu)$, una distribución normal con densidad

$$\pi(\mu) \propto \exp\left(-\frac{1}{2\tau^2}(\mu - \mu_0)^2\right)$$

Demostrar que la distribución a posteriori de $\mu$ es Normal con media y varianza:

$$E[\mu|x] = \mu_0 \frac{\sigma^2/n}{\tau^2 + \sigma^2/n} + \bar{x}\frac{\tau^2}{\tau^2 + \sigma^2/n}$$
$$\text{Var}[\mu|x] = \kappa^2 = \frac{\tau^2\sigma^2/n}{\tau^2 + \sigma^2/n}$$

Para resolver esta demostración aplicaremos el Teorema de Bayes omitiendo el cálculo del denominador, ya que este solo depende de la muestra $x$. Escribiremos la relación de proporcionalidad y luego reconoceremos el modelo de distribución resultante.

1) Función de Verosimilitud

Para una muestra $x_1, \dots, x_n$ de una distribución $\mathcal{N}(\mu, \sigma^2)$, la verosimilitud conjunta (descartando los términos que no dependen de $\mu$) es proporcional a:

$$f(x|\mu) \propto \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right)$$

Utilizando la propiedad $\sum(x_i-\mu)^2 = \sum(x_i-\bar{x})^2 + n(\bar{x}-\mu)^2$ y omitiendo el primer término por no depender del parámetro $\mu$, obtenemos:

$$f(x|\mu) \propto \exp\left(-\frac{n}{2\sigma^2}(\mu-\bar{x})^2\right)$$

2) Distribución a Priori

El enunciado define la densidad a priori como:

$$\pi(\mu) \propto \left(-\frac{1}{2\tau^2}(\mu-\mu_0)^2\right)$$

Agrupamos los términos en el exponente:

$$\pi(\mu|x) \propto \exp\left(-\frac{1}{2}\left[\frac{n}{\sigma^2}(\mu^2-2\mu\bar{x}+\bar{x}^2)+\frac{1}{\tau^2}(\mu^2-2\mu\mu_0+\mu_0^2)\right]\right)$$

Nos centramos exclusivamente en los términos que contienen $\mu$, ya que el resto pasará a formar parte de la constante de proporcionalidad:

$$\pi(\mu|x) \propto \exp\left(-\frac{1}{2}\left[\mu^2\left(\frac{n}{\sigma^2}+\frac{1}{\tau^2}\right)-2\mu\left(\frac{n\bar{x}}{\sigma^2}+\frac{\mu_0}{\tau^2}\right)\right]\right)$$

Esta expresión tiene la estructura del núcleo de una distribución Normal, que se define completando el cuadrado como $A\mu^2 - 2B\mu = A\left(\mu - \frac{B}{A}\right)^2 + C$.

3) Reconocimiento de los Parámetros (Media y Varianza)

identificamos la distribución a posteriori reconociendo el modelo sin tener que calcular el denominador exacto.

Sea el término cuadrático (inversa de la varianza $1/\kappa^2$):

$$\frac{1}{\kappa^2} = \frac{n}{\sigma^2}+\frac{1}{\tau^2} = \frac{n\tau^2+\sigma^2}{\sigma^2\tau^2}$$

Despejando la varianza a posteriori y dividiendo numerador y denominador entre $n$:

$$\mathrm{Var}[\mu|x] = \kappa^2 = \frac{\sigma^2\tau^2}{n\tau^2+\sigma^2} = \frac{\tau^2(\sigma^2/n)}{\tau^2+\sigma^2/n}$$

Sea la media a posteriori $E[\mu|x]$ el término lineal dividido por el cuadrático ($B/A$):

$$E[\mu|x] = \kappa^2\left(\frac{n\bar{x}}{\sigma^2}+\frac{\mu_0}{\tau^2}\right)$$

Sustituimos el valor de $\kappa^2$ que acabamos de hallar, pero lo expresamos como $\frac{\tau^2(\sigma^2/n)}{\tau^2+\sigma^2/n}$, y reescribimos el término entre paréntesis adaptando el primer sumando:

$$E[\mu|x] = \left(\frac{\tau^2(\sigma^2/n)}{\tau^2+\sigma^2/n}\right)\left(\frac{\bar{x}}{\sigma^2/n}+\frac{\mu_0}{\tau^2}\right)$$

Al multiplicar distribuyendo el primer factor sobre los dos términos del paréntesis, se simplifican los denominadores cruzados:

$$E[\mu|x] = \bar{x}\frac{\tau^2}{\tau^2+\sigma^2/n}+\mu_0\frac{\sigma^2/n}{\tau^2+\sigma^2/n}$$

**3)** Consideramos una m.a.s. de $X \sim \mathrm{Exp}(1/\kappa)$. Nota: $\kappa$ es la esperanza de $X$, consideramos a priori $\pi(\kappa) \propto 1/\kappa$, que se considera una a priori no informativa y es la usual en este caso.

**a)** Demostrar que la densidad a posteriori de $\kappa|\mathbf{x}$ es proporcional a $\kappa^{-n-1}\exp\left(-\sum_i \frac{x_i}{\kappa}\right)$

Partimos de la función de verosimilitud para una muestra $x_1, \dots, x_n$ de una distribución exponencial con esperanza $\kappa$ (tasa $1/\kappa$). La función de densidad es $f(x) = \frac{1}{\kappa}\exp(-x/\kappa)$.

La verosimilitud conjunta de la muestra es:

$$f(\mathbf{x}|\kappa) = \prod_{i=1}^{n} \frac{1}{\kappa}\exp\left(-\frac{x_i}{\kappa}\right) = \kappa^{-n}\exp\left(-\frac{1}{\kappa}\sum_{i=1}^{n} x_i\right)$$

Se nos da una distribución a priori no informativa:

$$\pi(\kappa) \propto \kappa^{-1}$$

Aplicamos el Teorema de Bayes en su forma proporcional:

$$\pi(\kappa|\mathbf{x}) \propto f(\mathbf{x}|\kappa)\pi(\kappa)$$

Multiplicamos ambas expresiones:

$$\pi(\kappa|\mathbf{x}) \propto \left[\kappa^{-n}\exp\left(-\frac{1}{\kappa}\sum_{i=1}^{n} x_i\right)\right]\kappa^{-1}$$

Agrupando los términos de $\kappa$, obtenemos la expresión final solicita:

$$\pi(\kappa|\mathbf{x}) \propto \kappa^{-n-1}\exp\left(-\frac{1}{\kappa}\sum_{i=1}^{n} x_i\right)$$

**b)** Demostrar que, si transformamos $\kappa$, considerando $\lambda = \frac{1}{\kappa}$, $\lambda|\mathbf{x}$ admite una densidad gamma con parámetris $n$ y $1/\sum_i x_i$.

Definimos el cambio de variable $\lambda = 1/\kappa$, lo que implica que $\kappa = 1/\lambda$. Para hallar la distribución $\lambda|\mathbf{x}$, aplicamos el teorema del cambio de variable, que requiere multiplicar por el valor absoluto del Jacobiano $J = \frac{\mathrm{d}\kappa}{\mathrm{d}\lambda}$:

$$|J| = \left|-\frac{1}{\lambda^2}\right| = \lambda^{-2}$$

Sustituimos $\kappa$ por $1/\lambda$ en la distribución a posteriori obtenida en el apartado anterior y multiplicamos por el Jacobiano:

$$\pi(\lambda|\mathbf{x}) \propto \left(\frac{1}{\lambda}\right)^{-n-1}\exp\left(-\frac{1}{1/\lambda}\sum_{i=1}^{n} x_i\right)\cdot\lambda^{-2}$$

Simplificamos los exponentes algebraicamente:

$$\pi(\lambda|\mathbf{x}) \propto \lambda^{n+1}\exp\left(-\lambda\sum_{i=1}^{n} x_i\right)\lambda^{-2}$$
$$\pi(\lambda|\mathbf{x}) \propto \lambda^{n-1}\exp\left(-\lambda\sum_{i=1}^{n} x_i\right)$$

Reconocemos la estructura (el núcleo) de una distribución de probabilidad conocida. La expresión corresponde al núcleo de una **distribución Gamma**:

- Parámetro de forma (shape): $\alpha = n$.
- Parámetro de tasa (rate): $\beta = \sum_{i=1}^{n} x_i$.

**c)** En un experimento sobre duración de dispositivo, obtenemos los siguientes valores en horas: 6562, 2280, 50, 989, 1797. Obtener un intervalo de credibilidad al 90% para la inversa de $k$. Obtener el mismo intervalo para $\kappa$.